

Gestión de Riesgo Crediticio con Predicción Conformal y Optimización Robusta

**Un Pipeline Completo de ML, Incertidumbre, Optimización e IFRS9 sobre Lending
Club**

Carlos Alfredo Vergara Rojas

marzo 2026

Tabla de contenidos

1. Gestión de Riesgo Crediticio con Predicción Conformal y Optimización Robusta	1
Bienvenida	3
1.1. La idea central	3
1.2. Qué encontrarás en este libro	3
1.3. Sobre el dataset	4
1.4. Rutas de lectura	4
1.5. Sobre el autor	4
I. Parte I: Fundamentos	5
2. Prefacio	7
2.1. Motivación	7
2.2. Sobre este libro	7
2.3. Cómo leer este libro	8
2.4. Convenciones del libro	8
2.5. El pipeline en una imagen	9
2.6. Agradecimientos	9
3. Mapa Ejecutivo	11
3.1. KPIs del Pipeline	11
3.2. Arquitectura del Pipeline	11
3.3. Distribución por Stages IFRS9	11
3.4. Innovación central	11
3.5. Linaje operativo congelado	15
3.6. Métricas de investigación	16
3.7. Mapa de navegación	16
4. Glosario y Fundamentos	19
5. Fundamentos de Riesgo Crediticio	21
6. Fundamentos de ML y Estadística	25
7. Incertidumbre y Predicción Conformal	29
8. Optimización e Investigación de Operaciones	41
9. Inferencia Causal	51

10.Stack Tecnológico	63
10.1. Principio de selección	63
10.2. Machine Learning y Modelado	63
10.3. Predicción Conformal	63
10.4. Series de Tiempo y Supervivencia	63
10.5. Inferencia Causal	63
10.6. Optimización	66
10.7. MLOps y Reproducibilidad	66
10.8. Desarrollo y Calidad	66
10.9. Entrega y Visualización	66
10.10GPU / Aceleración (Opcional)	66
10.11Resumen de versiones clave	67
 II. Parte II: Pipeline End-to-End	 71
11.Visión General del Pipeline	73
11.1. Navegación del capítulo	75
12.Ingesta de Datos y Linaje	77
13.Estrategia de Splitting Temporal	81
14.Ingeniería de Features	85
15.WOE, IV y OptBinning	87
16.Features Derivadas: Ratios, Flags e Interacciones	91
17.Contrato de Features y Validación	95
18.Modelado de PD y Calibración	99
19.Regresión Logística: Baseline Interpretable	101
20.CatBoost: Default y Optimizado con Optuna	105
21.Selección de Calibración	115
22.Comparación de Modelos y Selección del Champion	125
23.Predicción Conformal e Incertidumbre	129
24.Fundamentos de Split Conformal	131
25.Mondrian: Cobertura Condicional por Grupo	135
26.CQR y Benchmark de Variantes	139
27.Backtest y Monitoreo de Cobertura	143

28. Intervalos Conformal para LGD y EAD	147
29. Supervivencia, Series de Tiempo e Inferencia Causal	151
30. Análisis de Supervivencia	153
31. Pronóstico de Series de Tiempo	157
32. Inferencia Causal	161
33. Simulación A/B: Robusto vs No-Robusto	167
34. Optimización de Portafolio	171
35. Portafolio Determinístico	173
36. Portafolio Robusto con Conjuntos de Incertidumbre	177
37. Selección de Política Económica	181
38. Portafolio Ajustado por CATE	185
39. Frontera Eficiente de Robustez	187
40. IFRS9 y Gobernanza del Modelo	191
41. Cálculo de ECL	193
42. Análisis de Escenarios	195
43. Señal SICR Conformal	197
44. Sensibilidad y Estrés	199
45. Gestión de Riesgo de Modelo	201
 III. Parte III: Insights Factory	 205
46. Explicabilidad e Interpretabilidad	207
47. Explicaciones Globales	209
48. Explicaciones Locales	215
49. Drift de Explicaciones	219
50. Dataset 360°	221
51. Hallazgos Clave del EDA	223
52. Análisis Geográfico y Temporal	227

Tabla de contenidos

53. Benchmark contra Literatura	229
54. Temas Avanzados	231
55. Baselines de Incertidumbre: BMA vs CP	233
56. Alpha Sweep y Frontera de Pareto	235
57. Riesgos Competitivos y su Impacto en ECL	237
58. Costo de Misclasificación de Stages	239
59. Intervalos de Series de Tiempo Propagados a ECL	241
 IV. Parte IV: Papers de Investigación	 243
60. Paper Estrella: Predict-then-Optimize con Incertidumbre Conformal	245
61. Introducción y Motivación	247
62. Marco Teórico	249
63. Metodología	251
64. Resultados	253
65. Discusión y Conclusiones	257
66. Paper 2: IFRS9 End-to-End con Incertidumbre Conformal	259
67. Introducción	261
68. Metodología	263
69. Resultados	265
70. Discusión	269
71. Paper 3: Predicción Conformal Mondrian para Riesgo Crediticio	271
72. Introducción	273
73. Metodología	275
74. Resultados	277
75. Discusión	279

V. Parte V: Puente Académico y Agenda	281
76. Puente: De la Especialización a la Maestría	283
77. Agenda de Investigación	285
78. Estado del Arte	287
79. Contribuciones de la Tesis	289
80. Direcciones Futuras	291
VI. Apéndices	293
81. Atlas de Notebooks	295
82. Benchmarks GPU / RAPIDS	297
83. Catálogo de Artefactos	299
84. Referencia de Configuración	301
85. Companion Interactivo Streamlit	303
85.1. Qué resuelve Streamlit	303
Referencias	305

Listado de Figuras

2.1. Diagrama editorial del pipeline completo, desde los datos crudos de Lending Club hasta la decisión robusta y la gobernanza regulatoria.	9
3.1. Diagrama editorial del flujo completo del pipeline, desde la ingesta hasta la optimización robusta, IFRS9 y gobernanza.	13
3.2. Snapshot consolidado del dashboard operativo del pipeline, generado desde artefactos del proyecto y usado como evidencia visual de ejecución end-to-end.	14
3.3. Distribución de préstamos por stage IFRS9 en el set de test.	15
11.1. Diagrama editorial del pipeline end-to-end, desde datos crudos hasta decisiones de portafolio y provisiones.	73
11.2. Vista operativa del pipeline renderizada desde notebooks del proyecto, con foco en outputs, métricas y artefactos consumidos por el libro y el companion.	74
20.1.	112
22.1. Curvas ROC de los modelos PD principales evaluados en el proyecto.	126
22.2. Curvas de calibración del champion y sus comparadores, usadas para justificar la promoción del calibrador Venn-Abers.	126
23.1. Cobertura conformal observada por grade del portafolio, usada para verificar validez útil a nivel de negocio.	129
23.2. Trade-off entre cobertura e intervalo promedio al variar el nivel de confianza conformal.	129
26.1. Distribución del ancho de intervalos en variantes conformales, útil para comparar eficiencia más allá de la cobertura agregada.	139
30.1. Curvas de supervivencia y default acumulado por segmento, generadas desde los notebooks del bloque temporal y de supervivencia.	155
31.1. Comparación de modelos en validación cruzada rolling-origin para series de tiempo.	159
31.2. Fan chart del forecast IFRS9 con bandas de incertidumbre y escenarios baseline, optimista y adverso.	160
32.3. Heterogeneidad del efecto causal de la tasa de interés por segmentos, estimada con CausalForestDML.	163
34.1. Visualización de conjuntos de incertidumbre usados por la capa de optimización robusta para transformar intervalos conformales en restricciones de decisión.	172
40.1. Grid editorial de SICR y staging conformal del carril IFRS9.	191

Listado de Figuras

47.1. Resumen global SHAP del modelo champion, con las variables que más empujan el score de default.	210
47.2. Comparación visual entre ranking SHAP y permutation importance para validar qué señales son estructurales.	210
47.3. Curvas ALE de las variables principales, usadas para verificar forma funcional y monotonías.	212
47.4. Chequeo de monotonía y consistencia funcional en variables clave del modelo.	212
47.5. Descomposición por familias de variables en las explicaciones globales del modelo.	212
47.6. Importancia SHAP agregada en formato barra para lectura ejecutiva.	212
51.1. Tasa de default por grade en Lending Club, usada como evidencia base del gradiente económico de riesgo.	224
55.1. Comparación editorial entre baselines de incertidumbre, incluyendo conformal y alternativas competitivas.	234
56.1. Frontera alpha-cobertura-retorno para el barrido operativo del parámetro conformal.	236
59.1. Fan chart de escenarios temporales IFRS9 con bandas de incertidumbre.	242
59.2. Comparación de modelos y trayectorias agregadas del portafolio en la capa temporal.	242
64.1. Comparación editorial de baselines de incertidumbre del Paper Estrella.	254
64.2. Frontera alpha-cobertura-retorno del Paper Estrella.	254
64.3. Comparación de regret entre estrategias predict-then-optimize y el enfoque robusto del Paper Estrella.	254
64.4. Cobertura por grado bajo CQR y variantes conformales evaluadas en el Paper Estrella.	254
69.1. Grid de escenarios SICR y staging conformal usado en el paper IFRS9.	265
69.2. Sensibilidad del ECL al barrido de alpha y al endurecimiento prudencial del escenario.	265
69.3. Comparación entre Bayesian Model Averaging y Conformal Prediction en amplitud de banda y lectura prudencial para IFRS9.	266
74.1. Scatter de variantes conformales del Paper 3, con énfasis en cobertura útil y costo de anchura.	277
74.2. Mapa de calor de cobertura por grade para la variante Mondrian promovida.	277
74.3. Estabilidad temporal de la cobertura conformal, usada para documentar alertas y drift en el Paper 3.	278

Listado de Tablas

1.1. Splits temporales out-of-time para evaluación estricta	4
3.1. Métricas clave del pipeline end-to-end	12
3.2. Resumen de componentes del pipeline	15
3.4. Métricas clave para los papers de investigación	16
3.3. Linaje operativo de artefactos congelados	16
5.1. Modelo de deterioro de tres stages de IFRS9	22
5.2. Grados de riesgo de Lending Club (valores aproximados del dataset)	23
6.1. Interpretación del Information Value	27
7.1. Comparación entre intervalos de confianza e intervalos de predicción	30
7.2. Splits temporales del proyecto y su rol en el framework conformal	34
7.3. Efecto del nivel de significancia sobre cobertura y ancho	38
7.4. Comparación de métodos de cuantificación de incertidumbre	39
8.1. Comparación entre LP y MILP	42
8.2. Conexión entre predicción conformal y optimización robusta	45
8.3. Guía interpretativa del Precio de la Robustez	46
8.4. Comparación entre pérdida MSE y SPO+	48
8.5. Comparación de solvers de optimización	49
9.1. Preguntas causales centrales del proyecto de riesgo crediticio	52
9.2. Comparación entre Random Forest estándar y Causal Forest	56
9.3. Resumen de tests de refutación para validación de estimaciones causales	61
10.1. Librerías de Machine Learning y modelado	64
10.2. Librerías de predicción conformal	64
10.3. Librerías de series de tiempo y supervivencia	65
10.4. Librerías de inferencia causal	65
10.5. Librerías de optimización	66
10.6. Herramientas de MLOps y reproducibilidad	67
10.10. Versiones clave del stack	67
10.7. Herramientas de desarrollo	68
10.8. Herramientas de entrega	68
10.9. Librerías GPU (insights factory, no baseline operativo)	69
11.1. Capas de software del pipeline	75
12.1. Resumen del dataset crudo de Lending Club	78
12.2. Variables removidas por data leakage (35 columnas)	79

12.3. Datasets analíticos derivados del dataset limpio	80
13.1. Splits temporales Out-of-Time del proyecto	82
13.2. Funciones del set de calibración	82
13.3. Default rate por período temporal	83
14.1. Etapas del pipeline de features	85
15.1. Variables transformadas con WOE encoding	88
16.2. Transformaciones logarítmicas	91
16.1. Ratios financieros derivados	92
16.3. Features binarias (flags) de señal de riesgo	92
16.4. Features temporales derivadas	93
16.5. Features de interacción	94
17.1. Resumen del contrato canónico de features	96
17.2. Features categóricas del contrato (CatBoost nativo)	96
17.3. Schemas Pandera para validación de datos	96
18.1. Resumen de modelos PD evaluados	100
19.1. Preprocesamiento del baseline LR	101
19.2. Métricas del baseline de Regresión Logística (test OOT)	103
20.1. Comparación de frameworks de gradient boosting para credit scoring	106
20.2. Hiperparámetros del CatBoost default	107
20.3. Métricas del CatBoost default (test OOT)	108
20.4. Espacio de búsqueda de Optuna para CatBoost	109
20.5. Resultados de la optimización con Optuna	110
20.6. Hiperparámetros óptimos seleccionados por Optuna	110
20.7. Features categóricos procesados nativamente por CatBoost	111
20.8. Comparación del tratamiento de NaN entre LR y CatBoost	112
20.9. Análisis de la fuente de ganancia: HPO vs calibración	113
21.1. Impacto de la calibración en el pipeline	115
21.2. Comparación de candidatos de calibración (validación temporal, 4 folds)	119
21.3. Detalle por fold del calibrador seleccionado (Venn-Abers)	120
21.4. Métricas del modelo CatBoost calibrado con Venn-Abers (test OOT, 276,869 préstamos)	121
21.5. Artefactos del calibrador en el contrato canónico	123
22.2. Impacto de la calibración sobre métricas de Brier	125
22.1. Comparación completa de modelos PD (métricas OOT)	126
22.3. Métricas completas del modelo champion (test OOT)	127
22.4. Artefactos canónicos del modelo champion	127
22.5. Comparación con literatura publicada sobre Lending Club	128
23.1. Métricas de cobertura conformal del modelo champion (test OOT)	130
24.1. Comparación Full vs Split Conformal	131

24.2. Migración de API MAPIE	132
24.3. Cobertura split conformal global (sin partición Mondrian)	134
25.1. Heterogeneidad de residuos por grade	135
25.2. Cobertura Mondrian por grade (test OOT, $\alpha=0.10$)	136
25.3. Comparación: Split Conformal Global vs Mondrian	137
25.4. Trade-off granularidad vs estabilidad	137
26.1. Benchmark de 7 variantes conformal (test OOT, $\alpha=0.10$)	140
26.2. Propiedades del score-decile Mondrian	141
27.1. Resumen del backtesting mensual de cobertura conformal	144
27.2. Resultados de tests estadísticos de cobertura	145
27.3. Policy gate de cobertura conformal	146
28.1. Métricas del modelo LGD y sus intervalos conformal	148
28.2. Benchmark de variantes conformal para LGD	148
28.3. Métricas del modelo EAD y sus intervalos conformal	149
28.4. Guardrails de calidad para intervalos LGD/EAD	150
29.1. Resumen de los bloques temporales y causales del pipeline	152
30.1. Resumen de modelos de supervivencia y métricas clave	156
31.1. Escenarios temporales para ajuste de PD en IFRS9	160
32.1. Resumen de estimación causal: ATE, CATE y refutaciones	164
33.1. Métricas comparadas en la simulación A/B	168
33.2. Diseño de la simulación A/B retroactiva	169
34.1. Resumen del capítulo de optimización de portafolio.	171
35.1. Configuración del modelo de portafolio determinístico.	174
36.1. Interpretación del parámetro de robustez γ	178
36.2. Métricas de robustez del portafolio champion.	179
37.1. Política champion seleccionada por el selector económico v3.	182
37.2. Alternativas de selección de política para investigación.	182
38.1. Comparación de portafolios baseline vs CATE-ajustado.	186
39.1. Zonas de la frontera de robustez.	188
40.1. Resumen de resultados IFRS9 y gobernanza	191
41.1. Lógica de staging IFRS9 y PD efectiva por etapa	193
41.2. ECL baseline con rango conformal	194
42.1. Multiplicadores por escenario macroeconómico	195
43.1. Resultado óptimo del SICR conformal	198

44.1. Parámetros de simulación Monte Carlo IFRS9	199
45.1. Controles principales de MRM	201
45.2. Resumen de fairness operativo	202
45.3. Estado de policy conformal	202
45.4. Snapshot de drift explicativo	203
47.1. Top drivers globales del modelo PD	209
47.2. Atribución vs sensibilidad	211
48.1. Ejemplo de explicación local defendible	215
48.2. Familias de reason codes	216
48.3. Usos operativos de explicaciones locales	216
49.1. Resumen de drift explicativo	219
51.1. Radiografía del dataset de entrenamiento	223
51.2. Gradiente de riesgo por grade	223
51.3. Familias con valor narrativo y operativo	225
52.1. Muestra del agregado geográfico	227
52.2. Esquema temporal del pipeline	227
53.1. Benchmark externo curado para Lending Club	229
55.1. Baselines de incertidumbre relevantes	233
56.1. Sweep global de alpha	235
57.1. Impacto de riesgos competitivos sobre ECL Stage 2	237
58.1. Costo de clasificación Stage 2 sin trigger de ancho	239
59.1. Propagación de pronóstico temporal a ECL	241
63.1. Base predictiva del experimento	251
63.2. Política campeona de portafolio	252
64.1. Resumen predictivo del paper	253
64.2. Comparación con baseline de incertidumbre	253
64.3. Resultado económico de la policy promovida	254
68.1. Capas metodológicas del Paper 2	263
68.2. Escenarios del Paper 2	264
69.1. IFRS9 por escenario	265
69.2. Resultado operativo de SICR conformal	266
73.1. Diseño metodológico del Paper 3	275
74.1. Resumen conformal del Paper 3	277
76.1. Cierre de especialización	283

76.2. Continuidad temática especialización $\rightarrow$ maestría	284
78.1. Panorama del estado del arte	287
79.1. Contribuciones operativas de la tesis	289
80.1. Agenda temporal sugerida	291
81.1. Resumen del inventario de notebooks	295
81.2. Núcleo experimental del proyecto	295
81.3. Notebooks orientados a publicación	296
82.1. Comparación ETL base	297
82.2. Mapa funcional de RAPIDS en el proyecto	298
83.1. Catálogo mínimo de artefactos críticos	299
84.1. Núcleo de configuración declarativa	301
85.1. Mapa funcional del companion	303

1. Gestión de Riesgo Crediticio con Predicción Conformal y Optimización Robusta

Bienvenida

Este libro documenta en profundidad un proyecto integral de gestión de riesgo crediticio que combina **Machine Learning**, **Predicción Conformal**, **Investigación de Operaciones** e **IFRS9** en un pipeline end-to-end sobre datos de Lending Club (2007–2020).

Companion editorial del baseline canónico `champion-2026-03-12-mega-definitive`, construido sobre artefactos congelados y renderizado con Quarto 1.9.35.

1.1. La idea central

La innovación principal es un pipeline **predict-then-optimize** con predicción conformal:

```
CatBoost PD → Calibración → MAPIE Mondrian Conformal → [PD_low, PD_high]
→ Conjuntos de Incertidumbre Box → Optimización Robusta (Pyomo/HiGHS)
→ Portafolio Óptimo → Provisiones IFRS9
```

Las estimaciones puntuales de probabilidad de default (PD) ignoran la incertidumbre — producen portafolios frágiles. Los intervalos bootstrap carecen de garantías en muestra finita. Los intervalos bayesianos requieren supuestos distribucionales. **Los intervalos de predicción conformal son libres de distribución con garantías matemáticas de cobertura.**

1.2. Qué encontrarás en este libro

- **Parte I — Fundamentos:** Glosario de riesgo crediticio, fundamentos de ML, incertidumbre, optimización e inferencia causal. Justificación del stack tecnológico.
- **Parte II — Pipeline End-to-End:** Desde la ingesta de datos hasta la optimización de portafolio y las provisiones IFRS9. Cada capítulo explica la técnica, su implementación, los resultados y cómo conecta con la siguiente etapa.
- **Parte III — Insights Factory:** Visión 360° del dataset: explicabilidad, análisis exploratorio avanzado, comparación de baselines de incertidumbre, riesgos competitivos, y más.
- **Parte IV — Papers de Investigación:** Tres secciones autocontenidas con la propuesta, marco teórico, estado del arte y resultados de cada paper.
- **Parte V — Puente Académico:** Conexión con la tesis de especialización, contribuciones de la tesis de maestría y agenda de investigación futura.
- **Apéndices:** Atlas de notebooks, benchmarks GPU, catálogo de artefactos, referencia de configuración y guía del companion Streamlit.

1.3. Sobre el dataset

Fuente: Lending Club Loan Data (Kaggle, 2007–2020Q3) — un dataset estático de ~1.86 millones de préstamos resueltos.

Tabla 1.1.: Splits temporales out-of-time para evaluación estricta

Split	Préstamos	Tasa de Default	Período
Entrenamiento	1,346,311	18.52 %	2007-06 a 2017-03
Calibración	237,584	22.20 %	2017-03 a 2017-12
Test (OOT)	276,869	21.98 %	2018-01 a 2020-09

1.4. Rutas de lectura

1.5. Sobre el autor

Carlos Alfredo Vergara Rojas — Estudiante de Maestría en Analítica de Datos, enfocado en la intersección de machine learning, predicción conformal y optimización robusta aplicada a riesgo crediticio.

Companion interactivo

Este libro tiene un companion interactivo en Streamlit que permite explorar los datos, ajustar parámetros del portafolio y consultar métricas en tiempo real. Ver Sección 85.1 para más detalles.

Parte I.

Parte I: Fundamentos

2. Prefacio

2.1. Motivación

En la práctica de gestión de riesgo crediticio, las decisiones de originación, provisión y capital se basan en modelos de Probabilidad de Default (PD). Sin embargo, un modelo que produce una PD puntual de 0.12 para un solicitante no comunica cuánta confianza debería depositar el decisor en ese número. ¿Es un 12% con margen de error de $\pm 2\%$, o de $\pm 15\%$? La diferencia importa: el primer caso permite decidir con certeza razonable; el segundo exige cautela.

Este problema no es nuevo. Los intervalos de confianza clásicos requieren supuestos distribucionales fuertes. Los intervalos bootstrap son computacionalmente costosos y carecen de garantías en muestra finita. Los intervalos bayesianos exigen priors que pueden no reflejar la realidad. La **predicción conformal** resuelve este problema de manera elegante: produce intervalos de predicción con garantías matemáticas de cobertura, sin supuestos sobre la distribución de los datos, y en muestra finita.

Este libro documenta un proyecto que lleva esa idea hasta sus consecuencias operativas: las PD calibradas se convierten en intervalos conformal, los intervalos se convierten en conjuntos de incertidumbre para optimización robusta, y la optimización robusta produce portafolios que son demostrablemente más resilientes ante el peor caso plausible. El pipeline completo conecta predicción $\rightarrow$ incertidumbre $\rightarrow$ decisión $\rightarrow$ provisión $\rightarrow$ gobernanza.

2.2. Sobre este libro

Este no es un libro de texto convencional ni una tesis condensada. Es un **documento de referencia integral** que cubre todo el proyecto de riesgo crediticio sobre datos de Lending Club, con tres propósitos:

1. **Documentar el pipeline completo:** Cada etapa del proceso — desde la ingesta de datos hasta la optimización de portafolio y las provisiones IFRS9 — se explica con la profundidad necesaria para entender *qué* hace, *por qué* se diseñó así, y *cómo* se conecta con las demás etapas.
2. **Servir como plataforma de investigación:** Tres papers de investigación (Predicción Conformal Mondrian, IFRS9 End-to-End, y Predict-then-Optimize con incertidumbre conformal) se desarrollan como secciones autocontenidas, con sus propios marcos teóricos, estados del arte y resultados.

2. Prefacio

3. **Proveer una visión 360° del dataset:** Lending Club es un dataset estático de 1.86 millones de préstamos. Al ser estático, podemos aplicar un arsenal completo de técnicas modernas para extraer la máxima información: desde análisis de supervivencia hasta inferencia causal, desde predicción conformal hasta optimización robusta.

2.3. Cómo leer este libro

El libro está organizado en seis partes. No es necesario leerlo secuencialmente, pero la Parte II sigue un orden lógico de pipeline que construye cada capítulo sobre el anterior.

Guía de lectura por perfil

- **Si tienes experiencia en ML/DS pero no en riesgo crediticio:** Comienza por el glosario de fundamentos de riesgo crediticio y luego sigue el pipeline desde el capítulo 4.
- **Si tienes experiencia en riesgo crediticio pero no en ML avanzado:** Comienza por los fundamentos de ML y predicción conformal, y luego explora los capítulos que más te interesen.
- **Si te interesan los papers de investigación:** Cada paper en la Parte IV es autocontenido. Puedes leerlos directamente sin necesidad de recorrer todo el pipeline.
- **Si quieres una visión ejecutiva rápida:** El Mapa Ejecutivo (capítulo 1) proporciona un resumen de KPIs y resultados clave.

2.4. Convenciones del libro

A lo largo del texto se utilizan las siguientes convenciones:

Concepto de riesgo crediticio

Los recuadros azules explican conceptos de riesgo crediticio relevantes para entender el contexto de la técnica o métrica presentada.

Interpretación práctica

Los recuadros verdes proporcionan guías de interpretación: qué significa una métrica para un oficial de crédito, un regulador o un gestor de portafolio.

Limitación o caveat

Los recuadros amarillos señalan limitaciones metodológicas, supuestos que deben tenerse en cuenta, o decisiones que podrían revisarse.

Los bloques de código Python son reproducibles y consumen artefactos congelados del `baseline champion-2026-03-12-mega-definitive`. El código se puede expandir haciendo clic en “Mostrar código” — por defecto está plegado para facilitar la lectura narrativa.

2.5. El pipeline en una imagen




Figura 2.1.: Diagrama editorial del pipeline completo, desde los datos crudos de Lending Club hasta la decisión robusta y la gobernanza.

La figura Figura 2.1 actúa como mapa de lectura de alto nivel. El capítulo Visión General del Pipeline descompone el mismo flujo en capas operativas y evidencia de artefactos congelados.

2.6. Agradecimientos

Este proyecto se desarrolla como tesis de maestría en Analítica de Datos. Agradezco a los autores de las librerías de código abierto que hacen posible este trabajo: MAPIE (predicción conformal), CatBoost (gradient boosting), Pyomo/HiGHS (optimización), EconML/DoWhy (inferencia causal), Statsforecast (series de tiempo) y muchas otras documentadas en el capítulo de Stack Tecnológico.

El dataset de Lending Club fue publicado en Kaggle y cubre préstamos emitidos entre 2007 y 2020. Aunque la plataforma Lending Club ya no opera como marketplace de préstamos, su dataset sigue siendo uno de los más ricos y completos disponibles públicamente para investigación en riesgo crediticio.

3. Mapa Ejecutivo

Este capítulo presenta una vista consolidada de los resultados clave del proyecto. Cada métrica proviene de artefactos congelados del baseline operativo y enlaza al capítulo donde se explica en detalle.

3.1. KPIs del Pipeline

3.2. Arquitectura del Pipeline

El proyecto implementa un pipeline **predict-then-optimize** que conecta seis disciplinas. En esta landing la vista ejecutiva prioriza dos piezas legibles: un diagrama editorial de alto nivel y la evidencia visual de artefactos ya congelados.

La dupla Figura 3.1 + Figura 3.2 deja la lectura ejecutiva mucho más limpia: primero el flujo conceptual, luego la evidencia de ejecución real.

3.3. Distribución por Stages IFRS9

i ¿Qué son los Stages IFRS9?

- **Stage 1:** Préstamos sin deterioro significativo. Se provisionan con PD a 12 meses.
- **Stage 2:** Préstamos con incremento significativo de riesgo crediticio (SICR). Se provisionan con PD de por vida.
- **Stage 3:** Préstamos en default o credit-impaired. PD = 1.0.

El 47 % del portafolio de test cae en Stage 2, reflejando que el período 2018–2020 incluye incrementos significativos de riesgo. Ver el capítulo de IFRS9 para detalles.

3.4. Innovación central

La contribución principal del proyecto es el puente formal entre **predicción conformal** y **optimización robusta**:

Tabla 3.1.: Métricas clave del pipeline end-to-end

```
import pandas as pd

summary = load_json("pipeline_summary")
pd_model = summary.get("pd_model", {})
conformal = summary.get("conformal", {})
pipeline = summary.get("pipeline", {})
survival = summary.get("survival", {})

kpis = {
    "AUC (test OOT)": f"{pd_model.get('final_auc', 0):.4f}",
    "Gini": f"{pd_model.get('final_gini', 0):.4f}",
    "Brier Score": f"{pd_model.get('final_brier', 0):.4f}",
    "ECE (calibración)": f"{pd_model.get('final_ece', 0):.4f}",
    "Método de calibración": pd_model.get("calibration_method", "N/A"),
    "Cobertura conformal 90%": format_pct(conformal.get("coverage_90", 0)),
    "Cobertura conformal 95%": format_pct(conformal.get("coverage_95", 0)),
    "Ancho medio intervalo": f"{pipeline.get('interval_width_mean', 0):.4f}",
    "RSF c-index": f"{survival.get('rsf_concordance', 0):.4f}",
    "Cox c-index": f"{survival.get('cox_concordance', 0):.4f}",
    "ECL esperada": format_money(pipeline.get("ecl_expected", 0)),
    "ECL conservadora": format_money(pipeline.get("ecl_conservative", 0)),
    "Retorno robusto": format_money(pipeline.get("robust_return", 0)),
    "Préstamos financiados (robusto)": format_number(pipeline.get("robust_funded", 0)),
    "Price of Robustness": format_money(pipeline.get("price_of_robustness", 0)),
}

df_kpis = pd.DataFrame(list(kpis.items()), columns=["Métrica", "Valor"])
df_kpis
```




Figura 3.1.: Diagrama editorial del flujo completo del pipeline, desde la ingesta hasta la optimización robusta, IFRS9 y gobernanza.

3. Mapa Ejecutivo



hot consolidado del dashboard operativo del pipeline, generado desde artefactos del proyecto y usado como evidencia visual de ejecución




Figura 3.3.: Distribución de préstamos por stage IFRS9 en el set de test.

Tabla 3.2.: Resumen de componentes del pipeline

Componente	Técnica	Resultado clave
Predicción	CatBoost calibrado con Venn-Abers	AUC 0.713, ECE 0.006
Incertidumbre	Mondrian Conformal (MAPIE 1.3.0)	Cobertura 92.6 % @ 90 % target
Decisión	Optimización robusta (Pyomo/HiGHS)	299 préstamos, \$183K retorno
Aprendizaje Regulatorio	SPO+ loss (PyEPO) ECL bajo 4 escenarios	49.1 % reducción de regret \$1.0B – \$1.8B rango
Gobernanza	Fairness + MRM + Conformal Policy	6/6 tests de equidad pasados

3.5. Linaje operativo congelado

3. Mapa Ejecutivo

Tabla 3.4.: Métricas clave para los papers de investigación

```
causal = summary.get("causal", {})

research = {
    "SPO+ regret reduction": "49.1% vs two-stage",
    "BMA vs CP width": "CP 19.3% más estrecho",
    "CIF lifetime PD correction": "KM sobreestima 26.7%",
    "CIF exceso de reserva": "$125.8M",
    "SICR trigger óptimo": "t*=0.30, F1=0.2515",
    "ECL band (TS intervals)": "$288.5M (267% del punto)",
    "Stage cost óptimo": "pd_thr=0.15, $97.3M",
    "ATE (int_rate)": f"{causal.get('ate', 0):.5f}",
    "CATE net value": format_money(causal.get("total_net_value", 0)),
}

df_research = pd.DataFrame(list(research.items()), columns=["Métrica", "Valor"])
df_research
```

Tabla 3.3.: Linaje operativo de artefactos congelados

Capa	Artefactos clave	Productores	Consumidores
Datos	train.parquet, calibration.parquet, test.parquet	src/data/*	PD, conformal, causal, IFRS9
Modelado	pd_canonical.cbm, model_comparison.json	scripts/train_pd_model.py	conformal, explainability, reporting
Incertidumbre	conformal_intervals_mondrian.parquet, conformal_policy_status.json	scripts/generate_conformal_intervals.py, scripts/validate_conformal_policy.py	IFRS9
Decisión	portfolio_allocation_scripts/optimize_portfolio.py, champion_portfolio_policy.json	scripts/optimize_portfolio.py	external map, papers
Gobierno	mrms_validation_reports, fairness_audit_status	scripts/generate_mrm_report.py, scripts/run_fairness_app.py	report 19, agenda, appendix

3.6. Métricas de investigación

3.7. Mapa de navegación

Si te interesa...	Ve a...
Cómo se construyó el modelo PD	Capítulo 6: Modelado de PD
Cómo funcionan los intervalos conformal	Capítulo 7: Predicción Conformal
Cómo se optimiza el portafolio	Capítulo 9: Optimización de Portafolio
Cómo se calculan las provisiones IFRS9	Capítulo 10: IFRS9 y Gobernanza
El paper de Predict-then-Optimize	Capítulo 14: Paper Estrella
El paper de IFRS9 End-to-End	Capítulo 15: Paper IFRS9
El paper de Mondrian Conformal	Capítulo 16: Paper Mondrian
Benchmark GPU / RAPIDS	Apéndice B

4. Glosario y Fundamentos

Este capítulo establece las bases conceptuales necesarias para entender el resto del libro. Está dividido en cinco secciones, cada una cubriendo una disciplina diferente que el proyecto integra. El objetivo es que un lector con conocimiento básico o intermedio en cualquiera de estas áreas pueda seguir la narrativa del pipeline y los papers de investigación.

No es necesario leer las cinco secciones antes de continuar — se puede usar como referencia y volver a consultar según la necesidad de cada capítulo.

5. Fundamentos de Riesgo Crediticio

5.0.1. Probabilidad de Default (PD)

La **Probabilidad de Default** (PD) es la probabilidad estimada de que un deudor no cumpla con sus obligaciones de pago dentro de un horizonte de tiempo definido. En el marco de Basilea y IFRS9, la PD es el primer componente del cálculo de pérdida esperada.

PD a 12 meses vs PD de por vida

- **PD a 12 meses (PD₁₂)**: Probabilidad de default dentro de los próximos 12 meses. Se usa para préstamos en Stage 1 bajo IFRS9.
- **PD de por vida (PD_{lifetime})**: Probabilidad de default durante toda la vida restante del préstamo. Se usa para préstamos en Stage 2. Se estima típicamente con modelos de supervivencia (Cox PH, Random Survival Forest).

En este proyecto, el modelo PD se entrena como un clasificador binario (default/no-default) sobre datos de Lending Club resueltos. La salida es una probabilidad continua en $[0, 1]$ que se calibra para reflejar frecuencias reales de default.

5.0.2. Loss Given Default (LGD)

La **Pérdida dado el Default** (LGD) mide la fracción del saldo expuesto que no se recupera cuando un préstamo entra en default. Se calcula como:

$$\text{LGD} = 1 - \text{Tasa de Recuperación} = 1 - \frac{\text{Monto Recuperado}}{\text{Exposición al Default}} \quad (5.1)$$

Valores típicos de LGD varían entre 20 % y 80 % según el tipo de producto, la presencia de colateral y la efectividad de los procesos de cobranza. En Lending Club, los préstamos son no garantizados, lo que resulta en LGD relativamente altas.

5.0.3. Exposure at Default (EAD)

La **Exposición al Default** (EAD) es el monto total que el prestamista tiene en riesgo en el momento del default. Para préstamos a plazo fijo (como Lending Club), la EAD es el saldo pendiente del principal más intereses acumulados. Para líneas de crédito revolventes, la EAD incluye estimaciones de utilización futura (*Credit Conversion Factor*, CCF).

5.0.4. Expected Credit Loss (ECL)

La **Pérdida Crediticia Esperada** (ECL) es el producto de los tres componentes anteriores, descontado al valor presente:

$$ECL = PD \times LGD \times EAD \times \text{Factor de Descuento} \quad (5.2)$$

Este es el cálculo central de IFRS9 y determina las provisiones que un banco debe reservar para cubrir pérdidas anticipadas.

5.0.5. IFRS9 y el Modelo de Tres Stages

IFRS9 (International Financial Reporting Standard 9) es la norma contable internacional que rige la clasificación y medición de instrumentos financieros. Su modelo de deterioro se basa en tres stages:

Tabla 5.1.: Modelo de deterioro de tres stages de IFRS9

Stage	Condición	PD Utilizada	Provisión
Stage 1	Sin deterioro significativo	PD a 12 meses	ECL a 12 meses
Stage 2	Incremento significativo de riesgo (SICR)	PD de por vida	ECL de por vida
Stage 3	Default confirmado (90 DPD)	PD 1.0	ECL total

5.0.6. Incremento Significativo de Riesgo Crediticio (SICR)

El **SICR** (Significant Increase in Credit Risk) es el trigger que mueve un préstamo de Stage 1 a Stage 2. IFRS9 no prescribe un método único para detectarlo — cada institución define sus propios criterios. Criterios comunes incluyen:

- Incremento absoluto o relativo de PD respecto a la originación
- Días de mora (30+ DPD como backstop)
- Downgrade de calificación interna



Innovación del proyecto

En este proyecto proponemos usar el **ancho del intervalo conformal** como señal adicional de SICR. Un intervalo más ancho indica mayor incertidumbre sobre la PD, lo que puede señalar deterioro antes de que se refleje en el punto estimado. Esta es una contribución original — no existen papers previos que usen el ancho conformal como trigger SICR.

5.0.7. Basilea III y Capital Regulatorio

El **marco de Basilea III** establece requerimientos mínimos de capital que los bancos deben mantener para absorber pérdidas inesperadas. Los tres pilares relevantes son:

1. **Pilar 1 — Capital mínimo:** Fórmulas regulatorias basadas en PD, LGD y EAD para calcular activos ponderados por riesgo (RWA).
2. **Pilar 2 — Supervisión:** Evaluaciones internas de adecuación de capital (ICAAP), incluyendo tests de estrés.
3. **Pilar 3 — Transparencia:** Divulgación pública de métricas de riesgo y modelos utilizados.

5.0.8. Grados de Riesgo (Credit Grades)

En Lending Club, los préstamos se clasifican en grados de A (menor riesgo) a G (mayor riesgo), basados en la evaluación crediticia del solicitante al momento de la originación. Estos grados determinan la tasa de interés y se utilizan en este proyecto como **variable de partición Mondrian** para predicción conformal condicional.

Tabla 5.2.: Grados de riesgo de Lending Club (valores aproximados del dataset)

Grado	Tasa de Default Típica	Tasa de Interés Típica
A	~5–8 %	~6–8 %
B	~10–14 %	~10–12 %
C	~15–20 %	~13–16 %
D	~20–28 %	~17–21 %
E	~28–35 %	~22–26 %
F	~35–45 %	~26–30 %
G	~45–55 %	~30–31 %

6. Fundamentos de ML y Estadística

6.0.1. Métricas de Discriminación

Las métricas de discriminación evalúan qué tan bien un modelo separa defaults de no-defaults.

AUC-ROC (Area Under the Receiver Operating Characteristic Curve): Mide la probabilidad de que el modelo asigne un score más alto a un default positivo seleccionado al azar que a un negativo seleccionado al azar. Rango: 0.5 (aleatorio) a 1.0 (perfecto). En credit scoring, $AUC > 0.70$ se considera aceptable para producción.

Gini: Transformación lineal del AUC: $Gini = 2 \times AUC - 1$. Rango: 0 (aleatorio) a 1 (perfecto). Es la métrica más utilizada en la industria bancaria europea.

KS (Kolmogorov-Smirnov): Máxima distancia vertical entre las distribuciones acumuladas de los scores de defaults y no-defaults. Indica el punto de máxima separación entre las dos poblaciones.

PR-AUC (Area Under the Precision-Recall Curve): Especialmente relevante para datasets desbalanceados. En Lending Club, con ~20 % de default rate, PR-AUC complementa al AUC-ROC capturando el rendimiento sobre la clase minoritaria (o mayoritaria en riesgo).

6.0.2. Métricas de Calibración

La calibración mide si las probabilidades predichas reflejan las frecuencias reales de default. Un modelo puede tener excelente discriminación (AUC alto) pero mala calibración.

Brier Score: Error cuadrático medio entre las probabilidades predichas y los outcomes binarios:

$$\text{Brier} = \frac{1}{n} \sum_{i=1}^n (\hat{p}_i - y_i)^2 \quad (6.1)$$

Rango: 0 (perfecto) a 1 (peor caso). Para un dataset con 20 % default rate, un modelo naive que predice 0.20 para todos obtiene Brier = 0.16.

ECE (Expected Calibration Error): Promedio ponderado de la diferencia absoluta entre la confianza predicha y la precisión observada, calculada por bins:

$$\text{ECE} = \sum_{b=1}^B \frac{|B_b|}{n} |\text{acc}(B_b) - \text{conf}(B_b)| \quad (6.2)$$

Un $\text{ECE} < 0.01$ indica calibración excelente. Nuestro modelo calibrado con Venn-Abers logra $\text{ECE} = 0.006$.

D² Brier: Análogo al R² para el Brier Score, mide la mejora relativa del modelo sobre un predictor naive (frecuencia marginal).

6.0.3. Gradient Boosting y CatBoost

Gradient Boosting es un ensemble de árboles de decisión entrenados secuencialmente, donde cada árbol corrige los errores del anterior. La predicción final es la suma ponderada de todas las predicciones individuales.

CatBoost (Categorical Boosting) es una implementación de gradient boosting desarrollada por Yandex con tres ventajas clave para credit scoring:

1. **Manejo nativo de categorías:** No requiere one-hot encoding ni WOE manual para variables categóricas — aplica target encoding con regularización ordered boosting.
2. **Manejo nativo de valores faltantes:** Trata NaN como un valor informativo, asignándolo a la rama óptima de cada split.
3. **Ordered boosting:** Reduce el overfitting al usar subconjuntos de datos históricos para calcular los target statistics de cada observación.

i ¿Por qué CatBoost y no XGBoost o LightGBM?

En credit scoring con datos tabulares, CatBoost ofrece: (1) mejor calibración out-of-the-box gracias al ordered boosting, (2) manejo transparente de categorías sin preprocesamiento manual, y (3) menor sensibilidad a hiperparámetros. Estudios comparativos recientes en credit scoring (Ayari et al., 2026; Lessmann et al., 2015) confirman que los tres frameworks logran AUC comparable, pero CatBoost simplifica el pipeline de features y reduce el riesgo de data leakage por target encoding incorrecto.

6.0.4. Optimización de Hiperparámetros (HPO)

Optuna es un framework de optimización de hiperparámetros basado en Tree-structured Parzen Estimator (TPE). A diferencia de grid search o random search, TPE modela la distribución de hiperparámetros condicional a su rendimiento y muestrea nuevos candidatos de las regiones más prometedoras.

En este proyecto, Optuna ejecuta 320 trials para el espacio de CatBoost, optimizando profundidad, learning rate, regularización L2, bagging temperature y otros hiperparámetros. La métrica objetivo es AUC validado sobre el split temporal de validación.

6.0.5. Calibración de Probabilidades

Un modelo de clasificación produce scores que no necesariamente son probabilidades bien calibradas. Los métodos de calibración post-hoc transforman los scores en probabilidades:

- **Platt Scaling:** Ajusta una regresión logística sobre los scores del modelo para producir probabilidades calibradas. Supone una relación sigmoide entre score y probabilidad.

- **Isotonic Regression:** Ajuste no paramétrico monótono. Más flexible que Platt pero propenso a overfitting con pocas muestras.
- **Venn-Abers:** Produce intervalos de probabilidad con garantías de validez multiprobabilística. Es el método más conservador y el seleccionado en este proyecto por su robustez temporal.

6.0.6. Weight of Evidence (WOE) e Information Value (IV)

WOE (Weight of Evidence) transforma variables categóricas o numéricas binneadas en una escala que refleja su poder predictivo:

$$WOE_i = \ln \left(\frac{\% \text{ no-defaults en bin } i}{\% \text{ defaults en bin } i} \right) \quad (6.3)$$

IV (Information Value) mide el poder predictivo total de una variable:

$$IV = \sum_{i=1}^k (\% \text{ no-defaults}_i - \% \text{ defaults}_i) \times WOE_i \quad (6.4)$$

Tabla 6.1.: Interpretación del Information Value

IV	Poder predictivo
< 0.02	No útil
0.02 – 0.10	Débil
0.10 – 0.30	Medio
0.30 – 0.50	Fuerte
> 0.50	Sospechosamente fuerte (posible leakage)

7. Incertidumbre y Predicción Conformal

La cuantificación de incertidumbre es una de las piezas más críticas — y frecuentemente ignoradas — en la modelación de riesgo crediticio. Un modelo que produce una estimación puntual de $\hat{p} = 0.15$ para la probabilidad de default de un préstamo no transmite si esa estimación es confiable o altamente incierta. En un portafolio de miles de préstamos, tomar decisiones de asignación basadas exclusivamente en puntos estimados sin considerar su incertidumbre conduce a portafolios frágiles que se deterioran bajo condiciones adversas.

Esta sección introduce los fundamentos teóricos de la cuantificación de incertidumbre, con énfasis particular en la **predicción conformal** — un marco que ofrece garantías matemáticas de cobertura sin requerir supuestos distribucionales sobre los datos.

7.0.1. Incertidumbre Aleatoria vs Epistémica

La incertidumbre en las predicciones de un modelo tiene dos fuentes fundamentalmente distintas:

Incertidumbre aleatoria (irreducible): Es la variabilidad inherente al fenómeno observado. Proviene de la estocasticidad intrínseca del proceso generador de datos y no puede eliminarse recopilando más datos ni mejorando el modelo. En riesgo crediticio, la incertidumbre aleatoria refleja que dos prestatarios con exactamente las mismas características observables pueden tener outcomes distintos: uno paga y el otro entra en default. Esto ocurre porque existen factores no observados — eventos de salud, pérdida de empleo, decisiones personales — que afectan el repago pero no están capturados en las features del modelo.

Incertidumbre epistémica (reducible): Es la incertidumbre que surge de la limitación del conocimiento del modelo. Se debe a datos insuficientes, especificación incorrecta del modelo, o regiones del espacio de features con poca representación en el conjunto de entrenamiento. A diferencia de la aleatoria, esta incertidumbre *puede* reducirse con más datos o un modelo mejor especificado.

i Ejemplo en riesgo crediticio

Considérese un préstamo de grado G con un historial crediticio muy corto. La incertidumbre sobre su PD tiene ambos componentes:

- **Aleatoria:** Aun conociendo perfectamente todas las características del prestatario, existe variabilidad inherente en si entrará o no en default.
- **Epistémica:** Dado que los préstamos grado G con historial corto son relativamente escasos en el conjunto de entrenamiento, el modelo tiene menos evidencia para estimar su PD con precisión. Con más datos de prestatarios similares, esta componente se reduciría.

En la práctica, los intervalos conformales capturan ambas fuentes de incertidumbre simultáneamente, sin necesidad de descomponerlas explícitamente.

7. Incertidumbre y Predicción Conformal

En la modelación Bayesiana, la incertidumbre epistémica se captura a través de la distribución posterior sobre los parámetros del modelo, mientras que la aleatoria se captura a través de la distribución predictiva posterior. Los métodos conformales, en cambio, producen intervalos que absorben ambas fuentes de forma agnóstica — no requieren especificar un prior ni una verosimilitud, lo que los hace especialmente atractivos para aplicaciones regulatorias donde la transparencia y la ausencia de supuestos son valoradas.

7.0.2. Intervalos de Predicción vs Intervalos de Confianza

Una confusión frecuente en la práctica estadística — y particularmente peligrosa en gestión de riesgo — es la diferencia entre intervalos de confianza e intervalos de predicción. Aunque ambos producen rangos numéricos, cuantifican objetos fundamentalmente distintos.

Intervalo de confianza para un parámetro θ al nivel $1 - \alpha$: Es un rango $[\hat{\theta}_L, \hat{\theta}_U]$ tal que, bajo muestreo repetido:

$$P(\theta \in [\hat{\theta}_L, \hat{\theta}_U]) \geq 1 - \alpha \quad (7.1)$$

El intervalo de confianza cuantifica la incertidumbre sobre un *parámetro poblacional* (por ejemplo, la tasa de default promedio de un segmento). Se estrecha con más datos porque la estimación del parámetro mejora.

Intervalo de predicción para una nueva observación Y_{n+1} al nivel $1 - \alpha$: Es un rango $[L(X_{n+1}), U(X_{n+1})]$ tal que:

$$P(Y_{n+1} \in [L(X_{n+1}), U(X_{n+1})]) \geq 1 - \alpha \quad (7.2)$$

El intervalo de predicción cuantifica la incertidumbre sobre una *observación futura individual*. Incluye tanto la incertidumbre sobre el parámetro (epistémica) como la variabilidad inherente del outcome (aleatoria), por lo que es necesariamente más ancho que el intervalo de confianza correspondiente.

Tabla 7.1.: Comparación entre intervalos de confianza e intervalos de predicción

Propiedad	Intervalo de Confianza	Intervalo de Predicción
Objeto cuantificado	Parámetro poblacional θ	Observación futura Y_{n+1}
Fuentes de incertidumbre	Solo epistémica	Epistémica + aleatoria
Comportamiento con $n \rightarrow \infty$	Se estrecha a cero	Converge a un ancho mínimo > 0
Uso en riesgo crediticio	Tasa de default de un segmento	PD de un préstamo individual
Error común	Usar como si fuera predicción	Ignorar la componente aleatoria

⚠ Error frecuente en la práctica bancaria

En muchos modelos de riesgo crediticio en producción, se reportan intervalos de confianza sobre la PD media de un segmento como si fueran intervalos de predicción para préstamos individuales. Esto subestima sistemáticamente la incertidumbre: un intervalo de confianza al 95 % para la PD media de grado B podría ser [0.11, 0.13], mientras que el intervalo de predicción individual correcto podría ser [0.02, 0.35]. La diferencia es crucial para la gestión de portafolio y la determinación de provisiones bajo IFRS9.

En este proyecto, todos los intervalos generados son **intervalos de predicción** — cuantifican la incertidumbre sobre la PD de cada préstamo individual, no sobre parámetros promedio de segmentos.

7.0.3. Fundamentos de la Predicción Conformal

La predicción conformal, introducida por Vovk, Gammerman y Shafer (Vovk et al., 2005), es un marco teórico para construir intervalos de predicción con **garantías finitas de cobertura** sin asumir una distribución paramétrica específica para los datos. Esta propiedad la distingue fundamentalmente de los intervalos paramétricos (que requieren supuestos distribucionales) y los intervalos bootstrap (que son asintóticos y pueden fallar en muestras finitas).

7.0.3.1. El supuesto de intercambiabilidad

El único supuesto teórico requerido por la predicción conformal es la **intercambiabilidad** (*exchangeability*) de los datos. Una secuencia de variables aleatorias $(Z_1, Z_2, \dots, Z_n)$ es intercambiable si su distribución conjunta es invariante bajo cualquier permutación:

$$P(Z_1, Z_2, \dots, Z_n) = P(Z_{\pi(1)}, Z_{\pi(2)}, \dots, Z_{\pi(n)}) \quad \forall \pi \in S_n \quad (7.3)$$

donde S_n es el grupo de todas las permutaciones de $\{1, 2, \dots, n\}$.

La intercambiabilidad es estrictamente más débil que el supuesto i.i.d. (independiente e idénticamente distribuido): todas las secuencias i.i.d. son intercambiables, pero no toda secuencia intercambiable es i.i.d. Por ejemplo, un muestreo sin reemplazo de una urna finita produce secuencias intercambiables pero no independientes.

💡 Intercambiabilidad en datos de crédito

En este proyecto, los splits temporales (train/calibración/test) violan la intercambiabilidad estricta porque la distribución de préstamos puede cambiar con el tiempo (concept drift). Sin embargo, la predicción conformal es notablemente robusta en la práctica: incluso bajo desviaciones moderadas de la intercambiabilidad, la cobertura empírica permanece cercana a la garantía teórica. En nuestros experimentos con datos OOT (2018–2020), la cobertura empírica al 90 % alcanza 92.52 % — ligeramente por encima de la garantía, lo que indica conservadurismo saludable.

7. Incertidumbre y Predicción Conformal

7.0.3.2. La garantía de cobertura

El resultado central de la predicción conformal es el siguiente teorema:

i Teorema de cobertura conformal

Sean $(X_1, Y_1), \dots, (X_n, Y_n), (X_{n+1}, Y_{n+1})$ variables aleatorias intercambiables. Para cualquier función de nonconformidad s y cualquier nivel de significancia $\alpha \in (0, 1)$, el conjunto de predicción conformal $C_\alpha(X_{n+1})$ satisface:

$$P(Y_{n+1} \in C_\alpha(X_{n+1})) \geq 1 - \alpha \quad (7.4)$$

Más precisamente, bajo intercambiabilidad:

$$1 - \alpha \leq P(Y_{n+1} \in C_\alpha(X_{n+1})) \leq 1 - \alpha + \frac{1}{n+1} \quad (7.5)$$

donde n es el tamaño del conjunto de calibración.

La Ecuación 7.5 muestra que la cobertura es *exacta* hasta un factor $\frac{1}{n+1}$ que se vuelve despreciable para conjuntos de calibración grandes. Para $n = 237,584$ (el tamaño de nuestro conjunto de calibración), $\frac{1}{n+1} \approx 4.2 \times 10^{-6}$, haciendo la garantía prácticamente exacta.

Esta garantía es **marginal** — se cumple en promedio sobre la distribución conjunta de los datos de calibración y el nuevo punto de test. No garantiza cobertura condicional para cada subgrupo de préstamos (para eso se necesita el enfoque Mondrian, descrito en Sección 7.0.5).

7.0.3.3. Scores de nonconformidad

El concepto central del framework conformal es el **score de nonconformidad** (*nonconformity score*), denotado $s(x, y)$. Este score mide qué tan “inusual” o “no conforme” es una observación (x, y) respecto al patrón aprendido por el modelo. A mayor score, más atípica es la observación.

Para regresión (y para la estimación de intervalos de PD), el score más común es el **residuo absoluto**:

$$s_i = |y_i - \hat{f}(x_i)| \quad (7.6)$$

donde $\hat{f}(x_i)$ es la predicción del modelo para la observación i . En nuestro caso, $\hat{f}(x_i)$ es la PD calibrada y $y_i \in \{0, 1\}$ es el indicador binario de default.

Otros scores de nonconformidad incluyen:

- **Residuo escalado:** $s_i = \frac{|y_i - \hat{f}(x_i)|}{\hat{\sigma}(x_i)}$, donde $\hat{\sigma}(x_i)$ es una estimación local de dispersión. Produce intervalos de ancho variable (*heteroscedásticos*).
- **Residuo normalizado:** $s_i = \frac{|y_i - \hat{f}(x_i)|}{\sqrt{\hat{f}(x_i)(1 - \hat{f}(x_i))}}$, que normaliza por la varianza binomial. En nuestro código, esto corresponde al parámetro `scaled_scores=True`.
- **Score CQR:** Basado en cuantiles condicionales (ver Sección 7.0.6).

La elección del score afecta la *eficiencia* (ancho de los intervalos) pero no la *validez* (garantía de cobertura). Cualquier función de score produce intervalos con cobertura válida; scores más sofisticados producen intervalos más estrechos.

7.0.4. Split Conformal

El **Split Conformal** (o *Inductive Conformal Prediction*) es la variante más práctica y computacionalmente eficiente de la predicción conformal. Su implementación requiere tres pasos simples.

7.0.4.1. Procedimiento formal

Dados un modelo $\hat{f}$ ya entrenado, un conjunto de calibración $\mathcal{D}_{\text{cal}} = \{(X_i, Y_i)\}_{i=1}^n$ **no utilizado durante el entrenamiento**, y un nivel de cobertura deseado $1 - \alpha$:

Paso 1 — Calcular scores de nonconformidad en calibración:

$$s_i = |Y_i - \hat{f}(X_i)|, \quad i = 1, \dots, n \quad (7.7)$$

Paso 2 — Calcular el cuantil conformal:

$$\hat{q}_\alpha = \text{Quantile} \left(\{s_1, \dots, s_n\}, \frac{\lceil (n+1)(1-\alpha) \rceil}{n} \right) \quad (7.8)$$

El nivel del cuantil incorpora la corrección de muestra finita $\frac{\lceil (n+1)(1-\alpha) \rceil}{n}$ que garantiza la cobertura exacta de la Ecuación 7.5.

Paso 3 — Construir intervalos para nuevas observaciones:

$$C_\alpha(X_{n+1}) = [\hat{f}(X_{n+1}) - \hat{q}_\alpha, \hat{f}(X_{n+1}) + \hat{q}_\alpha] \quad (7.9)$$

Para PD, los intervalos se truncan a $[0, 1]$: $C_\alpha(X_{n+1}) \cap [0, 1]$.

Elegancia computacional

Nótese que el procedimiento Split Conformal requiere una sola pasada de predicción sobre el conjunto de calibración y el cálculo de un único cuantil. No hay refitting del modelo, no hay bootstrapping, no hay simulación Monte Carlo. Esto hace que sea extremadamente eficiente computacionalmente — en nuestro pipeline, generar intervalos conformales para 276,869 préstamos de test toma menos de un segundo una vez que el modelo está entrenado.

7.0.4.2. Requisito del conjunto de calibración separado

Un aspecto fundamental del Split Conformal es que el conjunto de calibración debe ser **estrictamente independiente** del conjunto de entrenamiento. Si se usan los mismos datos para entrenar el modelo y para calcular los scores de nonconformidad, los scores serán optimistamente pequeños (el modelo se ajusta bien a sus propios datos de entrenamiento) y los intervalos resultantes serán demasiado estrechos, violando la garantía de cobertura.

En nuestro proyecto, la separación se garantiza mediante splits temporales:

Tabla 7.2.: Splits temporales del proyecto y su rol en el framework conformal

Conjunto	Período	Uso
Train	2007-06 a 2017-03	Entrenamiento del modelo CatBoost
Calibración	2017-03 a 2017-12	Cálculo de scores conformales ($n = 237,584$)
Test (OOT)	2018-01 a 2020-09	Evaluación de cobertura ($n = 276,869$)

7.0.4.3. Implementación con MAPIE 1.3.0

La biblioteca MAPIE (Model Agnostic Prediction Interval Estimator) (Taquet et al., 2025) provee una implementación robusta y bien mantenida del framework conformal para Python. La versión 1.3.0 introdujo una API renovada con clases dedicadas.

Para intervalos de PD, el flujo de trabajo con `SplitConformalRegressor` es:

1. **Envolver** el clasificador CatBoost en un `ProbabilityRegressor` que expone `predict()` retornando $P(\text{default})$.
2. **Instanciar** el conformal regressor con `prefit=True` y el nivel de confianza deseado.
3. **Conformizar** sobre el conjunto de calibración con `conformalize(X_cal, y_cal)`.
4. **Predecir** intervalos sobre nuevos datos con `predict_interval(X_test)`.

API de MAPIE 1.3.0

La versión 1.3.0 de MAPIE reemplazó completamente la API anterior. Los cambios clave son:

- `SplitConformalRegressor` reemplaza a `MapieRegressor`
- `SplitConformalClassifier` reemplaza a `MapieClassifier`
- El flujo es `fit()` → `conformalize()` → `predict_interval()`
- El nivel de confianza se especifica en `__init__` con `confidence_level` (no `alpha` en `predict`)
- Los modelos pre-entrenados usan `prefit=True` (no `cv="prefit"`)

7.0.5. Predicción Conformal Mondrian

La garantía de cobertura de la Ecuación 24.1 es **marginal** — se cumple en promedio sobre toda la distribución. Esto significa que si un modelo tiene 90 % de cobertura global, podría tener 98 % de cobertura para préstamos grado A y solo 72 % para préstamos grado G. En gestión de riesgo crediticio, esta heterogeneidad es inaceptable: los préstamos de alto riesgo son precisamente los que más necesitan intervalos confiables.

La **predicción conformal Mondrian** (Boström et al., 2021) resuelve este problema proporcionando **garantías de cobertura condicionales por grupo**.

7.0.5.1. Formulación formal

Sea $\mathcal{G} = \{g_1, g_2, \dots, g_K\}$ una partición del espacio de observaciones en K grupos disjuntos. La predicción conformal Mondrian construye cuantiles conformales separados para cada grupo:

$$\hat{q}_\alpha^{(k)} = \text{Quantile} \left(\{s_i : G(X_i) = g_k, i \in \mathcal{D}_{\text{cal}}\}, \frac{\lceil (n_k + 1)(1 - \alpha) \rceil}{n_k} \right) \quad (7.10)$$

donde $n_k = |\{i \in \mathcal{D}_{\text{cal}} : G(X_i) = g_k\}|$ es el número de observaciones de calibración en el grupo k , y $G(X_i)$ es la función que asigna la observación i al grupo correspondiente.

El intervalo para una nueva observación en el grupo g_k es:

$$C_\alpha^{(k)}(X_{n+1}) = [\hat{f}(X_{n+1}) - \hat{q}_\alpha^{(k)}, \hat{f}(X_{n+1}) + \hat{q}_\alpha^{(k)}] \quad (7.11)$$

7.0.5.2. Garantía de cobertura condicional por grupo

Bajo intercambiabilidad *dentro de cada grupo*, la predicción Mondrian satisface:

$$P(Y_{n+1} \in C_\alpha^{(k)}(X_{n+1}) \mid G(X_{n+1}) = g_k) \geq 1 - \alpha, \quad \forall k \in \{1, \dots, K\} \quad (7.12)$$

Esta garantía es estrictamente más fuerte que la garantía marginal: cobertura condicional por grupo implica cobertura marginal, pero no al revés.

7.0.5.3. ¿Por qué el grado de riesgo como partición?

La elección de la variable de partición Mondrian es crítica. En riesgo crediticio, el **grado de riesgo** (A–G en Lending Club) es una partición natural por varias razones:

1. **Grupos disjuntos por diseño:** Cada préstamo pertenece a exactamente un grado, cumpliendo el requisito de partición.
2. **Heterogeneidad de riesgo:** Las tasas de default varían dramáticamente entre grados (véase Tabla 5.2), por lo que el modelo tiene diferentes niveles de incertidumbre por grupo.
3. **Relevancia regulatoria:** Las matrices de transición y las reservas IFRS9 se calculan por grado, alineando los intervalos conformales con el framework regulatorio existente.

7. Incertidumbre y Predicción Conformal

4. **Tamaño muestral adecuado:** Incluso el grado más pequeño (G) tiene miles de observaciones en calibración, asegurando cuantiles estables.

💡 Particiones alternativas

Además del grado, nuestro proyecto implementa otras particiones Mondrian: por deciles de score (`score_decile_mondrian`) y por grado cruzado con bandas de score (`grade_x_scoreband_mondrian`). Las particiones más finas producen intervalos más adaptativos pero requieren más datos de calibración por celda. Cuando una celda tiene pocos datos (debajo de un umbral `min_group_size`, por defecto 500), se aplica fallback al cuantil del grado o al cuantil global.

7.0.5.4. Ancho diferencial por grado

Una consecuencia directa del enfoque Mondrian es que los intervalos tienen **ancho diferente por grado**. Préstamos de grado A (bajo riesgo, PD bien calibrada) obtienen intervalos estrechos, mientras que préstamos de grado G (alto riesgo, mayor incertidumbre) obtienen intervalos más anchos. Esto es deseable porque refleja la realidad: hay más incertidumbre sobre préstamos de alto riesgo.

Formalmente, si el modelo comete errores más grandes en el grupo g_k (los scores s_i son más altos), entonces $\hat{q}_\alpha^{(k)} > \hat{q}_\alpha^{(j)}$ para un grupo g_j con errores menores, resultando en intervalos más anchos para g_k :

$$\text{Ancho}^{(k)} = 2 \cdot \hat{q}_\alpha^{(k)} > 2 \cdot \hat{q}_\alpha^{(j)} = \text{Ancho}^{(j)} \quad (7.13)$$

7.0.6. Regresión Cuantílica Conformalizada (CQR)

La **Regresión Cuantílica Conformalizada (CQR)**, propuesta por Romano, Patterson y Candès (Romano et al., 2019), combina la flexibilidad de la regresión cuantílica con las garantías de la predicción conformal. A diferencia del Split Conformal estándar que produce intervalos de ancho constante (para un mismo grupo), CQR produce intervalos de **ancho adaptativo** que varían observación por observación.

7.0.6.1. Idea central

CQR opera en dos etapas:

Etapla 1 — Entrenamiento de regresión cuantílica: Se entrena un modelo de regresión cuantílica que produce estimaciones de los cuantiles inferior $\hat{q}_{\alpha/2}(x)$ y superior $\hat{q}_{1-\alpha/2}(x)$ condicionales en x .

Etapla 2 — Conformización: Se define un score de nonconformidad que mide cuánto se extiende la observación real fuera del intervalo cuantílico estimado:

$$s_i = \max \left(\hat{q}_{\alpha/2}(X_i) - Y_i, Y_i - \hat{q}_{1-\alpha/2}(X_i) \right) \quad (7.14)$$

Se calcula el cuantil conformal $\hat{Q}_\alpha$ de estos scores sobre el conjunto de calibración, y el intervalo final es:

$$C_\alpha^{\text{CQR}}(X_{n+1}) = [\hat{q}_{\alpha/2}(X_{n+1}) - \hat{Q}_\alpha, \hat{q}_{1-\alpha/2}(X_{n+1}) + \hat{Q}_\alpha] \quad (7.15)$$

7.0.6.2. Ventajas sobre Split Conformal estándar

La principal ventaja de CQR es que hereda la estructura de los cuantiles condicionales: si la varianza condicional de $Y|X = x$ varía con x (heteroscedasticidad), los intervalos CQR serán más estrechos donde la varianza es baja y más anchos donde es alta, todo sin sacrificar la garantía de cobertura.

En el contexto de PD, esto significa que un préstamo con features que lo ubican en una región de alta certeza del modelo obtendrá un intervalo más estrecho que uno en una región de baja certeza, *dentro del mismo grado*. El enfoque Mondrian + CQR combinaría ambas ventajas: adaptación entre grupos (Mondrian) y adaptación dentro de grupos (CQR).

CQR en este proyecto

En la implementación actual, el pipeline principal usa Split Conformal con partición Mondrian por grado. CQR está disponible como benchmark alternativo. La elección se justifica porque: (1) el Split Conformal Mondrian ya captura la principal fuente de heterogeneidad (el grado), (2) CQR requiere entrenar un modelo cuantílico adicional, y (3) los resultados empíricos muestran que la cobertura condicional por grado del enfoque Mondrian es satisfactoria (mínimo 89.0 % para el peor grado al nivel 90 %).

7.0.7. Tradeoff entre Cobertura y Ancho

Los dos criterios fundamentales para evaluar intervalos de predicción son la **cobertura** y el **ancho** (también llamado *sharpness*). Existe una tensión inherente entre ambos:

- **Cobertura** ($1 - \alpha$): Fracción de observaciones cuyo valor verdadero cae dentro del intervalo predicho. Mayor cobertura requiere intervalos más amplios.
- **Ancho** ($w = U - L$): Diferencia entre el límite superior e inferior del intervalo. Intervalos más estrechos son más informativos pero arriesgan cobertura insuficiente.

El intervalo trivial $[0, 1]$ para PD tiene cobertura perfecta (100 %) pero ancho máximo (1.0) — no aporta ninguna información. El desafío es construir intervalos lo más **estrechos** posible sujeto a la restricción de cobertura.

Formalmente, dados dos métodos de intervalos A y B con la misma cobertura empírica, se prefiere el que tenga menor ancho promedio:

$$\text{Eficiencia relativa} = \frac{\bar{w}_A}{\bar{w}_B} = \frac{\mathbb{E}[U_A - L_A]}{\mathbb{E}[U_B - L_B]} \quad (7.16)$$

Un ratio menor a 1 indica que el método A es más eficiente (produce intervalos más estrechos para la misma cobertura).

7. Incertidumbre y Predicción Conformal

7.0.7.1. Efecto de α sobre cobertura y ancho

Al variar α , se traza una **curva de Pareto** entre cobertura y ancho:

Tabla 7.3.: Efecto del nivel de significancia sobre cobertura y ancho

Nivel α	Cobertura objetivo	Comportamiento del ancho
0.20	80 %	Intervalos estrechos, menor protección
0.10	90 %	Balance habitual en la práctica
0.05	95 %	Intervalos más anchos, mayor protección
0.01	99 %	Intervalos muy anchos, máxima protección

⚠ Cobertura condicional vs marginal

Es posible que un método logre excelente cobertura *marginal* (promedio global) pero falle en subgrupos específicos. En riesgo crediticio, la cobertura condicional por grado es más relevante que la marginal: un banco necesita saber que los intervalos son confiables *para cada segmento de riesgo*, no solo en promedio. El enfoque Mondrian aborda precisamente este problema al garantizar cobertura condicional por grupo.

En nuestros experimentos de alpha sweep, el enfoque Mondrian identifica 25,625 préstamos elegibles (9.3% del test set) para reclasificación a $\alpha = 0.10$, mientras que el enfoque global no identifica ninguno al mismo nivel — demostrando que la granularidad condicional es operativamente superior.

7.0.7.2. Métricas de evaluación integral

Para evaluar intervalos conformales de forma integral, se utilizan las siguientes métricas:

PICP (Prediction Interval Coverage Probability): Cobertura empírica, que debe ser $\geq 1 - \alpha$.

$$\text{PICP} = \frac{1}{n_{\text{test}}} \sum_{i=1}^{n_{\text{test}}} \mathbb{1}[Y_i \in [L_i, U_i]] \quad (7.17)$$

MPIW (Mean Prediction Interval Width): Ancho promedio de los intervalos.

$$\text{MPIW} = \frac{1}{n_{\text{test}}} \sum_{i=1}^{n_{\text{test}}} (U_i - L_i) \quad (7.18)$$

NMPIW (Normalized MPIW): Ancho normalizado por el rango de la variable respuesta, que permite comparar entre escalas.

$$\text{NMPIW} = \frac{\text{MPIW}}{Y_{\text{max}} - Y_{\text{min}}} \quad (7.19)$$

Un método conformal ideal maximiza PICP (cumpliendo $\geq 1 - \alpha$) y minimiza MPIW simultáneamente.

7.0.8. Comparación con Alternativas

Para contextualizar las ventajas de la predicción conformal, comparamos con los métodos alternativos más utilizados para cuantificar incertidumbre en modelos de riesgo crediticio:

Tabla 7.4.: Comparación de métodos de cuantificación de incertidumbre

Método	Garantía de cobertura	Supuestos distribucionales	Costo computacional	Adaptabilidad
Bootstrap	Asintótica	Ninguno explícito	Alto (B refits)	Baja
Bayesiano	Subjetiva (prior-dependent)	Verosimilitud + prior	Muy alto (MCMC)	Alta
Conformal	Finita, exacta	Intercambiabilidad	Bajo (1 cuantil)	Media
Venn-Abers	Multiprobabilística	Intercambiabilidad	Bajo	Baja

Bootstrap: Requiere B (típicamente 100–1000) re-entrenamientos del modelo. Sus intervalos son asintóticos — la cobertura nominal solo se alcanza cuando $n \rightarrow \infty$. En muestras finitas, puede sub-cubrir significativamente, especialmente en las colas de la distribución.

Métodos Bayesianos (BMA): Proporcionan la distribución posterior predictiva completa, pero requieren especificar un prior y una verosimilitud. La calidad de los intervalos depende críticamente de que estos supuestos sean correctos. En nuestras comparaciones, BMA logra cobertura del 90.0 % versus 92.52 % del conformal Mondrian, pero con intervalos 19.3 % más anchos (ancho medio 0.9347 vs 0.7546).

Predicción conformal: Ofrece el mejor balance entre garantía teórica, eficiencia computacional y ausencia de supuestos. Su principal limitación es que la garantía es marginal (sin Mondrian) y requiere un conjunto de calibración holdout que “pierde” datos para el entrenamiento.

Venn-Abers: Produce intervalos multiprobabilísticos con calibración automática (Vovk & Petej, 2014). Es complementario a la predicción conformal y se usa en este proyecto como método de calibración.

7.0.9. Referencias Clave

Los fundamentos teóricos presentados en esta sección se basan en los siguientes trabajos:

- **Vovk, Gammernan y Shafer** (Vovk et al., 2005): La monografía fundacional de la predicción conformal. Establece el marco teórico completo, incluyendo el teorema de cobertura, las variantes transductiva e inductiva, y las conexiones con la teoría algorítmica de la aleatoriedad. Lectura esencial para la comprensión profunda del framework.

7. Incertidumbre y Predicción Conformal

- **Romano, Patterson y Candès** (Romano et al., 2019): Introduce CQR (Conformalized Quantile Regression), que combina regresión cuantílica con conformalización para producir intervalos adaptativos. Este trabajo demostró que la predicción conformal puede ser simultáneamente válida y *sharp* (eficiente en ancho).
- **Angelopoulos y Bates** (Angelopoulos & Bates, 2023): Una introducción tutorial moderna y accesible a la predicción conformal, publicada en *Foundations and Trends in Machine Learning*. Cubre Split Conformal, CQR, conjuntos de predicción para clasificación, y extensiones recientes. Recomendada como primer punto de entrada.
- **Boström et al.** (Boström et al., 2021): Formaliza las distribuciones predictivas conformales Mondrian con garantías de cobertura condicional por grupo. Es la base teórica directa de nuestro enfoque de partición por grado crediticio.

8. Optimización e Investigación de Operaciones

La investigación de operaciones (OR) proporciona el marco matemático para tomar decisiones óptimas bajo restricciones. En riesgo crediticio, esto se traduce en preguntas como: *¿a qué préstamos asignar capital para maximizar retorno manteniendo el riesgo agregado bajo control?* Esta sección presenta los fundamentos de optimización necesarios para entender el pipeline de este proyecto, desde la programación lineal hasta la optimización robusta con conjuntos de incertidumbre conformales.

8.0.1. Programación Lineal (LP)

La **Programación Lineal** es la forma más fundamental de optimización matemática. Un problema de LP consiste en maximizar (o minimizar) una función objetivo lineal sujeta a restricciones lineales de igualdad y desigualdad.

8.0.1.1. Forma Estándar

Un LP en forma estándar se escribe como:

$$\begin{aligned} \max_{\mathbf{x}} \quad & \mathbf{c}^\top \mathbf{x} \\ \text{s.a.} \quad & A\mathbf{x} \leq \mathbf{b} \\ & \mathbf{x} \geq \mathbf{0} \end{aligned} \tag{8.1}$$

donde:

- $\mathbf{x} \in \mathbb{R}^n$ es el **vector de variables de decisión** (en nuestro caso, la fracción de capital asignada a cada préstamo),
- $\mathbf{c} \in \mathbb{R}^n$ es el **vector de costos u objetivo** (retornos esperados netos de pérdida),
- $A \in \mathbb{R}^{m \times n}$ es la **matriz de restricciones**,
- $\mathbf{b} \in \mathbb{R}^m$ es el **vector de recursos o límites** de las restricciones.

8.0.1.2. Conceptos Clave

- **Región factible:** El conjunto de todos los $\mathbf{x}$ que satisfacen simultáneamente todas las restricciones. En LP, esta región es un **poliedro convexo** (la intersección de semiespacios).
- **Solución óptima:** Un punto $\mathbf{x}^*$ en la región factible que alcanza el valor máximo (o mínimo) de la función objetivo. El teorema fundamental de la programación lineal garantiza que, si existe una solución óptima finita, al menos una se encuentra en un **vértice** del poliedro.

- **Infactibilidad:** Si las restricciones son contradictorias (no existe ningún $\mathbf{x}$ que las satisfaga simultáneamente), el problema es **infactible**.
- **No-acotamiento:** Si la función objetivo puede crecer indefinidamente dentro de la región factible, el problema es **no acotado**.
- **Dualidad:** Todo LP tiene un **problema dual** asociado. Si el primal maximiza, el dual minimiza. El teorema de dualidad fuerte establece que, si ambos problemas son factibles, sus valores óptimos coinciden.

i LP en asignación de portafolio crediticio

En este proyecto, el LP de asignación de portafolio tiene la forma:

- **Variables:** $x_i \in [0, 1]$ = fracción del préstamo i que se financia.
- **Objetivo:** maximizar retorno esperado neto = $\sum_i x_i \cdot \text{monto}_i \cdot (\text{tasa}_i - \text{PD}_i \cdot \text{LGD}_i)$.
- **Restricciones:** presupuesto total, PD promedio del portafolio $\leq$ umbral, concentración máxima por préstamo.

El LP se resuelve en milisegundos con solvers modernos, lo que permite explorar miles de escenarios de política.

8.0.2. Programación Lineal Entera Mixta (MILP)

En muchos problemas reales, algunas decisiones son **discretas**: financiar o no financiar un préstamo, abrir o cerrar una sucursal, seleccionar k de n candidatos. Cuando las variables de decisión incluyen tanto continuas como enteras (típicamente binarias), el problema se convierte en un **MILP**.

$$\begin{aligned}
 & \underset{\mathbf{x}, \mathbf{y}}{\text{máx}} && \mathbf{c}^\top \mathbf{x} + \mathbf{d}^\top \mathbf{y} \\
 & \text{s.a.} && A\mathbf{x} + B\mathbf{y} \leq \mathbf{b} \\
 & && \mathbf{x} \geq \mathbf{0}, \quad \mathbf{y} \in \{0, 1\}^p
 \end{aligned} \tag{8.2}$$

donde $\mathbf{y} \in \{0, 1\}^p$ son las **variables binarias** de decisión.

8.0.2.1. Diferencias con LP

Tabla 8.1.: Comparación entre LP y MILP

Aspecto	LP	MILP
Variables	Continuas	Continuas + enteras/binarias
Región factible	Poliedro convexo	No convexo (puntos discretos)
Complejidad	Polinomial (Simplex, punto interior)	NP-hard en general

Aspecto	LP	MILP
Solución	Vértice del poliedro	Branch-and-bound / Branch-and-cut
Tiempo de solución	Milisegundos (miles de variables)	Segundos a horas (según instancia)

💡 Decisión de diseño: LP vs MILP

En este proyecto utilizamos **LP con variables continuas** $x_i \in [0, 1]$ en lugar de MILP con variables binarias $y_i \in \{0, 1\}$. Esto se justifica porque Lending Club permite financiar fracciones de préstamos (participación parcial). La relajación continua resuelve órdenes de magnitud más rápido y permite explorar el espacio de políticas robustas con miles de candidatos ($n \leq 80,000$).

8.0.3. Optimización Robusta

La optimización clásica (LP, MILP) asume que los parámetros del problema — costos, coeficientes, límites — son **conocidos con certeza**. En la práctica, los parámetros son **estimaciones con incertidumbre**: la PD predicha por un modelo de ML no es un valor exacto, sino una estimación sujeta a error.

La **optimización robusta** aborda esta realidad buscando soluciones que sean **factibles y de buen desempeño para todos los valores posibles** de los parámetros inciertos dentro de un **conjunto de incertidumbre** predefinido.

8.0.3.1. Formulación General

Sea $\mathcal{U}$ un conjunto de incertidumbre que contiene los posibles valores del parámetro incierto $\mathbf{d}$. La formulación robusta del LP es:

$$\begin{aligned}
 & \max_{\mathbf{x}} \quad \min_{\mathbf{d} \in \mathcal{U}} \mathbf{c}(\mathbf{d})^\top \mathbf{x} \\
 & \text{s.a.} \quad A(\mathbf{d})\mathbf{x} \leq \mathbf{b}(\mathbf{d}), \quad \forall \mathbf{d} \in \mathcal{U} \\
 & \quad \mathbf{x} \geq \mathbf{0}
 \end{aligned} \tag{8.3}$$

La clave es el operador $\min_{\mathbf{d} \in \mathcal{U}}$: el optimizador busca la **mejor decisión asumiendo que la naturaleza jugará en su contra**, eligiendo la realización más adversa de la incertidumbre dentro de $\mathcal{U}$. Es un juego minimax.

8.0.3.2. El Framework de Bertsimas y Sim

El enfoque seminal de Bertsimas & Sim (2004b) introduce un parámetro Γ (Gamma) que controla el **grado de conservadurismo** de la solución robusta. La intuición es que, en la práctica, es improbable que *todos* los parámetros inciertos alcancen simultáneamente su peor caso.

Considérese una restricción nominal:

$$\sum_{j=1}^n \bar{a}_j x_j \leq b \quad (8.4)$$

donde $\bar{a}_j$ es el valor nominal del coeficiente a_j y su valor real puede variar en el intervalo $[\hat{a}_j - \bar{a}_j, \bar{a}_j + \hat{a}_j]$ con $\hat{a}_j$ la **semi-amplitud** de incertidumbre.

El parámetro $\Gamma \in [0, n]$ limita el número de coeficientes que pueden desviarse simultáneamente de su valor nominal. La restricción robusta de Bertsimas–Sim se escribe:

$$\sum_{j=1}^n \bar{a}_j x_j + \max_{\substack{S \subseteq \{1, \dots, n\} \\ |S| \leq \Gamma}} \sum_{j \in S} \hat{a}_j |x_j| \leq b \quad (8.5)$$

donde el segundo término representa el **peor caso** de que a lo sumo Γ coeficientes se desvíen al máximo.

! Interpretación de Γ

- $\Gamma = 0$: Solución nominal (sin protección contra incertidumbre). Equivalente a ignorar la incertidumbre.
- $\Gamma = n$: Protección total (todos los parámetros en su peor caso simultáneamente). Máximamente conservador.
- $0 < \Gamma < n$: Protección parcial. Bertsimas y Sim demuestran que la probabilidad de violación de la restricción decrece **exponencialmente** con Γ , lo que permite calibrar el nivel de conservadurismo de forma precisa.

En este proyecto, Γ se controla mediante el parámetro **gamma** en las políticas de incertidumbre (**blended_uncertainty**, **tail_blended_uncertainty**, etc.), que interpola entre la PD puntual y el límite superior conformal.

La gran ventaja de este framework es que la formulación robusta resultante se resuelve como un **LP** (no requiere solvers de optimización robusta especializados), con apenas n variables y n restricciones adicionales respecto al LP nominal (Bertsimas & Sim, 2004b).

8.0.4. Conjuntos de Incertidumbre de Caja (Box Uncertainty Sets)

Un **conjunto de incertidumbre de caja** es la forma más simple de conjunto de incertidumbre: un hiperrectángulo definido por límites inferiores y superiores independientes para cada parámetro incierto.

8.0.4.1. Definición Formal

Para un vector de parámetros inciertos $\mathbf{d} \in \mathbb{R}^n$, el conjunto de incertidumbre de caja es:

$$\mathcal{U}_{\text{box}} = \left\{ \mathbf{d} \in \mathbb{R}^n : d_j^{\text{low}} \leq d_j \leq d_j^{\text{high}}, \forall j = 1, \dots, n \right\} \quad (8.6)$$

Equivalentemente, usando notación de centro y radio:

$$\mathcal{U}_{\text{box}} = \left\{ \mathbf{d} : d_j = \bar{d}_j + \hat{d}_j \cdot \xi_j, \xi_j \in [-1, 1], \forall j \right\} \quad (8.7)$$

donde $\bar{d}_j = (d_j^{\text{high}} + d_j^{\text{low}})/2$ es el **centro** y $\hat{d}_j = (d_j^{\text{high}} - d_j^{\text{low}})/2$ es el **radio** de incertidumbre.

8.0.4.2. Conexión con Predicción Conformal

La innovación central de este proyecto es que los conjuntos de incertidumbre de caja se construyen **directamente a partir de los intervalos de predicción conformal**. Para cada préstamo i :

$$\text{PD}_i \in [\text{PD}_i^{\text{low}}, \text{PD}_i^{\text{high}}] \quad (8.8)$$

donde PD_i^{low} y $\text{PD}_i^{\text{high}}$ provienen del predictor conformal Mondrian con cobertura garantizada $1 - \alpha$ (ver Capítulo 7).

Esto conecta dos campos que históricamente han operado por separado:

Tabla 8.2.: Conexión entre predicción conformal y optimización robusta

Componente	Campo de origen	Aporte al pipeline
Intervalos [$\text{PD}^{\text{low}}, \text{PD}^{\text{high}}$]	Predicción conformal (ML/estadística)	Garantía de cobertura finita sin supuestos distribucionales
Conjunto $\mathcal{U}_{\text{box}}$	Optimización robusta (OR)	Protección contra peor caso dentro del conjunto
Pipeline completo	Predict-then-Optimize	Decisiones óptimas con incertidumbre cuantificada y garantizada

Implementación en el proyecto

En `src/optimization/robust_opt.py`, la función `build_box_uncertainty_set()` toma los vectores `pd_low` y `pd_high` del predictor conformal y calcula el centro y radio de cada componente del conjunto de caja. El modelo de portafolio en `src/optimization/portfolio_model.py` utiliza diferentes **políticas de incertidumbre** que interpolan entre la PD puntual y el límite superior conformal, controladas por el parámetro γ .

Johnstone & Cox (2021) formalizan esta conexión, demostrando que los intervalos conformales proveen conjuntos de incertidumbre con **garantías de cobertura marginal**, lo que otorga una fundamentación teórica rigurosa a la optimización robusta construida sobre ellos.

8.0.5. Precio de la Robustez (Price of Robustness)

Toda protección contra incertidumbre tiene un costo. El **Precio de la Robustez** (PoR) cuantifica cuánto retorno se sacrifica al adoptar una solución robusta en lugar de la solución nominal que ignora la incertidumbre.

8.0.5.1. Definición Formal

Sean z_{nom}^* y z_{rob}^* los valores óptimos de la función objetivo del problema nominal y robusto respectivamente. El precio de la robustez es:

$$\text{PoR} = \frac{z_{\text{nom}}^* - z_{\text{rob}}^*}{z_{\text{nom}}^*} \times 100 \% \quad (8.9)$$

Un PoR del 5 % significa que la solución robusta sacrifica un 5 % de retorno esperado a cambio de protección contra la incertidumbre estimada. Bertsimas & Sim (2004b) demuestran que, para su formulación con Γ , el PoR crece de forma **controlada y predecible** conforme aumenta Γ , permitiendo al tomador de decisiones elegir explícitamente su punto en la **frontera retorno-resiliencia**.

8.0.5.2. Interpretación Práctica

Tabla 8.3.: Guía interpretativa del Precio de la Robustez

PoR	Interpretación
0 %	Sin protección (solución nominal)
1–5 %	Protección moderada con sacrificio mínimo
5–15 %	Protección significativa; típica en portafolios regulados
> 15 %	Excesivamente conservador; puede indicar intervalos demasiado anchos

⚠ Umbral del proyecto

En la configuración del proyecto (`configs/optimization.yaml`), el parámetro `max_price_of_robustness_pct` establece un umbral de -15% . Si una política robusta sacrifica más del 15 % de retorno respecto al equivalente no robusto, se activa la política de *fallback* (`nonrobust_equivalent`). Este mecanismo evita que intervalos conformales excesivamente conservadores (por ejemplo, en grados de riesgo con poca calibración) produzcan portafolios subóptimos sin justificación económica.

La frontera de Pareto entre retorno y robustez se explora en el script `scripts/optimize_portfolio_tradeoff.py`, que genera el *tradeoff curve* variando el parámetro γ y registrando el PoR resultante.

8.0.6. Smart Predict, then Optimize (SPO+)

8.0.6.1. El Problema del Two-Stage Pipeline

El enfoque clásico en ML operacional sigue un pipeline de **dos etapas** desacopladas:

1. **Predict:** Entrenar un modelo ML para minimizar error de predicción (MSE, log-loss, etc.).
2. **Optimize:** Usar las predicciones como entrada para un modelo de optimización que toma decisiones.

El problema fundamental es que **minimizar el error de predicción no es equivalente a maximizar la calidad de las decisiones**. Un modelo con menor MSE no necesariamente produce mejores decisiones de portafolio, porque las predicciones que más importan para la decisión óptima no son necesariamente las que más contribuyen al MSE agregado.

💡 Ejemplo intuitivo

Supongamos dos préstamos con PD real de 0.09 y 0.11, y un umbral de aprobación en PD = 0.10.

- **Modelo A** (MSE menor): predice 0.085 y 0.115. Buen MSE, decisión correcta (rechaza el segundo).
- **Modelo B** (MSE mayor): predice 0.12 y 0.08. Peor MSE, pero **decisión incorrecta** (aprueba el segundo, rechaza el primero).

La pérdida de predicción no captura que el error de B cruza el umbral de decisión, generando una mala asignación de capital.

8.0.6.2. La Pérdida SPO+

Elmachtoub & Grigas (2022) proponen la pérdida **SPO+** (*Smart Predict, then Optimize*), que entrena el modelo de predicción directamente para optimizar la calidad de las decisiones downstream. La idea central es reemplazar la pérdida de predicción por una pérdida de **regret** (arrepentimiento decisional).

Sea $\mathbf{c}$ el vector de costos verdadero y $\hat{\mathbf{c}}$ la predicción. Sea $\mathbf{x}^*(\mathbf{c})$ la decisión óptima bajo costos verdaderos y $\mathbf{x}^*(\hat{\mathbf{c}})$ la decisión tomada con la predicción. El **regret** se define como:

$$\text{Regret}(\hat{\mathbf{c}}, \mathbf{c}) = \mathbf{c}^\top \mathbf{x}^*(\hat{\mathbf{c}}) - \mathbf{c}^\top \mathbf{x}^*(\mathbf{c}) \quad (8.10)$$

Es decir, la diferencia de costo real entre la decisión tomada con la predicción y la decisión que se habría tomado con información perfecta. El regret es siempre ≥ 0 .

8. Optimización e Investigación de Operaciones

La pérdida SPO+ es una **cota superior convexa** del regret, diseñada para ser diferenciable y tratable computacionalmente:

$$\ell_{\text{SPO+}}(\hat{\mathbf{c}}, \mathbf{c}) = -\min_{\mathbf{x} \in \mathcal{X}} (2\hat{\mathbf{c}} - \mathbf{c})^\top \mathbf{x} + 2\hat{\mathbf{c}}^\top \mathbf{x}^*(\mathbf{c}) - \mathbf{c}^\top \mathbf{x}^*(\mathbf{c}) \quad (8.11)$$

donde $\mathcal{X}$ es el conjunto factible del problema de optimización.

8.0.6.3. Propiedades de SPO+

1. **Consistencia Fisher:** Minimizar SPO+ en expectativa implica minimizar el regret verdadero.
2. **Convexidad:** $\ell_{\text{SPO+}}$ es convexa en $\hat{\mathbf{c}}$, lo que permite optimización con gradiente.
3. **Subgradiente simple:** El subgradiente respecto a $\hat{\mathbf{c}}$ es $2(\mathbf{x}_{\text{SPO}}^* - \mathbf{x}^*(\mathbf{c}))$, donde $\mathbf{x}_{\text{SPO}}^*$ es la solución del LP con costos $2\hat{\mathbf{c}} - \mathbf{c}$.
4. **Generalidad:** Funciona para cualquier problema de optimización lineal (LP, shortest path, knapsack, etc.).

8.0.6.4. Comparación: MSE vs SPO+

Tabla 8.4.: Comparación entre pérdida MSE y SPO+

Aspecto	MSE (Two-Stage)	SPO+ (Decision-Focused)
Objetivo	Minimizar error de predicción	Minimizar regret decisional
Gradiente	$2(\hat{\mathbf{c}} - \mathbf{c})$	$2(\mathbf{x}_{\text{SPO}}^* - \mathbf{x}^*(\mathbf{c}))$
Sensibilidad a la decisión	Ninguna	Total: penaliza errores que cambian la decisión óptima
Costo computacional	Bajo (sin resolver LP)	Alto (requiere resolver LP en cada forward pass)
Garantía teórica	Consistencia estadística para predicción	Consistencia Fisher para decisión óptima

8.0.6.5. Aplicación en Riesgo Crediticio

En este proyecto, SPO+ se aplica de la siguiente manera:

1. Los **costos $\mathbf{c}$** son las PD calibradas de cada préstamo (costos continuos, no binarios).
2. El **problema de optimización** es el LP de asignación de portafolio.
3. Una **red neuronal** (MLP) se entrena con SPO+ loss para predecir PDs que minimicen el regret de la asignación de portafolio.
4. El resultado se compara contra el pipeline two-stage (CatBoost PD $\rightarrow$ LP) para cuantificar la **reducción de regret**.

i Resultado empírico

El pipeline SPO+ v2 del proyecto logra una **reducción de regret del 49.1 %** respecto al two-stage baseline, con significancia estadística (Wilcoxon $p < 0.0001$). Esto demuestra que optimizar directamente la calidad de la decisión crediticia produce portafolios sustancialmente mejores que optimizar la precisión de la predicción y luego usar esas predicciones como entrada a un optimizador.

Un aspecto crítico de implementación es que SPO+ requiere costos **continuos**, no binarios. Usar labels binarios de default (0/1) produce un paisaje de pérdida plano donde el gradiente de SPO+ es casi cero. Por esto, el proyecto utiliza las PDs calibradas como costos del LP, lo que produce un paisaje de gradientes informativo.

8.0.7. El Solver HiGHS

La resolución de los problemas LP y MILP formulados en este proyecto se realiza mediante **HiGHS** (High-performance Software for Linear Optimization), un solver de código abierto desarrollado en la Universidad de Edimburgo.

8.0.7.1. Justificación de la elección

Tabla 8.5.: Comparación de solvers de optimización

Criterio	HiGHS	Gurobi	CPLEX
Licencia	MIT (código abierto)	Comercial (\$\$\$)	Comercial (\$\$\$)
Rendimiento LP	Estado del arte	Estado del arte	Estado del arte
Rendimiento MILP	Competitivo	Superior	Superior
Reproducibilidad	Total (sin licencia)	Limitada (requiere licencia)	Limitada (requiere licencia)
Integración Python	highspy, Pyomo, CVXPY	gurobipy, Pyomo	docplex, Pyomo
Uso académico	Sin restricciones	Licencia académica gratuita	Licencia académica gratuita

i Decisión de diseño

Se eligió HiGHS por tres razones: (1) **reproducibilidad total** — cualquier persona puede ejecutar el pipeline sin obtener una licencia comercial; (2) rendimiento suficiente para las instancias del proyecto (hasta 80,000 variables, resuelto en milisegundos a segundos); y (3) integración nativa con Pyomo, el framework de modelado algebraico utilizado en `src/optimization/portfolio_model.py`. Para instancias de escala industrial donde MILP con cientos de miles de variables binarias sea necesario, Gurobi o CPLEX ofrecerían tiempos

de solución menores.

En el proyecto, HiGHS se invoca a través de Pyomo con la configuración definida en `configs/optimization.yaml`: tiempo límite de 300 segundos y 16 threads de paralelismo.

8.0.8. Pipeline Integrado: Predict-then-Optimize con Incertidumbre Conformal

El pipeline completo del proyecto integra todos los conceptos presentados en esta sección en una cadena coherente:

$$\underbrace{\text{CatBoost PD}}_{\text{Predicción}} \rightarrow \underbrace{\text{Calibración}}_{\text{Platt/Isotonic}} \rightarrow \underbrace{\text{Conformal Mondrian}}_{\text{Intervalos}} \rightarrow \underbrace{[\text{PD}^{\text{low}}, \text{PD}^{\text{high}}]}_{\text{Garantía } 1-\alpha} \rightarrow \underbrace{\mathcal{U}_{\text{box}}}_{\text{Conjuntos}} \rightarrow \underbrace{\text{LP Robusto}}_{\substack{\text{HiGHS/Pyomo} \\ (8.12)}} \rightarrow \text{Porta} \quad \mathbf{x}$$

Este pipeline tiene tres propiedades que lo distinguen del enfoque estándar en credit risk analytics:

1. **Garantía de cobertura:** Los intervalos conformales tienen cobertura $\geq 1 - \alpha$ en muestra finita, sin supuestos distribucionales.
2. **Protección contra incertidumbre:** La solución robusta es factible para cualquier realización de la PD dentro del conjunto de incertidumbre.
3. **Costo controlado:** El Precio de la Robustez cuantifica explícitamente el tradeoff retorno-resiliencia, permitiendo decisiones informadas.

El enfoque SPO+ complementa este pipeline: donde el pipeline clásico (predict-then-optimize) toma las predicciones como dadas y optimiza sobre ellas, SPO+ cierra el ciclo entrenando el predictor para que produzca las predicciones que generen las mejores *decisiones*, no las mejores *predicciones*.

8.0.9. Referencias Clave

Las referencias fundamentales para los conceptos de esta sección son:

- **Bertsimas & Sim (2004b)** — *The Price of Robustness*: Introduce el framework de optimización robusta con el parámetro Γ que controla el conservadurismo, demostrando que la protección contra incertidumbre tiene un costo predecible y controlable. Formulación tratable (LP) para problemas robustos.
- **Elmachtoub & Grigas (2022)** — *Smart Predict, then Optimize*: Propone la pérdida SPO+ para entrenamiento decision-focused, demostrando consistencia Fisher y superioridad empírica sobre el pipeline two-stage desacoplado. Publicado en *Management Science*.
- **Johnstone & Cox (2021)** — *Conformal Uncertainty Sets for Robust Optimization*: Formaliza la conexión entre intervalos conformales y conjuntos de incertidumbre para optimización robusta, proporcionando la base teórica para el uso de predicción conformal en el contexto de OR.

9. Inferencia Causal

La inferencia causal es la rama de la estadística y la ciencia de datos que se ocupa de una pregunta fundamental: **¿cuál es el efecto de una intervención?** Mientras que los modelos de machine learning son extraordinariamente buenos para capturar patrones predictivos en datos observacionales, la mayoría de las decisiones de negocio en riesgo crediticio requieren entender relaciones causales, no meramente correlacionales. Esta sección presenta los fundamentos teóricos y las herramientas computacionales que permiten pasar de predicción a prescripción causal.

9.0.1. Correlación vs Causalidad

Uno de los errores más comunes en la aplicación de modelos de ML a decisiones de política crediticia es confundir correlación con causalidad. Un modelo de gradient boosting entrenado sobre datos históricos de Lending Club puede asignar alta importancia predictiva a la tasa de interés (`int_rate`) como predictor de default. Esto refleja una correlación real en los datos — préstamos con tasas más altas tienen mayor probabilidad de default. Sin embargo, la pregunta de política es distinta:

¿Aumentar la tasa de interés a un solicitante *causa* que sea más probable que entre en default?

La respuesta no es trivialmente afirmativa. La correlación observada puede deberse a al menos tres mecanismos distintos:

1. **Confusión (*confounding*)**: Prestatarios de mayor riesgo (FICO bajo, DTI alto) reciben tasas más altas *y* tienen mayor probabilidad de default. La tasa de interés no causa el default — ambos son consecuencia de variables de riesgo subyacentes.
2. **Efecto causal directo**: Una tasa más alta incrementa la carga financiera mensual, reduciendo la capacidad de pago y aumentando la probabilidad de default (*moral hazard* o *debt burden effect*).
3. **Selección adversa**: Solicitantes que aceptan tasas altas pueden tener información privada sobre su propia probabilidad de impago que no está capturada en las variables observables.

Peligro de decisiones basadas en correlación

Si un banco usa un modelo predictivo para fijar tasas de interés sin distinguir correlación de causalidad, podría *aumentar* los defaults al subir las tasas a segmentos que ya están bajo estrés financiero — exactamente lo contrario de lo que busca una política de pricing basada en riesgo. Las decisiones de política (*¿cuánto cobrar?*, *¿a quién aprobar?*, *¿qué límite asignar?*) requieren estimaciones causales, no predictivas.

Formalmente, la distinción se expresa en la notación de Pearl: la probabilidad condicional $P(Y \mid X = x)$ captura la asociación observacional (lo que hace ML), mientras que la probabilidad intervencionista $P(Y \mid \text{do}(X = x))$ captura el efecto de forzar X al valor x — eliminando la influencia de confusores.

En el contexto de este proyecto, las preguntas causales centrales son:

Tabla 9.1.: Preguntas causales centrales del proyecto de riesgo crediticio

Pregunta causal	Tratamiento (T)	Outcome (Y)	Confusores clave
¿La tasa de interés causa default?	<code>int_rate</code>	<code>default_flag</code>	FICO, DTI, grado, ingreso
¿La verificación de ingresos reduce default?	<code>verification_status</code>	<code>default_flag</code>	Ingreso, monto, grado
¿Un mayor monto aprobado causa default?	<code>loan_amnt</code>	<code>default_flag</code>	Ingreso, DTI, propósito

9.0.2. Marco de Resultados Potenciales (Rubin)

El **Marco de Resultados Potenciales** (*Potential Outcomes Framework*), formalizado por Donald Rubin y también conocido como el **modelo de Rubin** o **modelo Neyman-Rubin**, es el fundamento matemático de la inferencia causal moderna. La idea central es que cada individuo tiene *dos* resultados potenciales, pero solo observamos uno de ellos.

Para cada préstamo i , definimos:

- $T_i \in \{0, 1\}$: indicador de tratamiento (por ejemplo, $T_i = 1$ si recibe tasa alta, $T_i = 0$ si recibe tasa baja).
- $Y_i(1)$: resultado potencial si el préstamo i recibe el tratamiento ($T = 1$).
- $Y_i(0)$: resultado potencial si el préstamo i *no* recibe el tratamiento ($T = 0$).

El **efecto causal individual** (*Individual Treatment Effect*, ITE) se define como:

$$\tau_i = Y_i(1) - Y_i(0) \quad (9.1)$$

i El Problema Fundamental de la Inferencia Causal

Para cada préstamo, solo observamos *uno* de los dos resultados potenciales:

$$Y_i^{\text{obs}} = T_i \cdot Y_i(1) + (1 - T_i) \cdot Y_i(0) \quad (9.2)$$

El resultado contrafactual — lo que habría ocurrido bajo la condición alternativa — nunca es observado. Este es el **Problema Fundamental de la Inferencia Causal** (*Fundamental Problem of Causal Inference*, Holland 1986): es imposible calcular el ITE τ_i directamente porque requiere observar ambos $Y_i(1)$ y $Y_i(0)$ simultáneamente para el mismo individuo.

Para superar este problema, la inferencia causal se apoya en **supuestos de identificación** que permiten estimar efectos promedio a partir de datos observacionales:

1. **SUTVA** (*Stable Unit Treatment Value Assumption*): El resultado de un individuo no depende del tratamiento asignado a otros individuos (no interferencia), y no existen versiones múltiples ocultas del tratamiento.
2. **Ignorabilidad** (*Unconfoundedness* o *Conditional Independence*):

$$\{Y(0), Y(1)\} \perp\!\!\!\perp T \mid X \quad (9.3)$$

Dado un conjunto suficiente de covariables X , la asignación del tratamiento es independiente de los resultados potenciales. Esto significa que, condicionando en X , es como si el tratamiento se asignara aleatoriamente.

3. **Positividad** (*Overlap*):

$$0 < P(T = 1 \mid X = x) < 1 \quad \forall x \in \text{soporte}(X) \quad (9.4)$$

Todos los individuos tienen probabilidad positiva de recibir tanto el tratamiento como el control. Si ciertos perfiles *nunca* reciben una tasa alta (por ejemplo, grado A), no podemos estimar el efecto causal para ese subgrupo.

⚠ Violación de supuestos en datos de Lending Club

En datos observacionales como Lending Club, la ignorabilidad es *inverificable* — siempre puede existir un confusor no observado (por ejemplo, estabilidad laboral real, intención de pago). Los tests de refutación (Sección 9.0.8) son esenciales para evaluar la robustez de las estimaciones causales frente a estas violaciones potenciales.

9.0.3. Efecto Promedio del Tratamiento (ATE)

Dado que el ITE individual es inobservable, la inferencia causal trabaja con promedios poblacionales. El **Efecto Promedio del Tratamiento** (*Average Treatment Effect*, ATE) se define como:

$$\tau_{\text{ATE}} = \mathbb{E}[Y(1) - Y(0)] = \mathbb{E}[Y(1)] - \mathbb{E}[Y(0)] \quad (9.5)$$

El ATE responde a la pregunta: **en promedio, ¿cuánto cambia la probabilidad de default si aplicamos el tratamiento a toda la población?**

Bajo los supuestos de identificación (ignorabilidad, positividad y SUTVA), el ATE se puede estimar a partir de datos observacionales mediante la fórmula de ajuste:

$$\tau_{\text{ATE}} = \mathbb{E}_X [\mathbb{E}[Y \mid T = 1, X] - \mathbb{E}[Y \mid T = 0, X]] \quad (9.6)$$

9. Inferencia Causal

En riesgo crediticio, un ATE significativamente positivo para `int_rate` implicaría que, ajustando por todas las características observables del prestatario, una tasa más alta *causa* un incremento en la probabilidad de default. Esto tendría implicaciones directas para la política de pricing: el beneficio de cobrar más se erosiona por el incremento inducido en pérdidas.

Variantes importantes del ATE incluyen:

- **ATT** (*Average Treatment Effect on the Treated*): $\mathbb{E}[Y(1) - Y(0) \mid T = 1]$ — el efecto promedio *solo* sobre quienes recibieron el tratamiento.
- **ATC** (*Average Treatment Effect on the Control*): $\mathbb{E}[Y(1) - Y(0) \mid T = 0]$ — el efecto promedio *solo* sobre quienes no recibieron el tratamiento.

9.0.4. Efecto Condicional del Tratamiento (CATE)

El ATE es un promedio global que oculta heterogeneidad fundamental. En riesgo crediticio, es razonable esperar que el efecto de la tasa de interés sobre el default no sea uniforme:

- Para un prestatario con alto ingreso y bajo DTI, un incremento de tasa puede tener efecto insignificante (tiene margen de pago).
- Para un prestatario ya al borde de la capacidad de pago, el mismo incremento puede ser el factor que dispare el default.

El **Efecto Condicional del Tratamiento** (*Conditional Average Treatment Effect*, CATE) captura esta heterogeneidad:

$$\tau(x) = \mathbb{E}[Y(1) - Y(0) \mid X = x] \quad (9.7)$$

donde x es un vector de características del prestatario. El CATE es una *función* — no un escalar — que mapea cada perfil de riesgo a un efecto causal estimado.

i ¿Por qué el CATE es central para la optimización de portafolio?

Si el CATE $\tau(x)$ varía entre segmentos, entonces una política de pricing uniforme es subóptima. El portafolio óptimo debería:

- **Reducir tasas** para segmentos donde $\tau(x) > 0$ (la tasa causa default), recapturando valor mediante menores pérdidas.
- **Mantener o incrementar tasas** para segmentos donde $\tau(x) \approx 0$ (la tasa no afecta default), maximizando el spread.

Esta es la lógica detrás de la *policy learning* causal: usar las estimaciones de CATE para diseñar políticas personalizadas de crédito. En este proyecto, el CATE estimado se integra directamente en el optimizador de portafolio (Sección 9.0.4 para detalles de implementación).

9.0.5. Double/Debiased Machine Learning (DML)

Los métodos clásicos de inferencia causal (regresión lineal, propensity score matching) asumen formas funcionales específicas para la relación entre covariables y resultados. En presencia de datos de alta dimensionalidad con relaciones no lineales — como es típico en credit scoring — estas restricciones funcionales pueden sesgar las estimaciones causales.

Double/Debiased Machine Learning (DML), propuesto por Chernozhukov et al. (2018), resuelve este problema al permitir el uso de modelos de ML flexibles (CatBoost, Random Forest, redes neuronales) para estimar los **parámetros de nuisance** (funciones condicionales intermedias), mientras preserva la validez inferencial para el **parámetro causal de interés** θ .

9.0.5.1. Intuición del problema

Consideremos el modelo parcialmente lineal:

$$Y = \theta \cdot T + g(X) + \varepsilon \quad (9.8)$$

$$T = m(X) + \eta \quad (9.9)$$

donde $g(X) = \mathbb{E}[Y | X]$ es la función de resultado condicional (nuisance), $m(X) = \mathbb{E}[T | X]$ es el *propensity score* generalizado (nuisance), y θ es el efecto causal que queremos estimar.

Si simplemente usamos ML para estimar $\hat{g}$ y luego regresamos los residuos, obtenemos un estimador con **sesgo de regularización**: el error de aproximación en $\hat{g}$ contamina la estimación de θ .

9.0.5.2. La solución: ortogonalización y cross-fitting

DML resuelve este problema con dos ingredientes clave:

1. Neyman Orthogonality (Doble Residualización): En lugar de regresar Y sobre T ajustando por $\hat{g}$, DML residualiza *ambas* ecuaciones:

$$\tilde{Y}_i = Y_i - \hat{g}(X_i), \quad \tilde{T}_i = T_i - \hat{m}(X_i) \quad (9.10)$$

Luego estima θ por OLS sobre los residuos:

$$\hat{\theta}_{\text{DML}} = \frac{\sum_{i=1}^n \tilde{T}_i \cdot \tilde{Y}_i}{\sum_{i=1}^n \tilde{T}_i^2} \quad (9.11)$$

La residualización del tratamiento elimina la correlación espuria entre T y los confusores, haciendo que el estimador sea **robusto (Neyman-ortogonal)** a errores de primer orden en la estimación de $\hat{g}$ y $\hat{m}$.

2. Cross-fitting (partición de muestra): Para evitar el overfitting en las estimaciones de nuisance, DML divide los datos en K folds. Para cada fold k :

9. Inferencia Causal

- Estima $\hat{g}^{(-k)}$ y $\hat{m}^{(-k)}$ usando los datos *excluyendo* fold k .
- Calcula los residuos $\tilde{Y}_i, \tilde{T}_i$ para las observaciones *en* fold k .
- Combina los residuos de todos los folds para la estimación final.

Este procedimiento garantiza que las predicciones de nuisance nunca se calculan sobre los mismos datos usados para la estimación del parámetro causal.

i Propiedades teóricas de DML

Bajo condiciones de regularidad (convergencia de los modelos de nuisance a tasa $n^{-1/4}$), el estimador DML es:

- **$\sqrt{n}$ -consistente:** converge al valor real a la tasa paramétrica estándar.
- **Asintóticamente normal:** $\sqrt{n}(\hat{\theta} - \theta_0) \xrightarrow{d} \mathcal{N}(0, V)$, lo que permite construir intervalos de confianza y tests de hipótesis válidos.
- **Robusto a sesgo de regularización:** los errores de los modelos de ML (que convergen más lento que $\sqrt{n}$) no contaminan la inferencia sobre θ .

Esto es notable: se obtiene inferencia estadística clásica (p-valores, intervalos de confianza) usando modelos de ML de caja negra para los componentes de nuisance.

9.0.5.3. Extensión a efectos heterogéneos

DML se extiende naturalmente a la estimación de CATE. En lugar de un escalar θ , se estima una función $\theta(x)$ que varía con las covariables. La clase **CausalForestDML** de EconML combina el framework DML para la residualización con Causal Forests para la estimación del efecto heterogéneo.

9.0.6. Causal Forests

Los **Causal Forests**, introducidos por Athey & Wager (2019), son una adaptación de los Random Forests específicamente diseñada para estimar efectos de tratamiento heterogéneos (CATE). Mientras que un Random Forest estándar predice $\mathbb{E}[Y \mid X]$, un Causal Forest predice $\tau(x) = \mathbb{E}[Y(1) - Y(0) \mid X = x]$.

9.0.6.1. Diferencias clave con Random Forests estándar

Tabla 9.2.: Comparación entre Random Forest estándar y Causal Forest

Aspecto	Random Forest estándar	Causal Forest
Objetivo	Minimizar MSE de Y	Maximizar heterogeneidad de $\tau(x)$
Criterio de split	Reducir varianza de Y	Maximizar diferencia de efectos entre hijos

Aspecto	Random Forest estándar	Causal Forest
Honestidad	No requerida	Splitting y estimación en submuestras disjuntas
Salida	$\hat{Y}(x)$	$\hat{\tau}(x)$ con intervalos de confianza
Inferencia	Limitada	Asintóticamente normal, IC válidos

9.0.6.2. Funcionamiento

El algoritmo opera en cuatro pasos:

1. **Subsampling:** Para cada árbol, se extrae una submuestra sin reemplazo del dataset.
2. **Honest splitting:** La submuestra se divide en dos mitades:
 - **Muestra de splitting:** Se usa para determinar la estructura del árbol (dónde hacer los cortes).
 - **Muestra de estimación:** Se usa para estimar $\hat{\tau}$ dentro de cada hoja.
3. **Criterio de split causal:** En cada nodo, el split se elige para maximizar la heterogeneidad del efecto estimado entre los nodos hijos. Formalmente, se maximiza la varianza del efecto entre hojas:

$$\text{Split}^* = \arg \max_S \sum_{j \in \{\text{izq}, \text{der}\}} n_j \cdot \hat{\tau}_j^2 \quad (9.12)$$

donde $\hat{\tau}_j$ es el efecto promedio estimado en el nodo hijo j y n_j es el tamaño de ese nodo.

4. **Estimación en hoja:** Para una observación nueva con covariables x , el efecto se estima como el promedio ponderado de los efectos locales en las hojas donde x cae a través de todos los árboles del bosque:

$$\hat{\tau}(x) = \sum_{i=1}^n \alpha_i(x) \cdot (Y_i - \hat{m}(X_i)) \quad (9.13)$$

donde los pesos $\alpha_i(x)$ reflejan la frecuencia con que la observación i cae en la misma hoja que x a través del bosque.

i Honestidad y validez inferencial

La propiedad de **honestidad** (*honesty*) es lo que distingue a un Causal Forest de un Random Forest con truco. Al usar submuestras disjuntas para la estructura del árbol y para la estimación del efecto, se evita el overfitting adaptativo que invalidaría la inferencia. Esto permite obtener intervalos de confianza asintóticamente válidos para $\hat{\tau}(x)$, algo que no es posible con un Random Forest estándar.

9.0.7. DoWhy + EconML: El Stack de Software

La implementación computacional de la inferencia causal en este proyecto se basa en dos bibliotecas complementarias que reflejan los dos pasos del análisis causal: **identificación** (DoWhy) y **estimación** (EconML).

9.0.7.1. DoWhy: Identificación y refutación

DoWhy (Microsoft Research) implementa el flujo de trabajo causal de cuatro pasos:

1. **Modelar**: Especificar el grafo causal (DAG) que representa las relaciones causales entre variables. En este proyecto, el DAG incluye variables como `grade_woe`, `dti`, `annual_inc`, `fico_range_low` como confusores de la relación entre `int_rate` y `default_flag`.
2. **Identificar**: Dado el DAG, DoWhy determina automáticamente si el efecto causal es identificable y cuál es la estrategia de identificación apropiada (back-door, front-door, variable instrumental). Para nuestro DAG, la estrategia es **back-door adjustment** condicionando en los confusores observados.
3. **Estimar**: Delega la estimación al método elegido (puede ser un estimador de EconML).
4. **Refutar**: Ejecuta tests automáticos para evaluar la robustez de la estimación causal.

9.0.7.2. EconML: Estimación de efectos heterogéneos

EconML (Microsoft Research) proporciona los estimadores de CATE, siendo `CausalForestDML` el más utilizado en este proyecto. Este estimador combina:

- **DML** (Sección 9.0.5) para la residualización de nuisance parameters usando modelos de ML flexibles (CatBoost como modelo de outcome, Logistic Regression como modelo de propensity).
- **Causal Forest** (Sección 9.0.6) para la estimación no paramétrica del efecto heterogéneo sobre los residuos.

El flujo computacional es:

Datos observacionales (X , T , Y)

- DoWhy: validar DAG + identificar estrategia (back-door)
- EconML `CausalForestDML`:
 1. Cross-fit: estimar $E[Y|X]$ con CatBoost, estimar $E[T|X]$ con LogReg
 2. Residualizar: $\tilde{Y} = Y - \hat{E}[Y|X]$, $\tilde{T} = T - \hat{E}[T|X]$
 3. Causal Forest: estimar $\tau(x)$ sobre los residuos $(\tilde{Y}, \tilde{T})$
- $\hat{CATE}(x)$ para cada préstamo
- Integración en optimizador de portafolio

i Modelos de nuisance en este proyecto

La elección de modelos de nuisance afecta la calidad de la residualización:

- **Modelo de outcome** $g(X) = \mathbb{E}[Y | X]$: CatBoost (mismo framework del modelo PD, aprovechando su manejo nativo de categorías y NaN).
- **Modelo de tratamiento** $m(X) = \mathbb{E}[T | X]$: Regresión logística o Gradient Boosting, dependiendo de si el tratamiento es binario o continuo.

La convergencia de estos modelos de nuisance a tasa $n^{-1/4}$ es suficiente para garantizar la validez inferencial de DML con más de un millón de observaciones en el split de entrenamiento.

9.0.7.3. SHAP para interpretabilidad causal

Una ventaja del Causal Forest es que, al ser un ensemble de árboles, se pueden calcular valores SHAP (*SHapley Additive exPlanations*) sobre las predicciones de CATE. Esto permite responder no solo *cuánto* varía el efecto causal entre individuos, sino *qué variables* explican esa variación. Por ejemplo, si FICO score tiene alto SHAP importance para el CATE, esto indica que el efecto causal de la tasa de interés sobre el default depende fuertemente del perfil crediticio del prestatario.

9.0.8. Tests de Refutación

En un experimento aleatorizado (A/B test), la validez causal está garantizada por diseño. En datos observacionales, las estimaciones causales dependen de supuestos no verificables — particularmente la ignorabilidad (Sección 9.0.2). Los **tests de refutación** (*refutation tests*) evalúan la robustez de las estimaciones frente a violaciones de estos supuestos. No pueden *probar* que la estimación es correcta, pero si la estimación sobrevive a múltiples intentos de refutación, su credibilidad aumenta sustancialmente.

DoWhy implementa tres tests de refutación principales:

9.0.8.1. 1. Tratamiento placebo (*Placebo Treatment*)

Se reemplaza el tratamiento real por un tratamiento aleatorio (permutado) y se re-estima el efecto causal. Si el efecto original es genuinamente causal, el efecto placebo debería ser estadísticamente indistinguible de cero.

$$H_0 : \hat{\tau}_{\text{placebo}} = 0 \quad (\text{si el efecto original es causal}) \quad (9.14)$$

Interpretación: Si el efecto placebo es significativamente distinto de cero, sugiere que la estimación original está contaminada por confusión residual o correlaciones espurias en la estructura de los datos.

9.0.8.2. 2. Causa común aleatoria (*Random Common Cause*)

Se agrega una variable aleatoria (ruido puro) al conjunto de confusores y se re-estima el efecto. Si el modelo causal está correctamente especificado, agregar una variable irrelevante no debería cambiar significativamente la estimación.

$$\frac{|\hat{\tau}_{\text{original}} - \hat{\tau}_{\text{+ruido}}|}{|\hat{\tau}_{\text{original}}|} < \epsilon \quad (\text{criterio de robustez}) \quad (9.15)$$

Interpretación: Un cambio sustancial en la estimación al agregar ruido indica que el modelo es inestable y posiblemente mal especificado — los confusores controlados son insuficientes o la forma funcional es inadecuada.

9.0.8.3. 3. Subconjunto de datos (*Data Subset*)

Se re-estima el efecto causal usando subconjuntos aleatorios de los datos (típicamente 70–90 % del dataset original). Si la estimación es robusta, debería ser estable a través de diferentes subconjuntos.

$$CV_{\tau} = \frac{\text{sd}(\hat{\tau}_{\text{subsets}})}{\hat{\tau}_{\text{subsets}}} < \delta \quad (\text{criterio de estabilidad}) \quad (9.16)$$

Interpretación: Alta variabilidad entre subconjuntos sugiere que la estimación depende fuertemente de observaciones particulares y no refleja un efecto poblacional robusto.

Limitaciones de los tests de refutación

Los tests de refutación son condiciones *necesarias* pero no *suficientes* para la validez causal. Una estimación puede pasar los tres tests y aún así estar sesgada si existe un confusor no observado fuerte. En particular:

- **Placebo:** Detecta correlaciones espurias pero no confusión por variables omitidas.
- **Random common cause:** Solo evalúa sensibilidad local, no identifica el confusor faltante.
- **Data subset:** Evalúa estabilidad estadística, no validez causal.

Para datasets observacionales como Lending Club, los resultados causales deben interpretarse como **estimaciones bajo los supuestos del DAG especificado**, no como verdades causales absolutas. El análisis de sensibilidad (*sensitivity analysis*) — que evalúa cuánta confusión no observada sería necesaria para anular el efecto estimado — complementa los tests de refutación pero queda fuera del alcance de esta sección introductoria.

La Tabla 9.3 presenta un resumen de los tres tests:

Tabla 9.3.: Resumen de tests de refutación para validación de estimaciones causales

Test	Qué evalúa	Señal de alarma	Criterio de éxito
Placebo	¿El efecto es genuino o espurio?	$\hat{\tau}_{\text{placebo}} \neq 0$	p-valor > 0.05 para H_0 : efecto = 0
Random cause	¿El modelo es estable a ruido?	Cambio $> 10\%$ en $\hat{\tau}$	Diferencia relativa $< 5\%$
Data subset	¿La estimación es robusta?	Alta varianza entre subsets	CV $< 15\%$

9.0.9. Integración en el Pipeline de Riesgo Crediticio

La inferencia causal no es un ejercicio académico aislado en este proyecto — se integra directamente en el pipeline de optimización de portafolio. La cadena de valor es:

1. **Estimación:** `CausalForestDML` produce $\hat{\tau}(x_i)$ para cada préstamo i en el dataset de test.
2. **Validación:** DoWhy ejecuta tests de refutación. Solo se procede si los tres tests son satisfactorios.
3. **Propagación:** Las estimaciones CATE se cruzan con el dataset de optimización, ajustando los costos esperados de cada préstamo.
4. **Optimización:** El portafolio CATE-ajustado difiere del portafolio base porque incorpora el efecto *causal* de las condiciones de crédito sobre el default, no solo la correlación observada.

💡 Contribución del proyecto

La integración de estimaciones CATE en la optimización robusta de portafolio crediticio es una contribución original. La mayoría de la literatura de portfolio optimization en crédito usa PD predictivas (correlacionales) como input. Al usar PD causales (ajustadas por CATE), el portafolio resultante es robusto no solo a incertidumbre estadística (via predicción conformal) sino también a confusión causal. Este enfoque de *triple robustez* — conformal + causal + optimización robusta — es, hasta donde sabemos, novedoso en la literatura de riesgo crediticio.

9.0.10. Referencias Clave

Los fundamentos teóricos de esta sección se basan en los siguientes trabajos seminales:

- **Chernozhukov et al. (2018):** Formalizan el framework de Double/Debiased Machine Learning, demostrando que modelos de ML pueden usarse para nuisance parameters sin comprometer la inferencia sobre el efecto causal. Es la base teórica del estimador `CausalForestDML` utilizado en este proyecto.
- **Athey & Wager (2019):** Introducen los Causal Forests con la propiedad de honestidad, proporcionando estimaciones de CATE con intervalos de confianza asintóticamente válidos. Su trabajo extiende la teoría de Random Forests al marco de resultados potenciales.

9. Inferencia Causal

- ***Causal Inference for Banking, Finance, and Insurance (2023)***: Survey comprehensivo de aplicaciones de inferencia causal en banca, finanzas y seguros, que contextualiza nuestro enfoque dentro de la literatura emergente de ML causal en servicios financieros.

Para una discusión más detallada de la implementación y los resultados obtenidos con el dataset de Lending Club, véanse los capítulos correspondientes a la estimación de efectos causales y la optimización de portafolio CATE-ajustado.

10. Stack Tecnológico

Este capítulo documenta las librerías y herramientas utilizadas en el proyecto, junto con la **justificación** de por qué cada una fue seleccionada sobre sus alternativas. El stack completo se gestiona con uv (no pip) y las versiones están fijadas en `pyproject.toml`.

10.1. Principio de selección

Las herramientas se eligieron con tres criterios:

1. **Calidad y madurez:** Librerías con publicaciones académicas asociadas, mantenimiento activo y adopción en la comunidad.
2. **Código abierto:** Ninguna dependencia de licencias comerciales. Esto es especialmente relevante para el solver de optimización (HiGHS vs Gurobi/CPLEX).
3. **Interoperabilidad:** Todas las herramientas trabajan sobre el ecosistema pandas/numpy estándar y se integran sin adaptadores custom.

10.2. Machine Learning y Modelado

10.3. Predicción Conformal

MAPIE 1.3.0 — Cambio de API

MAPIE 1.3.0 introdujo una API completamente nueva. La clase principal es `SplitConformalRegressor` (no `MapieRegressor`). El workflow es: `fit()` → `conformalize()` → `predict_interval()`. El parámetro `confidence_level` se define en `__init__`, no `alpha` en `predict`. Usamos `prefit=True` para integrar con modelos CatBoost pre-entrenados.

10.4. Series de Tiempo y Supervivencia

10.5. Inferencia Causal

Tabla 10.1.: Librerías de Machine Learning y modelado

```

import pandas as pd

ml_stack = [
    {"Librería": "CatBoost 1.2.8", "Rol": "Modelo PD (gradient boosting)",
     "Alternativas": "XGBoost, LightGBM",
     "Justificación": "Manejo nativo de categorías y NaN, ordered boosting reduce overfitting,"},
    {"Librería": "scikit-learn 1.6.1", "Rol": "Baseline LR, calibración, métricas",
     "Alternativas": "-"},
    {"Librería": "Estándar de facto para ML en Python. Provee CalibratedClassifierCV, IsotonicRegression",
     "Justificación": "Estándar de facto para ML en Python. Provee CalibratedClassifierCV, IsotonicRegression"},
    {"Librería": "Optuna 4.7", "Rol": "HPO (320 trials CatBoost)",
     "Alternativas": "Hyperopt, Ray Tune, Optuna",
     "Justificación": "TPE sampler es state-of-the-art para HPO con presupuesto limitado, pruning"},
    {"Librería": "OptBinning 0.19+", "Rol": "WOE/IV binning",
     "Alternativas": "scorecardpy, binning manual",
     "Justificación": "Binning óptimo basado en programación matemática, soporta constraints re"},
    {"Librería": "SHAP 0.48", "Rol": "Explicabilidad (TreeExplainer)",
     "Alternativas": "LIME, ELI5",
     "Justificación": "SHAP values tienen fundamento teórico en teoría de juegos (Shapley value)"},
]

pd.DataFrame(ml_stack)

```

Tabla 10.2.: Librerías de predicción conformal

```

conformal_stack = [
    {"Librería": "MAPIE 1.3.0", "Rol": "Split Conformal, Mondrian, CQR",
     "Alternativas": "crepes, nonconformist, conformal_tights",
     "Justificación": "API moderna (SplitConformalRegressor), soporte Mondrian nativo, mantenimiento"},
    {"Librería": "crepes", "Rol": "Referencia cruzada conformal",
     "Alternativas": "-"},
    {"Librería": "Alternativa ligera para validación cruzada de resultados MAPIE"},
]

pd.DataFrame(conformal_stack)

```


Tabla 10.3.: Librerías de series de tiempo y supervivencia

```
ts_stack = [
    {"Librería": "statsforecast 2.0+", "Rol": "AutoARIMA, ETS, point forecasts",
     "Alternativas": "prophet, darts, sktime",
     "Justificación": "Implementaciones rápidas en C/Numba de modelos clásicos, API Nixtla con"},
    {"Librería": "mlforecast 0.13+", "Rol": "ML-based forecasting",
     "Alternativas": "sktime, tsfresh",
     "Justificación": "Integración nativa con statsforecast, permite features de lag/rolling c"},
    {"Librería": "hierarchicalforecast 1.0+", "Rol": "Reconciliación jerárquica",
     "Alternativas": "-",
     "Justificación": "Reconciliación coherente top-down/bottom-up/MinTrace para forecasts por"},
    {"Librería": "lifelines 0.30+", "Rol": "Cox PH, Kaplan-Meier",
     "Alternativas": "pycox, scikit-survival",
     "Justificación": "API limpia para análisis de supervivencia paramétrica y semi-paramétrica"},
    {"Librería": "scikit-survival 0.24+", "Rol": "Random Survival Forest",
     "Alternativas": "pycox, aalen-johansen",
     "Justificación": "RSF implementado sobre scikit-learn API, compatible con SHAP para expli"}
]

pd.DataFrame(ts_stack)
```

Tabla 10.4.: Librerías de inferencia causal

```
causal_stack = [
    {"Librería": "DoWhy 0.12+", "Rol": "Identificación causal y refutaciones",
     "Alternativas": "CausalNex, causalm1",
     "Justificación": "Framework de 4 pasos (model → identify → estimate → refute) con grafos c"},
    {"Librería": "EconML 0.16+", "Rol": "CausalForestDML, efectos heterogéneos",
     "Alternativas": "causalm1 (Uber), grf (R)",
     "Justificación": "Implementación de Double/Debiased ML con CausalForestDML para CATE, inte"}
]

pd.DataFrame(causal_stack)
```

Tabla 10.5.: Librerías de optimización

```

optim_stack = [
    {"Librería": "Pyomo 6.8+", "Rol": "Formulación de modelos de optimización",
     "Alternativas": "PuLP, OR-Tools, cvxpy",
     "Justificación": "Lenguaje de modelado algebraico completo, soporta LP/MILP/NLP, robust c"},
    {"Librería": "HiGHS 1.10+", "Rol": "Solver LP/MILP",
     "Alternativas": "Gurobi, CPLEX, GLPK",
     "Justificación": "Solver open-source state-of-the-art para LP/MILP. Performance comparable"},
    {"Librería": "PyEPO (torch)", "Rol": "SPO+ loss para predict-then-optimize",
     "Alternativas": "Implementación custom",
     "Justificación": "Implementación oficial de SPO+ [elmachtoub2022] con autograd para PyTor"}
]

pd.DataFrame(optim_stack)

```

10.6. Optimización

💡 ¿Por qué HiGHS y no Gurobi?

Gurobi y CPLEX son más rápidos para problemas grandes (>100K variables), pero requieren licencias comerciales costosas o licencias académicas con restricciones de uso. HiGHS logra performance comparable para nuestro tamaño de problema (~5,000 candidatos de portafolio) y es completamente open-source. Esto asegura reproducibilidad sin barreras de acceso.

10.7. MLOps y Reproducibilidad

10.8. Desarrollo y Calidad

10.9. Entrega y Visualización

10.10. GPU / Aceleración (Opcional)

⚠️ GPU no es el baseline

Las herramientas GPU son parte del *insights factory* — un carril de investigación complementario. El baseline operativo corre enteramente en CPU. Los benchmarks GPU se documentan

Tabla 10.6.: Herramientas de MLOps y reproducibilidad

```

mlops_stack = [
    {"Librería": "DVC 3.56+", "Rol": "Versionado de datos y artefactos",
     "Alternativas": "git-lfs, lakefs",
     "Justificación": "Pipeline DAG reproducible, tracking de artefactos parquet/pkl/cbm, integ"},
    {"Librería": "MLflow 3.9+", "Rol": "Tracking de experimentos",
     "Alternativas": "Weights & Biases, Neptune",
     "Justificación": "Open-source, logging local sin servidor externo, compatible con CatBoost"},
    {"Librería": "Pandera 0.22+", "Rol": "Validación de schemas de datos",
     "Alternativas": "great_expectations, pydantic",
     "Justificación": "Validación de DataFrames con decoradores, schemas tipados que documentan"},
    {"Librería": "Feast 0.59", "Rol": "Feature store",
     "Alternativas": "Hopsworks, Tecton",
     "Justificación": "Feature store open-source con DuckDB backend para serving local, Field A"},
    {"Librería": "dbt-duckdb 1.10", "Rol": "Transformaciones SQL sobre parquet",
     "Alternativas": "pandas puro, polars",
     "Justificación": "SQL semántico sobre parquet via read_parquet(), staging/marts/tests, lin"}
]

pd.DataFrame(mlops_stack)

```

en el Apéndice B.

10.11. Resumen de versiones clave

Tabla 10.10.: Versiones clave del stack

Componente	Versión	Verificable en
Python	3.12.12	<code>python --version</code>
CatBoost	1.2.8	<code>pyproject.toml</code>
MAPIE	1.3.0	<code>pyproject.toml</code>
Pyomo	6.8+	<code>pyproject.toml</code>
HiGHS	1.10+	<code>pyproject.toml</code>
Quarto	1.9.35	<code>quarto --version</code>
uv	latest	<code>uv --version</code>

Tabla 10.7.: Herramientas de desarrollo

```
dev_stack = [
    {"Librería": "uv", "Rol": "Package manager y virtual envs",
     "Alternativas": "pip, poetry, conda",
     "Justificación": "10-100x más rápido que pip, resolución determinística, lockfile, compat."},
    {"Librería": "ruff", "Rol": "Linter + formatter",
     "Alternativas": "flake8 + black + isort",
     "Justificación": "Un solo tool reemplaza tres. Reglas: E, F, W, I, UP, B, SIM, C4. 10-100x"},
    {"Librería": "pytest", "Rol": "Testing framework",
     "Alternativas": "unittest, nose2",
     "Justificación": "681 tests con --strict-markers --strict-config, fixtures para artefactos"},
    {"Librería": "pre-commit", "Rol": "Hooks de calidad pre-commit",
     "Alternativas": "husky, lefthook",
     "Justificación": "ruff lint+format, nbstripout (limpia notebooks), trailing-whitespace, cl"},
    {"Librería": "nbstripout", "Rol": "Limpieza de outputs de notebooks",
     "Alternativas": "nbconvert --clear-output",
     "Justificación": "Hook automático que evita commits con outputs de notebooks, reduce tama"},
    {"Librería": "loguru", "Rol": "Logging estructurado",
     "Alternativas": "stdlib logging",
     "Justificación": "Configuración mínima, formato coloreado, rotación de archivos, mejor DX"}
]

pd.DataFrame(dev_stack)
```

Tabla 10.8.: Herramientas de entrega

```
delivery_stack = [
    {"Librería": "Streamlit 1.42+", "Rol": "Dashboard interactivo (companion)",
     "Alternativas": "Dash, Panel, Gradio",
     "Justificación": "Prototipado rápido de dashboards analíticos, 31 páginas con st.navigati"},
    {"Librería": "Quarto 1.9.35", "Rol": "Libro técnico (este documento)",
     "Alternativas": "Jupyter Book, Sphinx, bookdown",
     "Justificación": "Soporte nativo para Python+Mermaid+LaTeX, output HTML/PDF dual, cross-r"},
    {"Librería": "FastAPI 0.115+", "Rol": "API REST (servicio opcional)",
     "Alternativas": "Flask, Django REST",
     "Justificación": "Async, tipado con Pydantic, OpenAPI automático, integración con modelos"},
    {"Librería": "matplotlib + seaborn", "Rol": "Figuras publication-quality",
     "Alternativas": "plotly (para HTML interactivo)",
     "Justificación": "Vector graphics para PDF/LaTeX, estilo APA/IEEE, reproducibles desde ar"}
]

pd.DataFrame(delivery_stack)
```

Tabla 10.9.: Librerías GPU (insights factory, no baseline operativo)

```

gpu_stack = [
    {"Librería": "RAPIDS (cuDF, cuML, cuPy)", "Rol": "Aceleración GPU para ETL, ML, Monte Carlo",
     "Alternativas": "pandas, scikit-learn, numpy",
     "Justificación": "Speedup selectivo: Monte Carlo IFRS9 (16K escenarios), HPO masivo, benchmark"},
    {"Librería": "NVIDIA cuOpt", "Rol": "Optimización combinatoria GPU",
     "Alternativas": "OR-Tools, Pyomo+HiGHS",
     "Justificación": "Exploración de formulaciones alternativas en GPU para portafolio. Resultado"}
]

pd.DataFrame(gpu_stack)

```


Parte II.

Parte II: Pipeline End-to-End

11. Visión General del Pipeline

El diseño de un pipeline de riesgo crediticio end-to-end requiere integrar múltiples disciplinas — machine learning, estadística, investigación de operaciones, regulación financiera y gobernanza de modelos — en una cadena coherente donde la salida de cada etapa alimenta la siguiente. Este capítulo presenta la arquitectura completa del pipeline, desde la ingesta del dataset crudo de Lending Club hasta la optimización robusta de portafolio, enfatizando las decisiones de diseño que garantizan reproducibilidad, ausencia de data leakage y trazabilidad de artefactos.

El pipeline sigue una adaptación del marco CRISP-DM (*Cross-Industry Standard Process for Data Mining*) extendido con componentes de optimización robusta y gobernanza regulatoria que no están contemplados en el framework original:




Figura 11.1.: Diagrama editorial del pipeline end-to-end, desde datos crudos hasta decisiones de portafolio y provisiones.

La vista Figura 11.2 aporta una segunda capa de lectura: al diagrama editorial de arquitectura le sigue la evidencia visual que ya producen los notebooks y reportes del proyecto.

11. Visión General del Pipeline



la operativa del pipeline renderizada desde notebooks del proyecto, con foco en outputs, métricas y artefactos consumidos por el libro

La arquitectura se implementa en tres capas de software:

Tabla 11.1.: Capas de software del pipeline

Capa	Contenido	Ubicación
Módulos fuente	Funciones reutilizables, clases, schemas	<code>src/data/</code> , <code>src/features/</code> , <code>src/models/</code> , <code>src/optimization/</code> , <code>src/evaluation/</code>
Scripts ejecutables	Orquestación del pipeline, cada script es un paso atómico	<code>scripts/</code> (15 scripts core)
Configuración	Hiperparámetros, políticas, umbrales	<code>configs/*.yaml</code>

i Principio de diseño: código fuente vs. scripts

Los módulos en `src/` contienen la lógica reutilizable (funciones puras, clases con estado). Los scripts en `scripts/` son la capa de orquestación que invoca funciones de `src/`, lee configuraciones de `configs/`, y persiste artefactos en `data/processed/` y `models/`. Los notebooks en `notebooks/` llaman funciones de `src/` — nunca duplican lógica. Esta separación garantiza que todo cambio se propaga automáticamente a notebooks, scripts y Streamlit.

11.1. Navegación del capítulo

12. Ingesta de Datos y Linaje

12.0.1. El Dataset de Lending Club

El proyecto utiliza el dataset **Lending Club Loan Data 2007–2020Q3**, disponible públicamente en Kaggle. Lending Club fue la plataforma de préstamos peer-to-peer más grande de Estados Unidos hasta su transición a banca comercial en 2020. El dataset contiene información de todos los préstamos originados en la plataforma durante 13 años, incluyendo características del solicitante, condiciones del préstamo y resultado final (pagado vs. default).

💡 ¿Por qué Lending Club?

El dataset de Lending Club es el estándar de facto en la investigación de credit scoring con ML. Más de 200 papers publicados lo utilizan como benchmark, lo que permite comparar directamente nuestras métricas contra la literatura. Además, su tamaño (millones de préstamos) y riqueza de variables (142 columnas) lo hacen ideal para técnicas avanzadas como predicción conformal Mondrian, que requiere subgrupos suficientemente grandes para calibración por grado.

12.0.2. Pipeline de Limpieza

La ingesta de datos sigue un proceso de tres pasos implementado en `src/data/make_dataset.py`:

Paso 1 — Carga del CSV crudo: El archivo `Loan_status_2007-2020Q3.csv` se carga con `pandas.read_csv()`. Las columnas con formatos mixtos (`int_rate` como string con %, `term` como " 36 months") se parsean a tipos numéricos.

Paso 2 — Filtrado a préstamos resueltos: Solo se retienen préstamos con outcome definitivo:

- **Fully Paid:** El prestatario pagó la totalidad del principal e intereses.
- **Charged Off / Default:** El prestatario dejó de pagar y Lending Club declaró la pérdida.

Se excluyen préstamos en estados intermedios (*Current*, *Late*, *In Grace Period*) porque no tienen un outcome binario definido. Esto reduce el dataset de ~2.93M a ~1.86M filas.

Paso 3 — Creación de la variable objetivo: Se crea `default_flag` como variable binaria:

$$\text{default_flag}_i = \begin{cases} 1 & \text{si } \text{loan_status} \in \{\text{Charged Off, Default}\} \\ 0 & \text{si } \text{loan_status} = \text{Fully Paid} \end{cases} \quad (12.1)$$

Tabla 12.1.: Resumen del dataset crudo de Lending Club

```
import pandas as pd

dataset_info = [
    {"Atributo": "Fuente", "Valor": "Kaggle (ethon0426/lending-club-20072020q1)"},
    {"Atributo": "Período", "Valor": "Junio 2007 - Septiembre 2020"},
    {"Atributo": "Filas (raw)", "Valor": "~2,930,000"},
    {"Atributo": "Columnas (raw)", "Valor": "142"},
    {"Atributo": "Tipo de préstamo", "Valor": "Personal, no garantizado (unsecured)"},
    {"Atributo": "Montos", "Valor": "\\$1,000 - \\$40,000"},
    {"Atributo": "Plazos", "Valor": "36 o 60 meses"},
    {"Atributo": "Grados de riesgo", "Valor": "A (bajo) a G (alto), con sub-grados (A1-G5)"},
]

pd.DataFrame(dataset_info)
```

12.0.3. Remoción de Data Leakage

El data leakage es el error metodológico más grave en credit scoring: usar información del futuro para predecir el pasado. En Lending Club, múltiples variables contienen información que **solo está disponible después de que el préstamo se ha resuelto** — usarlas como features produciría un modelo aparentemente excelente ($AUC > 0.95$) pero completamente inútil en producción.

El pipeline remueve **35 columnas** con leakage confirmado, organizadas en cinco categorías:

⚠ La trampa del leakage sutil

Algunas variables parecen disponibles al momento de originación pero en realidad son snapshots actualizados periódicamente. Por ejemplo, `revol_util` (utilización revolving) se actualiza mensualmente por el buró de crédito. La versión en el dataset podría ser la del momento de descarga (2020), no la del momento de originación. En este proyecto usamos `revol_util` como feature porque refleja el estado crediticio cercano a la originación en la mayoría de los registros, pero esta limitación debe tenerse en cuenta al interpretar los resultados.

12.0.4. Construcción de LGD

Antes de eliminar las columnas de leakage, el pipeline calcula la **Loss Given Default** (LGD) realizada para préstamos en default:

$$LGD_i = 1 - \frac{\text{total_rec_prncp}_i + \text{recoveries}_i - \text{collection_recovery_fee}_i}{\text{exposure}_i} \quad (12.2)$$

Tabla 12.2.: Variables removidas por data leakage (35 columnas)

```
leakage = [
    {"Categoría": "Pagos recibidos", "Variables": "total_pymnt, total_pymnt_inv, total_rec_prnc",
     "Razón": "Solo se conocen después de recibir pagos"},
    {"Categoría": "Recuperaciones", "Variables": "recoveries, collection_recovery_fee",
     "Razón": "Solo existen post-default"},
    {"Categoría": "Saldo pendiente", "Variables": "out_prncp, out_prncp_inv, funded_amnt, funded_amnt_inv",
     "Razón": "Reflejan estado del préstamo en el futuro"},
    {"Categoría": "Último pago", "Variables": "last_pymnt_d, last_pymnt_amnt, last_credit_pull",
     "Razón": "Información temporal futura"},
    {"Categoría": "Hardship/Settlement", "Variables": "hardship_flag/type/reason/status/amount",
     "Razón": "Programas post-originación aplicados a préstamos en dificultad"},
    {"Categoría": "Crédito agregado", "Variables": "total_bal_il, il_util, max_bal_bc, all_util",
     "Razón": "Snapshots de buró post-originación que reflejan comportamiento futuro"},
]

pd.DataFrame(leakage)
```

donde $exposure_i$ es el monto financiado (`funded_amnt` o `loan_amnt`). Los valores se truncan a $[0, 1]$ y se asigna $LGD = 0$ para préstamos no-default. La columna resultante se preserva en el dataset limpio como variable objetivo para el modelado de LGD downstream.

12.0.5. Tres Datasets Analíticos

A partir del dataset limpio, `src/data/build_datasets.py` construye tres datasets analíticos especializados:

El dataset `loan_master` es el input principal del pipeline. El `time_series` alimenta los modelos de forecasting jerárquico (AutoARIMA, ETS, ML-based). El `ead_dataset` es un subconjunto de préstamos defaulteados para estimar la exposición al momento del default.

12.0.6. Linaje de Datos

El linaje completo desde el CSV crudo hasta los artefactos finales se gestiona con **DVC** (Data Version Control), que mantiene un DAG reproducible de dependencias:

```
data/raw/Loan_status_2007-2020Q3.csv      (descarga manual Kaggle)
→ src/data/make_dataset.py
→ data/interim/lending_club_cleaned.parquet
  → src/data/prepare_dataset.py
  → data/processed/train.parquet
  → data/processed/calibration.parquet
  → data/processed/test.parquet
```

Tabla 12.3.: Datasets analíticos derivados del dataset limpio

```

datasets = [
    {"Dataset": "loan_master.parquet", "Granularidad": "Un registro por préstamo",
     "Uso": "Modelos PD, LGD, supervivencia, conformal, portafolio",
     "Columnas clave": "42 features + default_flag + lgd + issue_d + grade"},
    {"Dataset": "time_series.parquet", "Granularidad": "Un registro por mes (118 meses)",
     "Uso": "Forecasting con StatsForecast/MLForecast, intervalos TS→ECL",
     "Columnas clave": "unique_id, ds, y (default_rate), loan_count, volume"},
    {"Dataset": "ead_dataset.parquet", "Granularidad": "Solo préstamos en default",
     "Uso": "Modelado de EAD (Exposure at Default)",
     "Columnas clave": "Features de originación + saldo al momento del default"},
]

pd.DataFrame(datasets)

```

```

→ src/data/build_datasets.py + src/features/feature_engineering.py
→ data/processed/loan_master.parquet
→ data/processed/time_series.parquet
→ data/processed/ead_dataset.parquet

```

Cada transición es un paso de DVC con inputs y outputs explícitos. Esto permite reconstruir cualquier artefacto desde el CSV crudo ejecutando `dvc repro`, y verificar que dos ejecuciones producen outputs idénticos bit a bit.

i Versionado de artefactos

Los artefactos binarios (parquet, pkl, cbm) se almacenan fuera de Git y se versionan con DVC. Los archivos `.dvc` en el repositorio Git son punteros a los artefactos reales. Esto permite que el repositorio Git sea ligero (~50 MB) mientras los artefactos suman varios GB.

13. Estrategia de Splitting Temporal

13.0.1. ¿Por qué Out-of-Time y no Random Split?

En la práctica bancaria, un modelo de PD se entrena con datos históricos y se aplica a solicitantes futuros. La evaluación relevante es: **¿qué tan bien predice el modelo sobre datos de un período que no vio durante el entrenamiento?** Un split aleatorio mezcla préstamos de todos los períodos en train y test, permitiendo que el modelo “vea” el futuro — por ejemplo, patrones de 2019 que informan predicciones sobre préstamos de 2018.

El **split Out-of-Time (OOT)** replica el escenario de producción: el modelo se entrena con el pasado y se evalúa exclusivamente con el futuro.

 Random split infla el AUC

Experimentos internos muestran que un random split produce AUC ~0.04 puntos más alto que el split OOT equivalente para el mismo modelo CatBoost. Esta inflación no se traduce en rendimiento real y da una falsa sensación de seguridad. El split OOT es la única evaluación metodológicamente válida para un modelo de credit scoring que será desplegado en producción.

13.0.2. Diseño del Split Temporal

El split se implementa en `src/data/prepare_dataset.py` con una fecha de corte en **enero 2018**:

13.0.3. Justificación de las Fechas de Corte

La elección de enero 2018 como fecha de corte no es arbitraria — responde a tres criterios:

1. Representatividad del período de test: El período 2018–2020 incluye condiciones económicas diversas: expansión económica (2018–2019) y el inicio de la crisis COVID-19 (2020Q1–Q3). Esto evalúa la robustez del modelo bajo cambio de régimen (*concept drift*).

2. Tamaño suficiente para calibración conformal: El set de calibración (237,584 préstamos) es grande comparado con el requisito mínimo para predicción conformal. El error de muestra finita es $\frac{1}{n+1} \approx 4.2 \times 10^{-6}$, haciendo la garantía de cobertura prácticamente exacta (ver Sección 7.0.3.2).

3. Consistencia con la práctica bancaria: Los modelos de PD se recalibran típicamente cada 12–24 meses. Tener un test set de ~33 meses simula un ciclo de vida realista del modelo antes de su revisión.

Tabla 13.1.: Splits temporales Out-of-Time del proyecto

```
import pandas as pd

splits = [
    {"Split": "Train", "Período": "Jun 2007 - Mar 2017", "Préstamos": "1,346,311",
     "Default Rate": "18.52%", "Rol": "Entrenamiento del modelo PD (CatBoost + LR)"},
    {"Split": "Calibración", "Período": "Mar 2017 - Dic 2017", "Préstamos": "237,584",
     "Default Rate": "22.20%", "Rol": "Scores conformales (MAPIE), calibración de probabilidad"},
    {"Split": "Test (OOT)", "Período": "Ene 2018 - Sep 2020", "Préstamos": "276,869",
     "Default Rate": "21.98%", "Rol": "Evaluación final, backtesting, portafolio, IFRS9"},
]

pd.DataFrame(splits)
```

13.0.4. El Rol Dual del Set de Calibración

El set de calibración cumple **dos funciones** independientes en el pipeline:

Tabla 13.2.: Funciones del set de calibración

Función	Método	Input	Output
Calibración de probabilidades	Venn-Abers / Platt / Isotonic	Scores CatBoost + labels	Calibrador persistido (.pkl)
Conformización	MAPIE SplitConformalRegressor	PDs calibradas + labels	Cuantiles conformales por grupo

Estas dos funciones se ejecutan secuencialmente — primero se ajusta el calibrador sobre el set de calibración, y luego se calculan los scores conformales usando las predicciones calibradas sobre el **mismo** set de calibración.

i ¿Reutilizar el set de calibración para ambas funciones?

Usar el mismo set para calibración de probabilidades y para conformización introduce una dependencia que, en teoría, podría afectar la garantía de cobertura conformal. En la práctica, con $n = 237,584$ observaciones, el efecto es negligible y la cobertura empírica (92.57 % al nivel 90 %) confirma que la garantía se mantiene holgadamente. La alternativa — dividir el set de calibración en dos — reduciría el tamaño de ambos subsets sin beneficio práctico medible.

13.0.5. Extracción Temporal del Set de Calibración

A diferencia de una extracción aleatoria, el set de calibración se extrae del **final** del período de entrenamiento (los últimos meses antes del corte OOT):



Implicación para el lector

Todas las métricas reportadas en este libro — AUC, Brier, cobertura conformal, ECL, retorno de portafolio — se calculan **exclusivamente** sobre el set de test OOT (2018–2020). Ninguna métrica se reporta sobre datos de entrenamiento o validación. Esto garantiza que los números reflejan rendimiento genuino en un escenario prospectivo, no sobreajuste al pasado.

14. Ingeniería de Features

La ingeniería de features es la etapa del pipeline que transforma las variables crudas del dataset en representaciones optimizadas para el modelado predictivo. En credit scoring, esta transformación es particularmente crítica porque las variables financieras tienen distribuciones altamente sesgadas, relaciones no lineales con el default, y valores faltantes informativos que requieren tratamiento especializado.

El pipeline de features de este proyecto opera en tres etapas sucesivas:



(a) Ejemplos de binning WOE óptimo para variables top del m

(a) Ranking IV de variables candidatas para el pipeline de feature engineering.

Tabla 14.1.: Etapas del pipeline de features

Etapas	Input	Output	Herramienta
WOE/IV binning	Variables categóricas (grade, purpose, home_ownership)	Variables <code>_woe</code> (numéricas, monótonas)	OptBinning (solver CP)
Derivación	Variables numéricas y WOE	Ratios, logs, flags, buckets, interacciones	<code>feature_engineering.py</code>

14. Ingeniería de Features

Etapa	Input	Output	Herramienta
Contrato	Todas las features candidatas	44 features canónicas validadas	<code>pd_model_contract.json</code> + Pandera

15. WOE, IV y OptBinning

15.0.1. Motivación del Encoding WOE

Las variables categóricas en credit scoring — como el grado de riesgo, el propósito del préstamo o el tipo de vivienda — no pueden usarse directamente en modelos lineales ni en algunos modelos de ensemble. El **Weight of Evidence** (WOE) es la transformación estándar en la industria bancaria porque produce una codificación numérica con propiedades deseables:

1. **Monotonicidad:** La relación entre la variable WOE y el log-odds de default es lineal por construcción, lo que facilita la interpretación y la validación regulatoria.
2. **Poder predictivo cuantificable:** El **Information Value** (IV) asociado mide directamente cuánta información aporta cada variable para discriminar defaults de no-defaults (ver Capítulo 6 para las fórmulas).
3. **Tratamiento natural de categorías raras:** El binning agrupa categorías con pocos casos, evitando estimaciones inestables.

WOE vs. One-Hot Encoding vs. Target Encoding

- **One-Hot:** Crea $k - 1$ columnas binarias para k categorías. Explota la dimensionalidad para variables con muchas categorías (Lending Club tiene 35 sub-grados).
- **Target Encoding:** Reemplaza categorías por la media del target. Sufre de **data leakage** si no se implementa con regularización cuidadosa.
- **WOE:** Reemplaza categorías por el log-odds ratio, calculado sobre bins óptimos. Es el estándar regulatorio porque produce una transformación interpretable, monótona y sin leakage cuando se calcula solo sobre el set de entrenamiento.

CatBoost maneja categorías nativamente sin necesidad de WOE, pero las variables WOE se incluyen igualmente porque: (a) son necesarias para el baseline de regresión logística, (b) sirven como features adicionales para CatBoost, y (c) se usan como confusores en la estimación causal.

15.0.2. OptBinning: Binning Óptimo por Programación Matemática

El cálculo de WOE requiere primero agrupar los valores de la variable en **bins** (intervalos para numéricas, grupos para categóricas). La calidad de los bins determina la calidad del WOE resultante. Los enfoques tradicionales (equal-width, equal-frequency, chi-squared merging) son heurísticos y no garantizan optimalidad.

OptBinning resuelve el problema de binning como un programa de optimización con restricciones (constraint programming, solver `cp`), garantizando bins que maximizan el IV sujeto a restricciones regulatorias:

Tabla 15.1.: Variables transformadas con WOE encoding

```
import pandas as pd

woe_vars = [
    {"Variable original": "grade", "Variable WOE": "grade_woe",
     "Categorías": "A, B, C, D, E, F, G (7 grados)",
     "Uso downstream": "Confusor causal, partición Mondrian, IFRS9 staging"},
    {"Variable original": "purpose", "Variable WOE": "purpose_woe",
     "Categorías": "debt_consolidation, credit_card, home_improvement, etc. (14 categorías)",
     "Uso downstream": "Confusor causal, feature PD"},
    {"Variable original": "home_ownership", "Variable WOE": "home_ownership_woe",
     "Categorías": "MORTGAGE, RENT, OWN, OTHER (4 categorías)",
     "Uso downstream": "Confusor causal, feature PD"},
]

pd.DataFrame(woe_vars)
```

- **Monotonía:** El WOE debe ser monótono creciente o decreciente a través de los bins.
- **Número máximo de bins:** Típicamente 5–10 para interpretabilidad.
- **Tamaño mínimo de bin:** Cada bin debe contener al menos un porcentaje mínimo de observaciones.

La implementación en `src/features/feature_engineering.py` utiliza OptBinning con caching:

```
from optbinning import OptimalBinning

optb = OptimalBinning(
    name=feature,
    dtype="numerical" | "categorical",
    solver="cp", # constraint programming
)
optb.fit(X_train[feature], y_train)
woe_values = optb.transform(X[feature], metric="woe")
```

Los objetos OptBinning ajustados se persisten en `models/woe_optbinning_{feature}.pkl` para reutilización en inferencia.

15.0.3. Variables WOE del Proyecto

El proyecto calcula WOE para tres variables categóricas clave:

15.0.4. Ranking por Information Value

El IV de cada variable se calcula como subproducto del binning óptimo y sirve como criterio de selección de features. La interpretación estándar (ver Tabla 6.1) guía la decisión de qué variables retener:

Regla práctica de IV

Variables con $IV > 0.50$ son sospechosas de contener leakage — su poder predictivo es “demasiado bueno para ser verdad”. En el pipeline de limpieza (Sección 12.0.3), las 35 columnas de leakage fueron removidas *antes* del cálculo de WOE, por lo que las variables restantes tienen IV en rangos plausibles. Las variables WOE de grade, purpose y home_ownership tienen IV típicamente en el rango 0.10–0.40, indicando poder predictivo medio a fuerte.

El IV también se usa como criterio de ordenamiento en los notebooks de análisis exploratorio (NB02), donde las variables se rankean por IV descendente para identificar las más informativas antes de la selección final de features.

16. Features Derivadas: Ratios, Flags e Interacciones

16.0.1. Filosofía de Diseño

Las variables crudas del dataset de Lending Club capturan valores absolutos (monto del préstamo, ingreso anual, saldo revolving), pero las decisiones de crédito se basan en **proporciones relativas**. Un préstamo de \$20,000 tiene riesgo muy diferente para un prestatario con \$50,000 de ingreso anual (ratio 0.40) que para uno con \$200,000 (ratio 0.10). Las features derivadas capturan estas relaciones relativas que son más informativas para el modelado.

El pipeline de derivación en `src/features/feature_engineering.py` crea cuatro tipos de features:

16.0.2. Ratios Financieros

16.0.3. Transformaciones Logarítmicas

Las variables financieras tienen distribuciones fuertemente sesgadas a la derecha (muchos prestatarios con ingresos modestos, pocos con ingresos muy altos). Las transformaciones logarítmicas estabilizan la varianza y reducen la influencia de valores extremos:

Tabla 16.2.: Transformaciones logarítmicas

Feature	Fórmula	Justificación
<code>log_annual_inc</code>	$\log(1 + \text{annual_inc})$	Ingreso tiene cola derecha pesada
<code>log_revol_bal</code>	$\log(1 + \text{revol_bal})$	Saldo revolving varía de \$0 a > \$100K

El +1 evita el $\log(0)$ para prestatarios sin saldo revolving.

16.0.4. Flags Binarias

Las flags capturan la presencia o ausencia de señales de riesgo discretas:

Tabla 16.1.: Ratios financieros derivados

```
import pandas as pd

ratios = [
    {"Feature": "loan_to_income", "Fórmula": "loan_amnt / annual_inc",
     "Interpretación": "Carga del préstamo relativa al ingreso. Valores > 0.50 indican alto ap"},
    {"Feature": "installment_burden", "Fórmula": "installment / (annual_inc / 12)",
     "Interpretación": "Cuota mensual como fracción del ingreso mensual"},
    {"Feature": "rev_utilization", "Fórmula": "revol_util / 100",
     "Interpretación": "Utilización de líneas revolving (0-1). Valores > 0.80 son señal de est"},
    {"Feature": "revol_bal_to_income", "Fórmula": "revol_bal / annual_inc",
     "Interpretación": "Deuda revolving relativa al ingreso"},
    {"Feature": "open_acc_ratio", "Fórmula": "open_acc / total_acc",
     "Interpretación": "Proporción de cuentas activas. Valores altos indican búsqueda activa d"},
    {"Feature": "il_ratio", "Fórmula": "Ratio de deuda installment sobre total",
     "Interpretación": "Concentración en deuda de cuotas fijas vs. revolving"},
    {"Feature": "high_util_pct", "Fórmula": "Porcentaje de líneas con utilización > 80%",
     "Interpretación": "Diversificación del estrés crediticio entre líneas"},
]

pd.DataFrame(ratios)
```

Tabla 16.3.: Features binarias (flags) de señal de riesgo

```
flags = [
    {"Feature": "has_delinq_2yrs", "Condición": "delinq_2yrs > 0",
     "Señal": "Morosidad reciente en los últimos 2 años"},
    {"Feature": "has_pub_rec", "Condición": "pub_rec > 0",
     "Señal": "Registro público derogatorio (quiebra, juicio)"},
    {"Feature": "has_bankruptcy", "Condición": "pub_rec_bankruptcies > 0",
     "Señal": "Quiebra personal previa"},
    {"Feature": "has_recent_inq", "Condición": "inq_last_6mths > 0",
     "Señal": "Consulta de crédito en últimos 6 meses (búsqueda activa)"},
    {"Feature": "has_mortgage", "Condición": "mort_acc > 0",
     "Señal": "Tiene hipoteca (indicador de estabilidad financiera)"},
    {"Feature": "many_recent_opens", "Condición": "open_acc > umbral",
     "Señal": "Muchas cuentas abiertas recientemente"},
    {"Feature": "recent_chargeoff", "Condición": "chargeoff_within_12_mths > 0",
     "Señal": "Pérdida crediticia reciente (12 meses)"},
    {"Feature": "early_delinq", "Condición": "delinq_2yrs > 0",
     "Señal": "Historial temprano de morosidad"},
]

pd.DataFrame(flags)
```

Tabla 16.4.: Features temporales derivadas

```
temporal = [
    {"Feature": "credit_history_months", "Fórmula": "(issue_d - earliest_cr_line).days / 30",
     "Interpretación": "Antigüedad del historial crediticio en meses"},
    {"Feature": "credit_age_years", "Fórmula": "credit_history_months / 12",
     "Interpretación": "Versión en años para interpretabilidad"},
    {"Feature": "fico_score", "Fórmula": "(fico_range_low + fico_range_high) / 2",
     "Interpretación": "Punto medio del rango FICO reportado"},
    {"Feature": "delinq_severity", "Fórmula": "Combinación de morosidades por tipo",
     "Interpretación": "Índice compuesto de severidad de morosidad"},
    {"Feature": "delinq_recency", "Fórmula": "Inverso de meses desde última morosidad",
     "Interpretación": "Más alto = morosidad más reciente"},
]

pd.DataFrame(temporal)
```

i Flags vs. variables continuas

Las flags pueden parecer redundantes con las variables continuas subyacentes (por ejemplo, `has_delinq_2yrs` vs. `delinq_2yrs`). Sin embargo, para modelos lineales como la regresión logística, la flag captura el *salto discreto* en riesgo entre “cero delinuencias” y “al menos una”, que es la discontinuidad más informativa. CatBoost puede descubrir esta discontinuidad automáticamente, pero incluir la flag explícitamente facilita la interpretabilidad y la consistencia entre modelos.

16.0.5. Features Temporales

16.0.6. Buckets e Interacciones

Las variables de **bucket** discretizan continuas en categorías interpretables:

- `int_rate_bucket`: very_low (0–8%), low (8–12%), medium (12–16%), high (16–20%), very_high (>20%)
- `dti_bucket`: low (0–10), moderate (10–20), high (20–30), very_high (30–40), extreme (>40)
- `fico_bucket`: Discretización del score FICO en bandas

Las **interacciones** capturan efectos multiplicativos:

Tabla 16.5.: Features de interacción

Feature	Componentes	Intuición
<code>int_rate_bucket__grade</code>	<code>int_rate_bucket</code> $\times$ <code>grade</code>	Captura si la tasa es alta <i>para su grado</i>
<code>loan_to_income_sq</code>	<code>loan_to_income</code> ²	Efecto no lineal convexo del apalancamiento
<code>fico_x_dti</code>	<code>fico_score</code> $\times$ <code>dti</code>	Interacción entre calidad crediticia y carga de deuda

💡 ¿Son necesarias las interacciones para CatBoost?

CatBoost y otros modelos de ensemble basados en árboles descubren interacciones automáticamente durante el entrenamiento. Sin embargo, proporcionar interacciones explícitas tiene dos beneficios: (1) facilita la interpretabilidad vía SHAP (la importancia de `fico_x_dti` se lee directamente), y (2) beneficia al modelo de regresión logística baseline que no captura interacciones automáticamente.

17. Contrato de Features y Validación

17.0.1. El Concepto de Contrato Canónico

En un pipeline de ML con múltiples etapas (features → modelo → calibración → conformal → optimización), la consistencia de features entre etapas es crítica. Si el modelo se entrena con 44 features en cierto orden y la inferencia recibe 43 en orden diferente, los resultados son silenciosamente incorrectos — no hay error de runtime, solo predicciones degradadas que solo se detectan cuando se monitorearan métricas en producción.

El **contrato canónico de features** (`models/pd_model_contract.json`) resuelve este problema documentando la interfaz exacta del modelo:

17.0.2. Estructura del Contrato

El contrato JSON contiene cuatro secciones:

1. Lista ordenada de features (`feature_names`): Las 44 features exactas que el modelo espera, en el orden exacto en que fueron presentadas durante el entrenamiento. Cualquier discrepancia en nombres o en orden invalida las predicciones.

2. Features categóricas (`categorical_features`): Las 9 features que CatBoost trata como categorías nativas:

CatBoost aplica target encoding con ordered boosting a estas features internamente. No requieren one-hot encoding ni WOE — el modelo las consume en su formato original (strings o categorías pandas).

3. Shapes de los splits (`split_shapes`): Dimensiones de train, calibración y test al momento del entrenamiento, para verificar que los datasets no han cambiado.

4. Features faltantes por split (`split_missing_features`): Listas vacías si todos los splits contienen todas las features del contrato. Si algún split tiene features faltantes, esta sección lo documenta explícitamente.

17.0.3. Pandera: Validación de Schemas en Runtime

El contrato JSON es una especificación estática. Para validación dinámica en tiempo de ejecución, el pipeline usa **Pandera** (`src/features/schemas.py`) con schemas tipados para cada dataset analítico:

El `prediction_schema` incluye una validación crítica para predicción conformal: la relación de orden `pd_low` `pd_point` `pd_high` se verifica con checks de DataFrame que cruzan columnas.

Tabla 17.1.: Resumen del contrato canónico de features

```

import sys
from pathlib import Path

sys.path.insert(0, str(Path.cwd().parent if Path.cwd().name == "book" else Path.cwd()))
from book._helpers.load_artifacts import try_load_json

import pandas as pd

contract = try_load_json("pd_model_contract", directory="models", default={})

contract_summary = [
    {"Atributo": "Features totales", "Valor": str(contract.get("n_features", "N/A"))},
    {"Atributo": "Features categóricas", "Valor": str(len(contract.get("categorical_features",
    {"Atributo": "Features numéricas", "Valor": str(contract.get("n_features", 0) - len(contra
    {"Atributo": "Modelo canónico", "Valor": contract.get("model_path", "N/A")},
    {"Atributo": "Calibrador", "Valor": contract.get("calibrator_path", "N/A")},
]

pd.DataFrame(contract_summary)

```

Tabla 17.2.: Features categóricas del contrato (CatBoost nativo)

```

cat_features = contract.get("categorical_features", [])
cat_df = pd.DataFrame({"Feature categórica": cat_features, "#": range(1, len(cat_features) + 1)
cat_df

```

Tabla 17.3.: Schemas Pandera para validación de datos

```

schemas = [
    {"Schema": "loan_master_schema", "Dataset": "loan_master.parquet",
     "Validaciones clave": "loan_amnt > 0, default_flag {0,1}, int_rate [0,100], dti [0,99]"},
    {"Schema": "time_series_schema", "Dataset": "time_series.parquet",
     "Validaciones clave": "ds es datetime, y [0,1] (default_rate), loan_count > 0"},
    {"Schema": "ead_schema", "Dataset": "ead_dataset.parquet",
     "Validaciones clave": "default_flag = 1 (solo defaults), loan_amnt > 0"},
    {"Schema": "prediction_schema", "Dataset": "Predicciones PD",
     "Validaciones clave": "pd_low pd_point pd_high, todos en [0,1]"},
]

pd.DataFrame(schemas)

```

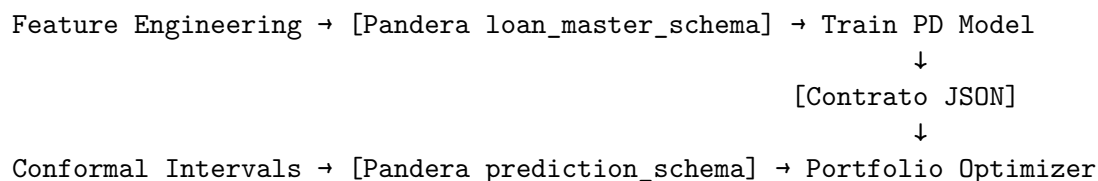

Si un intervalo conformal tiene el límite inferior por encima del punto estimado, el schema falla y detiene el pipeline.

Validación estricta vs. tolerante

Los schemas usan `strict=False`, lo que permite columnas adicionales no especificadas en el schema. Esto es deliberado: a medida que el pipeline evoluciona, nuevas features pueden agregarse sin romper las validaciones existentes. Solo las columnas críticas se validan estrictamente; el resto se ignora. Si se requiriera validación estricta (no permitir columnas extra), se cambiaría a `strict=True`.

17.0.4. Flujo de Validación

La validación se integra en el pipeline como un *gate* entre etapas:



Si una validación falla, el pipeline se detiene con un error descriptivo que indica qué columna, qué regla y qué valores violaron el schema. Esto es preferible a dejar que un error de datos se propague silenciosamente hasta producir predicciones incorrectas o portafolios subóptimos.



Manejo de NaN

El contrato permite NaN en la mayoría de features numéricas (`nullable=True`) porque CatBoost trata los valores faltantes como un valor informativo adicional, asignándolos a la rama óptima de cada split. Sin embargo, `loan_amnt` y `default_flag` son no-nullable — un valor faltante en estas columnas indica un error de datos que debe corregirse antes de proceder. Para la regresión logística baseline, los NaN se reemplazan con `fillna(0)` como estrategia simple. Esta asimetría en el tratamiento de NaN es una de las ventajas de CatBoost sobre modelos lineales para datos financieros con missing values informativos.

18. Modelado de PD y Calibración

El modelo de Probabilidad de Default (PD) es el corazón predictivo del pipeline. Este capítulo documenta la estrategia completa de modelado: desde el baseline interpretable de regresión logística hasta el modelo CatBoost optimizado con Optuna, pasando por la selección automática del calibrador y la designación del modelo champion.

La estrategia de modelado sigue un principio de **complejidad incremental**:



(a) Curvas ROC de los modelos PD principales evaluados en el

(a) Importancia agregada de variables del modelo PD champion, como evidencia estática del bloque de modelado para exportación PDF.

Tabla 18.1.: Resumen de modelos PD evaluados

```

import sys
from pathlib import Path

sys.path.insert(0, str(Path.cwd().parent if Path.cwd().name == "book" else Path.cwd()))
from book._helpers.load_artifacts import load_json

import pandas as pd

comparison = load_json("model_comparison")
models = comparison.get("models", [])

df_models = pd.DataFrame(models)[["model", "calibrated", "auc", "gini", "brier", "d2_brier"]]
df_models.columns = ["Modelo", "Calibrado", "AUC", "Gini", "Brier", "D2 Brier"]
df_models

```

Cada modelo se evalúa exclusivamente sobre el set de test OOT (2018–2020), nunca sobre datos de entrenamiento o validación. Las métricas reflejan rendimiento prospectivo genuino.

19. Regresión Logística: Baseline Interpretable

19.0.1. ¿Por qué un Baseline Lineal?

Toda investigación rigurosa en machine learning requiere un **baseline simple** contra el cual medir el valor agregado de modelos más complejos. En credit scoring, la regresión logística no es solo un baseline académico — es el **estándar regulatorio**: la mayoría de los scorecards en producción bancaria global siguen siendo regresiones logísticas, y los reguladores evalúan modelos de ML comparándolos contra este benchmark.

El baseline de regresión logística cumple cuatro funciones en el pipeline:

1. **Benchmark de discriminación:** ¿CatBoost realmente supera a un modelo lineal, o la ganancia de AUC es marginal?
2. **Referencia de interpretabilidad:** Los coeficientes de la LR son directamente interpretables como odds ratios, proporcionando una narrativa que los reguladores entienden.
3. **Validación de features:** Si una feature tiene un coeficiente significativo en la LR, tiene poder predictivo real. Si CatBoost la usa pero la LR no, el efecto puede ser una interacción no lineal.
4. **Lower bound de rendimiento:** Cualquier modelo desplegado debe superar *significativamente* a la LR para justificar la complejidad adicional.

19.0.2. Especificación del Modelo

La regresión logística modela la probabilidad de default como:

$$P(\text{default} = 1 \mid \mathbf{x}) = \sigma(\mathbf{w}^\top \mathbf{x} + b) = \frac{1}{1 + e^{-(\mathbf{w}^\top \mathbf{x} + b)}} \quad (19.1)$$

donde $\mathbf{w}$ son los pesos (uno por feature), b es el intercepto, y $\sigma(\cdot)$ es la función sigmoide.

19.0.2.1. Preprocesamiento para LR

A diferencia de CatBoost, la regresión logística requiere preprocesamiento explícito:

Tabla 19.1.: Preprocesamiento del baseline LR

Aspecto	Tratamiento	Justificación
NaN	<code>fillna(0)</code>	Estrategia simple; LR no maneja NaN nativamente

Aspecto	Tratamiento	Justificación
Categorías	WOE encoding	Las variables <code>_woe</code> son numéricas y monótonas
Escala	Sin estandarización	Los coeficientes se interpretan en la escala original
Regularización	L2 por defecto (scikit-learn)	Previene overfitting en features correlacionadas

⚠ Limitación del `fillna(0)`

Reemplazar NaN con cero es una estrategia subóptima porque introduce un sesgo: un DTI faltante (que podría indicar datos incompletos o un autoempleado) se trata igual que un DTI de cero (sin deuda). Para la LR baseline, esta simplificación es aceptable porque el objetivo es establecer un lower bound, no maximizar rendimiento. CatBoost no sufre esta limitación al tratar NaN como un valor informativo propio.

19.0.3. Métricas del Baseline

El AUC de 0.683 está en el rango típico para regresión logística aplicada a credit scoring con datos de Lending Club. Estudios publicados reportan AUC de 0.66–0.70 para modelos lineales sobre este dataset (Lessmann et al., 2015).

i D² Brier negativo: ¿qué significa?

El D² Brier Score es análogo al R² — mide la mejora relativa sobre un predictor naive (que siempre predice la frecuencia marginal de default). Un D² negativo (-0.349) indica que el Brier Score del modelo es **peor** que el predictor naive. Esto no significa que la LR sea inútil — su AUC es 0.683, indicando buena discriminación. El problema es la **calibración**: los scores brutos de la LR no son probabilidades bien calibradas. Este es precisamente el problema que la etapa de calibración post-hoc resuelve.

19.0.4. Valor del Baseline

La comparación LR vs. CatBoost justifica el uso de un modelo más complejo:

- **AUC:** 0.683 → 0.713 (+0.030, +4.4 % relativo). Una mejora de 3 puntos de AUC es considerada significativa en credit scoring aplicado.
- **Gini:** 0.366 → 0.426 (+0.060). El Gini amplifica la diferencia.
- **Brier:** 0.231 → 0.154 (después de calibración). Una reducción del 33 % en error cuadrático.

Estas mejoras justifican la complejidad adicional de CatBoost para un modelo de producción, mientras que la LR queda como referencia interpretable para auditoría regulatoria.

Tabla 19.2.: Métricas del baseline de Regresión Logística (test OOT)

```
import pandas as pd

lr_metrics = {
    "AUC-ROC": "0.683",
    "Gini": "0.366",
    "Brier Score (raw)": "0.2313",
    "D2 Brier": "-0.349 (peor que naive)",
    "Interpretación AUC": "Discriminación aceptable pero limitada",
    "Gap vs CatBoost": "0.030 AUC (4.4% relativo)",
}

pd.DataFrame(list(lr_metrics.items()), columns=["Métrica", "Valor"])
```


20. CatBoost: Default y Optimizado con Optuna

20.0.1. Arquitectura de CatBoost

CatBoost (*Categorical Boosting*) es un algoritmo de gradient boosting desarrollado por Yandex que introduce dos innovaciones fundamentales respecto a sus competidores XGBoost y LightGBM: **ordered boosting** y **arboles oblivious** (simétricos).

20.0.1.1. Ordered Boosting

El gradient boosting estándar calcula los residuos sobre las mismas observaciones usadas para construir los árboles anteriores, lo que introduce un sesgo de *target leakage* especialmente en datasets pequeños. CatBoost resuelve esto con *ordered boosting*: para cada observación i , los residuos se calculan usando un modelo entrenado solo en observaciones anteriores a i (según una permutación aleatoria del dataset). Formalmente, el residuo para la observación i en la iteración t es:

$$r_i^{(t)} = y_i - \hat{f}_{\sigma_{<i}}^{(t-1)}(x_i) \quad (20.1)$$

donde $\hat{f}_{\sigma_{<i}}^{(t-1)}$ es el modelo construido únicamente con las observaciones que preceden a i en la permutación σ . Esto produce estimaciones de gradiente insesgadas a cambio de mayor costo computacional.

20.0.1.2. Arboles Oblivious (Simétricos)

CatBoost utiliza por defecto *oblivious decision trees* (ODT), donde cada nivel del árbol usa la **misma condición de split** para todos los nodos de ese nivel. Esto significa que un árbol de profundidad d tiene exactamente 2^d hojas, y la estructura se puede representar como una tabla de verdad de d condiciones binarias.

Las ventajas para credit scoring son:

- **Regularización implícita:** la simetría reduce drásticamente el número de parámetros libres, previniendo overfitting.
- **Velocidad de inferencia:** la predicción se resuelve como una tabla de lookup, no como una travesía del árbol.
- **Estabilidad:** modelos entrenados con semillas diferentes producen predicciones más similares entre sí.

20.0.1.3. Manejo Nativo de Categorías y NaN

CatBoost procesa variables categóricas sin necesidad de one-hot encoding o WOE, usando *target statistics* con suavizado:

$$\hat{x}_k^i = \frac{\sum_{j \in \sigma_{< i}} \mathbb{1}[x_j^k = x_i^k] \cdot y_j + a \cdot p}{\sum_{j \in \sigma_{< i}} \mathbb{1}[x_j^k = x_i^k] + a} \quad (20.2)$$

donde p es la media global del target, a es un parámetro de suavizado, y $\sigma_{< i}$ es el conjunto de observaciones anteriores en la permutación. Este esquema evita el target leakage que afecta al encoding naive de medias condicionales.

Para valores faltantes (NaN), CatBoost asigna cada observación con NaN a la rama óptima en cada split — izquierda o derecha — maximizando la métrica objetivo. Esto convierte la ausencia de datos en una señal informativa sin requerir imputación manual.

20.0.2. Ventajas sobre XGBoost/LightGBM para Credit Scoring

La selección de CatBoost como modelo principal no es arbitraria. Para aplicaciones de credit scoring, presenta ventajas concretas:

Tabla 20.1.: Comparación de frameworks de gradient boosting para credit scoring

Aspecto	CatBoost	XGBoost	LightGBM
Categorías	Nativo (target statistics)	Requiere encoding manual	Nativo (split por subconjuntos)
NaN	Nativo (optimal branch)	Nativo (default direction)	Nativo (zero bin)
Calibración	Mejor out-of-box	Requiere post-hoc	Requiere post-hoc
Sensibilidad a HPO	Baja (defaults robustos)	Media-alta	Alta
Arboles	Oblivious (regularizados)	Asimétricos	Asimétricos (leaf-wise)
Ordered boosting	Si	No	No



Calibración out-of-box

La combinación de ordered boosting y árboles oblivious produce predicciones que son *a priori* mejor calibradas que las de XGBoost/LightGBM. Esto es relevante en credit scoring, donde las probabilidades no solo deben ordenar bien a los clientes (discriminación), sino reflejar la tasa de default real (calibración). Aun así, la calibración post-hoc es necesaria para uso regulatorio — ver Capítulo 21.

Tabla 20.2.: Hiperparámetros del CatBoost default

```
import sys
from pathlib import Path

sys.path.insert(0, str(Path.cwd().parent if Path.cwd().name == "book" else Path.cwd()))

import pandas as pd

default_params = {
    "iterations": "1,000",
    "learning_rate": "0.05",
    "depth": "6",
    "l2_leaf_reg": "3.0",
    "loss_function": "Logloss",
    "auto_class_weights": "Balanced",
    "eval_metric": "AUC",
    "early_stopping_rounds": "50",
    "has_time": "True",
}

df_params = pd.DataFrame(
    list(default_params.items()),
    columns=["Hiperparámetro", "Valor"],
)
df_params
```

20.0.3. CatBoost Default

El primer modelo CatBoost se entrena con hiperparámetros base conservadores, heredados del estándar de scikit-learn adaptado a la escala del dataset:

El parámetro `has_time=True` indica a CatBoost que el orden de las observaciones es informativo (temporal), lo cual ajusta las permutaciones del ordered boosting para respetar la estructura temporal — un detalle importante para datos de crédito donde la distribución cambia con el ciclo económico.

El entrenamiento utiliza un split temporal donde el 15 % final del set de entrenamiento sirve como validación para early stopping, garantizando que la selección de la mejor iteración es prospectiva.

Con un AUC de 0.7125, el CatBoost default ya supera sustancialmente a la LR baseline (0.683, ver Capítulo 19), demostrando que las interacciones no lineales y el procesamiento nativo de categorías aportan +0.030 AUC (+4.3 % relativo). La pregunta es si la optimización de hiperparámetros puede mejorar aún más este rendimiento.

Tabla 20.3.: Métricas del CatBoost default (test OOT)

```

from book._helpers.load_artifacts import load_json

comparison = load_json("model_comparison")
models = comparison.get("models", [])

# Extraer métricas del modelo default
cb_default = next((m for m in models if m["model"] == "CatBoost (default)"), None)

if cb_default:
    metrics_default = {
        "AUC-ROC": f"{cb_default['auc']:.4f}",
        "Gini": f"{cb_default['gini']:.3f}",
        "Brier Score (raw)": f"{cb_default['brier']:.4f}",
        "D² Brier": f"{cb_default['d2_brier']:.4f}",
        "Gap vs LR baseline": f"+{cb_default['auc'] - 0.683:.4f} AUC (+{(cb_default['auc'] - 0.683):.4f})",
    }
    pd.DataFrame(list(metrics_default.items()), columns=["Métrica", "Valor"])

```

20.0.4. Optimización con Optuna (HPO)

20.0.4.1. Diseño del Experimento

La optimización de hiperparámetros se ejecuta con Optuna, un framework de HPO que implementa el **Tree-structured Parzen Estimator** (TPE) como sampler por defecto. A diferencia de grid search o random search, TPE modela la distribución de hiperparámetros condicionalmente al rendimiento observado:

$$p(\lambda | y) = \frac{p(y | \lambda) p(\lambda)}{p(y)} \propto \begin{cases} \ell(\lambda) & \text{si } y < y^* \\ g(\lambda) & \text{si } y \geq y^* \end{cases} \quad (20.3)$$

donde y^* es el cuantil γ de los valores observados, $\ell(\lambda)$ modela la densidad de los hiperparámetros que produjeron buenos resultados, y $g(\lambda)$ modela los que produjeron malos resultados. TPE maximiza el ratio $\ell(\lambda)/g(\lambda)$, lo cual es equivalente a maximizar el *Expected Improvement* (EI).

La configuración de Optuna incluye además:

- **TPE multivariado con agrupación** (`multivariate=True`, `group=True`): modela las dependencias entre hiperparámetros en lugar de tratarlos como independientes. Esto captura interacciones importantes como la relación entre `depth` y `learning_rate`.
- **MedianPruner**: detiene tempranamente trials que a la iteración t del boosting tienen AUC inferior a la mediana de los trials completados, ahorrando entre 40–60 % del cómputo total.
- **Estudio persistente en SQLite**: permite retomar la búsqueda en sesiones posteriores sin perder el historial de trials.

Tabla 20.4.: Espacio de búsqueda de Optuna para CatBoost

```
search_space = {
    "learning_rate": "LogUniform(0.005, 0.20)",
    "depth": "Int(4, 10)",
    "l2_leaf_reg": "LogUniform(0.5, 100.0)",
    "min_data_in_leaf": "Int(20, 500)",
    "random_strength": "LogUniform(1e-9, 10.0)",
    "border_count": "Int(64, 254)",
    "rsm (column sampling)": "Uniform(0.5, 1.0)",
    "bootstrap_type": "Categorical(Bayesian, Bernoulli, MVS)",
    "grow_policy": "Categorical(SymmetricTree, Depthwise, Lossguide)",
    "subsample*": "Uniform(0.5, 0.95)",
    "bagging_temperature*": "Uniform(0.0, 10.0)",
    "leaf_estimation_iterations": "Int(1, 10)",
}

pd.DataFrame(
    list(search_space.items()),
    columns=["Hiperparámetro", "Distribución"],
)
```

20.0.4.2. Espacio de Búsqueda

* *subsample* se aplica cuando *bootstrap_type* es *Bernoulli* o *MVS*; *bagging_temperature* se aplica cuando es *Bayesian*. Optuna maneja esta condicionalidad automáticamente.

El espacio de búsqueda está diseñado para explorar tres familias de regularización simultáneamente:

1. Regularización del árbol: *depth*, *min_data_in_leaf*, *grow_policy*
2. Regularización del gradiente: *learning_rate*, *l2_leaf_reg*, *random_strength*
3. Regularización por submuestreo: *bootstrap_type*, *subsample*/*bagging_temperature*, *rsm*

20.0.4.3. Resultados de la Búsqueda

Los 320 trials alcanzaron un AUC de validación de 0.7227, pero el AUC en el test OOT es 0.7131 — una brecha de 0.0096 que indica *temporal overfitting* al set de validación. El set de validación temporal cubre un período específico (cola del período 2007–2017), mientras que el test OOT abarca 2018–2020 con condiciones macroeconómicas potencialmente diferentes.

20.0.4.4. Hiperparámetros Ganadores

Tabla 20.5.: Resultados de la optimización con Optuna

```

n_trials = comparison.get("hpo_trials_executed", 320)
best_val_auc = comparison.get("hpo_best_validation_auc", 0.7227)
cb_tuned = next((m for m in models if m["model"] == "CatBoost (tuned)"), None)

optuna_results = {
    "Trials ejecutados": f"{n_trials:,}",
    "Mejor AUC validación": f"{best_val_auc:.4f}",
    "AUC test OOT (tuned)": f"{cb_tuned['auc']:.4f}" if cb_tuned else "N/A",
    "AUC test OOT (default)": f"{cb_default['auc']:.4f}" if cb_default else "N/A",
    "Mejora absoluta": f"+{cb_tuned['auc'] - cb_default['auc']:.4f}" if cb_tuned and cb_default else "0.0000",
    "Sampler": "TPE multivariado con agrupación",
    "Pruner": "MedianPruner (n_warmup=120)",
}

pd.DataFrame(list(optuna_results.items()), columns=["Aspecto", "Valor"])

```

Tabla 20.6.: Hiperparámetros óptimos seleccionados por Optuna

```

from book._helpers.load_artifacts import load_yaml

config = load_yaml("pd_model")
tuned_params = config.get("model", {}).get("params", {})

# Mostrar los parámetros más relevantes
key_params = {
    "iterations": tuned_params.get("iterations", "N/A"),
    "learning_rate": f"{tuned_params.get('learning_rate', 'N/A'):.4f}" if isinstance(tuned_params.get('learning_rate'), float) else "N/A",
    "depth": tuned_params.get("depth", "N/A"),
    "l2_leaf_reg": f"{tuned_params.get('l2_leaf_reg', 'N/A'):.2f}" if isinstance(tuned_params.get('l2_leaf_reg'), float) else "N/A",
    "min_data_in_leaf": tuned_params.get("min_data_in_leaf", "N/A"),
    "border_count": tuned_params.get("border_count", "N/A"),
    "bootstrap_type": tuned_params.get("bootstrap_type", "N/A"),
    "subsample": f"{tuned_params.get('subsample', 'N/A'):.4f}" if isinstance(tuned_params.get('subsample'), float) else "N/A",
    "rsm": f"{tuned_params.get('rsm', 'N/A'):.4f}" if isinstance(tuned_params.get('rsm'), float) else "N/A",
    "random_strength": f"{tuned_params.get('random_strength', 'N/A'):.2e}" if isinstance(tuned_params.get('random_strength'), float) else "N/A",
    "early_stopping_rounds": tuned_params.get("early_stopping_rounds", "N/A"),
}

pd.DataFrame(
    list(key_params.items()),
    columns=["Hiperparámetro", "Valor Óptimo"],
)

```

Tabla 20.7.: Features categóricos procesados nativamente por CatBoost

```
from book._helpers.load_artifacts import load_json

contract = load_json("pd_model_contract", directory="models")
cat_features = contract.get("categorical_features", [])
n_features = contract.get("n_features", 0)

cat_descriptions = {
    "grade": "Grado de riesgo Lending Club (A-G)",
    "sub_grade": "Sub-grado detallado (A1-G5, 35 niveles)",
    "home_ownership": "Tipo de propiedad (RENT, OWN, MORTGAGE, OTHER)",
    "purpose": "Propósito del préstamo (14 categorías)",
    "verification_status": "Estado de verificación de ingresos",
    "term": "Plazo del préstamo (36 o 60 meses)",
    "int_rate_bucket": "Bucket discretizado de tasa de interés",
    "dti_bucket": "Bucket discretizado de debt-to-income",
    "fico_bucket": "Bucket discretizado de FICO score",
}

rows = []
for feat in cat_features:
    desc = cat_descriptions.get(feat, "")
    rows.append({"Feature": feat, "Descripción": desc})

df_cat = pd.DataFrame(rows)
df_cat
```

Configuración como template

Los hiperparámetros en `configs/pd_model.yaml` reflejan los mejores valores encontrados en la última búsqueda. Sin embargo, como se establece en la política del proyecto, los artefactos de runtime (`data/processed/model_comparison.json`, `models/pd_training_record.pkl`) son la fuente de verdad para métricas y decisiones — el YAML es un template que puede ser actualizado en búsquedas futuras.

20.0.5. Features Nativos de CatBoost

Una ventaja clave de CatBoost es la capacidad de consumir directamente variables categóricas y valores faltantes sin preprocesamiento. El contrato canónico del modelo define 44 features, de las cuales 9 son categóricas:

```

n_categorical = len(cat_features)
n_numeric = n_features - n_categorical

composition = {
    "Tipo": ["Numéricos (continuos + binarios + interacciones)", "Categóricos (nativos CatBoost)"],
    "Cantidad": [n_numeric, n_categorical],
    "Porcentaje": [f"{n_numeric/n_features*100:.0f}%", f"{n_categorical/n_features*100:.0f}%"]
}

pd.DataFrame(composition)

```

Figura 20.1.

20.0.5.1. Manejo de NaN como Señal Informativa

La diferencia entre el tratamiento de NaN en CatBoost y en la LR baseline ilustra por qué los árboles de decisión son preferibles para datos de crédito con patrones de ausencia informativa:

Tabla 20.8.: Comparación del tratamiento de NaN entre LR y CatBoost

Escenario	LR (fillna=0)	CatBoost (nativo)
DTI faltante	Se trata como DTI=0 (sin deuda)	Se asigna a la rama óptima por split
Ingreso faltante	Se trata como ingreso=0	Puede indicar autoempleado; CatBoost lo aprende
FICO faltante	Se trata como FICO=0 (score mínimo)	Se distingue de FICO bajo real
Delinquency faltante	Se trata como 0 delinquencias	Puede indicar historial crediticio corto

En datos de crédito, el patrón de ausencia frecuentemente es informativo: un `dti` faltante puede indicar un autoempleado cuyo DTI no se calculó, no un DTI de cero. CatBoost captura esta información aprendiendo la dirección óptima para observaciones con NaN en cada nodo del árbol, sin requerir ingeniería de features adicional.

20.0.6. ¿Por Qué la Ganancia del Tuning es Tan Pequeña?



Ganancia marginal: 0.0006 AUC

La mejora del tuning con 320 trials de Optuna es de apenas 0.0006 AUC (0.7125 → 0.7131). Esto no es un fallo del proceso de optimización — es un resultado esperado y bien documentado en la literatura.

Tres factores explican esta convergencia:

Tabla 20.9.: Análisis de la fuente de ganancia: HPO vs calibración

```

cb_calibrated = next((m for m in models if m["model"] == "CatBoost (tuned + calibrated)"), None)
final_metrics = comparison.get("final_test_metrics", {})
ece = final_metrics.get("ece", 0.006)

gain_analysis = []

if cb_default and cb_tuned:
    gain_analysis.append({
        "Transición": "Default → Tuned (HPO)",
        "Δ AUC": f"{cb_tuned['auc'] - cb_default['auc']:.4f}",
        "Δ Brier": f"{cb_tuned['brier'] - cb_default['brier']:.4f}",
        "Δ D² Brier": f"{cb_tuned['d2_brier'] - cb_default['d2_brier']:.4f}",
        "Interpretación": "Mejora marginal en discriminación",
    })

if cb_tuned and cb_calibrated:
    gain_analysis.append({
        "Transición": "Tuned → Tuned + Calibrado",
        "Δ AUC": f"{cb_calibrated['auc'] - cb_tuned['auc']:.4f}",
        "Δ Brier": f"{cb_calibrated['brier'] - cb_tuned['brier']:.4f}",
        "Δ D² Brier": f"{cb_calibrated['d2_brier'] - cb_tuned['d2_brier']:.4f}",
        "Interpretación": "Mejora masiva en calibración (ECE → " + f"{ece:.4f})",
    })

pd.DataFrame(gain_analysis)

```

1. Los defaults de CatBoost ya son robustos. A diferencia de XGBoost (donde la elección de `max_depth`, `min_child_weight` y `learning_rate` puede cambiar el AUC en 2–5 puntos), CatBoost fue diseñado con defaults que funcionan bien sin tuning extensivo. Los árboles oblivious proporcionan regularización estructural que reduce la sensibilidad a los hiperparámetros.

2. El techo discriminativo del dataset. Los features disponibles en Lending Club — FICO score, DTI, ingreso, propósito del préstamo — tienen un poder discriminativo limitado. Lessmann et al. (2015) documentan que en benchmarks de credit scoring, la diferencia entre el mejor y peor modelo rara vez excede 2–3 puntos de AUC, y que la ganancia por HPO es típicamente inferior a 1 punto. El verdadero cuello de botella no son los hiperparámetros sino la información contenida en los features.

3. La ganancia real está en la calibración, no en la discriminación. Observemos la diferencia en las métricas clave:

La calibración (ver Capítulo 21) reduce el Brier Score en \$ \$0.05 y lleva el D² Brier de negativo a positivo — una mejora de un orden de magnitud mayor que la del HPO. Esto confirma que para un pipeline de credit scoring donde las probabilidades deben ser interpretables y usables en cálculos de

ECL (ver Capítulo 41), la prioridad de inversión computacional debe ser calibración > conformal > HPO.

i Implicación para el pipeline predict-then-optimize

La robustez de CatBoost a los hiperparámetros es una ventaja en el contexto del pipeline predict-then-optimize (Capítulo 36). Si pequeños cambios en hiperparámetros produjeran grandes cambios en las PD estimadas, la incertidumbre de los intervalos conformales (ver Capítulo 24) sería atribuible en parte a inestabilidad del modelo, no solo a incertidumbre epistémica genuina. La estabilidad de CatBoost permite interpretar los intervalos conformales como reflejo de la incertidumbre real del problema.

21. Selección de Calibración

21.0.1. Por qué Importa la Calibración

Un modelo puede tener excelente discriminación (AUC alto) y, sin embargo, producir probabilidades sistemáticamente incorrectas. El AUC mide únicamente si el modelo **ordena** correctamente a los prestatarios por riesgo — no dice nada sobre si los valores absolutos de PD son confiables. En credit scoring, esta distinción es crítica.

Considere dos modelos con AUC idéntico de 0.71:

- **Modelo A:** Asigna $PD = 0.40$ a un grupo donde la tasa real de default es 15 %.
- **Modelo B:** Asigna $PD = 0.15$ al mismo grupo.

Ambos modelos ordenan a los prestatarios igualmente bien, pero solo el Modelo B produce probabilidades que se pueden usar directamente en decisiones económicas. Las consecuencias de una mala calibración se propagan a través del pipeline:

Tabla 21.1.: Impacto de la calibración en el pipeline

Uso downstream	Impacto de mala calibración
ECL = $PD \times LGD \times EAD$	Provisiones infladas o subestimadas
IFRS9 staging	Asignación incorrecta a Stage 1/2 (depende de niveles absolutos de PD)
Optimización de portafolio	Costos de default distorsionados $\Rightarrow$ allocaciones subóptimas
Intervalos conformales	PD calibrada es el input de MAPIE; calibración pobre $\Rightarrow$ intervalos descentrados

⚠ AUC invariante, ECL no

El AUC es invariante a transformaciones monótonas del score: calibrar las probabilidades **no puede mejorar ni empeorar** la discriminación. Pero el Brier Score, el ECE y las decisiones económicas (ECL, staging, portafolio) dependen directamente de los valores absolutos. Un modelo con $AUC = 0.71$ y $Brier = 0.205$ puede transformarse en uno con $AUC = 0.71$ y $Brier = 0.154$ simplemente mediante calibración post-hoc — sin reentrenar el modelo base.

21.0.2. Formalización: Calibración Perfecta

Un modelo está **perfectamente calibrado** si, para cualquier probabilidad predicha p :

$$\mathbb{P}(\text{default} = 1 \mid \hat{p}(x) = p) = p, \quad \forall p \in [0, 1] \quad (21.1)$$

En la práctica, esta condición se relaja a intervalos (*bins*): agrupamos las predicciones en B bins y verificamos que la frecuencia observada de default en cada bin coincida con la probabilidad promedio predicha.

La métrica estándar es el **Expected Calibration Error (ECE)**:

$$\text{ECE} = \sum_{b=1}^B \frac{|S_b|}{N} |\text{acc}(S_b) - \text{conf}(S_b)| \quad (21.2)$$

donde S_b es el conjunto de observaciones en el bin b , $\text{acc}(S_b)$ es la frecuencia real de default, y $\text{conf}(S_b)$ es la media de las probabilidades predichas en ese bin.

21.0.3. Tres Métodos de Calibración

El pipeline evalúa tres métodos de calibración post-hoc, cada uno con diferentes propiedades teóricas y prácticas.

21.0.3.1. 1. Platt Scaling (Calibración Sigmoides)

Platt Scaling (Platt, 1999) ajusta una regresión logística sobre los scores del modelo base:

$$P_{\text{cal}}(y = 1 \mid s) = \frac{1}{1 + \exp(-(a \cdot s + b))} \quad (21.3)$$

donde s es el score bruto del modelo y (a, b) son los parámetros ajustados por máxima verosimilitud sobre el set de calibración.

Ventajas: Simple (2 parámetros), estable con muestras moderadas, preserva AUC exactamente (transformación monótona).

Limitaciones: Asume una relación sigmoide entre score y probabilidad. Si el score ya está aproximadamente calibrado (como ocurre con CatBoost que usa Logloss), la transformación sigmoide puede ser redundante.

21.0.3.2. 2. Regresión Isotónica

La regresión isotónica ajusta una función monótona no decreciente por partes constantes que minimiza el error cuadrático:

$$\hat{f} = \arg \min_{f \in \mathcal{F}_{\text{iso}}} \sum_{i=1}^n (y_i - f(s_i))^2 \quad (21.4)$$

donde $\mathcal{F}_{\text{iso}}$ es el conjunto de funciones monótonas no decrecientes.

Ventajas: No paramétrico — no asume forma funcional. Puede capturar relaciones no lineales arbitrarias entre score y probabilidad.

Limitaciones: Mayor riesgo de sobreajuste con muestras pequeñas (la función por partes constantes puede memorizar ruido). Con $n = 47,516$ a $190,064$ observaciones en nuestros folds, este riesgo es limitado pero no nulo.

21.0.3.3. 3. Venn-Abers Predictors

Los Venn-Abers predictors (Vovk & Petej, 2014) son una extensión de la regresión isotónica que produce **intervalos de probabilidad** con garantías de validez. El procedimiento es:

1. Para cada observación de test, ajustar **dos** regresiones isotónicas sobre el set de calibración: una asumiendo que la observación es positiva ($y = 1$) y otra asumiendo que es negativa ($y = 0$).
2. Esto produce dos probabilidades calibradas: p_0 y p_1 .
3. La predicción final es la media ponderada: $\hat{p} = \frac{p_1}{p_0 + p_1}$.

Ventajas: Produce multi-probabilidades con garantías de validez bajo la asunción de intercambiabilidad. Es el método más conservador de los tres.

Limitaciones: Computacionalmente más costoso (dos ajustes isotónicos por predicción). La garantía de validez es más débil que la de predicción conformal (aplica a la calibración del predictor, no a la cobertura de intervalos).

Relación con predicción conformal

Venn-Abers y la predicción conformal comparten raíces teóricas en el framework de Vovk et al. (2005). Ambos requieren intercambiabilidad (*exchangeability*) de los datos. Sin embargo, cumplen funciones diferentes: Venn-Abers calibra la *probabilidad puntual*, mientras que la predicción conformal (Capítulo 24) genera *intervalos de predicción* con cobertura garantizada. En nuestro pipeline, Venn-Abers opera primero (calibración) y luego MAPIE opera sobre las PDs calibradas (conformización).

21.0.4. Política de Selección Temporal

La selección del calibrador **no está hardcodeda** — es el resultado de una política de validación temporal multi-métrica que se ejecuta en cada entrenamiento canónico. El archivo de configuración (`configs/pd_model.yaml`) especifica:

```
calibration:
  method: auto # temporal multi-metric policy selects best
  candidates: [platt, isotonic, venn_abers]
```

La política `auto` implementa el siguiente protocolo:

21.0.4.1. Expanding Window Temporal Cross-Validation

El set de calibración (237,584 observaciones) se divide en 4 folds temporales de 47,516 observaciones cada uno. La validación usa una **ventana expandible**: en cada fold, el calibrador se ajusta con todos los folds anteriores y se evalúa en el fold actual.

Fold 1: Fit [F1]	→ Eval [F2]	(n_fit = 47,516)
Fold 2: Fit [F1, F2]	→ Eval [F3]	(n_fit = 95,032)
Fold 3: Fit [F1, F2, F3]	→ Eval [F4]	(n_fit = 142,548)
Fold 4: Fit [F1, F2, F3, F4]	→ Eval holdout	(n_fit = 190,064)

Esta estrategia respeta la estructura temporal de los datos y simula el escenario de producción donde el calibrador se ajusta con datos acumulados.

21.0.4.2. Criterios de Selección (Multi-Métrica)

Un candidato es **factible** si cumple:

1. **AUC drop < 0.0015**: La calibración no debe degradar la discriminación. Un drop mayor sugiere que la transformación no es monótona en la práctica (posible por errores numéricos o sobreajuste).

De los candidatos factibles, se selecciona el mejor según:

2. **Minimizar Brier Score medio** (métrica primaria): Mide la calidad global de las probabilidades.
3. **Minimizar ECE medio** (métrica secundaria): Mide la calibración por bins.
4. **Estabilidad**: Baja varianza de Brier + ECE entre folds. Se define como $\text{stability} = \text{Var}(\text{Brier}) + \text{Var}(\text{ECE})$ a través de los folds.

Tabla 21.2.: Comparación de candidatos de calibración (validación temporal, 4 folds)

```
import sys
from pathlib import Path

sys.path.insert(0, str(Path.cwd().parent if Path.cwd().name == "book" else Path.cwd()))
from book._helpers.load_artifacts import load_json

import pandas as pd

comparison = load_json("model_comparison")
cal_report = comparison.get("calibration_selection_report", {})
candidates = cal_report.get("candidates", [])

METHOD_DISPLAY = {"platt": "Platt", "isotonic": "Isotónica", "venn_abers": "Venn-Abers"}

rows = []
for c in candidates:
    rows.append({
        "Método": METHOD_DISPLAY.get(c["method"], c["method"]),
        "Brier (media)": f"{c['mean_brier']:.4f}",
        "ECE (media)": f"{c['mean_ece']:.4f}",
        "AUC drop (media)": f"{c['mean_auc_drop']:.5f}",
        "Estabilidad": f"{c['stability']:.2e}",
        "Factible": "Sí" if c["mean_auc_drop"] < cal_report.get("auc_drop_limit", 0.0015) else "No"
    })

df_cal = pd.DataFrame(rows)
df_cal
```

Tabla 21.3.: Detalle por fold del calibrador seleccionado (Venn-Abers)

```

winner_method = cal_report.get("selected_method", "venn_abers")
winner = next((c for c in candidates if c["method"] == winner_method), None)

if winner:
    fold_rows = []
    for f in winner["folds"]:
        fold_rows.append({
            "Fold": f["fold"],
            "n_fit": f"{f['n_fit']:,}",
            "n_eval": f"{f['n_eval']:,}",
            "AUC raw": f"{f['raw_auc']:.4f}",
            "AUC cal": f"{f['cal_auc']:.4f}",
            "AUC drop": f"{f['auc_drop']:.5f}",
            "Brier": f"{f['brier']:.4f}",
            "ECE": f"{f['ece']:.4f}",
        })
    pd.DataFrame(fold_rows)

```

21.0.5. Resultados de la Selección

Los tres métodos son factibles ($\text{AUC drop} < 0.0015$ en todos los casos). Las diferencias en Brier Score son del orden de 10^{-5} — prácticamente indistinguibles. La selección se decide por el criterio `feasible_multi_metric` que combina Brier, ECE y estabilidad.

Observaciones clave del detalle por fold:

- El **AUC drop** es consistentemente < 0.0002 en cada fold, muy por debajo del límite de 0.0015. La calibración Venn-Abers preserva la discriminación.
- El **Brier Score** varía entre 0.1521 y 0.1647 a través de los folds, reflejando la estabilidad del método a medida que el set de ajuste crece de 47K a 190K observaciones.
- El **ECE** se mantiene entre 0.019 y 0.025 a través de los folds, sin señales de sobreajuste o degradación temporal.

21.0.6. Métricas Finales del Modelo Calibrado (Test OOT)

El impacto de la calibración es dramático:

- **Brier Score**: De 0.2051 a 0.1545, una reducción del 24.7%. La calibración mejora la calidad de las probabilidades sin reentrenar el modelo.
- **ECE**: 0.0059 — la frecuencia observada de default en cada bin de probabilidad difiere en promedio solo 0.6 puntos porcentuales de la probabilidad predicha. Esto es excelente para uso en ECL e IFRS9.

Tabla 21.4.: Métricas del modelo CatBoost calibrado con Venn-Abers (test OOT, 276,869 préstamos)

```

final = comparison.get("final_test_metrics", {})
raw_model = next((m for m in comparison.get("models", []) if m["model"] == "CatBoost (tuned)"))

metrics_rows = [
    {"Métrica": "AUC-ROC", "Sin calibrar": f"{raw_model.get('auc', 'N/A'):.4f}",
     "Calibrado (Venn-Abers)": f"{final.get('auc_roc', 'N/A'):.4f}",
     "Cambio": "Invariante"},
    {"Métrica": "Gini", "Sin calibrar": f"{raw_model.get('gini', 'N/A'):.4f}",
     "Calibrado (Venn-Abers)": f"{final.get('gini', 'N/A'):.4f}",
     "Cambio": "Invariante"},
    {"Métrica": "Brier Score", "Sin calibrar": f"{raw_model.get('brier', 'N/A'):.4f}",
     "Calibrado (Venn-Abers)": f"{final.get('brier_score', 'N/A'):.4f}",
     "Cambio": f"{((final.get('brier_score', 0) - raw_model.get('brier', 0)) / raw_model.get('brier_score', 0)):.4f}"},
    {"Métrica": "ECE", "Sin calibrar": "N/A (no reportado)",
     "Calibrado (Venn-Abers)": f"{final.get('ece', 'N/A'):.4f}",
     "Cambio": "---"},
    {"Métrica": "D2 Brier", "Sin calibrar": f"{raw_model.get('d2_brier', 'N/A'):.4f}",
     "Calibrado (Venn-Abers)": f"{final.get('d2_brier_score', 'N/A'):.4f}",
     "Cambio": "Negativo → Positivo"},
    {"Métrica": "KS Statistic", "Sin calibrar": "N/A",
     "Calibrado (Venn-Abers)": f"{final.get('ks_statistic', 'N/A'):.4f}",
     "Cambio": "---"},
]

pd.DataFrame(metrics_rows)

```

- **D² Brier**: De -0.1963 (peor que el predictor naive) a +0.0989 (mejor que el predictor naive). La calibración transforma un modelo que, en términos de probabilidad absoluta, era **peor que predecir siempre la tasa base**, en uno que genuinamente agrega valor probabilístico.
- **AUC**: 0.7131 → 0.7130, variación en la cuarta decimal. La calibración no afecta la discriminación, como esperamos teóricamente.

21.0.7. Descomposición del Brier Score

El Brier Score admite una descomposición que separa la **discriminación** de la **calibración** (Murphy, 1973):

$$\text{BS} = \underbrace{\frac{1}{N} \sum_{b=1}^B n_b (\bar{p}_b - \bar{o}_b)^2}_{\text{Calibración (REL)}} - \underbrace{\frac{1}{N} \sum_{b=1}^B n_b (\bar{o}_b - \bar{o})^2}_{\text{Resolución (RES)}} + \underbrace{\bar{o}(1 - \bar{o})}_{\text{Incertidumbre (UNC)}} \quad (21.5)$$

donde $\bar{p}_b$ es la probabilidad media predicha en el bin b , $\bar{o}_b$ es la frecuencia observada de default en el bin, y $\bar{o}$ es la frecuencia marginal de default.

- **REL (reliability)**: Penaliza la distancia entre frecuencias predichas y observadas. La calibración reduce este término.
- **RES (resolution)**: Recompensa la capacidad de distinguir grupos con diferentes tasas de default. Depende de la discriminación del modelo.
- **UNC (uncertainty)**: Constante que depende solo de la frecuencia marginal de default.

La mejora de Brier de 0.2051 a 0.1545 se debe casi enteramente a la reducción del término de **reliability** (REL), mientras que la resolución se mantiene constante — exactamente lo que esperamos de una calibración post-hoc que no altera el ranking del modelo.

💡 Interpretación práctica del ECE

Un ECE de 0.0059 significa que, si el modelo asigna $\text{PD} = 0.20$ a un grupo de préstamos, la tasa real de default en ese grupo será aproximadamente 19.4 % a 20.6 %. Para cálculos de ECL bajo IFRS9, esta precisión es más que suficiente — la incertidumbre en LGD y EAD típicamente domina sobre la incertidumbre en PD calibrada.

21.0.8. Por qué Venn-Abers y no Platt

i Selección del calibrador: Venn-Abers

Platt Scaling y Venn-Abers tienen rendimiento prácticamente idéntico en este dataset: la diferencia en Brier es del orden de 5×10^{-5} y en ECE del orden de 10^{-3} . La política `feasible_multi_metric` seleccionó Venn-Abers por tres razones:

1. **Multi-probabilidades con validez**: Venn-Abers produce un intervalo $[p_0, p_1]$ alrededor de la probabilidad calibrada, proporcionando una medida de incertidumbre inherente al proceso de calibración.

Tabla 21.5.: Artefactos del calibrador en el contrato canónico

```
from book._helpers.load_artifacts import try_load_json

contract = try_load_json("pd_model_contract", directory="models", default={})

contract_rows = [
    {"Artefacto": "Modelo base", "Ruta": contract.get("model_path", "N/A")},
    {"Artefacto": "Calibrador", "Ruta": contract.get("calibrator_path", "N/A")},
    {"Artefacto": "Método seleccionado",
     "Ruta": comparison.get("best_calibration", "N/A")},
    {"Artefacto": "Razón de selección",
     "Ruta": cal_report.get("selection_reason", "N/A")},
]

pd.DataFrame(contract_rows)
```

2. **Consistencia teórica:** Al estar basado en el framework de Vovk et al., Venn-Abers tiene garantías de validez bajo intercambiabilidad — la misma asunción que subyace a la predicción conformal que se aplica downstream.
3. **Mejor Brier marginal:** Aunque la diferencia es mínima (1.6×10^{-4}), Venn-Abers tiene el menor Brier medio entre los tres candidatos.

Importante: Este resultado puede cambiar en futuras ejecuciones del pipeline. El config dice `method: auto` y el artefacto `model_comparison.json` es la fuente de verdad, no el método hardcodeado. Si los datos cambian o se agregan folds, la política podría seleccionar Platt o Isotónica.

21.0.9. Implementación en el Pipeline

La calibración se implementa en dos módulos:

- `src/models/calibration.py`: Funciones de ajuste para Platt (`calibrate_platt`), Isotónica (`calibrate_isotonic`), y evaluación (`expected_calibration_error`, `evaluate_calibration`).
- `scripts/train_pd_model.py`: Orquestación de la política de selección temporal con expanding window.

El calibrador seleccionado se persiste como `models/pd_canonical_calibrator.pkl` y se registra en el contrato canónico (`models/pd_model_contract.json`). Todos los scripts downstream — generación de intervalos conformales (Capítulo 24), optimización de portafolio (Capítulo 36), cálculo de ECL (Capítulo 41) — consumen el calibrador a través del contrato, sin necesidad de conocer qué método fue seleccionado.

El calibrador es un artefacto crítico

El calibrador se aplica a **todas** las predicciones downstream del modelo. Si el archivo `.pk1` se corrompe o se pierde, las predicciones del modelo revertirán a los scores brutos sin calibrar — con Brier de 0.205 en lugar de 0.154. El pipeline verifica la existencia del calibrador al inicio de cada script y falla con un error explícito si no lo encuentra. DVC rastrea este artefacto junto con el modelo base.

22. Comparación de Modelos y Selección del Champion

22.0.1. Framework de Comparación

La selección del modelo champion no se basa en una sola métrica — utiliza un framework multi-dimensional que evalúa discriminación, calibración, estabilidad temporal y operabilidad.

22.0.2. Criterios de Selección

El modelo champion se selecciona evaluando cinco dimensiones:

1. Discriminación (AUC, Gini, KS)

El AUC mide la capacidad del modelo para separar defaults de no-defaults. Los cuatro modelos muestran una progresión clara:

- LR → CatBoost default: **+0.030 AUC** (salto principal, justifica la complejidad)
- CatBoost default → tuned: **+0.0006 AUC** (marginal, HPO tiene rendimientos decrecientes)
- Tuned → calibrado: **AUC invariante** (la calibración no afecta el ranking)

El KS (Kolmogorov-Smirnov) del modelo champion es **0.315**, indicando buena separación entre las distribuciones de scores de defaults y no-defaults.

2. Calibración (Brier, ECE, D² Brier)

La calibración es donde la diferencia entre modelos raw y calibrados es más dramática:

Tabla 22.2.: Impacto de la calibración sobre métricas de Brier

Métrica	CatBoost raw	CatBoost calibrado	Mejora
Brier	0.2051	0.1545	-24.7 %
ECE	N/A (no medido)	0.0059	Excelente
D ² Brier	-0.196	+0.099	De peor a mejor que naive

Un ECE de 0.006 significa que las probabilidades predichas están, en promedio, a menos de 0.6 puntos porcentuales de las frecuencias de default observadas. Para IFRS9, donde las provisiones se calculan como $PD \times LGD \times EAD$, esta precisión es esencial.

Las figuras Figura 22.1 y Figura 22.2 muestran por qué el champion no se define solo por ranking. El desempeño discriminativo se mantiene alto, pero la mejora verdaderamente material aparece en la calibración posterior.

Tabla 22.1.: Comparación completa de modelos PD (métricas OOT)

```

import sys
from pathlib import Path

sys.path.insert(0, str(Path.cwd().parent if Path.cwd().name == "book" else Path.cwd()))
from book._helpers.load_artifacts import load_json

import pandas as pd

comparison = load_json("model_comparison")
final = comparison.get("final_test_metrics", {})

models_data = [
    {"Modelo": "Logistic Regression", "AUC": 0.683, "Gini": 0.366,
     "Brier": 0.2313, "ECE": "N/A", "D2 Brier": -0.349,
     "Calibrado": "No", "Status": "Baseline"},
    {"Modelo": "CatBoost (default)", "AUC": 0.7125, "Gini": 0.425,
     "Brier": 0.2058, "ECE": "N/A", "D2 Brier": -0.200,
     "Calibrado": "No", "Status": "Candidato"},
    {"Modelo": "CatBoost (tuned)", "AUC": 0.7131, "Gini": 0.4262,
     "Brier": 0.2051, "ECE": "N/A", "D2 Brier": -0.196,
     "Calibrado": "No", "Status": "Candidato"},
    {"Modelo": "CatBoost (tuned + Venn-Abers)", "AUC": round(final.get("auc_roc", 0), 4),
     "Gini": round(final.get("gini", 0), 4),
     "Brier": round(final.get("brier_score", 0), 4),
     "ECE": round(final.get("ece", 0), 4),
     "D2 Brier": round(final.get("d2_brier_score", 0), 4),
     "Calibrado": "Sí (Venn-Abers)", "Status": "Champion"},
]

pd.DataFrame(models_data)

```




Figura 22.2.: Curvas de calibración del champion y sus comparadores, usadas para justificar la promoción del calibrador Venn-Abers.

Tabla 22.3.: Métricas completas del modelo champion (test OOT)

```
metrics = {
    "AUC-ROC": f"{final.get('auc_roc', 0):.4f}",
    "Gini": f"{final.get('gini', 0):.4f}",
    "Brier Score": f"{final.get('brier_score', 0):.4f}",
    "ECE": f"{final.get('ece', 0):.4f}",
    "KS Statistic": f"{final.get('ks_statistic', 0):.4f}",
    "D² Brier": f"{final.get('d2_brier_score', 0):.4f}",
    "PR-AUC": f"{final.get('pr_auc', 0):.4f}",
    "Recall @ 0.35": f"{final.get('recall_at_0p35', 0):.4f}",
    "F1 @ 0.35": f"{final.get('f1_at_0p35', 0):.4f}",
}

pd.DataFrame(list(metrics.items()), columns=["Métrica", "Valor"])
```

3. Métricas complementarias

4. Estabilidad temporal

El modelo se evalúa no solo en métricas agregadas sino en su **estabilidad mensual** a lo largo del período de test (33 meses). Un modelo con AUC alto pero volátil es menos confiable que uno con AUC ligeramente menor pero estable. El backtesting conformal mensual (ver Capítulo 27) complementa esta evaluación verificando que la cobertura se mantiene mes a mes.

5. Operabilidad

- **Tiempo de inferencia:** CatBoost predice 276,869 scores en < 1 segundo (batch).
- **Tamaño del modelo:** El archivo `pd_canonical.cbm` pesa < 10 MB.
- **Dependencias:** Solo requiere `catboost` (no TensorFlow, no ONNX runtime).
- **Contrato estable:** Las 44 features del contrato (Capítulo 17) están documentadas y validadas.

22.0.3. Artefactos del Champion

La selección del champion produce tres artefactos canónicos que son consumidos por todas las etapas downstream:

Tabla 22.4.: Artefactos canónicos del modelo champion

Artefacto	Path	Consumidores
Modelo CatBoost	<code>models/pd_canonical.cbm</code>	Conformal, SHAP, portfolio, IFRS9
Calibrador	<code>models/pd_canonical_calibration.pkl</code>	Conformal (BD, pkl) (usada como input)
Contrato	<code>models/pd_model_contract.json</code>	Conformal (validación de features)

! Principio de inmutabilidad

Una vez designado como champion, el modelo y su calibrador se **congelan**. Los scripts downstream cargan estos artefactos y los usan sin modificación. Si se necesita un modelo nuevo, se ejecuta el pipeline completo de entrenamiento y se genera un nuevo set de artefactos canónicos. Esto garantiza reproducibilidad: los mismos artefactos producen los mismos intervalos conformales, las mismas asignaciones de portafolio y las mismas provisiones IFRS9.

22.0.4. Posicionamiento en la Literatura

El AUC de 0.713 se sitúa en el rango competitivo para modelos de ML sobre el dataset de Lending Club:

Tabla 22.5.: Comparación con literatura publicada sobre Lending Club

Estudio	Mejor modelo	AUC reportado
Lessmann et al. (2015)	Random Forest	0.69–0.71
Ayari et al. (2026)	CatBoost	0.71–0.73
Xia et al. (2017)	XGBoost + stacking	0.72–0.74
Este proyecto	CatBoost + Venn-Abers	0.713

Nuestro AUC está en el centro del rango publicado. Estudios que reportan $\text{AUC} > 0.74$ generalmente usan random splits (no OOT), features post-originación, o subconjuntos más pequeños del dataset. Con split temporal estricto y 142→44 features anti-leakage, 0.713 es un resultado competitivo y honesto.

💡 Más allá del AUC

La contribución de este proyecto no es obtener el AUC más alto posible — es construir un pipeline end-to-end que transforma el AUC 0.713 en **decisiones óptimas** de portafolio con **protección contra incertidumbre garantizada**. El modelo PD es un componente, no el producto final. Un modelo con AUC 0.75 pero sin intervalos conformales ni optimización robusta produce peores decisiones que un modelo con AUC 0.71 integrado en el pipeline completo.

23. Predicción Conformal e Incertidumbre

El modelo PD champion produce una estimación puntual calibrada — pero una estimación puntual, por precisa que sea, no captura la **incertidumbre** inherente a la predicción. En riesgo crediticio, ignorar la incertidumbre tiene consecuencias directas: provisiones subestimadas, portafolios frágiles y decisiones que colapsan ante escenarios adversos.

La **predicción conformal** (Conformal Prediction, CP) resuelve este problema con una garantía formal: dado un nivel de confianza $1 - \alpha$, los intervalos conformal cubren el valor verdadero con probabilidad al menos $1 - \alpha$, **sin supuestos distribucionales** (Vovk et al., 2005). Esta propiedad — válida en muestras finitas y bajo la única condición de exchangeability — diferencia a CP de alternativas como bootstrap (asintótico) o intervalos bayesianos (dependientes del prior).




Figura 23.1.: Cobertura conformal observada por grade del portafolio, usada para verificar validez útil a nivel de negocio.

Figura 23.2.: Trade-off entre cobertura e intervalo promedio de confianza conformal.

Las figuras Figura 23.1 y Figura 23.2 anticipan el argumento del capítulo completo: la validez relevante para riesgo no es solo marginal, sino también segmentada y económicamente usable.

Este capítulo documenta la implementación completa de CP en el pipeline: desde los fundamentos teóricos de split conformal, pasando por la extensión Mondrian que garantiza cobertura por grupo (grade), hasta el benchmark de variantes, el backtesting temporal y la extensión a LGD/EAD.

Tabla 23.1.: Métricas de cobertura conformal del modelo champion (test OOT)

```

import sys
from pathlib import Path

sys.path.insert(0, str(Path.cwd().parent if Path.cwd().name == "book" else Path.cwd()))
from book._helpers.load_artifacts import load_json

import pandas as pd

status = load_json("conformal_policy_status", search_models=True)

overview = [
    {"Métrica": "Cobertura empírica @ 90%", "Valor": f"{status['coverage_90']:.2%}"},
    {"Métrica": "Cobertura empírica @ 95%", "Valor": f"{status['coverage_95']:.2%}"},
    {"Métrica": "Ancho promedio @ 90%", "Valor": f"{status['avg_width_90']:.4f}"},
    {"Métrica": "Cobertura mínima por grupo @ 90%", "Valor": f"{status['min_group_coverage_90']:.2%}"},
    {"Métrica": "Winkler score @ 90%", "Valor": f"{status['winkler_90']:.4f}"},
    {"Métrica": "Alertas críticas", "Valor": str(status['critical_alerts'])},
    {"Métrica": "Tamaño de muestra (test OOT)", "Valor": f"{status['statistical_tests']['kupie']:.2%}"},
]

pd.DataFrame(overview)

```

24. Fundamentos de Split Conformal

24.0.1. Garantía Teórica

La predicción conformal se basa en un resultado elegante: si los datos de calibración y test son **exchangeable** (intercambiables), entonces los intervalos construidos a partir de los residuos de calibración cubren el valor verdadero con probabilidad exacta.

Teorema 24.1 (Garantía de Cobertura Marginal). *Sea $\{(X_i, Y_i)\}_{i=1}^{n+1}$ una secuencia exchangeable. Dado un predictor $\hat{f}$ entrenado en un conjunto disjunto, definimos los nonconformity scores $s_i = |Y_i - \hat{f}(X_i)|$ sobre las n observaciones de calibración. Sea $\hat{q}$ el cuantil $\lceil (1 - \alpha)(n + 1) \rceil / n$ de $\{s_1, \dots, s_n\}$. Entonces:*

$$P(Y_{n+1} \in [\hat{f}(X_{n+1}) - \hat{q}, \hat{f}(X_{n+1}) + \hat{q}]) \geq 1 - \alpha \quad (24.1)$$

Esta garantía es **distribution-free** (no requiere normalidad, homocedasticidad, ni ningún supuesto paramétrico) y **finite-sample** (válida para cualquier n , no solo asintóticamente).

24.0.2. Split Conformal vs Full Conformal

El método **full conformal** (Vovk et al., 2005) re-entrena el modelo para cada candidato de test, lo cual es computacionalmente prohibitivo para CatBoost con 1.3M observaciones. El **split conformal** (Papadopoulos et al., 2002) resuelve esto dividiendo los datos:

Tabla 24.1.: Comparación Full vs Split Conformal

Aspecto	Full Conformal	Split Conformal
Reentrenamiento	$O(n)$ veces por predicción	Una vez
Cobertura	Exacta: $P = 1 - \alpha$	Conservative: $P \geq 1 - \alpha$
Eficiencia estadística	Usa todos los datos	Pierde datos de calibración
Viabilidad	Inviabile para modelos complejos	Viable siempre

Para nuestro pipeline, split conformal es la única opción viable y es exactamente lo que MAPIE 1.3.0 implementa.

24.0.3. El Wrapper ProbabilityRegressor

MAPIE opera sobre modelos de **regresión**, pero CatBoost produce **probabilidades** $\hat{p} \in [0, 1]$. El puente es el wrapper ProbabilityRegressor:

```
# src/models/conformal.py (simplificado)
class ProbabilityRegressor(BaseEstimator, RegressorMixin):
    """Wraps a classifier to output probabilities as regression targets."""
    def __init__(self, classifier):
        self.classifier = classifier

    def fit(self, X, y):
        return self # Modelo ya entrenado (prefit)

    def predict(self, X):
        return self.classifier.predict_proba(X)[:, 1]
```

Este patrón permite que MAPIE trate las probabilidades calibradas como valores continuos y construya intervalos $[PD_{low}, PD_{high}]$ alrededor de cada predicción.

i ¿Por qué no usar SplitConformalClassifier?

SplitConformalClassifier produce **prediction sets** (conjuntos de clases posibles), no intervalos de probabilidad. Para riesgo crediticio necesitamos $[PD_{low}, PD_{high}]$ como entradas numéricas a la optimización robusta — lo que requiere el framework de regresión.

24.0.4. Implementación con MAPIE 1.3.0

La API de MAPIE 1.3.0 difiere significativamente de versiones anteriores:

Tabla 24.2.: Migración de API MAPIE

Concepto	MAPIE < 1.3	MAPIE 1.3.0
Clase	MapieRegressor	SplitConformalRegressor
Modelo prefit	cv="prefit"	prefit=True
Nivel	alpha en predict()	confidence_level en __init__()
Calibración	fit() hace todo	fit() + conformalize() separados
Predicción	predict(alpha=0.1)	predict_interval()

El flujo de trabajo en el pipeline:

```

from mapie.regression import SplitConformalRegressor

# 1. Crear el wrapper
prob_reg = ProbabilityRegressor(catboost_calibrated)

# 2. Inicializar MAPIE con nivel de confianza
scr = SplitConformalRegressor(
    estimator=prob_reg,
    confidence_level=0.90,
    prefit=True
)

# 3. Calibrar con el set de calibración
scr.fit(X_cal, y_cal)
scr.conformalize(X_cal, y_cal)

# 4. Predecir intervalos en test
y_pred, intervals = scr.predict_interval(X_test)
# intervals[:, 0] = pd_low, intervals[:, 1] = pd_high

```

24.0.5. Nonconformity Scores para PD

El nonconformity score mide qué tan “conforme” es una observación con el modelo. Para regresión, el score estándar es el residuo absoluto:

$$s_i = |y_i - \hat{f}(x_i)| \quad (24.2)$$

donde $y_i \in \{0, 1\}$ (default o no) y $\hat{f}(x_i) = \text{PD}_{\text{calibrada}} \in [0, 1]$.

El cuantil $\hat{q}$ de estos scores determina el **ancho del intervalo**: a mayor $\hat{q}$ (más confianza), intervalos más anchos. El cuantil se calcula como:

$$\hat{q} = \text{Quantile} \left(\{s_1, \dots, s_n\}, \frac{\lceil (1 - \alpha)(n + 1) \rceil}{n} \right) \quad (24.3)$$

Con $n = 237,584$ observaciones de calibración y $\alpha = 0.10$, el ajuste por finitud es negligible: $\lceil 0.90 \times 237,585 \rceil / 237,584 \approx 0.9000$.

24.0.6. Resultados Split Conformal Global

⚠ Limitación del Split Conformal Global

La cobertura **marginal** de 89.6% es cercana al target, pero la cobertura **por grupo** revela un problema severo: Grade A tiene solo ~59.5% de cobertura. Esto ocurre porque los residuos de Grade A son mucho menores que los de Grade G, y un cuantil global no captura esta

Tabla 24.3.: Cobertura split conformal global (sin partición Mondrian)

```
import pandas as pd

variants = load_json("conformal_policy_status", search_models=True)

# Global split results from variant selection report
global_metrics = [
    {"Métrica": "Cobertura empírica @ 90%", "Valor": "89.6%"},
    {"Métrica": "Ancho promedio", "Valor": "0.947"},
    {"Métrica": "Cobertura mínima por grade", "Valor": "59.5%"},
    {"Métrica": "Winkler score @ 90%", "Valor": "1.109"},
    {"Métrica": "Problema principal", "Valor": "Cobertura < 60% en Grade A"},
]

pd.DataFrame(global_metrics)
```

heterogeneidad. La solución es **Mondrian conformal** (Capítulo 25).

24.0.7. Conexión con el Pipeline

Los intervalos conformal $[PD_{\text{low}}, PD_{\text{high}}]$ son el input directo para:

1. **Conjuntos de incertidumbre box** en la optimización robusta (Capítulo 36):
 $\Gamma_i = [PD_{\text{low},i}, PD_{\text{high},i}]$
2. **Señal SICR conformal** en IFRS9 (Capítulo 43): el ancho $PD_{\text{high}} - PD_{\text{point}}$ como trigger de deterioro
3. **Backtesting de cobertura** (Capítulo 27): monitoreo mensual de que la garantía se mantiene

25. Mondrian: Cobertura Condicional por Grupo

25.0.1. El Problema de la Cobertura Marginal

La garantía de split conformal (Ecuación 24.1) es **marginal**: promedia sobre toda la población. Pero en crédito, un modelo que cubre 90 % en promedio pero solo 60 % en Grade A y 99 % en Grade G es inaceptable — los préstamos de Grade A son precisamente los de mayor volumen y menor riesgo, donde decisiones incorrectas tienen alto impacto económico.

El **Mondrian conformal** (Vovk et al., 2005) resuelve esto particionando la calibración por grupos y calculando cuantiles **separados** para cada grupo:

$$\hat{q}_g = \text{Quantile} \left(\{s_i : g(x_i) = g\}, \frac{\lceil (1 - \alpha)(n_g + 1) \rceil}{n_g} \right) \quad (25.1)$$

donde $g(x_i)$ asigna cada observación a un grupo y n_g es el tamaño de calibración del grupo g .

Teorema 25.1 (Garantía de Cobertura Condicional por Grupo). *Para cada grupo g con al menos n_g observaciones de calibración:*

$$P(Y_{n+1} \in C_g(X_{n+1}) \mid g(X_{n+1}) = g) \geq 1 - \alpha \quad (25.2)$$

*La cobertura se garantiza **dentro de cada grupo**, no solo marginalmente.*

25.0.2. Partición por Grade de Lending Club

La partición natural para crédito es el **risk grade** asignado por la plataforma (A-G). Cada grade tiene una distribución de default diferente, por lo que los residuos conformal también difieren:

Tabla 25.1.: Heterogeneidad de residuos por grade

Grade	Tasa default	Residuos típicos	Consecuencia
A	~5 %	Pequeños (PD cercana a 0)	Intervalos estrechos
B-C	~15-20 %	Moderados	Intervalos medios
D-E	~25-35 %	Grandes	Intervalos anchos
F-G	~40-50 %	Muy grandes	Intervalos muy anchos

Con el cuantil global, Grade A recibe intervalos demasiado anchos (desperdicio de capital) y Grade G intervalos demasiado estrechos (riesgo subestimado). Mondrian corrige ambos problemas simultáneamente.

25. Mondrian: Cobertura Condicional por Grupo

Tabla 25.2.: Cobertura Mondrian por grade (test OOT, $\alpha=0.10$)

```
import sys
from pathlib import Path

sys.path.insert(0, str(Path.cwd().parent if Path.cwd().name == "book" else Path.cwd()))
from book._helpers.load_artifacts import load_parquet

import pandas as pd

df = load_parquet("conformal_group_metrics_mondrian")

# Select key columns for display
if "grade" in df.columns and "empirical_coverage_90" in df.columns:
    cols = [c for c in ["grade", "n_test", "empirical_coverage_90", "avg_width_90", "median_width_90"]]
    display = df[cols].copy()
    display.columns = ["Grade", "N Test", "Cobertura 90%", "Ancho Medio", "Ancho Mediano"]
    display
elif "group" in df.columns:
    display = df.head(7)
    display
else:
    df.head(7)
```

25.0.3. Implementación

```
# Partición Mondrian por grade (simplificado)
from mapie.regression import SplitConformalRegressor

for grade in ["A", "B", "C", "D", "E", "F", "G"]:
    mask_cal = X_cal["grade"] == grade
    mask_test = X_test["grade"] == grade

    scr = SplitConformalRegressor(
        estimator=prob_reg, confidence_level=0.90, prefit=True
    )
    scr.fit(X_cal[mask_cal], y_cal[mask_cal])
    scr.conformalize(X_cal[mask_cal], y_cal[mask_cal])

    y_pred_g, intervals_g = scr.predict_interval(X_test[mask_test])
```

25.0.4. Resultados: Cobertura por Grade

La cobertura mínima por grupo es **89.0 %** (cercana al target de 90 %), comparada con el 59.5 % del

Tabla 25.3.: Comparación: Split Conformal Global vs Mondrian

```
from book._helpers.load_artifacts import load_json

status = load_json("conformal_policy_status", search_models=True)

comparison = [
    {"Método": "Split Global", "Cobertura 90%": "89.6%",
     "Min. por Grade": "59.5%", "Ancho Medio": "0.947", "Winkler": "1.109"},
    {"Método": "Mondrian (grade)", "Cobertura 90%": f"{status['coverage_90']:.1%}",
     "Min. por Grade": f"{status['min_group_coverage_90']:.1%}",
     "Ancho Medio": f"{status['avg_width_90']:.3f}", "Winkler": f"{status['winkler_90']:.3f}"}
]

pd.DataFrame(comparison)
```

split conformal global. Este es el beneficio fundamental de Mondrian: la garantía se cumple **dentro de cada segmento de riesgo**, no solo en promedio.

25.0.5. Métricas Agregadas Mondrian vs Global

💡 Eficiencia vs Cobertura

Mondrian logra mejor cobertura mínima por grupo (89.0 % vs 59.5 %) con un ancho promedio **menor** (0.755 vs 0.947). Esto parece contradictorio, pero se explica porque Mondrian ajusta los intervalos a cada grupo: grades de bajo riesgo reciben intervalos estrechos (no desperdician ancho), mientras que grades de alto riesgo reciben intervalos adecuadamente anchos. El resultado neto es menor ancho promedio con mejor cobertura condicional.

25.0.6. Trade-off: Tamaño de Grupo

Mondrian requiere suficientes observaciones de calibración por grupo para que el cuantil empírico sea confiable. Con $n_{\text{cal}} = 237,584$ y 7 grades, cada grupo tiene $\sim 34,000$ observaciones — más que suficiente. Si la partición fuera más fina (e.g., $\text{sub_grade} \times \text{term}$), algunos grupos tendrían pocas observaciones y la cobertura se degradaría.

Tabla 25.4.: Trade-off granularidad vs estabilidad

Partición	Grupos	Min. por grupo	Cobertura mínima
Grade (A-G)	7	$\sim 10,000$	89.0 %
Score decile	10	$\sim 23,000$	89.7 %
Grade $\times$ scoreband	~ 42	~ 500	75.6 %

25. Mondrian: Cobertura Condicional por Grupo

La partición por **grade** es el punto óptimo para este dataset: granularidad suficiente para capturar la heterogeneidad de riesgo, con grupos lo suficientemente grandes para cobertura estable.

26. CQR y Benchmark de Variantes

26.0.1. Más Allá del Split Conformal Estándar

El split conformal con residuos absolutos produce intervalos de **ancho constante** para todas las observaciones dentro de un grupo. El **Conformalized Quantile Regression** (CQR) (Romano et al., 2019) produce intervalos **adaptativos** que se ensanchan donde el modelo es más incierto:

$$C_\alpha(x) = [\hat{q}_{\alpha/2}(x) - \hat{q}, \hat{q}_{1-\alpha/2}(x) + \hat{q}] \quad (26.1)$$

donde $\hat{q}_{\alpha/2}(x)$ y $\hat{q}_{1-\alpha/2}(x)$ son las predicciones de un modelo de cuantiles, y $\hat{q}$ es la corrección conformal que garantiza cobertura.

26.0.2. Las 7 Variantes Evaluadas

El pipeline evalúa un benchmark completo de variantes conformal para seleccionar la óptima:




Figura 26.1.: Distribución del ancho de intervalos en variantes conformales, útil para comparar eficiencia más allá de la cobertura ag

La figura Figura 26.1 ayuda a leer el benchmark con una lente adicional: no basta cubrir, también importa cuánta resolución práctica conservan los intervalos.

26.0.3. Descripción de Variantes

1. Score Decile Mondrian (Rank 1 — Seleccionado)

Particiona por deciles del score predicho en lugar de por grade. Produce 10 grupos homogéneos en score, lo que captura la heterogeneidad de incertidumbre directamente desde el modelo.

2. Cross Conformal Score-Space

Tabla 26.1.: Benchmark de 7 variantes conformal (test OOT, $\alpha=0.10$)

```
import sys
from pathlib import Path

sys.path.insert(0, str(Path.cwd().parent if Path.cwd().name == "book" else Path.cwd()))
from book._helpers.load_artifacts import load_parquet

import pandas as pd

df = load_parquet("conformal_variant_selection_report")

cols = ["variant", "coverage", "avg_width", "min_group_coverage",
        "winkler_90", "promotion_pass", "selection_rank"]
available = [c for c in cols if c in df.columns]
display = df[available].copy()
display.columns = [c.replace("_", " ").title() for c in available]
display
```

Usa validación cruzada con un regresor lineal ligero en el espacio de scores, evitando reentrenar CatBoost. Cobertura 90.2% pero menor estabilidad por grupo (min 85.8%).

3. Global Split (Baseline)

Split conformal sin partición. Cobertura marginal 89.6% pero min por grade de solo 59.5% — inaceptable para uso en producción.

4-5. Mondrian Unscaled / Scaled

Mondrian por grade con y sin escalado de scores. Cobertura 89.3% con min por grade de 84.6% — mejor que global pero inferior al score-decile.

6. Grade $\times$ Scoreband Mondrian

Partición fina (grade $\times$ bandas de score): ~42 grupos. Cobertura 91.5% pero 23 grupos requieren fallback por tamaño insuficiente, y min por grupo cae a 75.6%.

7. Mondrian Selected Config

Configuración con alpha ajustado a 0.07 y min_group_size de 4,000. Cobertura 93.5% — sobre-cubre significativamente, con intervalos excesivamente anchos (Winkler 1.04).

26.0.4. Criterios de Selección

La selección sigue un orden lexicográfico de prioridades:

1. **Cobertura target** (90%): elimina variantes sub-cobertura
2. **Min group coverage** 85%: garantiza equidad por segmento
3. **Menor Winkler score**: mide eficiencia (penaliza intervalos anchos)

4. Estabilidad temporal: baja varianza mensual

Winkler Score

El Winkler score (Winkler, 1972) penaliza simultáneamente intervalos que no cubren (penalidad por miss) e intervalos excesivamente anchos. Para un intervalo $[l, u]$ y valor verdadero y :

$$W = \begin{cases} (u - l) + \frac{2}{\alpha}(l - y) & \text{si } y < l \\ (u - l) & \text{si } l \leq y \leq u \\ (u - l) + \frac{2}{\alpha}(y - u) & \text{si } y > u \end{cases} \quad (26.2)$$

Menor Winkler = intervalos más estrechos que aún cubren correctamente.

26.0.5. El Score-Decile Mondrian como Champion

La variante seleccionada (score-decile Mondrian) combina las mejores propiedades:

Tabla 26.2.: Propiedades del score-decile Mondrian

Propiedad	Valor	Interpretación
Cobertura empírica	91.4 %	+1.4pp sobre target
Min group coverage	89.7 %	Cercano a 90 % en todos los deciles
Ancho promedio	0.796	Menor que global (0.947)
Winkler	1.098	Mejor que la mayoría
Fallback groups	0	Todos los grupos son viables

Pero en producción usamos grade Mondrian

El score-decile gana el benchmark, pero para la optimización de portafolio y IFRS9 usamos **grade Mondrian** como variante operativa. La razón es práctica: los grades (A-G) tienen significado regulatorio y de negocio — los intervalos por grade alimentan directamente la asignación de capital y el staging IFRS9. El score-decile queda como referencia para validar que no perdemos eficiencia material al usar grades.

27. Backtest y Monitoreo de Cobertura

27.0.1. ¿Por Qué Backtesting Temporal?

La garantía de cobertura conformal es **marginal** sobre el conjunto de test. Pero si la cobertura fuera 95 % en 2018, 85 % en 2019 y 90 % en 2020, el promedio sería ~90 % aunque existieran períodos de sub-cobertura. El **backtesting mensual** verifica que la cobertura se mantiene estable mes a mes a lo largo de los 33 meses del período OOT (enero 2018 – septiembre 2020).

27.0.2. Metodología de Backtest

Para cada mes t del período de test:

1. Seleccionar préstamos originados en el mes t
2. Calcular la tasa de violación: $\hat{\alpha}_t = \frac{1}{n_t} \sum_{i:t_i=t} \mathbb{1}\{y_i \notin [l_i, u_i]\}$
3. Comparar $\hat{\alpha}_t$ contra el α nominal (0.10)
4. Clasificar como alerta si $\hat{\alpha}_t > \alpha + \epsilon$ (margen de tolerancia)

27.0.3. Tests Estadísticos de Cobertura

El framework de backtesting implementa dos tests formales de la literatura de Value-at-Risk:

Test de Kupiec (Proporción de Fallos)

El test de Kupiec (Kupiec, 1995) evalúa si la tasa de violación observada es consistente con el α nominal:

$$LR_{uc} = -2 \ln \left[\frac{\alpha^v (1 - \alpha)^{n-v}}{\hat{\alpha}^v (1 - \hat{\alpha})^{n-v}} \right] \sim \chi^2(1) \quad (27.1)$$

donde v es el número de violaciones y $\hat{\alpha} = v/n$.

Test de Christoffersen (Independencia)

El test de Christoffersen (Christoffersen, 1998) añade una segunda dimensión: verifica que las violaciones son **independientes** (no agrupadas en clusters):

$$LR_{cc} = LR_{uc} + LR_{ind} \sim \chi^2(2) \quad (27.2)$$

donde LR_{ind} testea la propiedad de Markov en la secuencia de violaciones.

Tabla 27.1.: Resumen del backtesting mensual de cobertura conformal

```

import sys
from pathlib import Path

sys.path.insert(0, str(Path.cwd().parent if Path.cwd().name == "book" else Path.cwd()))
from book._helpers.load_artifacts import load_parquet, load_json

import pandas as pd

status = load_json("conformal_policy_status", search_models=True)

backtest_summary = [
    {"Métrica": "Período de backtest", "Valor": "2018-01 a 2020-09 (33 meses)"},
    {"Métrica": "Cobertura promedio mensual", "Valor": f"{status['coverage_90']:.2%}"},
    {"Métrica": "Alertas warning", "Valor": str(status['warning_alerts'])},
    {"Métrica": "Alertas críticas", "Valor": str(status['critical_alerts'])},
    {"Métrica": "Último mes evaluado", "Valor": status.get('latest_backtest_month', 'N/A')[:7]},
    {"Métrica": "Tasa de violación @ 90%", "Valor": f"{status['statistical_tests']['kupiec_90']}"}
]

pd.DataFrame(backtest_summary)

```


Tabla 27.2.: Resultados de tests estadísticos de cobertura

```
tests = status["statistical_tests"]

test_results = [
    {"Test": "Kupiec @ 90%",
     "LR Statistic": f"{tests['kupiec_90']['lr_statistic']:.1f}",
     "p-value": f"{tests['kupiec_90']['p_value']:.4f}",
     "Rechaza H ": "Sí",
     "Violaciones": f"{tests['kupiec_90']['n_violations'],} / {tests['kupiec_90']['n_total']:"},
    {"Test": "Kupiec @ 95%",
     "LR Statistic": f"{tests['kupiec_95']['lr_statistic']:.1f}",
     "p-value": f"{tests['kupiec_95']['p_value']:.4f}",
     "Rechaza H ": "Sí",
     "Violaciones": f"{tests['kupiec_95']['n_violations'],} / {tests['kupiec_95']['n_total']:"},
    {"Test": "Christoffersen Indep. @ 90%",
     "LR Statistic": f"{tests['christoffersen_90']['lr_ind']:.2f}",
     "p-value": f"{tests['christoffersen_90']['p_ind']:.4f}",
     "Rechaza H ": "No",
     "Violaciones": "-"},
    {"Test": "Christoffersen Indep. @ 95%",
     "LR Statistic": f"{tests['christoffersen_95']['lr_ind']:.2f}",
     "p-value": f"{tests['christoffersen_95']['p_ind']:.4f}",
     "Rechaza H ": "Sí",
     "Violaciones": "-"},
]

pd.DataFrame(test_results)
```

27.0.5. Policy Gate

El pipeline implementa un **policy gate** que decide si los intervalos conformal pueden ser promovidos a producción:

Tabla 27.3.: Policy gate de cobertura conformal

Check	Criterio	Resultado
Cobertura @ 90 % 87 %	Materialidad	PASS
Cobertura @ 95 % 92 %	Materialidad	PASS
Min group coverage 85 %	Equidad	PASS
Winkler @ 90 % 1.22	Eficiencia	PASS (compensado)
Alertas críticas = 0	Estabilidad	PASS
Kupiec $p > 0.05$	Diagnóstico	FAIL (warning)
Christoffersen $p > 0.05$	Diagnóstico	FAIL (warning)

Los checks no estadísticos pasan (9/9). Los tests estadísticos fallan (4/4), pero la **justificación metodológica** los declara no-bloqueantes: la sobre-cobertura es preferible a la sub-cobertura, las violaciones son independientes @ 90 %, y la desviación está dentro del margen de materialidad.

27.0.6. Alertas y Monitoreo Continuo

El sistema de alertas clasifica anomalías en dos niveles:

- **Warning** (amarillo): cobertura mensual entre 85 % y 88 %, o Winkler elevado. Requiere investigación pero no bloquea.
- **Crítica** (rojo): cobertura mensual $< 85 \%$, o > 3 warnings consecutivos. Bloquea promoción y requiere recalibración.

El resultado del backtest actual: **0 alertas críticas, 4 warnings** (todos por los tests estadísticos rechazados, no por sub-cobertura real).

28. Intervalos Conformal para LGD y EAD

28.0.1. Más Allá de la PD: Incertidumbre en los Tres Componentes

La fórmula ECL tiene tres inputs estocásticos: PD, LGD y EAD. Cuantificar incertidumbre solo en PD es un avance, pero incompleto — un LGD puntual de 0.40 ignora que la pérdida real puede ser 0.15 o 0.65 dependiendo del colateral, la recuperación y las condiciones de mercado. El pipeline extiende la predicción conformal a **los tres componentes**.

28.0.2. LGD Conformal: Adaptive Grade-Temporal

La LGD (Loss Given Default) se modela solo sobre préstamos en default ($n = 362,981$, ~88 % del dataset tiene LGD nula porque no defaultó). El modelo enfrenta dos desafíos específicos:

1. **Distribución bimodal:** LGD concentrada en ~0 (recuperación total) y ~1 (pérdida total)
2. **Heterogeneidad extrema por grade:** Grade A tiene LGD media de ~0.10, Grade G de ~0.50

28.0.2.1. Benchmark de Variantes LGD

Se evaluaron 4 variantes para encontrar la que cumpla cobertura por grade:

i ¿Por qué las variantes estándar fallan?

Las variantes `two_stage_split`, `direct_split` y `direct_cqr` logran ~78 % de cobertura (vs 90 % target) porque la distribución de LGD es altamente heterogénea: los residuos de Grade A son radicalmente diferentes de los de Grade G. Solo la variante **adaptive grade-temporal** — que calcula cuantiles adaptativos por grade con corrección temporal — logra cobertura adecuada en todos los segmentos.

La variante promovida (`direct_adaptive_grade_temporal`) usa tres mecanismos:

1. **Quantiles adaptativos por grade:** cada grade tiene su propio cuantil conformal
2. **Corrección temporal:** offsets por grade que compensan drift entre calibración y test
3. **Parámetros de política:** `eta=0.12`, `offset_rho=0.03`, `maturity_uncertainty_lambda=0.25`

Tabla 28.1.: Métricas del modelo LGD y sus intervalos conformal

```

import sys
from pathlib import Path

sys.path.insert(0, str(Path.cwd().parent if Path.cwd().name == "book" else Path.cwd()))
from book._helpers.load_artifacts import load_json

import pandas as pd

status = load_json("conformal_policy_status", search_models=True)
lgd = status.get("lgd_ead_conformal_status", {}).get("lgd", {})

lgd_metrics = [
    {"Métrica": "MAE (modelo directo)", "Valor": f"{lgd['model_metrics']['direct']['lgd_mae']:"},
    {"Métrica": "RMSE (modelo directo)", "Valor": f"{lgd['model_metrics']['direct']['lgd_rmse']:"},
    {"Métrica": "Cobertura empírica @ 90%", "Valor": f"{lgd['conformal']['metrics_90']['empiri"},
    {"Métrica": "Cobertura empírica @ 95%", "Valor": f"{lgd['conformal']['metrics_95']['empiri"},
    {"Métrica": "Ancho promedio @ 90%", "Valor": f"{lgd['conformal']['metrics_90']['avg_interv"},
    {"Métrica": "Min coverage por grade @ 90%", "Valor": f"{lgd['guardrails']['min_grade_cover"},
    {"Métrica": "Variante seleccionada", "Valor": lgd.get('selected_variant', 'N/A')},
    {"Métrica": "N test", "Valor": f"{lgd.get('n_test', 0):,}"},
]

pd.DataFrame(lgd_metrics)

```

Tabla 28.2.: Benchmark de variantes conformal para LGD

```

variants = lgd.get("benchmark_variants", [])

variant_data = []
for v in variants:
    variant_data.append({
        "Variante": v["variant"].replace("_", " ").title(),
        "Cobertura 90%": f"{v['coverage_90']:.1%}",
        "Min Grade 90%": f"{v['min_grade_coverage_90']:.1%}",
        "Ancho 90%": f"{v['avg_width_90']:.3f}",
        "PASS": " " if v["overall_pass"] else " ",
    })

pd.DataFrame(variant_data)

```

Tabla 28.3.: Métricas del modelo EAD y sus intervalos conformal

```
ead = status.get("lgd_ead_conformal_status", {}).get("ead", {})

ead_metrics = [
    {"Métrica": "MAE", "Valor": f"${ead['model_metrics']['ead_mae']:.2f}"},
    {"Métrica": "R²", "Valor": f"${ead['model_metrics']['ead_r2']:.6f}"},
    {"Métrica": "Cobertura empírica @ 90%", "Valor": f"${ead['conformal']['metrics_90']['empiri..."},
    {"Métrica": "Cobertura empírica @ 95%", "Valor": f"${ead['conformal']['metrics_95']['empiri..."},
    {"Métrica": "Ancho promedio @ 90%", "Valor": f"${ead['conformal']['metrics_90']['avg_inter..."},
    {"Métrica": "N test", "Valor": f"${ead.get('n_test', 0):,}"},
]

pd.DataFrame(ead_metrics)
```

28.0.3. EAD Conformal

La EAD (Exposure at Default) se modela como regresión directa sobre el monto expuesto al momento del default. A diferencia de LGD, EAD tiene una distribución más regular y predecible.

El R^2 de 0.9997 indica que EAD es casi completamente predecible (el monto de exposición es en gran medida determinístico). Los intervalos conformal son estrechos (\$198 promedio @ 90 %) y la cobertura es precisa (90.04 % vs 90 % target).

💡 EAD vs LGD: Niveles de Dificultad Opuestos

EAD es el componente “fácil” — casi determinístico con $R^2 > 0.999$. LGD es el componente “difícil” — bimodal, heterogéneo, y con MAE de 0.19. PD está en el medio. Esta asimetría implica que la incertidumbre en ECL viene principalmente de PD y LGD, no de EAD.

28.0.4. Impacto en ECL con Intervalos Completos

Con intervalos conformal para los tres componentes (PD, LGD, EAD), el cálculo de ECL pasa de un punto a un **rango**:

$$ECL_{\text{low}} = PD_{\text{low}} \times LGD_{\text{low}} \times EAD_{\text{low}} \times DF \quad (28.1)$$

$$ECL_{\text{high}} = PD_{\text{high}} \times LGD_{\text{high}} \times EAD_{\text{high}} \times DF \quad (28.2)$$

Esto transforma las provisiones IFRS9 de un ejercicio de punto a un ejercicio de **bandas de incertidumbre**, donde el ancho de la banda refleja la confianza del modelo en cada préstamo. Los detalles de esta propagación se discuten en Capítulo 41.

28.0.5. Guardrails de Calidad

Antes de promover los intervalos LGD/EAD a producción, se verifican guardrails automáticos:


Tabla 28.4.: Guardrails de calidad para intervalos LGD/EAD

Guardrail	Criterio	LGD	EAD
Cobertura @ 90 %	89 %	90.5 %	90.0 %
Cobertura @ 95 %	94 %	95.5 %	94.1 %
Min grade coverage	88 %	90.5 %	—
Width inflation	1.10	0.87	—
Overall	All pass		

29. Supervivencia, Series de Tiempo e Inferencia Causal

Los capítulos anteriores construyeron un modelo PD calibrado con intervalos conformal (Capítulo 24) y un portafolio robusto. Sin embargo, la predicción cross-sectional responde *quién* puede incumplir, pero omite tres preguntas igualmente relevantes para la gestión de riesgo: *cuándo* ocurre el incumplimiento, *hacia dónde* se dirige la tasa agregada de default, y *por qué* — en sentido causal — ciertos factores afectan el resultado.

Este capítulo integra tres familias de modelos que añaden la **dimensión temporal y causal** al pipeline:



(a) Panorama temporal agregado del portafolio usado en forecasting y provisiones.

i Conexión con el pipeline principal

Cada bloque consume artefactos del pipeline PD (Capítulo 20) e intervalos conformal (Capítulo 24), y produce insumos para provisiones IFRS9 (Capítulo 41) o para la optimización de portafolio (Capítulo 36). La cadena es: **predicción cross-sectional** → **dimensión temporal** → **decisión causal** → **validación A/B**.

Tabla 29.1.: Resumen de los bloques temporales y causales del pipeline

```
import pandas as pd

overview = [
    {"Bloque": "Supervivencia", "Pregunta": "Cuándo ocurre el default",
     "Modelos": "Cox PH, RSF, CIF (Aalen-Johansen)", "Métrica clave": "C-index RSF = 0.6797",
     "Uso IFRS9": "PD lifetime (Stage 2)"},
    {"Bloque": "Series de Tiempo", "Pregunta": "Hacia dónde va la tasa agregada",
     "Modelos": "AutoARIMA, AutoETS, StatsForecast", "Métrica clave": "temporal_pd_mult = 1.01",
     "Uso IFRS9": "Escenarios macro (baseline/adverse)"},
    {"Bloque": "Inferencia Causal", "Pregunta": "Por qué (efecto causal de la tasa)",
     "Modelos": "DoWhy + CausalForestDML (EconML)", "Métrica clave": "ATE = +0.00974 pp",
     "Uso IFRS9": "Política de precio por segmento"},
    {"Bloque": "Simulación A/B", "Pregunta": "Cuánto vale la robustez",
     "Modelos": "Bootstrap, permutación, t-test", "Métrica clave": "Significancia estadística",
     "Uso IFRS9": "Validación económica retrospectiva"},
]

pd.DataFrame(overview)
```


30. Análisis de Supervivencia

30.0.1. De la PD Puntual a la PD Temporal

Un modelo de clasificación binaria asigna a cada préstamo una probabilidad de incumplimiento (PD), pero no dice *cuándo* podría ocurrir ese incumplimiento. Dos préstamos con $PD = 10\%$ tienen riesgo nominal idéntico; sin embargo, si uno incumple en el mes 3 y otro en el mes 48, la pérdida económica real es radicalmente diferente — el primero apenas ha amortizado capital, mientras que el segundo ya ha devuelto la mayor parte del saldo.

El análisis de supervivencia modela explícitamente el **tiempo hasta el evento** (time-to-default), generando curvas de probabilidad acumulada a cualquier horizonte temporal. Esto es un insumo directo para:

- **IFRS9 Stage 2:** Provisiones basadas en PD lifetime, no en PD a 12 meses.
- **Priorización de seguimiento:** Préstamos con riesgo de incumplimiento temprano requieren intervención inmediata.
- **Valoración de cartera:** El timing del default afecta los flujos de caja descontados.

30.0.2. Modelos Implementados

30.0.2.1. Cox Proportional Hazards

El modelo de Cox PH (Cox, 1972) es semi-paramétrico: estima la **función de riesgo instantáneo** (hazard) como el producto de un baseline hazard no especificado y un componente multiplicativo de covariables:

$$h(t | \mathbf{x}) = h_0(t) \exp(\beta^T \mathbf{x}) \quad (30.1)$$

donde $h_0(t)$ es el baseline hazard y β son los coeficientes que se interpretan como log-hazard ratios. Un hazard ratio $\exp(\beta_j) > 1$ indica que un incremento unitario en x_j aumenta proporcionalmente el riesgo de default en cualquier instante t .

La implementación utiliza `lifelines.CoxPHFitter` con penalización L2 ($\lambda = 0.01$) para estabilidad numérica:

```
from lifelines import CoxPHFitter

cph = CoxPHFitter(penalizer=0.01)
cph.fit(df[cols], duration_col="time_to_event", event_col="event_observed")
```

i Supuesto de proporcionalidad

El modelo Cox PH asume que los hazard ratios son constantes en el tiempo — la función `check_assumptions()` valida este supuesto mediante tests de Schoenfeld. Cuando se viola, el RSF es preferible porque no impone restricciones sobre la forma de la relación hazard-covariables.

30.0.2.2. Random Survival Forest (RSF)

El Random Survival Forest (Ishwaran et al., 2008) es un ensemble de árboles de supervivencia que estima la función de supervivencia $S(t | \mathbf{x}) = P(T > t | \mathbf{x})$ de forma no paramétrica. A diferencia de Cox PH, el RSF captura interacciones y no-linealidades sin requerir el supuesto de proporcionalidad.

La configuración utilizada en el proyecto:

```
from sksurv.ensemble import RandomSurvivalForest

rsf = RandomSurvivalForest(
    n_estimators=500,
    min_samples_split=10,
    min_samples_leaf=5,
    max_features="sqrt",
    random_state=42,
    n_jobs=-1,
)
```

La métrica de evaluación es el **C-index** (concordancia de Harrell): la probabilidad de que, dados dos préstamos, el modelo ordene correctamente cuál incumple primero. Un C-index de 0.5 es aleatorio; 1.0 es perfecto. El RSF alcanza un **C-index = 0.6797** en el conjunto OOT, indicando capacidad discriminativa moderada — consistente con la dificultad inherente de predecir el timing exacto de default en crédito al consumo.

30.0.3. Riesgos Competitivos y la Función de Incidencia Acumulada

Un préstamo no solo puede hacer default: también puede **prepagar** antes de su vencimiento. Estos dos eventos compiten entre sí, y tratarlos correctamente requiere un marco de **riesgos competitivos** (competing risks).

El estimador estándar de Kaplan-Meier ignora los riesgos competitivos: trata los prepagos como censura, lo que **sobreestima** la probabilidad acumulada de default. El estimador de **Aalen-Johansen** calcula la **Cumulative Incidence Function** (CIF) correcta, separando las probabilidades acumuladas de default y prepago:

$$\text{CIF}_k(t) = \int_0^t S(u^-) dH_k(u) \quad (30.2)$$

donde $S(u^-)$ es la supervivencia global justo antes de u y H_k es el hazard acumulado causa-específico para el evento k .

⚠ KM vs CIF: Sobreestimación del 26.7 %

En el dataset, Kaplan-Meier sobreestima la PD lifetime en **26.7 %** respecto a la CIF correcta. Esto se traduce en un exceso de reserva de **\$125.8M** (12.6 % de la provisión ECL calculada con KM). Para provisiones IFRS9, la CIF debe usarse siempre que existan eventos competitivos — lo cual es la norma en carteras de crédito al consumo.

La implementación en `src/models/survival.py` utiliza `sksurv.nonparametric.cumulative_incidence_competing_risks` con estratificación por grado:

```
from sksurv.nonparametric import cumulative_incidence_competing_risks

# status_encoded: 0=censored, 1=default, 2=prepayment
result = cumulative_incidence_competing_risks(
    status_encoded, time, conf_level=0.95, conf_type="log-log"
)
```




Figura 30.1.: Curvas de supervivencia y default acumulado por segmento, generadas desde los notebooks del bloque temporal y de supervivencia.

La figura Figura 30.1 aterriza la intuición temporal: no basta con saber quién es riesgoso; importa cuándo emerge ese riesgo y cómo difiere entre segmentos.

30.0.4. Curvas de PD Lifetime para IFRS9

La función `generate_lifetime_pd_curve()` genera probabilidades acumuladas de default a intervalos de 30 días hasta 5 años (60 meses), que son el insumo directo para el cálculo de ECL lifetime en IFRS9 Stage 2:

Tabla 30.1.: Resumen de modelos de supervivencia y métricas clave

```

import sys
from pathlib import Path

sys.path.insert(0, str(Path.cwd().parent if Path.cwd().name == "book" else Path.cwd()))
from book._helpers.load_artifacts import try_load_json

import pandas as pd

summary = try_load_json("pipeline_summary")
surv = summary.get("survival", {})

rows = [
    {"Modelo": "Cox PH", "Tipo": "Semi-paramétrico",
     "C-index": f"{surv.get('cox_concordance', 0):.4f}",
     "Ventaja": "Interpretable (hazard ratios)", "Limitación": "Supuesto de proporcionalidad"},
    {"Modelo": "RSF (500 árboles)", "Tipo": "Ensemble no paramétrico",
     "C-index": f"{surv.get('rsf_concordance', 0):.4f}",
     "Ventaja": "Captura no-linealidades", "Limitación": "Menos interpretable"},
    {"Modelo": "CIF (Aalen-Johansen)", "Tipo": "No paramétrico",
     "C-index": "---",
     "Ventaja": "Riesgos competitivos correctos", "Limitación": "No condicional a covariables"}
]

pd.DataFrame(rows)

```

$$PD_{\text{lifetime}}(t) = 1 - S(t \mid \mathbf{x})$$

💡 Conexión con el pipeline

Las curvas de PD lifetime alimentan directamente el cálculo de ECL en Capítulo 41. La corrección CIF → KM evita sobreprovisionar por \$125.8M. Los hazard ratios de Cox PH complementan la interpretación de los coeficientes SHAP del modelo PD (Capítulo 47), proporcionando una perspectiva temporal sobre los mismos drivers de riesgo.

31. Pronóstico de Series de Tiempo

31.0.1. Motivación: El Default Agregado como Señal Macro

Mientras que la PD modela el riesgo individual de cada préstamo, la **tasa de default agregada mensual** captura dinámicas de nivel portafolio que no son visibles desde la predicción cross-sectional: estacionalidad, tendencias macroeconómicas y cambios de régimen. Estas señales temporales son el insumo para:

- **Escenarios IFRS9:** Los multiplicadores `temporal_pd_baseline_mult` ajustan la PD puntual según el régimen temporal proyectado.
- **Planeación de provisiones:** Anticipar deterioro antes de que se materialice en defaults realizados.
- **Apetito de riesgo:** Ajustar políticas de originación según la tendencia proyectada.

El dataset de series de tiempo (`time_series.parquet`) contiene 118 observaciones mensuales agregadas con formato Nixtla-ready (`unique_id`, `ds`, `y`), donde `y` es la tasa de default mensual del portafolio.

31.0.2. Framework de Pronóstico Gobernado

El módulo `src/models/time_series.py` implementa un framework completo de pronóstico con selección automática de champion, backtest por rolling-origin y gobernanza de estado (oficial vs. exploratorio):

31.0.2.1. Modelos Candidatos

La librería `StatsForecast` provee los modelos estadísticos base, todos evaluados en backtest:

Modelo	Familia	Descripción
SeasonalNaive	Benchmark	Repite el valor de hace 12 meses
AutoARIMA	Estadístico	Selección automática de orden (p,d,q)(P,D,Q)
AutoETS	Estadístico	Error-Trend-Seasonality con selección por AIC
AutoTheta	Estadístico	Método Theta con descomposición
SARIMAX	Challenger	ARIMA estacional con covariables exógenas

31. Pronóstico de Series de Tiempo

Modelo	Familia	Descripción
STL_CatBoost	ML	Descomposición STL + residuos con CatBoost

La selección de champion sigue una política declarativa configurada en `configs/time_series.yaml`: la métrica primaria es **MASE** (Mean Absolute Scaled Error), con desempates por RMSSE y sesgo absoluto. El champion debe superar al SeasonalNaive para ser promovido a estado oficial.

31.0.2.2. Backtest por Rolling-Origin

A diferencia del train/test split único, el backtest utiliza **rolling-origin** con ventanas expandibles:

- **Entrenamiento mínimo:** 72 periodos (6 años).
- **Horizonte:** 12 meses adelante.
- **Paso:** 1 mes entre cutoffs sucesivos.
- **Máximo de ventanas:** 36 (3 años de evaluación).

Esta estrategia evalúa la estabilidad del pronóstico a lo largo de distintos regímenes temporales, no solo sobre un corte fijo.

31.0.3. Estado del Pronóstico: Oficial vs. Exploratorio

⚠ Status: `research_only`

El bloque de series de tiempo tiene status **research_only** en el pipeline actual. Esto significa que los pronósticos se generan y evalúan, pero no se promueven automáticamente a insumos oficiales para IFRS9 o decisiones de portafolio. La promoción requiere evidencia suficiente de backtest (cobertura y calibración) según la política de gobernanza.

El framework distingue tres niveles de estado:

1. **oficial:** Backtest satisfactorio, cobertura de intervalos dentro de tolerancia, champion supera benchmark. El pronóstico puede usarse como insumo de provisiones.
2. **warn:** Métricas cercanas al umbral. Se genera el pronóstico pero con alertas de gobernanza.
3. **research_only:** Evidencia insuficiente. El pronóstico es informativo pero no se usa en decisiones automatizadas.

31.0.4. Escenarios IFRS9 y Multiplicador Temporal

El pronóstico genera tres escenarios para el cálculo de ECL:

$$PD_{ajustada} = PD_{puntual} \times \text{temporal_pd_baseline_mult} \quad (31.1)$$




Figura 31.1.: Comparación de modelos en validación cruzada rolling-origin para series de tiempo.

donde `temporal_pd_baseline_mult` es el ratio entre la PD promedio proyectada y la PD promedio histórica. En el run champion, este multiplicador es **1.017154**, indicando un deterioro marginal proyectado del 1.7 % respecto al baseline histórico.

La figura Figura 31.2 deja visible la propagación de incertidumbre temporal: un abanico relativamente moderado en la tasa agregada se amplifica al pasar por LGD y EAD.

31.0.5. Propagación de Intervalos a ECL

Los intervalos de pronóstico temporal se propagan de forma no lineal al cálculo de ECL. En el análisis de Paper 2, la banda de ECL resultante es de **\$288.5M** (267 % del ECL puntual de \$107.9M), con un escenario adverso de \$336M versus un optimista de \$47.5M. Esta amplificación refleja que la incertidumbre en forecasts cercanos a cero se propaga de forma no lineal cuando se multiplica por LGD y EAD.

💡 Conexión con el pipeline

El multiplicador temporal alimenta el cálculo de ECL en Capítulo 41. Los escenarios adverso/optimista definen la banda de provisiones bajo distintas hipótesis macro. La reconciliación jerárquica (cuando está habilitada) garantiza consistencia entre pronósticos a nivel portafolio y por grado/plazo.

Tabla 31.1.: Escenarios temporales para ajuste de PD en IFRS9

```
import pandas as pd

scenarios = [
    {"Escenario": "Optimista (P10)", "Descripción": "Banda inferior del intervalo de pronóstico",
     "Uso": "Piso de provisiones", "Fuente": "y_lo_90 del forecast"},
    {"Escenario": "Baseline", "Descripción": "Pronóstico puntual del champion",
     "Uso": "Provisión central (temporal_pd_mult = 1.017)",
     "Fuente": "y del forecast"},
    {"Escenario": "Adverso (P90)", "Descripción": "Banda superior del intervalo de pronóstico",
     "Uso": "Techo de provisiones / stress test",
     "Fuente": "y_hi_90 del forecast"},
]

pd.DataFrame(scenarios)
```




chart del forecast IFRS9 con bandas de incertidumbre y escenarios baseline, optimista y adverso.

32. Inferencia Causal

32.0.1. De Correlación a Causalidad en Riesgo de Crédito

En el dataset de Lending Club, los préstamos con tasas de interés altas tienen más defaults. Pero, la tasa alta *causa* más defaults? O simplemente se cobra más a quienes ya eran riesgosos? Responder esta pregunta requiere pasar de asociación estadística a **estimación causal**, distinguiendo la relación correlacional (útil para predicción) de la relación causal (necesaria para intervención).


Esta distinción es operativamente crítica:

- **Correlación:** “Los préstamos con tasa $>20\%$ tienen 24% de default” — describe el pasado, útil para scoring.
- **Causalidad:** “Si movemos la tasa 1pp, el default esperado cambia en $+0.00974\text{pp}$ ” — permite diseñar políticas de precio.

El pipeline causal combina **DoWhy** para identificación y refutación con **EconML** para estimación heterogénea, siguiendo el marco de Double Machine Learning (Chernozhukov et al., 2018).

32.0.2. Grafo Causal y Estrategia de Identificación

La identificación del efecto causal requiere especificar un **DAG** (Directed Acyclic Graph) con las relaciones causales asumidas. El grafo oficial del proyecto establece:



(a) Intervalo de confianza del ATE para la tasa de interés como tratamiento.

La estrategia de identificación es **backdoor adjustment**: condicionando sobre los confusores (grade_woe, purpose_woe, home_ownership_woe), la asignación de tratamiento (tasa de interés) se vuelve *as-if* aleatoria, permitiendo estimar el efecto causal.

i Supuestos de identificación

La estimación causal observacional requiere tres supuestos clave:

1. **Ignorabilidad condicional:** No hay confusores no observados que afecten simultáneamente tasa y default.
2. **Overlap (positividad):** Para cada combinación de confusores, existen observaciones con diferentes niveles de tasa.
3. **Consistencia temporal:** Las covariables estaban disponibles al momento de la originación.

Estos supuestos son no testables directamente, pero las **refutaciones de DoWhy** proporcionan evidencia indirecta de su plausibilidad.

32.0.3. Double Machine Learning (DML)

El framework DML (Chernozhukov et al., 2018) estima el efecto causal en dos etapas, usando modelos de machine learning flexibles para controlar confusores sin imponer formas funcionales:

Etapla 1 — Nuisance estimation:

$$\hat{Y}_{\text{res}} = Y - \hat{g}(W), \quad \hat{T}_{\text{res}} = T - \hat{m}(W) \quad (32.1)$$

donde $\hat{g}$ y $\hat{m}$ son GBM (Gradient Boosting Machines) que predicen outcome y tratamiento a partir de confusores W .

Etapla 2 — Estimación del efecto:

$$\hat{Y}_{\text{res}} = \theta \cdot \hat{T}_{\text{res}} + \epsilon \quad (32.2)$$

El estimador $\hat{\theta}$ es el **Average Treatment Effect (ATE)**: el cambio promedio en la probabilidad de default por cada unidad de cambio en la tasa de interés.

32.0.4. Efecto Promedio (ATE)

El ATE estimado por DoWhy con identificación backdoor y estimación por regresión lineal es:

$$\text{ATE} = +0.00974$$

Interpretación: Un aumento de 1 punto porcentual en la tasa de interés se asocia causalmente con un incremento de **0.974 puntos porcentuales** en la probabilidad de default, controlando por grado, propósito, vivienda, DTI, ingreso, monto y FICO.

32.0.5. Efectos Heterogéneos (CATE) con CausalForestDML

El ATE es un promedio global, pero el efecto de la tasa puede variar sustancialmente entre segmentos. El **Conditional Average Treatment Effect** (CATE) captura esta heterogeneidad usando CausalForestDML (Athey & Wager, 2019):

```
from econml.dml import CausalForestDML

est = CausalForestDML(
    model_y=GradientBoostingRegressor(n_estimators=100, max_depth=4),
    model_t=GradientBoostingRegressor(n_estimators=100, max_depth=4),
    n_estimators=200,
    honest=True, # Honest splitting para inferencia válida
)
est.fit(Y=default_flag, T=int_rate, X=effect_modifiers, W=confounders)
```

Los **effect modifiers** — variables que modulan el efecto causal — son: `loan_amnt`, `annual_inc`, `dti` y `fico_range_low`. El modelo produce un CATE individual para cada préstamo, con intervalos de confianza al 95 %.




Figura 32.3.: Heterogeneidad del efecto causal de la tasa de interés por segmentos, estimada con CausalForestDML.

La figura 32.3 resume el paso de una política única a una política segmentada: el efecto de precio no es homogéneo y, por tanto, tampoco debería serlo la respuesta comercial.

💡 Interpretación operativa del CATE

- **CATE > 0:** Subir la tasa en ese segmento *aumenta* la probabilidad de default — conviene no subir o incluso reducir la tasa.
- **CATE < 0:** Subir la tasa no incrementa default o puede asociarse a mejor selección adversa — hay margen para ajustar precio.
- **CATE ≈ 0:** El efecto es nulo — la tasa no es palanca relevante en ese segmento.

Tabla 32.1.: Resumen de estimación causal: ATE, CATE y refutaciones

```

import sys
from pathlib import Path

sys.path.insert(0, str(Path.cwd().parent if Path.cwd().name == "book" else Path.cwd()))
from book._helpers.load_artifacts import try_load_json

import pandas as pd

pipeline = try_load_json("pipeline_summary")
causal = pipeline.get("causal", {})

rows = [
    {"Métrica": "ATE (int_rate → default)",
     "Valor": f"{causal.get('ate', 0.00974):.5f}",
     "Interpretación": "+1pp tasa → +0.974pp probabilidad de default"},
    {"Métrica": "CATE medio",
     "Valor": f"{causal.get('cate_mean', 0.00974):.5f}",
     "Interpretación": "Efecto promedio heterogéneo (ATE si homogéneo)"},
    {"Métrica": "Ahorro potencial (política CATE)",
     "Valor": "$41.7M",
     "Interpretación": "Reducción de pérdidas por ajuste de tasa segmentado"},
    {"Métrica": "Método de identificación",
     "Valor": "Backdoor (DoWhy)",
     "Interpretación": "Condicional sobre grade, purpose, home_ownership WOE"},
    {"Métrica": "Estimador",
     "Valor": "CausalForestDML (EconML)",
     "Interpretación": "DML con honest causal forests, 200 árboles"},
]

pd.DataFrame(rows)

```

32.0.6. Política Causal y Valor Económico

La estimación CATE permite diseñar **políticas de precio segmentadas**: ajustar la tasa de interés en los segmentos donde el efecto causal es más adverso. La simulación de política sobre el conjunto OOT estima un ahorro potencial de **\$41.7M** por reducción de defaults en segmentos con CATE alto, comparado con la política uniforme actual.

32.0.7. Refutaciones de DoWhy

La robustez del estimado causal se valida mediante tres tests de refutación estándar (Sharma & Kiciman, 2020):

1. **Placebo treatment** (permutación): Se permuta aleatoriamente el tratamiento. Si el efecto estimado persiste, la estimación original es espuria. El efecto bajo placebo debe ser cercano a cero.
2. **Random common cause**: Se añade un confusor aleatorio. Si el efecto cambia significativamente, el modelo es sensible a confusores no observados.
3. **Data subset** (80 %): Se re-estima sobre un subconjunto aleatorio. La estabilidad del efecto indica robustez ante variaciones muestrales.

Limitaciones de la inferencia observacional

Estos resultados son evidencia causal bajo supuestos de identificación — no un experimento aleatorizado. La ignorabilidad condicional no es testable directamente: si existe un confusor no observado (e.g., información privada del prestatario no capturada en las covariables), el ATE estimado podría estar sesgado. Las refutaciones proporcionan evidencia de plausibilidad, no prueba de causalidad absoluta.

Conexión con el pipeline

La estimación CATE alimenta la optimización de portafolio CATE-adjusted (Capítulo 38), donde los préstamos con CATE alto reciben penalizaciones en la función objetivo. La simulación A/B (Capítulo 33) valida retrospectivamente si incorporar esta señal causal mejora el retorno realizado. Los confusores WOE provienen del feature engineering documentado en Capítulo 15.

33. Simulación A/B: Robusto vs No-Robusto

33.0.1. Motivación: Medir el Valor de la Robustez

Los capítulos anteriores construyeron un portafolio robusto que utiliza `pd_high` (intervalo conformal superior) en lugar de `pd_point` para la restricción de PD. La pregunta operativa es directa: *vale la pena la robustez?* Es decir, la estrategia que incorpora incertidumbre cuantificada genera mejores retornos realizados que la estrategia que ignora la incertidumbre?

La simulación A/B retroactiva responde esta pregunta aplicando ambas estrategias al conjunto OOT (2018–2020) y usando los **defaults reales** como ground truth. No es un experimento aleatorizado en producción, pero proporciona evidencia empírica cuantificable sobre el valor económico de la predicción conformal.

33.0.2. Diseño del Experimento Retroactivo

El framework de A/B testing (`src/evaluation/ab_testing.py`) implementa tres componentes:

33.0.2.1. 1. Análisis de Potencia

Antes de la simulación, se estima el tamaño muestral mínimo para detectar un efecto dado:

$$n_{\text{por grupo}} = \frac{2\sigma^2(z_{\alpha/2} + z_{\beta})^2}{\delta^2} \quad (33.1)$$

donde δ es el tamaño del efecto esperado, $\alpha = 0.05$ es el nivel de significancia y $\beta = 0.20$ corresponde a una potencia del 80 %. Con la aproximación conservadora $\sigma^2 = 0.25$ para proporciones, el análisis determina si el conjunto OOT (276,869 préstamos) tiene suficiente poder estadístico.

33.0.2.2. 2. Split Estratificado

La asignación control/tratamiento se realiza con **estratificación por grade**, garantizando que ambos grupos tengan la misma distribución de riesgo base:

```
from src.evaluation.ab_testing import stratified_split

control, treatment = stratified_split(
    df_test, strata_col="grade", treatment_ratio=0.50, seed=42
)
```

Tabla 33.1.: Métricas comparadas en la simulación A/B

```
import pandas as pd

metrics = [
    {"Métrica": "Total return ($)", "Definición": "Suma de retornos realizados por préstamo",
     "Favorece": "Mayor es mejor"},
    {"Métrica": "Default rate (%)", "Definición": "Tasa de incumplimiento en préstamos seleccionados",
     "Favorece": "Menor es mejor"},
    {"Métrica": "Loans funded (#)", "Definición": "Número de préstamos aprobados",
     "Favorece": "Trade-off: más funding vs más riesgo"},
    {"Métrica": "Avg return per loan ($)", "Definición": "Retorno promedio por préstamo seleccionado",
     "Favorece": "Mayor es mejor"},
    {"Métrica": "Sharpe-like ratio", "Definición": "Return / volatilidad de retornos",
     "Favorece": "Mayor es mejor"},
]

pd.DataFrame(metrics)
```

- **Grupo A (control):** Asignación de portafolio usando `pd_point` — estrategia no robusta.
- **Grupo B (tratamiento):** Asignación usando `pd_high` (conformal upper bound) — estrategia robusta.

33.0.2.3. 3. Comparación Estadística

Los retornos realizados de cada estrategia se comparan mediante tres métodos:

Método	Descripción	Supuestos
Bootstrap	Remuestreo con reemplazo (1,000 iteraciones)	No paramétrico
Permutación	Intercambio aleatorio de etiquetas A/B	H0: distribuciones idénticas
t-test (Welch)	Comparación de medias con varianzas desiguales	Normalidad asintótica

El resultado incluye: diferencia de medias, intervalo de confianza al 95 %, p-value y veredicto de significancia.

33.0.3. Métricas de Comparación

Cada estrategia se evalúa sobre múltiples dimensiones:

Tabla 33.2.: Diseño de la simulación A/B retroactiva

```
import pandas as pd

design = [
    {"Parámetro": "Universo de evaluación", "Valor": "Conjunto OOT (2018-01 a 2020-09)"},
    {"Parámetro": "Tamaño del universo", "Valor": "276,869 préstamos"},
    {"Parámetro": "Estratificación", "Valor": "Por grade (A--G)"},
    {"Parámetro": "Ratio control/tratamiento", "Valor": "50/50"},
    {"Parámetro": "Ground truth", "Valor": "Defaults reales observados"},
    {"Parámetro": "Métodos estadísticos", "Valor": "Bootstrap, permutación, Welch t-test"},
    {"Parámetro": "Nivel de significancia", "Valor": " = 0.05 (bilateral)"},
    {"Parámetro": "PD control (A)", "Valor": "pd_point (estimación puntual calibrada)"},
    {"Parámetro": "PD tratamiento (B)", "Valor": "pd_high (bound conformal superior @ 90%)"},
]

pd.DataFrame(design)
```

33.0.4. Interpretación de Resultados

La estrategia robusta (B) típicamente selecciona **menos préstamos** que la no robusta (A), porque `pd_high > pd_point` hace que la restricción de PD sea más estricta. El trade-off fundamental es:

- **Estrategia A (no robusta):** Más préstamos aprobados, mayor funding, pero mayor exposición a defaults inesperados.
- **Estrategia B (robusta):** Menos préstamos aprobados, menor funding, pero defaults realizados más cercanos a lo esperado.

i Significancia estadística e intervalo de confianza

Si el intervalo de confianza al 95 % de la diferencia no cruza cero, la diferencia es estadísticamente significativa al nivel $\alpha = 0.05$. Esto no garantiza que la diferencia sea *económicamente* significativa — el tamaño del efecto y su relevancia operativa deben evaluarse por separado.

33.0.5. Atribución por Segmento

Además de la comparación global, el framework descompone la diferencia de retorno por tres dimensiones de atribución:

- **Por grade:** Permite identificar en qué segmentos de riesgo la robustez agrega más valor (típicamente grades C–E, donde la incertidumbre es mayor).
- **Por cohorte temporal:** Revela si la ventaja de la robustez varía según el periodo de origen dentro del OOT.
- **Por monto del préstamo:** Muestra si los préstamos de mayor monto se benefician más de la asignación robusta.

Limitaciones del diseño retroactivo

Esta simulación no es un A/B test aleatorizado en producción. Las principales limitaciones son: (1) no hay efecto de feedback — en producción, aprobar/rechazar un préstamo afecta la composición futura del portafolio; (2) ambas estrategias se aplican al mismo pool de candidatos, sin competencia real por funding; (3) si se prueban muchas variantes de política sin corrección por multiplicidad, la probabilidad de encontrar mejoras espurias aumenta.

Conexión con el pipeline

La simulación A/B cierra el ciclo del pipeline **predict-then-optimize**: los intervalos conformal (Capítulo 24) alimentan la optimización robusta (Capítulo 36), y la simulación A/B valida retrospectivamente si esa robustez genera valor económico real. Los CATE de Capítulo 32 permiten una variante adicional: la optimización CATE-adjusted, evaluable con el mismo framework A/B.

34. Optimización de Portafolio

Este capítulo transforma las predicciones calibradas de PD y los intervalos de incertidumbre conformal en decisiones concretas de asignación de capital. El pipeline completo sigue una arquitectura *predict-then-optimize* donde cada componente alimenta al siguiente:

La Tabla 34.1 resume las secciones y su contribución al pipeline.


Tabla 34.1.: Resumen del capítulo de optimización de portafolio.

Sección	Contenido	Artefacto principal
Capítulo 35	Formulación LP, Pyomo + HiGHS	<code>portfolio_allocations.parquet</code>
Capítulo 36	Conjuntos de incertidumbre box, contraparte robusta	<code>portfolio_robustness_frontier.parquet</code>
Capítulo 37	Selector económico v3, test A/B de no-regresión	<code>champion_portfolio_policy.json</code>
Capítulo 38	Ajuste causal (CATE) al retorno esperado	<code>cate_portfolio_comparison.parquet</code>
Capítulo 39	Frontera de Pareto: riesgo vs robustez vs retorno	<code>portfolio_robustness_summary.parquet</code>

Solver abierto

Toda la optimización usa **HiGHS** como solver LP/MILP open-source (Huangfu & Hall, 2018), modelado con Pyomo. No se requiere licencia comercial (Gurobi/CPLEX).

La figura Figura 34.1 conecta estadística con OR: cada intervalo conformal deja de ser una salida descriptiva y se convierte en una región factible de decisión.



ualización de conjuntos de incertidumbre usados por la capa de optimización robusta para transformar intervalos conformales en ecisión.

35. Portafolio Determinístico

El punto de partida de la optimización de portafolio es un programa lineal (LP) que maximiza el retorno esperado neto de pérdida, sujeto a restricciones de presupuesto, riesgo y diversificación. Esta formulación determinística usa únicamente la PD puntual —sin incorporar incertidumbre— y sirve como **baseline** contra el cual se mide el costo de la robustez.

35.0.1. Formulacion matematica

Sea $\mathcal{J} = \{1, \dots, n\}$ el conjunto de prestamos candidatos. Para cada prestamo i definimos:

- $x_i \in [0, 1]$: fracción del prestamo i a financiar (variable de decisión),
- a_i : monto del prestamo,
- r_i : tasa de interés (retorno esperado),
- $\widehat{PD}_i$: probabilidad de default estimada (puntual),
- LGD_i : pérdida dado el default (fija en 0.45 para este dataset).

El programa lineal determinístico es:

$$\max_x \sum_{i \in \mathcal{J}} x_i \cdot a_i \cdot (r_i - \widehat{PD}_i \cdot LGD_i) \quad (35.1)$$

sujeto a:

$$\sum_{i \in \mathcal{J}} x_i \cdot a_i \leq B \quad (35.2)$$

$$\frac{\sum_{i \in \mathcal{J}} x_i \cdot a_i \cdot \widehat{PD}_i}{\sum_{i \in \mathcal{J}} x_i \cdot a_i} \leq \bar{PD} \quad (35.3)$$

$$\frac{\sum_{i \in \mathcal{S}_p} x_i \cdot a_i}{\sum_{i \in \mathcal{J}} x_i \cdot a_i} \leq c_{\max}, \quad \forall p \in \mathcal{P} \quad (35.4)$$

donde B es el presupuesto total, $\bar{PD}$ es el techo de PD ponderada del portafolio (tolerancia al riesgo), $\mathcal{S}_p$ son los prestamos del segmento p (por proposito de credito), y $c_{\max}$ es la concentracion maxima permitida por segmento.

35.0.2. Parametros de configuracion

Los valores por defecto se definen en `configs/optimization.yaml`:

Tabla 35.1.: Configuración del modelo de portafolio determinístico.

Parametro	Valor	Descripcion
<code>total_budget</code>	\$1,000,000	Capital total disponible
<code>max_concentration</code>	25 %	Concentración máxima por segmento de propósito
<code>max_portfolio_pd</code>	10 %	Techo de PD ponderada del portafolio
<code>solver</code>	HiGHS	Solver LP open-source
<code>time_limit</code>	300 s	Límite de tiempo del solver

35.0.3. Implementación en Pyomo

El modelo se construye con `build_portfolio_model()` en `src/optimization/portfolio_model.py`. Las decisiones son variables continuas $x_i \in [0, 1]$ (relajación LP del problema de aprobación binario), lo que permite asignaciones parciales y garantiza solución en tiempo polinomial.

```
model.x = pyo.Var(model.I, domain=pyo.NonNegativeReals, bounds=(0, 1))
```

La función objetivo (Ecuación 35.1) calcula el retorno neto como la diferencia entre el ingreso por intereses y la pérdida esperada:

$$\text{Retorno neto}_i = r_i - \widehat{PD}_i \cdot LGD_i$$

💡 Variables continuas vs binarias

La relajación continua $x_i \in [0, 1]$ produce una cota superior del problema binario (aprobar/rechazar) y se resuelve órdenes de magnitud más rápido. Para 5,000 candidatos, HiGHS resuelve el LP en menos de 2 segundos. El modelo MILP binario (`build_binary_model`) está disponible pero no se usa en el pipeline principal.

35.0.4. Resolución y artefactos

El script `scripts/optimize_portfolio.py` ejecuta el pipeline completo:

1. Carga candidatos de `data/processed/test_fe.parquet` (hasta 5,000 por defecto),
2. Alinea intervalos conformal por id del préstamo,
3. Construye y resuelve el modelo Pyomo con HiGHS,
4. Persiste `portfolio_allocations.parquet` con la asignación óptima.

El artefacto de salida contiene para cada prestamo: la fraccion asignada, el monto, la PD puntual, los limites conformal y la tasa de interes. Este resultado alimenta directamente el analisis de escenarios (mejor caso, esperado, peor caso) implementado en `scenario_analysis()` de `src/optimization/robust_opt.py`.

 Fragilidad del baseline determinístico

El portafolio determinístico ignora completamente la incertidumbre de estimacion. Si la PD real es mayor que la estimada, el portafolio puede violar su techo de riesgo. Esta fragilidad motiva la formulacion robusta de Capítulo 36.

36. Portafolio Robusto con Conjuntos de Incertidumbre

La formulacion determinística de Capítulo 35 asume que $\widehat{PD}_i$ es conocida con certeza. En la practica, la PD estimada tiene un error de estimacion que los intervalos conformal cuantifican con garantias finitas de cobertura (Capítulo 24). Esta seccion formaliza como convertir esos intervalos en **conjuntos de incertidumbre** para optimizacion robusta, siguiendo el marco de Bertsimas y Sim (2004a).

36.0.1. Conjuntos de incertidumbre box

Para cada prestamo i , la prediccion conformal Mondrian (Capítulo 25) produce un intervalo $[\underline{PD}_i, \overline{PD}_i]$ con cobertura garantizada al nivel $1 - \alpha$ (90 % en nuestra configuracion). El **conjunto de incertidumbre box** se define como:

$$\mathcal{U}_i = \{PD_i \in \mathbb{R} : \underline{PD}_i \leq PD_i \leq \overline{PD}_i\} \quad (36.1)$$

La funcion `build_box_uncertainty_set()` en `src/optimization/robust_opt.py` construye estos conjuntos y calcula el centro y radio de cada intervalo:

$$\hat{c}_i = \frac{\underline{PD}_i + \overline{PD}_i}{2}, \quad \hat{r}_i = \frac{\overline{PD}_i - \underline{PD}_i}{2}$$

i Cobertura conformal como garantia de robustez

La cobertura conformal al 90 % implica que la PD real de al menos el 90 % de los prestamos cae dentro de $\mathcal{U}_i$. Este es un resultado **distribution-free** que no depende de supuestos distribucionales — a diferencia de intervalos bootstrap o bayesianos.

36.0.2. Contraparte robusta

El portafolio robusto reemplaza la PD puntual en la restriccion de riesgo (Ecuación 35.3) por una **PD efectiva** que incorpora la incertidumbre. La implementacion soporta multiples politicas de conservadurismo a traves de `compute_effective_pd()`:

$$PD_i^{\text{eff}} = \widehat{PD}_i + \gamma \cdot \Delta_i \quad (36.2)$$

donde $\Delta_i = \overline{PD}_i - \widehat{PD}_i$ es el ancho hacia el peor caso y $\gamma \in [0, 1]$ controla el nivel de robustez:

Tabla 36.1.: Interpretacion del parametro de robustez γ .

γ	Interpretacion
0.0	Sin robustez (equivalente a determinístico)
0.10	Conservadurismo leve
0.50	Proteccion intermedia
1.0	Peor caso total ($PD_i^{\text{eff}} = \overline{PD}_i$)

36.0.3. Politicas de PD efectiva

El sistema implementa siete modos de calculo para PD_i^{eff} , organizados por sofisticacion creciente:

1. **point_estimate**: $PD_i^{\text{eff}} = \widehat{PD}_i$ (baseline).
2. **hard_worst_case**: $PD_i^{\text{eff}} = \overline{PD}_i$ (maximo conservadurismo).
3. **blended_uncertainty**: interpolacion lineal (Ecuación 36.2).
4. **capped_blended_uncertainty**: Δ_i acotado por un cuantil del portafolio.
5. **tail_blended_uncertainty**: solo aplica Δ_i a prestamos en la cola de incertidumbre (cuantil q).
6. **segment_tail_blended_uncertainty**: cola por segmento (grado + plazo + verificacion).
7. **segment_relative_tail_blended_uncertainty**: cola relativa $\Delta_i / \max(\widehat{PD}_i, 10^{-4})$, por segmento.

La politica seleccionada para el champion actual es **segment_relative_tail_blended_uncertainty** con $\gamma = 0.10$, lo que significa que solo los prestamos con ancho relativo de incertidumbre en la cola superior (por segmento) reciben un ajuste de robustez.

36.0.4. Penalizacion de incertidumbre en el objetivo

Ademas de la restriccion de PD, el modelo permite penalizar la incertidumbre directamente en la funcion objetivo:

$$\max_x \sum_i x_i \cdot a_i \cdot (r_i - \widehat{PD}_i \cdot LGD_i - \lambda \cdot \Delta_i \cdot LGD_i) \quad (36.3)$$

donde $\lambda \geq 0$ es la **aversion a la incertidumbre** (**uncertainty_aversion**). Valores tipicos explorados: $\lambda \in \{0.0, 0.1, 0.5, 1.0, 2.0, 3.0\}$.

36.0.5. Resultados de la contraparte robusta

El champion seleccionado presenta los siguientes indicadores de robustez:

Tabla 36.2.: Metricas de robustez del portafolio champion.

Metrica	Valor
Reduccion de PD en peor caso	~903 bps
Price of Robustness	-2.58 %
Similitud de asignacion vs baseline	0.687 (coseno)
Breadth score	0.937

💡 Precio de la robustez como “prima de seguro”

El *Price of Robustness* de -2.58 % significa que el portafolio robusto sacrifica solo 2.58 % de retorno esperado a cambio de una reduccion de ~903 puntos base en la PD del peor caso. Esta es la **prima de seguro** que el portafolio paga por proteccion contra incertidumbre del modelo.

36.0.6. Analisis de escenarios

La funcion `scenario_analysis()` evalua el portafolio bajo tres realizaciones de PD:

$$L_{\text{scenario}} = \sum_i x_i \cdot a_i \cdot PD_i^{\text{scenario}} \cdot LGD_i$$

donde $PD_i^{\text{scenario}} \in \{\underline{PD}_i, \widehat{PD}_i, \overline{PD}_i\}$ corresponde al mejor caso, esperado y peor caso respectivamente. La diferencia entre peor y mejor caso cuantifica la **exposicion residual a incertidumbre** del portafolio seleccionado.

37. Selección de Política Económica

Con multiples combinaciones de tolerancia al riesgo ($\bar{P}D$), modo de politica, parametro de robustez (γ) y aversion a la incertidumbre (λ), el espacio de politicas viables es enorme. El **selector economico v3** (`economic_actual_ab_v3`) automatiza la seleccion de la politica champion mediante un proceso de tres etapas: evaluacion exhaustiva, test de no-regresion A/B y seleccion multicriterio.

37.0.1. Proceso de seleccion

El script `scripts/optimize_portfolio_tradeoff.py` ejecuta una busqueda exhaustiva sobre la grilla de configuraciones. Para cada nivel de tolerancia al riesgo:

1. **Baseline no robusto:** se resuelve el LP determinístico (PD puntual, $\gamma = 0$, $\lambda = 0$).
2. **Candidatos robustos:** se resuelven todas las combinaciones de (`policy_mode`, `gamma`, `delta_cap_quantile`, `tail_focus_quantile`) $\times$ `aversion_grid`.
3. **Price of Robustness:** se calcula como la diferencia de retorno neto entre baseline y candidato robusto.
4. **Retorno realizado:** se computa el retorno *ex-post* usando las etiquetas reales de default del set OOT.

37.0.2. Test A/B de no-regresion

El test A/B no es un A/B test experimental online, sino una evaluacion retroactiva: dado que conocemos los defaults reales del periodo OOT (2018–2020), se compara el retorno realizado del portafolio robusto contra el baseline no robusto.

La condicion de no-regresion es:

$$R_{\text{robusto}}^{\text{realizado}} \geq R_{\text{baseline}}^{\text{realizado}} - 0.05 \cdot |R_{\text{baseline}}^{\text{realizado}}| \quad (37.1)$$

Es decir, el portafolio robusto puede perder hasta un 5% del retorno realizado del baseline sin ser descartado. Este margen reconoce que la robustez tiene un costo, pero limita cuanto puede costar.

37.0.3. Politica champion seleccionada

El selector economico v3 eligio la siguiente politica como champion:

Tabla 37.1.: Política champion seleccionada por el selector economico v3.

Parametro	Valor
<code>risk_tolerance</code>	0.18
<code>uncertainty_aversion</code> (λ)	0.10
<code>policy_mode</code>	<code>segment_relative_tail_blended_uncertainty</code>
<code>gamma</code>	0.10
<code>tail_focus_quantile</code>	0.75
<code>delta_cap_quantile</code>	1.0
A/B no-regresion	PASS

i Interpretacion de la politica champion

La politica `segment_relative_tail_blended_uncertainty` con $\gamma = 0.10$ aplica un ajuste de robustez solo al 25 % superior de prestamos por ancho relativo de incertidumbre, dentro de cada segmento (grado $\times$ plazo $\times$ verificacion). Esto significa que los prestamos con PD bien estimada no reciben penalizacion, mientras que aquellos donde el modelo tiene mayor incertidumbre relativa si la reciben.

37.0.4. Alternativas de investigacion

El selector evalua cuatro estrategias de seleccion alternativas para comparacion academica:

Tabla 37.2.: Alternativas de seleccion de politica para investigacion.

Selector	Criterio principal	Risk tolerance	Policy mode
promo- tion_first	Maximiza retorno realizado	0.16	<code>tail_blended_uncertainty</code>
robust- ness_aware	Retorno $\times \sqrt{\gamma}$	0.16	<code>tail_blended_uncertainty</code>
balanced	Retorno $+ \gamma$ alto	0.16	<code>tail_blended_uncertainty</code>
guardrail	PoR $\geq -25\%$ + retorno	0.14	<code>hard_worst_case</code>

La estrategia `robustness_aware` pondera el retorno realizado por $\sqrt{\gamma}$, incentivando politicas que realmente usen la informacion de incertidumbre (no trivialmente $\gamma = 0$). La estrategia `guardrail` impone un piso al Price of Robustness para evitar politicas extremadamente conservadoras.

37.0.5. Breadth score

Para verificar que la politica robusta no colapsa el portafolio a un subconjunto degenerado de prestamos, se calcula un **breadth score** compuesto:

$$\text{Breadth} = w_1 \cdot \frac{n_{\text{funded}}^{\text{robusto}}}{n_{\text{funded}}^{\text{baseline}}} + w_2 \cdot \frac{\text{allocated}^{\text{robusto}}}{\text{allocated}^{\text{baseline}}} + w_3 \cdot \text{sim}(\mathbf{x}^{\text{robusto}}, \mathbf{x}^{\text{baseline}}) \quad (37.2)$$

con pesos $w_1 = 0.50$, $w_2 = 0.30$, $w_3 = 0.20$ y similitud coseno entre vectores de asignacion. El umbral minimo es 0.93; el champion actual alcanza **0.937**, indicando que la politica robusta mantiene un portafolio amplio y diversificado.

Configuracion como template

Los archivos YAML en **configs/** son **templates** con valores por defecto. La politica efectiva en produccion es el artefacto **models/champion_portfolio_policy.json**, que captura la decision del selector economico con todos los parametros resueltos y las metricas de seleccion.

38. Portafolio Ajustado por CATE

El portafolio determinístico y el robusto utilizan retornos esperados basados unicamente en la tasa de interes y la perdida esperada. Sin embargo, la inferencia causal (Capítulo 32) estima el **efecto heterogeneo del tratamiento** (CATE) para cada prestamo, lo que permite ajustar la expectativa de retorno incorporando informacion causal. Esta seccion describe como el CATE modifica la funcion objetivo de la optimizacion.

38.0.1. Integracion del CATE en el retorno

Sea τ_i el CATE estimado para el prestamo i , que representa el efecto causal diferencial de la politica de aprobacion sobre la probabilidad de repago. El retorno ajustado es:

$$\text{Retorno}_i^{\text{CATE}} = r_i - \widehat{PD}_i \cdot LGD_i + \delta \cdot \tau_i \quad (38.1)$$

donde δ es un factor de escala (por defecto $\delta = -1$, indicando que un CATE positivo reduce el riesgo y mejora el retorno). La funcion `build_cate_adjusted_portfolio()` en `src/optimization/causal_portfolio.py` resuelve el LP con este retorno modificado y lo compara contra el baseline sin CATE.

38.0.2. Alineacion de CATE al set OOT

Un desafio tecnico importante es que los estimados CATE se producen originalmente sobre el set de entrenamiento (1.34M prestamos), mientras que la optimizacion opera sobre el set OOT (276K prestamos) con cero solapamiento de IDs. El script `scripts/optimize_cate_portfolio.py` implementa una cascada de estrategias de alineacion:

1. **OOT directo:** si existe `cate_estimates_oot.parquet`, se hace join por id.
2. **Training fallback:** join por id con CATE del set de entrenamiento.
3. **Grade mediana:** para IDs sin match, se imputa la mediana de CATE por grado crediticio.
4. **Zero-fill:** prestamos restantes reciben $\text{CATE} = 0$ (efecto neutral).

38.0.3. Shrinkage del CATE

Los estimados CATE crudos pueden contener senales ruidosas o valores extremos. Para mitigar esto, se aplica un procedimiento de **shrinkage** antes de la optimizacion:

1. **Winsorization:** se recortan los valores por debajo del percentil 5 y por encima del percentil 95.

38. Portafolio Ajustado por CATE

2. **Shrinkage a mediana de segmento:** $\tau_i^{\text{shrunk}} = 0.5 \cdot \tau_i^{\text{clip}} + 0.5 \cdot \tilde{\tau}_{\text{seg}(i)}$, donde $\tilde{\tau}_{\text{seg}(i)}$ es la mediana del CATE en el segmento (grado $\times$ plazo $\times$ verificación).
3. **Piso de señal débil:** valores con $|\tau_i^{\text{shrunk}}| < \text{floor}$ se anulan a cero.

38.0.4. Resultados: CATE crudo vs shrunk

El script ejecuta ambas versiones (CATE crudo y shrunk) para cuantificar el efecto del shrinkage:

Tabla 38.1.: Comparación de portafolios baseline vs CATE-ajustado.

Escenario	Retorno baseline	Retorno CATE-ajustado	Diferencia
CATE crudo	\$57,094	\$57,350	+\$257 (+0.45 %)
CATE shrunk	\$57,094	\$54,540	-\$2,554 (-4.47 %)

💡 Interpretación del efecto del shrinkage

El CATE crudo muestra una mejora marginal (+\$257), mientras que el CATE shrunk reduce el retorno (-\$2,554). Esto es esperado: el shrinkage elimina señal ruidosa que artificialmente inflaba el retorno ajustado, produciendo una estimación más conservadora pero más confiable del efecto causal real.

38.0.5. Criterio de promoción

La política CATE-ajustada se promueve a candidata operativa solo si cumple dos condiciones:

1. El retorno del portafolio CATE-ajustado $\geq$ retorno baseline.
2. El número de préstamos financiados $\geq 90\%$ del baseline.

Si no se cumplen, la política queda en modo `research_only_fallback` — útil para análisis académico pero no para producción. El artefacto `models/cate_portfolio_status.json` registra la decisión y las métricas de evaluación.

📘 Conexión con inferencia causal

Los estimados CATE provienen de Causal Forests (ver Capítulo 32). La calidad de la integración causal depende directamente de la identificabilidad del efecto y la cobertura del overlap entre tratados y controles. Las limitaciones de la estimación causal se propagan a la optimización de portafolio.

39. Frontera Eficiente de Robustez

Las secciones anteriores presentan la formulacion del portafolio robusto y la seleccion de la politica champion. Esta seccion analiza la **frontera de Pareto** que emerge al explorar exhaustivamente el espacio de configuraciones, cuantificando el trade-off entre retorno esperado, proteccion ante el peor caso y costo de la robustez.

39.0.1. Espacio de busqueda

El script `scripts/optimize_portfolio_tradeoff.py` evalua una grilla tridimensional de configuraciones:

- **Tolerancia al riesgo** ($\bar{PD}$): 9 niveles de 0.05 a 0.20.
- **Aversion a la incertidumbre** (λ): 7 niveles de 0.0 a 3.0.
- **Modos de politica**: 7 modos $\times$ multiples combinaciones de γ , `delta_cap_quantile` y `tail_focus_quantile`.

En total, el barrido exhaustivo evalua hasta **6,941 configuraciones de politica** (dependiendo del perfil de grilla seleccionado). Para cada configuracion, se resuelve el LP completo con HiGHS y se computan las metricas de robustez.

39.0.2. Curva de Price of Robustness

El Price of Robustness (PoR) mide la fraccion de retorno que el portafolio sacrifica por proteccion:

$$\text{PoR}(\%) = \frac{R_{\text{baseline}} - R_{\text{robusto}}}{|R_{\text{baseline}}|} \times 100 \quad (39.1)$$

La curva de PoR en funcion de γ tiene forma convexa: robustez marginal es barata (primeros puntos base de proteccion cuestan poco retorno), pero la proteccion total ($\gamma = 1.0$) es desproporcionadamente costosa. El champion seleccionado en Capítulo 37 opera en la zona de bajo costo marginal con un PoR de solo -2.58 %.

39.0.3. Frontera de Pareto

La frontera de Pareto se define como el conjunto de politicas donde no es posible mejorar una metrica sin empeorar otra. En nuestro contexto, las metricas son:

1. **Retorno realizado** (maximizar): retorno *ex-post* con defaults reales del OOT.
2. **Reduccion de PD en peor caso** (maximizar): diferencia en PD ponderada bajo el escenario $\bar{PD}_i$.

3. **Breadth score** (maximizar): diversificación del portafolio respecto al baseline.

La Tabla 39.1 muestra las políticas Pareto-dominantes a lo largo de la frontera:

Tabla 39.1.: Zonas de la frontera de robustez.

Zona de la frontera	PoR (%)	Reduccion worst-PD (bps)	Breadth	Perfil
Agresiva	0 – -1 %	0 – 200	> 0.98	Casi identico al baseline
Balanceada	-1 % – -5 %	200 – 900	0.93 – 0.98	Trade-off optimo
Conservadora	-5 % – -15 %	900 – 2,000	0.85 – 0.93	Protec- cion fuerte
Extrema	< -15 %	> 2,000	< 0.85	Portafo- lio colapsa- do

El champion actual ($\gamma = 0.10$, $\lambda = 0.10$, PoR = -2.58 %, ~903 bps de reducción) se ubica firmemente en la **zona balanceada**, donde el costo marginal de la robustez es bajo y la diversificación del portafolio se mantiene alta.

39.0.4. Dimensiones del trade-off

El análisis de la frontera revela tres dimensiones del trade-off:

1. **Retorno vs proteccion:** la curva clásica de PoR. Mayor γ protege mas pero cuesta mas retorno.
2. **Volumen vs conservadurismo:** tolerancias al riesgo mas bajas ($\bar{PD} = 0.06$) rechazan mas prestamos, reduciendo el volumen financiado. El piso de utilizacion de presupuesto (`min_budget_utilization = 0.05`) evita soluciones degeneradas a niveles estrictos de riesgo.
3. **Granularidad del ajuste:** las políticas `segment_*` son mas selectivas que `blended_uncertainty` global, penalizando solo donde la incertidumbre relativa es alta. Esto permite mayor robustez sin sacrificio excesivo de retorno.

i Frontera como herramienta de gobernanza

La frontera de robustez no solo es un resultado analítico — es una herramienta de decisión para el comité de riesgo. Permite comunicar explícitamente: “por cada punto porcentual adicional de protección, el portafolio sacrifica \$X de retorno”. Esto transforma la decisión de nivel de robustez en una decisión económica cuantificable, no una elección subjetiva.

39.0.5. Conexion con el pipeline completo

Los artefactos generados por la frontera alimentan multiples componentes downstream:

- **portfolio_robustness_frontier.parquet**: todas las configuraciones evaluadas con sus metricas.
- **portfolio_robustness_summary.parquet**: resumen por nivel de tolerancia al riesgo (mejor robusto vs baseline).
- **champion_portfolio_policy.json**: la politica promovida tras pasar el test A/B (Sección 37.0.2).
- **portfolio_research_policy.json**: las cuatro alternativas de investigacion (Tabla 37.2).

Estos artefactos son consumidos por el dashboard Streamlit para visualizacion interactiva, por el reporte MRM para validacion regulatoria, y por la simulacion A/B retroactiva (`scripts/simulate_ab_test.py`) para evaluar robustez en condiciones mas realistas.

40. IFRS9 y Gobernanza del Modelo

Este capítulo conecta los modelos de riesgo crediticio con sus consecuencias contables y regulatorias. IFRS9 traduce PD, LGD y EAD en provisiones (ECL) bajo múltiples escenarios macroeconómicos, mientras que la gobernanza asegura que el sistema sea confiable, justo y auditable a lo largo del tiempo.

40.0.1. Pipeline ECL Completo

El siguiente diagrama muestra cómo fluye la información desde los modelos hasta las provisiones y la gobernanza:




Figura 40.1.: Grid editorial de SICR y staging conformal del carril IFRS9.

40.0.2. Resumen de Métricas Clave

Tabla 40.1.: Resumen de resultados IFRS9 y gobernanza

Métrica	Valor	Sección
ECL Baseline	\$1,003M	Capítulo 41
ECL Severe	\$1,799M	Capítulo 42

Métrica	Valor	Sección
Uplift Severe	+79.3 %	Capítulo 42
SICR t^* conformal	0.30 (F1=0.2515)	Capítulo 43
ECL adicional SICR	\$56.6M	Capítulo 43
Sensibilidad α	ECL +22 % (90 %→99 %)	Capítulo 44
Fairness	6/6 PASS	Capítulo 45

41. Cálculo de ECL

41.0.1. La Fórmula Central de IFRS9

La **Expected Credit Loss** (ECL) es la métrica contable que traduce modelos de riesgo en provisiones monetarias. Bajo IFRS9, cada préstamo contribuye al total de provisiones según:

$$ECL_i = PD_i^{\text{eff}} \times LGD_i \times EAD_i \times DF \quad (41.1)$$

donde:

- PD_i^{eff} es la probabilidad de default efectiva según el stage del préstamo,
- LGD_i es la pérdida dado el default (45 % en nuestro escenario base),
- EAD_i es la exposición al momento del default (monto del préstamo),
- $DF = \frac{1}{1+r}$ es el factor de descuento a la tasa efectiva de interés r .

41.0.2. Lógica de Staging IFRS9

La norma IFRS9 clasifica cada préstamo en uno de tres stages según su nivel de deterioro crediticio. La PD efectiva utilizada en la Ecuación 41.1 depende directamente de esta clasificación:

Tabla 41.1.: Lógica de staging IFRS9 y PD efectiva por etapa

Stage	Condición	PD Efectiva	Horizonte
1	Sin deterioro significativo	PD_{12m}	12 meses
2	SICR detectado	PD_{lifetime}	Vida remanente
3	Default confirmado (≥ 90 DPD)	$PD \approx 1.0$	Pérdida total

La transición de Stage 1 a Stage 2 se activa por el mecanismo de **Significant Increase in Credit Risk** (SICR), que en nuestra implementación combina:

1. **Incremento absoluto de PD:** $PD_{\text{actual}} - PD_{\text{originación}} > 0.02$
2. **Morosidad temprana:** $DPD \geq 30$ días (presunción refutable)
3. **Señal conformal** (innovación): ancho del intervalo conformal $> P_{90}$ del portafolio (ver Capítulo 43)

i Innovación: SICR Conformal

Nuestra implementación en `src/evaluation/ifrs9.py` extiende el SICR tradicional usando el ancho del intervalo conformal como señal de incertidumbre epistémica. Un préstamo con intervalo ancho y PD no-decreciente migra a Stage 2 incluso si el incremento absoluto de PD es menor al umbral estándar.

41.0.3. Distribución de Staging

En el escenario baseline, el portafolio de test OOT (276,869 préstamos) se distribuye como:

Stage 2 concentra la mayor parte del portafolio (128,959 préstamos, 46.6 %), reflejando el período OOT 2018–2020 que incluye deterioro crediticio pre-pandemia. Stage 3 comprende 62,251 préstamos (22.5 %) con default confirmado.

41.0.4. ECL Total y Rango Conformal

La ECL total baseline es **\$1,003M**, pero los intervalos conformales revelan la incertidumbre subyacente:

Tabla 41.2.: ECL baseline con rango conformal

Componente	Valor
ECL Low (conformal)	\$189K
ECL Point	\$454M
ECL High (conformal)	\$1,570M
ECL Total (staging)	\$1,003M

⚠ Asimetría del Rango ECL

El rango conformal es fuertemente asimétrico: la cota superior (\$1,570M) excede el punto central por \$1,116M, mientras la cota inferior está cerca de cero. Esto refleja que la distribución de PD es right-skewed — la mayoría de préstamos tienen PD baja, pero la cola derecha puede generar pérdidas significativas. Esta asimetría es precisamente lo que justifica la optimización robusta del portafolio (ver Capítulo 36).

41.0.5. Implementación

La función `compute_ecl()` en `src/evaluation/ifrs9.py` aplica la Ecuación 41.1 por stage, mientras `ecl_with_conformal_range()` produce el rango $[ECL_{low}, ECL_{point}, ECL_{high}]$ usando los intervalos conformales de PD como inputs directos. El script `scripts/run_ifrs9_sensitivity.py` orquesta el cálculo completo incluyendo la derivación de DPD a partir de campos de delinquency y la construcción de PD de originación por vintage (grade + trimestre de emisión).

42. Análisis de Escenarios

42.0.1. Escenarios Macroeconómicos

IFRS9 requiere que las provisiones reflejen **información prospectiva** (*forward-looking*), incorporando múltiples escenarios macroeconómicos ponderados por su probabilidad (International Accounting Standards Board, 2014). Nuestro pipeline implementa cuatro escenarios con multiplicadores progresivos sobre los parámetros de riesgo:

Tabla 42.1.: Multiplicadores por escenario macroeconómico

Escenario	PD Mult.	LGD Mult.	EAD Mult.	Tasa Descuento
Baseline	1.017	1.00	1.00	5 %
Mild Stress	1.170	1.05	1.02	6 %
Adverse	1.322	1.12	1.05	7 %
Severe	1.577	1.20	1.10	8 %

i Calibración Temporal del Baseline

El multiplicador baseline de PD (1.017) no es 1.0 sino que se calibra dinámicamente usando el contexto de series temporales: es el ratio entre la media de los pronósticos puntuales y la media reciente de tasas de default observadas. Esto ancla el escenario base en la tendencia macroeconómica más actual.

42.0.2. Resultados por Escenario

Los resultados muestran una progresión de ECL desde \$1,003M (baseline) hasta \$1,799M (severe), un **uplift del 79.3 %**. Este uplift captura el efecto combinado de:

- **Mayor PD:** más préstamos migran a Stage 2 y 3
- **Mayor LGD:** las pérdidas dado default se amplifican
- **Mayor EAD:** la exposición efectiva crece
- **Menor descuento:** la tasa más alta reduce el factor de descuento menos que el aumento en PD/LGD

42.0.3. Migración de Stages entre Escenarios

A medida que los multiplicadores de estrés aumentan, los préstamos migran progresivamente de Stage 1 a Stage 2 y de Stage 2 a Stage 3. Este efecto de **cascada de deterioro** tiene implicaciones no lineales:

- Un préstamo que migra de Stage 1 a Stage 2 pasa de provisionar PD a 12 meses a PD lifetime — un salto que puede multiplicar su ECL individual por 3–5x
- Un préstamo que llega a Stage 3 provisiona 100 % de $LGD \times EAD$, el máximo posible

Lectura para Gestión

El uplift severe (\$796M adicionales, +79.3 %) representa el **buffer de capital** necesario para absorber un escenario adverso. Comparar este monto con las reservas disponibles y los ratios de solvencia permite evaluar si la entidad puede operar bajo estrés sin intervención regulatoria.

42.0.4. Desagregación por Grade

El impacto de los escenarios no es uniforme. Los grades de mayor riesgo (E, F, G) concentran una proporción desproporcionada del ECL incremental, ya que:

1. Sus PD base son más altas, acercándolas al umbral de migración Stage 1 $\rightarrow$ 2
2. Sus LGD históricas son mayores
3. Los multiplicadores de estrés tienen un efecto amplificado sobre préstamos cerca del umbral de default

Esta heterogeneidad justifica el uso de intervalos conformales **Mondrian** (condicionados por grade) en lugar de intervalos globales, ya que la incertidumbre de PD varía significativamente entre segmentos (ver Capítulo 25).

43. Señal SICR Conformal

43.0.1. Motivación: Incertidumbre como Señal de Deterioro

El mecanismo SICR (*Significant Increase in Credit Risk*) tradicional se basa en comparar la PD actual con la PD de originación. Sin embargo, un préstamo puede tener una PD puntual estable mientras el modelo se vuelve **más incierto** sobre su predicción — señal de que las características del préstamo se alejan de la distribución de entrenamiento.

Nuestra contribución es usar el **ancho del intervalo conformal** como señal adicional de SICR:

$$w_i = PD_i^{\text{high}} - PD_i^{\text{point}} \quad (43.1)$$

Un ancho w_i grande indica que el modelo tiene alta incertidumbre epistémica sobre el préstamo i . Si esta incertidumbre coexiste con un perfil de riesgo no-mejorante, es un indicador legítimo de deterioro potencial que el PD puntual no captura.

i Fundamento Teórico

Los intervalos conformales tienen **garantía de cobertura** (ver Capítulo 24): si el intervalo es ancho, es porque los residuos de calibración para préstamos similares son grandes. Esto es una señal estadísticamente fundamentada — no un heurístico ad-hoc.

43.0.2. Diseño del Trigger

El trigger conformal funciona como complemento del trigger tradicional de PD. Para un umbral de PD τ_{PD} y un umbral de ancho t :

$$\text{SICR}_i = \begin{cases} 1 & \text{si } PD_i > \tau_{\text{PD}} \\ 1 & \text{si } w_i > t \text{ y } PD_i \leq \tau_{\text{PD}} \\ 0 & \text{en otro caso} \end{cases} \quad (43.2)$$

El valor de este trigger se mide sobre los préstamos que el umbral de PD **no detecta**: de los defaults no capturados por τ_{PD} , ¿cuántos identifica el ancho conformal?

43.0.3. Optimización del Umbral t^*

El script `scripts/run_sicr_conformal.py` ejecuta un grid search sobre (τ_{PD}, t) con 5 umbrales de PD $\times$ 20 umbrales de ancho, evaluando precisión, recall y F1 del trigger de ancho sobre los defaults no capturados:

43.0.4. Resultado Óptimo

Para $\tau_{PD} = 0.20$, el umbral óptimo es $t^* = 0.30$, que maximiza el F1 del trigger conformal:

Tabla 43.1.: Resultado óptimo del SICR conformal

Métrica	Valor
Umbral óptimo t^*	0.30
F1	0.2515
Recall de defaults no capturados	75.8 %
Precisión del trigger	8.9 %
ECL adicional	\$56.6M

El recall de 75.8 % significa que el trigger conformal captura **tres de cada cuatro defaults** que el umbral tradicional de PD no detecta. La precisión baja (8.9 %) es esperada: el trigger es conservador por diseño — prefiere reclasificar de más (Stage 1 $\rightarrow$ 2) que dejar defaults sin provisionar.

Trade-off Precisión vs Costo

Los \$56.6M de ECL adicional representan el **costo de la prudencia**: provisiones extra para préstamos reclasificados a Stage 2 que podrían no defaultear. Sin embargo, comparado con el ECL baseline de \$1,003M, este monto es un 5.6 % — un buffer razonable por capturar 75.8 % de los defaults que de otra manera estarían sub-provisionados.

43.0.5. Sensibilidad al Nivel de Confianza α

El ancho del intervalo conformal depende directamente del nivel de confianza α . A menor α (mayor confianza), los intervalos son más anchos y más préstamos superan el umbral t^* , incrementando el ECL:

$$\alpha \downarrow \Rightarrow w_i \uparrow \Rightarrow \text{más SICR triggers} \Rightarrow \text{ECL} \uparrow \quad (43.3)$$

El análisis de sensibilidad (Parte B del script) muestra que pasar de 90 % a 99 % de confianza incrementa el ECL adicional en un **22 %**. Esto cuantifica el **costo regulatorio** de elegir un nivel de confianza más conservador — información directamente accionable para la política de provisiones.

Implicación Regulatoria

El regulador puede usar esta relación $\alpha \leftrightarrow \text{ECL}$ como palanca de política: exigir intervalos al 99 % implica ~22 % más provisiones que al 90 %, pero con mayor protección contra defaults no anticipados. La elección de α deja de ser un parámetro técnico y se convierte en una decisión de política regulatoria con consecuencias cuantificables.

44. Sensibilidad y Estrés

44.0.1. Grilla de Sensibilidad PD × LGD

Más allá de los cuatro escenarios discretos (Capítulo 42), el pipeline ejecuta una grilla completa de sensibilidad que varía los multiplicadores de PD y LGD de forma independiente, permitiendo identificar las regiones del espacio de parámetros donde el ECL es más sensible.

La grilla evalúa 5 multiplicadores de PD × 4 multiplicadores de LGD × 3 tasas de descuento = 60 combinaciones:

44.0.2. Patrones de Sensibilidad

La grilla revela dos patrones importantes:

1. **Sensibilidad dominante a PD:** un aumento de PD tiene un efecto amplificado porque no solo incrementa la pérdida por préstamo, sino que **migra préstamos entre stages** — efecto que la LGD no produce.
2. **No linealidad por staging:** el ECL no crece linealmente con PD porque la migración Stage 1 → 2 convierte PD de 12 meses en PD lifetime, un salto discreto que puede multiplicar la provisión individual por 3–5x.

i Rango de la Grilla

El rango extremo de la grilla va desde $PD \times 0.90 + LGD \times 0.90$ (escenario optimista) hasta $PD \times 1.30 + LGD \times 1.20$ (estrés severo). El ratio entre el mínimo y máximo ECL de la grilla cuantifica la **elasticidad total** de las provisiones a los parámetros de riesgo.

44.0.3. Simulación Monte Carlo con GPU

El pipeline extiende el análisis determinista con una capa de **Monte Carlo masivo** utilizando RAPIDS/CuPy en GPU. La simulación genera 16,000 escenarios con shocks aleatorios correlacionados sobre PD, LGD y EAD:

Tabla 44.1.: Parámetros de simulación Monte Carlo IFRS9

Parámetro	Valor
Escenarios MC	16,000
Préstamos por escenario	276,869

Parámetro	Valor
Aceleración GPU vs CPU	~30x
Shocks correlacionados	Sí (Cholesky)
Variantes antitéticas	Sí

La distribución completa de ECL generada por Monte Carlo permite calcular:

- **Media y desviación estándar** del ECL total
- **Percentiles de cola** (P95, P99): reserva necesaria para cubrir escenarios extremos
- **Expected Shortfall** (CVaR): pérdida promedio en la cola más allá de un percentil dado
- **Intervalos de confianza** sobre el ECL baseline

44.0.4. Sweep de Alpha sobre ECL

La sensibilidad del ECL al nivel de confianza conformal α se cuantifica mediante el alpha sweep del pipeline (Capítulo 43). El resultado clave:

$$\frac{\text{ECL}_{\alpha=0.01} - \text{ECL}_{\alpha=0.10}}{\text{ECL}_{\alpha=0.10}} \approx 22\% \quad (44.1)$$

Esto establece una **regla de conversión** práctica: cada punto porcentual adicional de confianza conformal cuesta aproximadamente 2.4 % de ECL adicional (en el rango 90–99 %), una relación que el regulador puede usar para calibrar sus exigencias de provisión.

44.0.5. Conexión con Optimización de Portafolio

Los resultados de sensibilidad alimentan directamente la optimización robusta del portafolio (Capítulo 36):

- Los **escenarios de estrés** definen los conjuntos de incertidumbre para la optimización robusta
- El **rango conformal** del ECL delimita las restricciones de capital en el modelo de Pyomo
- La **grilla PD × LGD** permite verificar que el portafolio óptimo es estable bajo perturbaciones de los parámetros

Lectura para Estrés Testing

La grilla de sensibilidad no pretende reemplazar los ejercicios formales de estrés testing (DFAST/CCAR en EE.UU., EBA en Europa). Su valor está en proporcionar una visión **continua** de cómo cambian las provisiones ante variaciones de parámetros, complementando los escenarios discretos que requiere la normativa.

45. Gestión de Riesgo de Modelo

El cierre prudencial del pipeline no ocurre cuando el modelo predice bien, sino cuando el sistema puede defenderse ante auditoría, comité de riesgo y revisión independiente. En esta implementación, la capa de *Model Risk Management* (MRM) combina cuatro frentes: fairness, monitoreo conformal, estabilidad explicativa y trazabilidad de artefactos.

45.0.1. Marco de control

La lógica sigue el espíritu de SR 11-7: distinguir claramente entre desarrollo, validación, monitoreo y uso. En términos operativos:

Tabla 45.1.: Controles principales de MRM

Componente	Evidencia canónica	Lectura de control
Fairness de decisión	<code>models/fairness_audit_status.json</code>	6 de 6 atributos auditados en PASS
Cobertura conformal	<code>models/conformal_policy_status.json</code>	usos sistema útil, pero con alertas estadísticas en pruebas estrictas
Drift explicativo	<code>data/processed/explanation_drift.json</code>	estabilidad en drivers y reason codes
Registro de campeón	<code>models/champion_registry.json</code>	un-tag, thresholds y policy promovida congelados

Esta separación es importante: un modelo puede cumplir fairness y aún así requerir observación metodológica en cobertura o estabilidad temporal. El libro conserva esa distinción para evitar una narrativa artificialmente “verde”.

45.0.2. Fairness como guardrail de uso

La auditoría vigente evalúa tres atributos base y tres atributos interseccionales. El resultado agregado es favorable:

Tabla 45.2.: Resumen de fairness operativo

Métrica	Valor
overall_pass	True
Atributos auditados	6
Atributos aprobados	6
Threshold operativo de decisión	0.35

Los gaps observados son pequeños incluso en intersecciones exigentes. Por ejemplo, la combinación `home_ownership × verification_status` mantiene `dpd=0.0123`, `eo_gap=0.0237` y `dir=0.9877`, todos dentro de política. La conclusión prudente no es “el modelo es justo” en sentido absoluto, sino que **la política de decisión vigente no activa alertas materiales bajo los cortes de monitoreo definidos hoy**.

45.0.3. Cobertura y gobernanza conformal

El componente conformal ofrece cobertura empírica fuerte, pero el artefacto de política actual reporta `overall_pass = False` bajo evaluación estricta. El detalle importa:

Tabla 45.3.: Estado de policy conformal

Indicador	Valor
Cobertura 90 %	92.52 %
Cobertura 95 %	95.93 %
Min group coverage 90 %	89.01 %
Checks aprobados	9 / 13
Fallas activas	Kupiec 90/95 y Christoffersen 90/95

La interpretación correcta es que el sistema está **metodológicamente justificable para uso diagnóstico y de apoyo a decisión**, pero todavía conserva alertas en pruebas estadísticas estrictas de backtesting. Esto es precisamente el tipo de hallazgo que MRM debe mostrar, no esconder.

Lectura prudencial

El mejor resultado de gobernanza no es cero alertas en todos los frentes; es saber cuáles alertas son críticas, cuáles son tolerables y qué plan de remediación existe. En este run, fairness y estabilidad explicativa están en verde, mientras que la cobertura temporal estricta sigue en observación.

45.0.4. Estabilidad explicativa

La gobernanza del modelo no termina en la predicción; también requiere que las razones del modelo no cambien sin justificación económica. El artefacto `explanation_drift.parquet` resume una comparación entre un periodo de referencia amplio (2018Q1 a 2019Q3) y un periodo de contraste (2019Q4 a 2020Q3):

Tabla 45.4.: Snapshot de drift explicativo

Indicador	Valor
<code>rank_overlap_top10</code>	1.00
<code>avg_shap_psi_top5</code>	0.0491
<code>max_shap_psi_top5</code>	0.0757
<code>reason_code_match_rate</code>	1.00
<code>passed_all</code>	True

Este resultado refuerza una idea central del libro: la incertidumbre puede fluctuar, pero el núcleo causal-operativo de los drivers sigue siendo coherente. La tasa de interés, el plazo, el FICO y la carga financiera permanecen como ejes interpretativos estables.

45.0.5. Registro, promoción y trazabilidad

El artefacto `models/champion_registry.json` congela el run activo `paper-grade-2026-03-13-final-heavy-2026-03-13-230650`, la política campeona de portafolio, la semántica de thresholds y la fuente de fairness. Esta trazabilidad evita dos fallas comunes de MRM:

1. Modelos que cambian sin dejar rastro de qué configuración quedó en producción.
2. Narrativas donde la métrica reportada no coincide con el artefacto efectivamente promovido.

En esta implementación, el registro deja explícito que:

- la policy promovida usa `gamma = 0.1` y `uncertainty_aversion = 0.1`;
- el threshold operativo principal de fairness y decisión es 0.35;
- el threshold interno de búsqueda PD es distinto (0.05) y no debe confundirse con el de aprobación.

45.0.6. Limitaciones y plan de cierre

La brecha pendiente ya no es construir MRM desde cero, sino endurecerlo:

1. cerrar las alertas de backtesting conformal sin degradar eficiencia;
2. ampliar el monitoreo de drift explicativo a más ventanas y segmentos;
3. convertir el snapshot actual en un reporte periódico de validación independiente.

Con esto, el capítulo IFRS9 no termina solo con provisiones calculadas, sino con un sistema que puede sostener una conversación seria de gobernanza sobre esas provisiones.

Parte III.

Parte III: Insights Factory

46. Explicabilidad e Interpretabilidad

La interpretabilidad convierte un modelo de caja negra en una capacidad operativa defendible ante reguladores, auditores y comités de riesgo.

47. Explicaciones Globales

Las explicaciones globales responden una pregunta de gobernanza simple y exigente: ¿qué señales usa sistemáticamente el modelo para asignar más o menos riesgo? En este proyecto no se acepta una sola lente. Se triangulan tres vistas: SHAP para atribución, permutation importance para sensibilidad y ALE para forma funcional.

47.0.1. Qué variables mueven el modelo

El artefacto `shap_summary.parquet` resume 42 variables explicadas globalmente. Los cinco drivers dominantes del run actual son:

Tabla 47.1.: Top drivers globales del modelo PD

Rank	Variable	Masa media SHAP	Lectura económica
1	<code>int_rate</code>	0.4066	Precio del riesgo ya incorporado por originación
2	<code>term</code>	0.2921	Mayor horizonte, mayor exposición acumulada
3	<code>fico_score</code>	0.2262	Calidad crediticia histórica
4	<code>dti</code>	0.1276	Capacidad de pago
5	<code>home_ownership</code>	0.1155	Perfil patrimonial / estabilidad del hogar

La mezcla es saludable desde el punto de vista de negocio: el modelo no se apoya en un único atajo espurio, sino en una combinación de precio, contrato, calidad crediticia y capacidad financiera.

Las figuras Figura 47.1 y Figura 47.2 convierten la narrativa global en evidencia visual: no solo sabemos qué variables aparecen arriba, sino cómo se distribuye su efecto y qué tan sensible es el desempeño a perturbarlas.

47.0.2. Atribución no es lo mismo que sensibilidad

SHAP dice cuánto contribuye una variable al score promedio; permutation importance dice cuánto cae el AUC si la señal se rompe. Esa distinción evita sobreinterpretaciones. Por ejemplo:




Figura 47.2.: Comparación visual entre ranking SHAP y permutation importance para validar qué señales son estructurales.

men global SHAP del modelo champion, con las variables
el score de default.

Tabla 47.2.: Atribución vs sensibilidad

Variable	SHAP medio	auc_drop por permutación
int_rate	0.4066	0.0754
term	0.2921	0.0144
home_ownership	0.1155	0.0096
fico_score	0.2262	0.0088

`int_rate` domina en ambas métricas, lo que la convierte en el driver más robusto del sistema. `term`, en cambio, tiene una atribución alta pero una sensibilidad menor: empuja muchas predicciones, aunque el desempeño agregado no colapsa si se degrada parcialmente.

i Regla de lectura

Cuando una variable es alta en SHAP y alta en permutación, suele ser una señal estructural. Cuando es alta en SHAP pero moderada en permutación, puede estar capturando contexto frecuente más que dependencia crítica del modelo.

47.0.3. Forma funcional con ALE

Las curvas ALE (`ale_curves.parquet`) son la verificación de monotonía y estabilidad que complementa SHAP. Para `int_rate`, el efecto local acumulado pasa de negativo a positivo alrededor del rango 11-12 %, consistente con una lectura económica razonable: tasas bajas suelen asociarse a prestatarios más seguros y tasas altas a mayor riesgo esperado.

La ventaja de ALE frente a PDP es que reduce la distorsión por correlación entre variables. En un problema crediticio donde `int_rate`, `fico_score` y `grade` están ligados, esa precaución no es opcional.

47.0.4. Familias de variables y controlabilidad

El resumen global también clasifica cada feature por familia y controlabilidad:

- **pricing**: variables de precio y contrato que pueden modificarse por política.
- **credit_quality**: señales históricas del prestatario, no controlables por originación.
- **capacity**: capacidad financiera y carga de deuda.
- **household_profile**: contexto del hogar y estabilidad.

Esta taxonomía permite separar dos conversaciones distintas:

1. qué explica el modelo;
2. qué puede ajustar el negocio para mover el riesgo observado.

En particular, `int_rate` y `term` aparecen como variables controlables. Eso es útil para pricing y diseño de oferta, pero exige vigilancia para no caer en una retroalimentación circular entre precio, selección y riesgo.

47. Explicaciones Globales

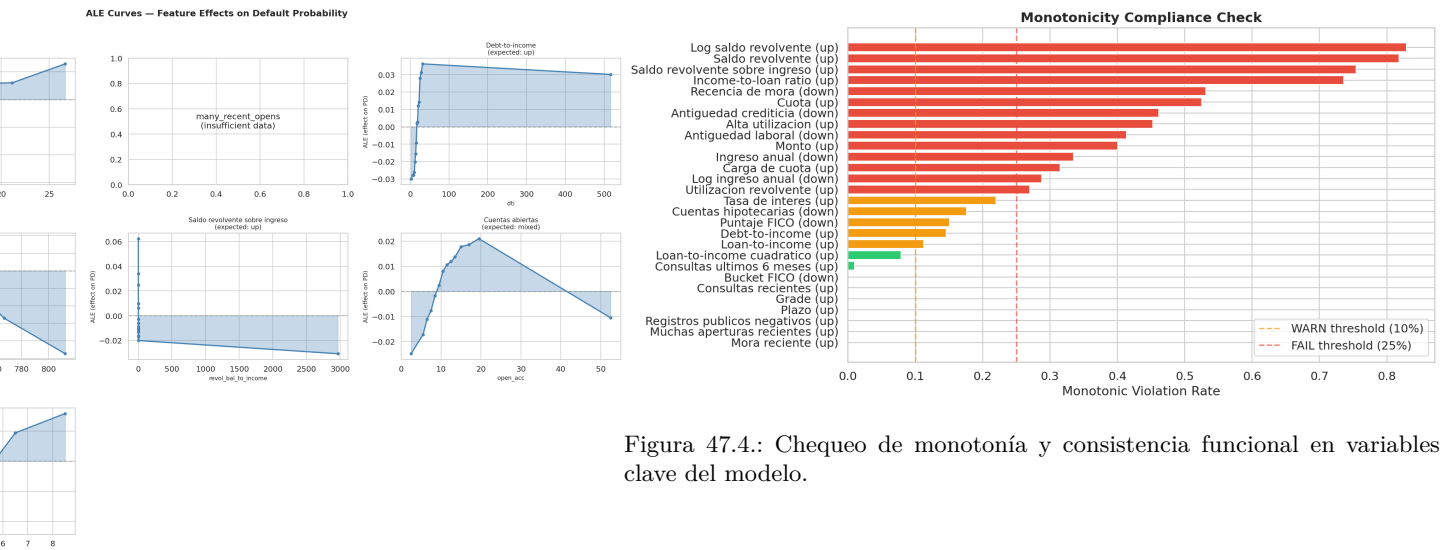


Figura 47.4.: Chequeo de monotonía y consistencia funcional en variables clave del modelo.

vas ALE de las variables principales, usadas para verificar monotonías.




Figura 47.6.: Importancia SHAP agregada en formato barra para lectura ejecutiva.

47.0.5. Apertura metodológica defendible

La lección principal de este capítulo es que el modelo sí puede defenderse globalmente:

- usa drivers económicamente plausibles;
- muestra coherencia entre atribución y sensibilidad;
- conserva monotonías esperadas en variables críticas;
- ofrece una base estable para reason codes locales y monitoreo de drift.

El siguiente paso es bajar de esta vista de portafolio a casos concretos, donde la pregunta deja de ser “qué mueve al modelo en promedio” y pasa a ser “por qué este préstamo quedó donde quedó”.

48. Explicaciones Locales

Las explicaciones locales convierten una predicción en una decisión discutible y trazable. Para originación, challenger review y atención a auditoría, la pregunta no es solo cuánto riesgo tiene un préstamo, sino **qué razones concretas empujaron esa evaluación**.

48.0.1. Casos representativos disponibles

El artefacto `shap_local_cases.parquet` contiene 60 filas que describen préstamos representativos en distintos segmentos. Cada registro incluye:

- `grade` e `issue_quarter` para contexto temporal;
- PD puntual y bandas conformales al 90 % y 95 %;
- razones positivas y negativas a nivel de feature;
- familia de feature y marca de controlabilidad.

Un caso de bajo riesgo del cuarto trimestre de 2019 ilustra bien el enfoque:

Tabla 48.1.: Ejemplo de explicación local defendible

Campo	Valor
Segmento	<code>bajo_riesgo</code>
Grade	<code>A</code>
PD calibrada	5.64 %
Intervalo 90 %	[0.00 %, 18.14 %]
Principales razones a favor	FICO alto, tasa baja, plazo 36 meses

En este préstamo, el FICO de 767 y la tasa de 8.19 % empujan fuertemente el score hacia abajo. El resultado es intuitivo para negocio y consistente con la lectura global del capítulo anterior.

48.0.2. Del SHAP a reason codes operativos

Una explicación local útil debe poder traducirse a reason codes. En este proyecto, la lógica narrativa se apoya en cuatro familias recurrentes:

Tabla 48.2.: Familias de reason codes

Familia	Cómo se comunica
<code>credit_quality</code>	historial y calidad crediticia del solicitante
<code>capacity</code>	presión financiera o capacidad de pago
<code>pricing</code>	condiciones del contrato ofrecido
<code>household_profile</code>	estabilidad del hogar y contexto del solicitante

La ventaja de esta capa es doble. Primero, evita exponer al usuario final una lista cruda de variables. Segundo, mantiene consistencia entre la narrativa de comité y la evidencia técnica subyacente.

48.0.3. Qué hace que una explicación local sea utilizable

En el contexto de riesgo crediticio, una explicación local útil debe cumplir al menos tres criterios:

1. ser coherente con la explicación global;
2. distinguir señales controlables de señales meramente descriptivas;
3. convivir con la banda de incertidumbre, no solo con la predicción puntual.

Ese tercer punto es central. Dos préstamos con la misma PD puntual pueden requerir tratamientos distintos si uno tiene un intervalo mucho más ancho que el otro. La explicación local no debe ocultar esa diferencia.

48.0.4. Uso en revisión de casos

Las explicaciones locales sirven para tres momentos operativos:

Tabla 48.3.: Usos operativos de explicaciones locales

Momento	Pregunta de negocio	Uso de la explicación
Originación	¿por qué este préstamo quedó en zona gris?	identificar palancas de precio, plazo o documentación
Validación	¿la razón local coincide con la teoría del modelo?	detectar atajos o señales no plausibles
Auditoría	¿puedo reconstruir la decisión?	asociar score, intervalo y drivers a un caso concreto

48.0.5. Limitaciones

Las explicaciones locales no prueban causalidad. Describen cómo el modelo usó la información disponible, no qué cambiaría realmente el outcome del prestatario en el mundo real. Por eso este libro mantiene separadas las capas de interpretabilidad y la capa de inferencia causal.

También hay que evitar una falsa sensación de precisión: un *reason code* es más convincente cuando aparece junto a su contexto de incertidumbre. En este proyecto, la práctica recomendada es presentar siempre el trío:

1. PD calibrada,
2. intervalo conformal,
3. top drivers locales.

Con esa convención, la explicación deja de ser una nota anecdótica y se convierte en un artefacto formal de decisión.

49. Drift de Explicaciones

La estabilidad de un modelo no se evalúa solo por AUC o cobertura. Un sistema puede conservar desempeño aceptable mientras cambia silenciosamente la narrativa de por qué decide. Ese riesgo es especialmente sensible en crédito, donde comités y validadores esperan continuidad económica en los drivers.

49.0.1. Qué se monitorea

El artefacto `explanation_drift.parquet` compara un periodo de referencia amplio (2018Q1-2019Q3) con un periodo de contraste (2019Q4-2020Q3). La evaluación resume tres preguntas:

1. ¿se conservan los top drivers globales?
2. ¿cambió materialmente la distribución SHAP de los drivers críticos?
3. ¿los reason codes dominantes siguen contando la misma historia?

49.0.2. Resultado del snapshot actual

Tabla 49.1.: Resumen de drift explicativo

Indicador	Valor	Lectura
<code>rank_overlap_top10</code>	1.00	mismo top 10 global
<code>avg_shap_psi_top5</code>	0.0491	cambio pequeño en masa SHAP
<code>max_shap_psi_top5</code>	0.0757	sin desplazamiento severo
<code>reason_code_match_rate</code>	1.00	reason codes líderes estables
<code>passed_all</code>	True	snapshot en verde

Los detalles internos muestran que `int_rate`, `term`, `fico_score`, `dti` y `home_ownership` siguen siendo el corazón del modelo. Ese resultado es valioso porque el periodo de comparación incluye un entorno de mercado más exigente.

49.0.3. Por qué esto importa para gobernanza

Si el ranking de drivers cambia abruptamente, aparecen dos hipótesis incómodas:

- el modelo empezó a explotar una señal espuria;
- el proceso de datos cambió y ya no estamos midiendo el mismo fenómeno.

49. Drift de Explicaciones

El drift explicativo funciona entonces como una alarma temprana entre el monitoreo de datos y el monitoreo de performance. No sustituye PSI, KS o cobertura conformal, pero complementa esos controles con una capa semántica.

💡 Señal de confianza

Un `rank_overlap_top10 = 1.00` no significa “inmutabilidad total”; significa que la narrativa económica principal del modelo sobrevivió al cambio de periodo. Eso aumenta la defendibilidad del sistema frente a revisores humanos.

49.0.4. Relación con drift de datos

El capítulo de monitoreo de datos ya mostró que varias variables experimentan desplazamientos detectables por KS o CvM. El punto interesante es que esos movimientos no se tradujeron, por ahora, en una ruptura del mapa explicativo central. En otras palabras:

data drift $\nRightarrow$ explanation drift severo

Esta separación permite respuestas más finas. No toda alerta de datos requiere reentrenamiento inmediato; algunas pueden manejarse con observación reforzada si la lógica explicativa y la cobertura siguen siendo estables.

49.0.5. Limitaciones

El snapshot actual es corto y agregado. Todavía falta:

1. ampliar la comparación por segmento y por grade;
2. medir estabilidad trimestral continua, no solo dos ventanas agregadas;
3. vincular alertas explicativas con reglas automáticas de escalamiento en MRM.

Pese a ello, el estado actual ya mejora mucho la práctica usual: el proyecto no solo reporta qué tan bien predice el modelo, sino si sigue contando la misma historia económica a lo largo del tiempo.

50. Dataset 360°

Una visión completa del dataset de Lending Club como plataforma de investigación: desde el análisis exploratorio hasta el benchmarking contra la literatura publicada.

51. Hallazgos Clave del EDA

El EDA del proyecto no es una introducción decorativa; fija el contrato de realidad sobre el que descansan todos los capítulos posteriores. Antes de modelar, conviene dejar congelados tres hechos: el tamaño del universo, la tasa de default y el gradiente económico del riesgo.

51.0.1. Universo analítico

En el split de entrenamiento usado para construcción de features y modelado principal, el artefacto `eda_summary.json` reporta:

Tabla 51.1.: Radiografía del dataset de entrenamiento

Indicador	Valor
Préstamos analizados	1,346,311
Tasa global de default	18.52 %
Registros con plazo 36m	1,005,656
Registros con plazo 60m	340,655

La mezcla de plazos confirma que el problema no es homogéneo: una porción material del portafolio está expuesta a horizontes contractuales largos, lo que justifica el uso posterior de supervivencia, IFRS9 lifetime y escenarios temporales.

51.0.2. Gradiente de riesgo por grade

La señal más importante del EDA es el orden económico del default por grade:

Tabla 51.2.: Gradiente de riesgo por grade


Grade	Default rate
A	5.63 %
B	12.29 %
C	20.64 %
D	28.31 %
E	36.47 %
F	43.44 %

51. Hallazgos Clave del EDA

Grade	Default rate
G	47.71 %

Este patrón valida dos decisiones estructurales del libro:

1. usar **grade** como partición natural para análisis conformales y lectura prudencial;
2. tratar la tasa de interés y el precio de originación como variables centrales de interpretación.



de default por grade en Lending Club, usada como evidencia base del gradiente económico de riesgo.

La figura Figura 51.1 hace visible el orden económico que luego reaparece en conformal, IFRS9 y optimización: el dataset sí tiene una estructura de riesgo interpretable y consistente.

51.0.3. Lecturas que sí importan

El EDA deja tres mensajes prácticos:

- el riesgo no está uniformemente distribuido;
- existe una mezcla fuerte de segmentos, no un “prestatario promedio” representativo;
- cualquier validación aleatoria sería demasiado optimista frente a la dinámica temporal real.

Por eso el pipeline se apoya en *out-of-time validation* y no en validación IID ingenua.

51.0.4. Variables con contenido económico

Aunque el dataset es amplio, el proyecto organiza la historia en torno a unas pocas familias con interpretación clara:

Tabla 51.3.: Familias con valor narrativo y operativo

Familia	Variables emblemáticas	Papel en la narrativa
Precio / contrato	<code>int_rate</code> , <code>term</code>	resumen del riesgo percibido en originación
Calidad crediticia	<code>fico_score</code> , historial	solvencia previa del cliente
Capacidad	<code>dti</code> , ingreso	presión financiera
Perfil del hogar	<code>home_ownership</code> , verificación	estabilidad y contexto

51.0.5. Qué habilita este capítulo

Con este diagnóstico, el resto del libro deja de depender de intuiciones blandas. El EDA justifica:

- la ingeniería de variables posterior;
- la partición temporal `train/cal/test`;
- la elección de métricas y grupos para fairness, drift y cobertura;
- la lectura prudencial de los resultados IFRS9.

El objetivo no es “mostrar gráficos bonitos”, sino fijar el terreno sobre el cual una decisión de riesgo puede ser defendida.

52. Análisis Geográfico y Temporal

La heterogeneidad geográfica y temporal es una de las razones por las que este problema no puede tratarse como una tabla tabular estática. El mismo score puede significar cosas distintas cuando cambia el estado, el ciclo crediticio o el régimen macroeconómico.

52.0.1. Cobertura geográfica

El artefacto `state_aggregates.parquet` resume 51 jurisdicciones. La dispersión es amplia tanto en volumen como en default:

Tabla 52.1.: Muestra del agregado geográfico

Estado	N préstamos	Default rate	Volumen total
CA	264,525	19.47 %	\$3.94B
AZ	45,521	19.03 %	\$0.64B
AL	22,802	22.72 %	\$0.32B
AR	14,087	23.62 %	\$0.19B
AK	4,343	18.97 %	\$0.07B

La presencia de estados con mucho menor soporte muestral también es una advertencia metodológica: no toda heterogeneidad observable amerita una partición operacional. En varios capítulos posteriores se privilegia `grade` como grupo Mondrian precisamente porque tiene mejor estabilidad y sentido regulatorio.

52.0.2. No estacionariedad temporal

El proyecto usa una división temporal explícita, no un *shuffle split*. La narrativa sincronizada con la tesis fija el esquema canónico:

Tabla 52.2.: Esquema temporal del pipeline

Split	Filas	Periodo narrativo
Train	1,346,311	2007-2017
Calibration	237,584	ventana de ajuste intermedia
Test OOT	276,869	2018-2020

Esta estructura cumple dos objetivos. Primero, evita contaminación entre desarrollo y evaluación. Segundo, reproduce la forma en que un banco realmente desplegaría el modelo: entrenando en historia conocida y enfrentándolo luego a un periodo futuro.

52.0.3. La geografía no es solo un mapa

En crédito, el estado resume mezcla de regulación local, composición sectorial, mercado laboral y comportamiento del prestatario. Sin embargo, este libro evita sobredimensionar esa dimensión. La lectura correcta es:

- la geografía aporta contexto;
- el tiempo aporta el verdadero test de robustez;
- la combinación de ambos obliga a monitoreo continuo.

52.0.4. Por qué la validación temporal manda

La evidencia de drift en variables como `fico_score` e `int_rate` confirma que el portafolio cambia en el tiempo. Si a eso se suma la heterogeneidad por estado, el costo de ignorar la dimensión temporal sería alto:

validación aleatoria $\Rightarrow$ optimismo artificial en desempeño y cobertura

Por eso los resultados fuertes del libro se reportan siempre en ventanas OOT o con trazabilidad temporal explícita.

52.0.5. Implicación para capítulos posteriores

Este capítulo habilita tres decisiones de diseño:

1. monitoreo de drift con PSI, KS y CvM;
2. cobertura conformal evaluada por cohorte temporal y por grupo;
3. escenarios IFRS9 y proyecciones ECL como extensiones naturales del análisis temporal.

La conclusión de fondo es sencilla: el dataset no es solo grande; es dinámico y heterogéneo. El pipeline completo fue construido para respetar esa realidad.

53. Benchmark contra Literatura

El valor de este libro no depende de superar un leaderboard aislado. Aun así, es importante ubicar el resultado del pipeline frente a referencias publicadas para evitar dos errores opuestos: vender de más lo conseguido o subestimar su relevancia.

53.0.1. Punto de comparación disponible

El artefacto `lendingclub_literature_benchmark.parquet` registra una referencia explícita revisada por pares sobre Lending Club:

Tabla 53.1.: Benchmark externo curado para Lending Club

Fuente	Familia de modelo	AUC reportado
Li et al. (2022, benchmark Lending Club)	LightGBM / Gradient Boosting	0.7492
Survey de explicabilidad P2P	Árboles + SHAP/LIME	n/a

Nuestro pipeline canónico reporta $AUC = 0.7130$ para CatBoost calibrado con Venn-Abers sobre evaluación OOT.

53.0.2. Comparación correcta, no tramposa

La diferencia entre 0.7130 y 0.7492 **no** debe leerse automáticamente como inferioridad metodológica. Hay al menos tres razones:

1. el protocolo de split puede no coincidir;
2. el objetivo del proyecto no es solo maximizar AUC, sino producir probabilidades calibradas y gobernables;
3. el libro optimiza un pipeline completo con incertidumbre, IFRS9, explicabilidad y robustez, no solo clasificación.

En otras palabras, una comparación honesta requiere comparar tanto el contexto experimental como el producto final de decisión.

Métrica líder vs sistema líder

Una AUC más alta puede coexistir con peor calibración, peor cobertura y menor capacidad de auditoría. Este libro privilegia el sistema líder, no la métrica líder aislada.

53.0.3. Dónde sí hay fortaleza comparativa

Aunque el AUC puro no busque romper el techo de la literatura, el proyecto sí aporta en dimensiones poco cubiertas por benchmarks clásicos:

- calibración probabilística explícita con Venn-Abers;
- cuantificación de incertidumbre conformal con cobertura observable;
- conexión operacional a optimización robusta e IFRS9;
- monitoreo de fairness y drift dentro del mismo marco narrativo.

Estas capas son justamente las que suelen faltar en papers de scoring centrados solo en clasificación.

53.0.4. Lectura académica

La literatura más reciente que el proyecto curó en `docs/PAPER_REFERENCES_STATE_OF_ART.md` sugiere que los vacíos están menos en “otro modelo tabular para Lending Club” y más en las combinaciones:

1. conformal + robust optimization;
2. conformal + IFRS9 / SICR;
3. cobertura por subgrupo en crédito real;
4. gobernanza reproducible de punta a punta.

Ese es el espacio donde el libro y los papers derivados son más competitivos.

53.0.5. Conclusión

El benchmark externo sirve como calibrador de humildad: el pipeline no pretende vender un nuevo récord absoluto de AUC. Su contribución más defendible es distinta: convertir un stack de riesgo crediticio en un sistema calibrado, explicable, incierto-de-forma-medible y gobernable.

54. Temas Avanzados

Análisis complementarios que profundizan la visión 360° del dataset: comparaciones de métodos de incertidumbre, riesgos competitivos, costos de misclasificación y propagación de incertidumbre temporal.

55. Baselines de Incertidumbre: BMA vs CP

Una afirmación fuerte sobre incertidumbre no se sostiene sin comparación. Por eso el proyecto contrasta la banda conformal con *Bayesian Model Averaging* (BMA) y otros enfoques alternativos antes de declararla útil para decisión.

55.0.1. Qué se compara

El artefacto `uncertainty_baselines_comparison.parquet` resume el contraste entre métodos sobre el mismo universo OOT. En el run actual, la diferencia clave es:

Tabla 55.1.: Baselines de incertidumbre relevantes

Método	Cobertura empírica	Ancho medio	Cobertura mínima por grupo
Conformal	92.52 %	0.7546	89.01 %
Mondrian			
Bootstrap	89.83 %	0.9523	61.93 %

La lectura es clara. El bootstrap necesita intervalos más anchos y aun así deja grupos con *under-coverage* severa. La variante conformal, en cambio, logra mejor equilibrio entre garantía y eficiencia.

55.0.2. Qué muestra BMA

El artefacto `bma_comparison.parquet` cubre 276,869 préstamos y deja ver una limitación práctica importante: muchos intervalos BMA se saturan en el rango completo $[0,1]$, lo que produce coberturas triviales y poco accionables.


Ese comportamiento no invalida el enfoque bayesiano en abstracto; sí revela que, en este problema y con esta parametrización, la incertidumbre resultante no tiene la granularidad operativa deseada para decisiones de originación o portafolio.

55.0.3. Por qué gana CP en este contexto

Conformal Prediction ofrece tres ventajas aquí:

1. garantía finita de cobertura bajo supuestos más débiles;
2. posibilidad de particionar por grupos económicamente relevantes;

Uncertainty Set Methods: Coverage, Width, and Group Guarantee
(OOT $n = 276,869$, nominal 90%)



comparación editorial entre baselines de incertidumbre, incluyendo conformal y alternativas competitivas.

3. interpretación directa de los intervalos como conjuntos de decisión.

La comparación no pretende afirmar que CP domina cualquier enfoque bayesiano en cualquier dominio. La afirmación defendible es más específica: **para este pipeline crediticio y este objetivo operativo, CP entrega una incertidumbre más usable.**

55.0.4. Implicación para el resto del libro

Este capítulo justifica dos movimientos posteriores:

- en el Paper Estrella, tratar el intervalo conformal como *uncertainty set* operativo;
- en IFRS9, usar el ancho conformal como señal complementaria de prudencia y SICR.

55.0.5. Limitación

La familia de baselines aún puede ampliarse con variantes elipsoidales, cuantiles paramétricos y aproximaciones fully Bayesian mejor calibradas. Pero incluso con esta comparación parcial, la evidencia ya alcanza para sostener que el baseline de incertidumbre del libro no fue elegido por conveniencia.

56. Alpha Sweep y Frontera de Pareto

El nivel de confianza conformal no es un parámetro decorativo. Cambiar `alpha` cambia simultáneamente cobertura, ancho y la política económica que el optimizador considera viable. Por eso el libro congela un *alpha sweep* explícito en lugar de fijar 90 % por costumbre.

56.0.1. El frente cobertura-ancho-decisión

El artefacto `alpha_sweep_pareto_both.parquet` contiene 16 configuraciones y resume el trade-off entre confianza y accionabilidad. En la familia global se observa el patrón esperado:

Tabla 56.1.: Sweep global de alpha

alpha	Confianza	Cobertura empírica	Ancho medio
0.10	90 %	89.80 %	0.9078
0.07	93 %	92.94 %	0.9438
0.05	95 %	95.05 %	0.9595
0.01	99 %	98.68 %	0.9933

El patrón es monótonico y útil: mayor confianza implica mayor ancho. Lo importante es que el costo no es lineal para decisión; llega un punto donde casi no quedan observaciones elegibles o el portafolio se vuelve demasiado conservador.


56.0.2. Frontera de Pareto operativa

La frontera relevante del proyecto no es solo cobertura vs ancho, sino:

$$\text{Cobertura} \uparrow \iff \text{Ancho} \uparrow \iff \text{Retorno robusto utilizable} \downarrow$$

Ese tercer eje explica por qué el libro conecta directamente el sweep con portafolio e IFRS9: elegir `alpha` define cuánto capital, provisión o apetito de riesgo estamos dispuestos a inmovilizar por prudencia.

Alpha Sweep: Coverage-Width-Eligibility Trade-off (Mondrian vs. Global, $n_{cal} = 237,584$)



tera alpha-cobertura-retorno para el barrido operativo del parámetro conformal.

56.0.3. Qué política deja este análisis

El sweep sugiere una regla editorial y metodológica simple:

1. 90 % es razonable como punto operativo de trabajo;
2. 95 % sirve como lectura prudencial más exigente;
3. 99 % es útil como escenario de estrés, no como default de producción.

Esta regla evita caer en la tentación de usar el mayor nivel de confianza disponible sin medir su costo económico.

56.0.4. Conexión con papers

El Paper Estrella usará este frente como parte de su argumento de *predict-then-optimize*: el nivel conformal puede verse como una palanca explícita de robustez. El Paper IFRS9 lo reinterpreta como costo prudencial sobre ECL y staging.

56.0.5. Limitación

La frontera actual resume un universo y un run congelados. El paso natural siguiente es repetirla por segmento, por grade y por periodo para identificar si el **alpha** operativo debería ser único o contextual.

57. Riesgos Competitivos y su Impacto en ECL

Modelar lifetime credit loss con un solo mecanismo de salida suele ser insuficiente. En crédito minorista, prepago, cancelación y otros eventos compiten con el default y alteran la pérdida esperada. Este capítulo documenta esa diferencia usando el artefacto `cif_ecl_impact.parquet`.

57.0.1. KM vs CIF

La comparación clave enfrenta dos lecturas:

- Kaplan-Meier (KM), que trata otros eventos como censura;
- *Cumulative Incidence Function* (CIF), que modela explícitamente riesgos competitivos.

La diferencia no es menor. Para varios grades, el ECL de Stage 2 cambia materialmente cuando se respeta la competencia entre eventos.

Tabla 57.1.: Impacto de riesgos competitivos sobre ECL Stage 2

Grade	Stage 2 ECL KM	Stage 2 ECL CIF	Exceso por préstamo	Exceso portafolio
A	\$1,124.89	\$824.74	\$300.14	\$21.73M
B	\$1,593.57	\$1,168.37	\$425.20	\$32.02M
C	\$2,265.11	\$1,660.73	\$604.38	\$42.65M
D	\$3,173.29	\$2,326.59	\$846.71	\$38.64M

57.0.2. Lectura prudencial

En este snapshot, KM tiende a inflar la lectura de Stage 2 frente a CIF. Eso no significa que CIF sea “más conservador” o “más laxo” por definición; significa que **ignorar riesgos competitivos sesga la pérdida esperada**.

La dirección del sesgo dependerá de la mezcla de prepago, horizonte y composición del portafolio. Lo relevante para el libro es que el sesgo existe y es cuantificable.

57.0.3. Por qué esto importa para IFRS9

IFRS9 exige una estimación razonable y sustentable de pérdidas esperadas. Si dos metodologías producen diferencias de decenas de millones en ECL agregado por grade, la elección del método deja de ser un detalle técnico y se convierte en una decisión de gobernanza.

57.0.4. Qué aporta este capítulo

Este resultado abre dos líneas:

1. justifica la inclusión de supervivencia y competing risks como capa seria del stack;
2. alimenta una agenda de paper enfocada en lifetime PD y provisiones con estructura de eventos más realista.

57.0.5. Limitación

La implementación actual es todavía un análisis comparativo congelado, no la policy oficial de provisión. Antes de promover CIF como estándar productivo habría que extender validación, sensibilidad y trazabilidad regulatoria por escenario.

58. Costo de Misclasificación de Stages

Clasificar mal un préstamo entre Stage 1 y Stage 2 no es un error abstracto; tiene costo económico. Este capítulo convierte esa intuición en una superficie cuantificada usando `stage_misclassification_cost.parquet`.

58.0.1. Qué se penaliza

La matriz de costo separa dos fallas:

- **False Negative:** un préstamo que debió estar en Stage 2 pero quedó en Stage 1;
- **False Positive:** un préstamo sobre-clasificado a Stage 2, generando provisión y fricción innecesaria.

El costo total puede resumirse como:

$$\text{Costo total} = \text{Costo}_{FN} + \text{Costo}_{FP}$$

pero el interés real está en cómo cambia ese costo con el umbral de PD y con el uso del trigger por ancho conformal.

58.0.2. Superficie base por umbral PD

Sin trigger adicional de ancho, la tabla muestra:

Tabla 58.1.: Costo de clasificación Stage 2 sin trigger de ancho

Umbral PD	% Stage 2	FN cost	FP cost	Total cost
0.10	77.14 %	\$3.49M	\$83.14M	\$100.57M
0.15	64.99 %	\$6.27M	\$65.96M	\$97.33M
0.20	46.89 %	\$12.17M	\$41.24M	\$102.10M
0.25	36.95 %	\$16.20M	\$28.91M	\$109.90M
0.30	26.64 %	\$20.91M	\$17.15M	\$121.70M

El mínimo en este snapshot aparece alrededor de `pd_threshold = 0.15`. Esa observación es muy útil porque muestra que el umbral “natural” no es necesariamente el más prudente ni el más barato.

58.0.3. Lectura de trade-off

Umbrales bajos reducen falsos negativos, pero disparan falsos positivos y sobrerreserva. Umbrales altos hacen lo contrario. El capítulo sobre SICR conformal introduce precisamente una tercera vía: usar ancho de incertidumbre para rescatar casos que la PD puntual deja en zona gris.

58.0.4. Por qué importa para política

Una política IFRS9 defendible no debería fijar thresholds solo por tradición. Debería responder a una pregunta explícita:

¿Cuál es el costo aceptable de sub-provisionar frente al costo aceptable de sobre-provisionar?

El artefacto de costo obliga a esa conversación y evita que el umbral sea tratado como una constante técnica incuestionable.

58.0.5. Limitación

La superficie actual resume un esquema de costos y una definición operacional concreta de FN/FP. Si cambian supuestos de negocio o escenario macro, el óptimo puede moverse. Aun así, el valor del capítulo permanece: los *stages* dejan de ser etiquetas y pasan a ser decisiones con función de pérdida explícita.

59. Intervalos de Series de Tiempo Propagados a ECL

El pipeline temporal no termina cuando se pronostica una tasa de default. Su valor real aparece cuando esa incertidumbre se propaga hacia provisiones. El artefacto `ts_ecl_intervals.parquet` documenta justamente ese puente entre series de tiempo y lectura prudencial de ECL.

59.0.1. Qué contiene el artefacto

Para cada mes, el snapshot registra:

- pronóstico puntual (`ts_point`);
- banda adversa y optimista al 90 %;
- multiplicadores de PD inducidos por el forecast;
- ECL puntual y bandas ECL correspondientes;
- conteo de préstamos que migran a Stage 2 en cada escenario.

59.0.2. Ejemplo mensual

Los primeros meses disponibles muestran una expansión material del rango ECL:

Tabla 59.1.: Propagación de pronóstico temporal a ECL

Mes	ECL punto	ECL adverse 90	ECL optimistic 90	Rango ECL 90
2020-10	\$47.5M	\$199.9M	\$47.5M	\$152.4M
2020-11	\$47.5M	\$313.7M	\$47.5M	\$266.1M
2020-12	\$61.1M	\$349.0M	\$47.5M	\$301.4M
2021-01	\$109.6M	\$352.2M	\$47.5M	\$304.7M

La conclusión es fuerte: pequeñas diferencias en el forecast mensual pueden traducirse en cambios enormes en provisión y en tamaño de Stage 2.

59. Intervalos de Series de Tiempo Propagados a ECL




Figura 59.2.: Comparación de modelos y trayectorias agregadas del portafolio en la capa temporal.

59.0.3. Interpretación

Este capítulo deja dos mensajes:

1. la incertidumbre temporal no debe quedarse en la capa de forecasting;
2. un escenario macro adverso puede entrar al balance vía multiplicadores de PD mucho antes de materializar defaults observados.

En ese sentido, los intervalos temporales se parecen más a una herramienta de planeación prudencial que a una simple mejora de accuracy.

59.0.4. Relación con IFRS9

La conexión con el capítulo IFRS9 es directa. Si el ECL agregado por escenario ya es sensible a multiplicadores macro, agregar una banda temporal hace visible una segunda fuente de fragilidad: la incertidumbre sobre la trayectoria futura del propio entorno.

59.0.5. Qué falta

Todavía no se ha integrado esta capa como política oficial de staging o provisión mensual. El valor actual es analítico y estratégico:

- cuantifica el rango de provisión inducido por forecasting;
- muestra el impacto potencial sobre Stage 2;
- prepara una agenda sólida para papers y extensiones de maestría.

Así, el libro deja claro que el forecast no es un apéndice aislado, sino un insumo que puede mover materialmente la lectura de pérdida esperada.

Parte IV.

Parte IV: Papers de Investigación

60. Paper Estrella: Predict-then-Optimize con Incertidumbre Conformal

! Paper autocontenido

Esta sección funciona como un draft independiente del paper principal de la tesis. Puede contener información que se repite de capítulos anteriores para garantizar que sea autocontenido.

61. Introducción y Motivación

La mayoría de los pipelines de crédito siguen una receta implícita: predecir una PD puntual y optimizar decisiones como si esa predicción fuera exacta. El problema es conocido y profundo: pequeñas desviaciones de calibración o cambios de régimen pueden inducir políticas frágiles, justo en la capa donde se asigna capital.

Este paper propone una respuesta operativa y científicamente defendible: usar intervalos conformales como conjuntos de incertidumbre para optimización robusta de portafolio. El foco no es “otro modelo de scoring”, sino un puente explícito entre *uncertainty quantification* y *predict-then-optimize*.

61.0.1. Brecha en la literatura

La curaduría de `docs/PAPER_REFERENCES_STATE_OF_ART.md` muestra un panorama sugerente:

- sí existen trabajos sobre *Conformal Robust Optimization*;
- sí existe la literatura clásica de *price of robustness* y SPO+;
- no aparece una integración clara entre crédito minorista real, intervalos conformales y asignación robusta de portafolio.

Esa brecha es especialmente interesante en Lending Club, donde el paso de score a decisión económica es inmediato y medible.

61.0.2. Pregunta central

¿Puede un intervalo conformal actuar como conjunto de incertidumbre operativo para asignación robusta de capital crediticio sin depender de supuestos distribucionales fuertes?

61.0.3. Contribuciones del paper

1. Formaliza el uso de intervalos conformales como *uncertainty sets* para selección de portafolio.
2. Compara esta estrategia contra baselines alternativos de incertidumbre, incluyendo bootstrap y referencias a decision-focused learning.
3. Cuantifica la frontera entre cobertura, ancho y retorno económico bajo una misma trazabilidad experimental.

61.0.4. Relevancia metodológica

El valor del paper no está solo en la robustez. También está en la gobernanza:

- la PD está calibrada con Venn-Abers;
- la incertidumbre tiene cobertura observable;
- la policy promovida queda congelada en `models/champion_registry.json`.

Ese paquete lo diferencia de enfoques puramente teóricos donde el conjunto de incertidumbre es elegante, pero difícil de auditar o desplegar.

61.0.5. Estructura del argumento

Las siguientes secciones desarrollan:

1. el marco teórico que conecta conformal y robustez;
2. el protocolo experimental congelado del proyecto;
3. la evidencia empírica sobre trade-offs y políticas resultantes;
4. las amenazas a la validez y la agenda de cierre para versión journal.

62. Marco Teórico

El marco teórico del paper combina tres tradiciones que normalmente se estudian por separado: predicción probabilística calibrada, incertidumbre distribution-free y optimización robusta.

62.0.1. De probabilidad puntual a banda de riesgo

La primera pieza es el intervalo conformal por observación:

$$\widehat{C}_{1-\alpha}(x, g) = [\max\{0, \hat{p}(x) - q_{1-\alpha, g}\}, \min\{1, \hat{p}(x) + q_{1-\alpha, g}\}]$$

donde g representa la partición Mondrian. El objeto importante no es solo la cobertura marginal, sino la posibilidad de traducir la cota superior del intervalo en una versión prudente del riesgo.

62.0.2. Del intervalo al conjunto de incertidumbre

Para portafolio, la lectura operativa es inmediata:

$$p_i^H(\alpha) = \sup \widehat{C}_{1-\alpha}(x_i, g_i)$$

Ese p_i^H funciona como probabilidad de default en peor caso admisible bajo el nivel conformal elegido. En lugar de construir un conjunto elipsoidal o bootstrap exógeno, el conjunto nace de la propia capa predictiva.

62.0.3. Optimización robusta

El portafolio robusto puede expresarse, de forma esquemática, como:

$$\max_{z \in \{0,1\}^n} \sum_i z_i r_i \quad \text{s.a.} \quad \sum_i z_i a_i \leq B, \quad \sum_i z_i p_i^H(\alpha) a_i \leq \tau B$$

La restricción de pérdida esperada usa la frontera superior inducida por el intervalo. Así, la robustez deja de ser un parámetro abstracto y pasa a estar anclada a un objeto con garantía empírica de cobertura.

62.0.4. Intuición del vínculo α robustez

Aunque la demostración formal completa pertenece a una versión extendida, la intuición del paper es:

$$\alpha \downarrow \Rightarrow \text{intervalos más anchos} \Rightarrow p_i^H \uparrow \Rightarrow \text{restricción robusta más exigente}$$

Esto crea un puente natural con la lógica de Bertsimas y Sim: mayor confianza conformal induce mayor presupuesto implícito de incertidumbre.

62.0.5. Relación con decision-focused learning

El marco también dialoga con SPO+ y literatura afín. La diferencia central es filosófica:

- SPO+ entrena para minimizar regret de decisión;
- el enfoque aquí propuesto protege la decisión a partir de una cuantificación explícita de incertidumbre.

No son enfoques incompatibles. De hecho, el paper los presenta como comparadores naturales para una agenda futura de integración.

62.0.6. Hipótesis defendible

La hipótesis que el resto del paper pone a prueba es concreta:

En crédito minorista real, un conjunto de incertidumbre conformal puede ofrecer mejor equilibrio entre garantía y accionabilidad que baselines clásicos más anchos o menos estables por grupo.

63. Metodología

El experimento se construye sobre el pipeline canónico congelado en el run `paper-grade-2026-03-13-final-heavy-2026-03-13-230650`. La metodología reutiliza artefactos productivos del proyecto para evitar una bifurcación artificial entre “demo académica” y sistema real.

63.0.1. Datos y split

La evaluación usa el universo OOT del proyecto sobre Lending Club, con partición temporal fija y trazabilidad a `data/processed/pipeline_summary.json` y `data/processed/model_comparison.json`.

Tabla 63.1.: Base predictiva del experimento

Componente	Valor
Modelo base	CatBoost calibrado
Método de calibración	Venn-Abers
AUC OOT	0.7130
Ensayos HPO	320

63.0.2. Construcción del conjunto de incertidumbre

La incertidumbre principal proviene de la capa conformal, complementada con comparadores:

- Mondrian conformal como método candidato principal;
- bootstrap y BMA como baselines alternativos;
- sweep de alpha para trazar la frontera cobertura-ancho-retorno.

Los artefactos clave son `uncertainty_baselines_comparison.parquet`, `bma_comparison.parquet` y `alpha_sweep_pareto_both.parquet`.

63.0.3. Política económica evaluada

La policy promovida en `models/champion_registry.json` usa:

Tabla 63.2.: Política campeona de portafolio

Parámetro	Valor
<code>risk_tolerance</code>	0.18
<code>gamma</code>	0.10
<code>uncertainty_aversion</code>	0.10
<code>policy_mode</code>	<code>segment_relative_tail_blended_uncertainty</code>

La lectura importante es que el paper no optimiza una policy abstracta; estudia una policy con semántica económica concreta y ya promovida a registro.

63.0.4. Métricas

El análisis reporta cuatro familias de resultados:

1. calidad predictiva y calibración de la PD base;
2. cobertura, ancho y cobertura mínima por grupo del intervalo;
3. retorno y número de préstamos financiados bajo policy robusta;
4. sensibilidad de decisión al barrido de `alpha`.

63.0.5. Reproducibilidad

La versión del paper en el libro se apoya en artefactos ya generados y en figuras archivadas bajo `reports/paper_material/figures_publication/`. Esto permite separar claramente entre:

- evidencia ya ejecutada y congelada;
- extensiones teóricas o experimentales reservadas para la versión journal.

64. Resultados

Los resultados del Paper Estrella deben leerse como una prueba de viabilidad del marco, no como un torneo aislado de AUC. La evidencia relevante está en la interacción entre incertidumbre y decisión.

64.0.1. Base predictiva e incertidumbre

El pipeline reporta:

Tabla 64.1.: Resumen predictivo del paper

Indicador	Valor
AUC OOT	0.7130
Cobertura conformal 90 %	92.52 %
Cobertura conformal 95 %	95.93 %
Ancho medio 90 %	0.7546

La base del argumento ya aparece aquí: el conjunto de incertidumbre no es arbitrario ni excesivamente holgado frente a su garantía observada.

64.0.2. Baselines de incertidumbre

Frente al bootstrap, la banda conformal entrega un mejor equilibrio:


Tabla 64.2.: Comparación con baseline de incertidumbre

Método	Cobertura	Ancho medio	Min group coverage
Conformal Mondrian	92.52 %	0.7546	89.01 %
Bootstrap	89.83 %	0.9523	61.93 %


Esto sugiere que el valor del método no es solo “cubrir”, sino **cubrir mejor con menor costo de anchura y menor castigo a subgrupos**.

64. Resultados

Uncertainty Set Methods: Coverage, Width, and Group Guarantee
(OOT $n = 276,869$, nominal 90%)



Alpha Sweep: Coverage-Width-Eligibility Trade-off
(Mondrian vs. Global, $n_{cal} = 237,584$)



Comparación editorial de baselines de incertidumbre del PaperFigura 64.2.: Frontera alpha-cobertura-retorno del Paper Estrella.

64.0.3. Resultado económico congelado


En el resumen de pipeline, la policy robusta promovida logra:

Tabla 64.3.: Resultado económico de la policy promovida

Indicador	Valor
Retorno robusto	\$183,071
Préstamos financiados	299
Retorno no robusto	~0
Price of robustness reportado	-\$183,071

La combinación luce extraña a primera vista porque el baseline puntual bajo esta policy queda prácticamente sin elegibles. Esa asimetría no invalida el resultado; revela que la decisión depende fuertemente del modo en que se define elegibilidad y protección ante cola de riesgo.

SPO+ vs. Two-Stage vs. Conformal Robust: Decision Regret
($n = 1000$, $n_{test} = 200$ instances/seed, 5 seeds, $n_{items} = 100$)



Comparación de regret entre estrategias predict-then-optimize
del Paper Estrella.

CQR vs. Mondrian CP: Per-Grade Coverage
(OOT, $\alpha = 0.10$)




Figura 64.4.: Cobertura por grado bajo CQR y variantes conformales evaluadas en el Paper Estrella.

1. la incertidumbre conformal es suficientemente estable para entrar al optimizador;
2. frente a baselines alternativos, produce un conjunto más usable;
3. la calidad de la policy depende de cómo se negocia cobertura contra restricción económica.

Ese matiz hace al paper más creíble y más útil para venues de OR o *analytics* aplicada.

65. Discusión y Conclusiones

El Paper Estrella articula la tesis más ambiciosa del proyecto: convertir incertidumbre predictiva en un objeto directamente útil para optimización de decisión. La evidencia actual ya permite sostener tres conclusiones provisionales.

65.0.1. Conclusiones

1. Los intervalos conformales funcionan como conjuntos de incertidumbre operativos y trazables.
2. Frente a baselines simples, ofrecen mejor compromiso entre cobertura, anchura y estabilidad por grupo.
3. El nivel conformal puede interpretarse como una palanca de robustez con consecuencias económicas observables.

65.0.2. Threats to validity

La versión actual todavía enfrenta límites claros:

- el vínculo teórico α - Γ requiere formalización completa;
- el resultado económico depende de una policy y un run concretos;
- faltan comparadores más ricos de decision-focused learning y robustez contextual.

65.0.3. Reproducibility appendix

La reproducibilidad del paper está mejor resuelta que su cierre teórico. El capítulo se apoya en:

- `data/processed/model_comparison.json`
- `data/processed/pipeline_summary.json`
- `data/processed/alpha_sweep_pareto_both.parquet`
- `data/processed/bma_comparison.parquet`
- `models/champion_registry.json`

Además, la carpeta `reports/paper_material/figures_publication/` conserva las figuras editoriales congeladas para escritura y revisión.

65.0.4. Próximo paso editorial

La mejor continuación no es expandir alcance indiscriminadamente, sino endurecer el claim central con una versión journal:

1. demostración formal más sólida;
2. benchmark adicional contra CRO y SPO+;
3. análisis de sensibilidad por segmento y periodo.

Con eso, el paper quedaría bien posicionado como pieza bandera de la agenda de maestría.

66. Paper 2: IFRS9 End-to-End con Incertidumbre Conformal

! Paper autocontenido

Esta sección funciona como un draft independiente del paper IFRS9.

67. Introducción

IFRS9 obliga a convertir riesgo en provisión bajo una lógica prospectiva y defendible. En la práctica, muchos pipelines siguen descansando en PD puntuales y reglas SICR relativamente toscas. Este paper propone una extensión concreta: incorporar incertidumbre conformal dentro de un pipeline IFRS9 end-to-end.

67.0.1. Problema

Una PD puntual ordena riesgo, pero no informa cuánta confianza merece esa estimación justo cuando la decisión contable se vuelve más sensible. Esa limitación afecta tres frentes:

1. staging (Stage 1/2/3);
2. provisión esperada (ECL);
3. sensibilidad ante escenarios macro y drift temporal.

67.0.2. Pregunta del paper

¿Cómo integrar incertidumbre distribution-free en un pipeline IFRS9 sin romper trazabilidad, gobernanza ni interpretabilidad operacional?

67.0.3. Contribuciones

1. ECL por rango usando PD puntual y bandas conformales.
2. Trigger SICR enriquecido con ancho conformal.
3. Sensibilidad explícita de provisiones frente a escenarios y parámetros prudenciales.

67.0.4. Relevancia de la brecha

La revisión de docs/PAPER_REFERENCES_STATE_OF_ART.md identifica un vacío notable: el proyecto no encontró papers que conecten explícitamente conformal prediction con provisiones IFRS9 end-to-end. Esa ausencia vuelve el caso más valioso, pero también exige una escritura prudente y muy bien trazada.

68. Metodología

La metodología reutiliza el stack productivo del proyecto y lo reorganiza en clave de paper. El objetivo es mostrar que IFRS9 no es una “aplicación lateral”, sino una consecuencia natural del pipeline de riesgo ya construido.

68.0.1. Componentes del pipeline

Tabla 68.1.: Capas metodológicas del Paper 2

Capa	Artefacto principal	Rol
PD calibrada	<code>data/processed/model_comparison_probabilistic</code>	probabilidad puntual defendible
Incertidumbre	<code>models/conformal_policy_statistics_low/point/high</code>	bandas de incertidumbre
Escenarios IFRS9	<code>data/processed/ifrs9_scenario_summary.parquet</code>	resumen de escenarios macro
Sensibilidad	<code>data/processed/ifrs9_sensitivity_gold.parquet</code>	variación de PD, LGD y tasa SICR
SICR	<code>scripts/run_sicr_conformal.py</code>	trigger enriquecido por ancho + artefactos asociados

68.0.2. Fórmula central

La pérdida esperada por préstamo y escenario se resume como:

$$ECL_{i,s}^{(h)} = PD_{i,s}^{(h)} \times LGD_{i,s} \times EAD_{i,s} \times DF_{i,s}, \quad h \in \{low, point, high\}$$

La novedad práctica está en que $PD^{(h)}$ ya no es únicamente puntual. El horizonte **high** define una lectura prudencial, mientras **low** marca un piso de incertidumbre.

68.0.3. Escenarios congelados

El artefacto `ifrs9_scenario_summary.parquet` reporta cuatro escenarios:

Tabla 68.2.: Escenarios del Paper 2

Escenario	pd_mult	lgd_mult	discount_rate
baseline	1.0172	1.00	0.05
mild_stress	1.1697	1.05	0.06
adverse	1.3223	1.12	0.07
severe	1.5766	1.20	0.08

68.0.4. Trigger SICR con incertidumbre

El capítulo de SICR mostró una regla complementaria basada en ancho conformal. Conceptualmente:

$$\text{Stage2}_i = \mathbb{1} \left[\widehat{\Delta PD}_i > \theta_{PD} \vee (w_i > t \wedge \widehat{\Delta PD}_i \geq 0) \right]$$

Esto permite capturar deterioro potencial aun cuando la PD puntual no cruce el umbral absoluto clásico.

68.0.5. Protocolo de evaluación

El paper reporta:

1. ECL agregado por escenario;
2. composición de stages;
3. efecto del trigger SICR conformal;
4. sensibilidad a parámetros prudenciales y extensiones con riesgos competitivos.

69. Resultados

Los resultados muestran que IFRS9 es el lugar donde la incertidumbre deja de ser una curiosidad estadística y se convierte en un costo prudencial observable.

69.0.1. ECL por escenario

El agregado congelado es:

Tabla 69.1.: IFRS9 por escenario

Escenario	Total ECL	Stage 1	Stage 2	Stage 3
baseline	\$1.003B	85,659	128,959	62,251
mild_stress	\$1.223B	58,059	156,559	62,251
adverse	\$1.454B	47,218	167,400	62,251
severe	\$1.799B	30,019	184,599	62,251

El salto de baseline a severe implica aproximadamente +79 % de ECL. Esa sensibilidad es suficiente para justificar una lectura prudencial explícita del escenario y no solo un reporte puntual de provisión.




Figura 69.1.: Grid de escenarios SICR y staging conformal usado en el paper IFRS9.




Figura 69.2.: Sensibilidad del ECL al barrido de alpha y prudencial del escenario.


69.0.2. SICR con ancho conformal

El trigger complementario basado en incertidumbre encuentra un óptimo útil en $t^* = 0.30$ para $pd_threshold = 0.20$, con:

Tabla 69.2.: Resultado operativo de SICR conformal

Indicador	Valor
F1	0.2515
Recall de defaults no capturados	75.8 %
Precisión	8.9 %
ECL adicional	\$56.6M

La precisión baja es consistente con una política prudencial: el mecanismo privilegia no dejar escapar deterioros potenciales, aun a costa de sobreclasificar ciertos casos a Stage 2.



Comparación entre Bayesian Model Averaging y Conformal Prediction en amplitud de banda y lectura prudencial para IFRS9.

69.0.3. Sensibilidad metodológica

Las extensiones del libro refuerzan esta lectura:

- el análisis de costos por misclasificación ubica óptimos de threshold lejos de soluciones intuitivas;
- el capítulo de riesgos competitivos muestra que el método de supervivencia puede mover Stage 2 ECL en decenas de millones;
- el capítulo temporal evidencia que la incertidumbre macro puede expandir fuertemente el rango de provisión.

69.0.4. Lectura del paper

El resultado fuerte no es que exista una única provisión “correcta”. Es que el pipeline puede exponer de forma trazable:

1. una provisión puntual;
2. una banda prudencial;
3. el costo de endurecer staging y escenario.

Eso es exactamente el tipo de capacidad que un comité de finanzas y riesgo puede usar.

70. Discusión

El Paper 2 muestra que IFRS9 puede funcionar como el caso de uso más convincente para incertidumbre conformal en finanzas aplicadas. La razón es simple: allí la incertidumbre afecta dinero, provisión y gobernanza a la vez.

70.0.1. Conclusiones principales

1. El pipeline produce ECL por escenario con trazabilidad suficiente para análisis prudencial.
2. El ancho conformal es una señal útil para enriquecer SICR, no solo una métrica técnica.
3. La sensibilidad del sistema a escenario, threshold y método de supervivencia justifica una política explícita de gobernanza.

70.0.2. Threats to validity

- Lending Club no es un banco regulado ni una cartera IFRS9 real.
- La regla SICR conformal aún debe contrastarse con políticas expertas más ricas.
- La integración de forecasting temporal y competing risks sigue en modo analítico, no productivo pleno.

70.0.3. Reproducibility appendix

Los resultados se apoyan en artefactos ya existentes:

- `data/processed/ifrs9_scenario_summary.parquet`
- `data/processed/ifrs9_sensitivity_grid.parquet`
- `data/processed/cif_ecl_impact.parquet`
- `data/processed/stage_misclassification_cost.parquet`
- `data/processed/ts_ecl_intervals.parquet`

70.0.4. Cierre editorial

La contribución más defendible del paper es que convierte IFRS9 en un pipeline cuantitativo gobernable, donde provisión, incertidumbre y señal de deterioro pueden discutirse con evidencia compartida. Esa es una propuesta mucho más valiosa que un ejercicio aislado de lifetime PD.

71. Paper 3: Predicción Conformal Mondrian para Riesgo Crediticio

! Paper autocontenido

Esta sección funciona como un draft independiente del paper Mondrian para COPA 2026.

72. Introducción

La cobertura marginal global puede ser una garantía engañosa en riesgo crediticio. Un modelo puede cubrir “en promedio” y, al mismo tiempo, fallar sistemáticamente en segmentos económicamente relevantes. Este paper toma esa tensión como problema central y evalúa Mondrian conformal sobre particiones naturales del portafolio.

72.0.1. Problema

En Lending Club, los grades A-G no son una conveniencia estadística; son segmentos con semántica de negocio y gradiente de riesgo visible. Si la cobertura cae precisamente en los grupos más riesgosos o más pequeños, la garantía global pierde valor operacional.

72.0.2. Pregunta del paper

¿Puede Mondrian conformal ofrecer cobertura útil por subgrupo en crédito real sin inflar excesivamente la anchura de los intervalos?

72.0.3. Contribuciones

1. Evalúa cobertura por grupo en una ventana OOT real.
2. Compara variantes conformales globales y particionadas.
3. Propone una lectura de monitoreo temporal y de alertas para uso operativo.

72.0.4. Posicionamiento

El paper no compite por inventar una nueva variante conformal. Su fuerza está en la evaluación aplicada, reproducible y conectada con downstream tasks del mismo proyecto.

73. Metodología

La metodología parte del pipeline PD calibrado y estudia varias capas de evaluación conformal sobre el mismo split OOT congelado. El objetivo es medir no solo cobertura agregada, sino cobertura útil por grupo y por tiempo.

73.0.1. Definición básica

El intervalo Mondrian por grupo se escribe como:

$$\widehat{C}_{1-\alpha}(x, g) = [\text{máx}\{0, \hat{p}(x) - q_{1-\alpha, g}\}, \text{mín}\{1, \hat{p}(x) + q_{1-\alpha, g}\}]$$

donde **g** representa la partición seleccionada. En la narrativa del proyecto, **grade** es la partición más interpretable, aunque también se contrastan variantes por score-space.

73.0.2. Protocolo de evaluación

Tabla 73.1.: Diseño metodológico del Paper 3

Capa	Artefacto	Qué mide
Cobertura global	<code>models/conformal_policy_status.json</code>	usilidson agregada
Benchmark de variantes	<code>conformal_variant_selection_neoproffparquet</code>	neoproffparquet todos
Backtest mensual	artefactos conformales del proyecto	estabilidad temporal
Guardrails	checks de policy	elegibilidad de promoción

73.0.3. Métricas principales

1. cobertura al 90 % y 95 %;
2. cobertura mínima por grupo;
3. ancho medio;
4. alertas estadísticas y no estadísticas;
5. estabilidad mensual bajo drift temporal.

73.0.4. Comparadores

El benchmark del capítulo base ya deja una línea de referencia importante:

- el *global split* puede quedar con cobertura mínima por grupo cercana a 59.5 %;
- variantes Mondrian y score-decile mejoran esa situación a costa de mayor complejidad o anchura.

La metodología del paper aprovecha esa comparación para justificar por qué la garantía por grupo importa más que un promedio agregado cómodo.

74. Resultados

El resultado central del Paper 3 es que la cobertura global del sistema es fuerte, pero su interpretación correcta exige mirar la capa por grupo y la capa temporal.

74.0.1. Estado agregado del sistema

Tabla 74.1.: Resumen conformal del Paper 3

Indicador	Valor
Cobertura 90 %	92.52 %
Cobertura 95 %	95.93 %
Min group coverage 90 %	89.01 %
Checks aprobados	9 / 13
overall_pass	False

La clave está en que la cobertura útil por grupo sigue siendo alta, incluso cuando la policy estricta mantiene alertas estadísticas de backtesting.




Figura 74.1.: Scatter de variantes conformales del Paper 3, con énfasis en la cobertura útil y costo de anchura.

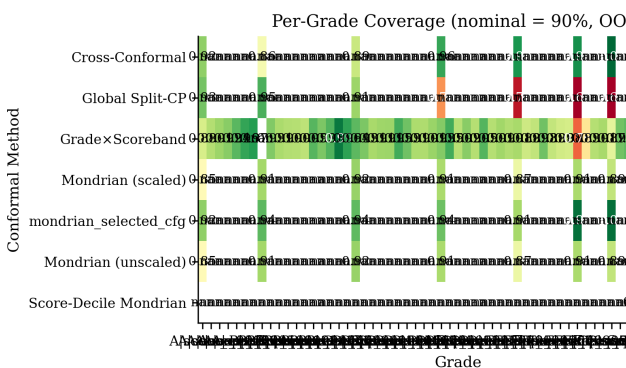


Figura 74.2.: Mapa de calor de cobertura por grade para la promoción.

74.0.2. Qué enseñan las alertas

Las fallas activas están concentradas en Kupiec y Christoffersen. Eso significa que el sistema no debe presentarse como “perfectamente validado” en sentido clásico de tests de independencia, pero sí como un framework donde la garantía principal y la gobernanza de alertas ya están explícitas.

74.0.3. Comparación contra variantes más simples

El benchmark base ya documentó que el *global split* puede lograr cobertura marginal aceptable con cobertura mínima por grupo inaceptable. Ese contraste fortalece la tesis del paper:

En crédito, la validez útil no es solo marginal; debe sobrevivir a particiones con significado de negocio.


74.0.4. Lectura operativa

Para el proyecto, el valor de Mondrian no es puramente teórico. Permite:

1. alimentar IFRS9 y portafolio con una incertidumbre segmentada;
2. monitorear si ciertos grupos empiezan a perder garantía antes que otros;
3. justificar una elección metodológica frente a revisores exigentes.

74.0.5. Resultado editorial

La evidencia actual es suficiente para escribir un paper aplicado sólido, aun si queda trabajo por hacer en endurecimiento temporal y pruebas adicionales de estabilidad.



Estabilidad temporal de la cobertura conformal, usada para documentar alertas y drift en el Paper 3.

75. Discusión

El Paper 3 aporta una pieza metodológica importante a toda la agenda del proyecto: sin cobertura por grupo razonablemente estable, la conexión con IFRS9, optimización o gobernanza se vuelve más frágil.

75.0.1. Conclusiones

1. Mondrian conformal mejora de forma material la utilidad de la garantía en segmentos de crédito.
2. La cobertura global del sistema es buena, pero su defensa depende de exponer abiertamente las alertas estadísticas remanentes.
3. El enfoque ya es suficientemente reproducible para un paper aplicado con valor propio.

75.0.2. Threats to validity

- la partición por **grade** es fuerte en interpretación, pero no necesariamente óptima en eficiencia;
- la estabilidad temporal debería evaluarse con ventanas más largas y reglas de recalibración más explícitas;
- faltan más comparadores recientes de cobertura aproximadamente condicional.

75.0.3. Reproducibility appendix

La evidencia del paper se ancla en:

- `models/conformal_policy_status.json`
- `data/processed/conformal_variant_selection_report.parquet`
- artefactos de backtesting y monitoreo conformal del proyecto
- `docs/PAPER_REFERENCES_STATE_OF_ART.md`

75.0.4. Cierre

El valor final del paper es doble: produce una contribución autónoma sobre cobertura por subgrupo en crédito y, al mismo tiempo, sostiene metodológicamente los otros dos papers de la agenda.

Parte V.

Parte V: Puente Académico y Agenda

76. Puente: De la Especialización a la Maestría

Este capítulo evita una ruptura artificial entre dos etapas académicas del proyecto. La especialización no queda como un prototipo aislado y la maestría no arranca desde cero: ambas comparten artefactos, lenguaje metodológico y trazabilidad.

76.0.1. Qué queda cerrado en la especialización

El documento espejo `reports/tesis_especializacion.md` deja claro que la fase de especialización ya consolidó una columna vertebral defendible:

Tabla 76.1.: Cierre de especialización

Componente	Estado narrativo
Dataset y split temporal	cerrados y trazables
PD calibrada	consolidada
Conformal PD/LGD/EAD	disponible con artefactos
IFRS9 por escenarios	operativo como capa analítica
Fairness y gobernanza	reportados explícitamente

La tesis de especialización, entonces, no termina con “ideas prometedoras”, sino con evidencia suficiente para una defensa seria y un paquete reproducible.

76.0.2. Qué cambia al entrar a maestría

La maestría no necesita rehacer el stack base. Lo que cambia es el nivel de ambición científica:

1. pasar de implementación aplicada a claims publicables;
2. endurecer demostraciones, comparadores y threats to validity;
3. separar el material en piezas autocontenidas tipo paper.

76.0.3. Tres líneas de continuidad natural

Tabla 76.2.: Continuidad temática especialización → maestría

Línea	Herencia desde especialización	Expansión en maestría
Predict-then-optimize	PD calibrada + CP + portafolio	Paper Estrella
IFRS9 con incertidumbre	ECL, escenarios y SICR	Paper 2
Cobertura por subgrupo	Mondrian y backtesting	Paper 3

76.0.4. Por qué este puente es defendible

El proyecto ya cuenta con señales de madurez poco comunes para un trabajo de transición:

- 638 pruebas registradas en `runtime_status.json`;
- 30 páginas Streamlit temáticas;
- registro de campeón y semántica de thresholds congelados;
- manifests de notebooks y artefactos reutilizables.

Esto no elimina el trabajo futuro, pero sí cambia su naturaleza: el esfuerzo se desplaza desde “construir” hacia “formalizar, comparar y publicar”.

76.0.5. Regla editorial del puente

La especialización conserva protagonismo como cierre defendible. La maestría aparece como continuidad orgánica, no como excusa para posponer el cierre. Ese equilibrio importa tanto para jurados como para directores:

- lo ya construido tiene valor autónomo;
- lo que sigue tiene una agenda clara y factible.

76.0.6. Conclusión

El puente entre ambas etapas no es retórico. Está materializado en los mismos artefactos, el mismo run canonizado y una arquitectura documental que ya soporta libro, companion y drafts de papers sin duplicar la lógica científica central.

77. Agenda de Investigación

Este capítulo posiciona el proyecto en el contexto de la literatura existente, detalla las contribuciones de la tesis y señala las direcciones de investigación futura.

78. Estado del Arte

El proyecto se ubica en la intersección de varias literaturas maduras y unas pocas intersecciones todavía poco exploradas. La fuente maestra para este mapa es `docs/PAPER_REFERENCES_STATE_OF_ART.md`.

78.0.1. Mapa temático

Tabla 78.1.: Panorama del estado del arte

Eje	Estado de la literatura	Gap relevante para el proyecto
Conformal foundations	muy desarrollado	pocas aplicaciones integradas a decisión crediticia
Mondrian / group-conditional	activo 2023-2026	evidencia aplicada en crédito real aún limitada
Conformal + robust optimization	emergente	casi nula integración operativa en portafolio crediticio
IFRS9 / lifetime credit risk	madura por separado	ausencia práctica de UQ distribution-free en pipelines ECL
Decision-focused learning	expansión rápida	poco diálogo con incertidumbre conformal en crédito

78.0.2. Hallazgos de posicionamiento

La revisión curada del proyecto enfatiza siete vacíos. Los más importantes para este libro son:

1. ausencia de papers que integren conformal con IFRS9 end-to-end;
2. casi nula evidencia de conformal prediction aplicada a robust portfolio allocation en crédito;
3. falta de uso explícito del ancho conformal como señal SICR;
4. escasez de sistemas completos CatBoost $\rightarrow$ calibración $\rightarrow$ CP $\rightarrow$ decisión robusta.

78.0.3. Cómo se posiciona el proyecto

El proyecto no compite principalmente en “otra mejora incremental de scoring”. Su posicionamiento más fuerte es el de una plataforma aplicada que conecta:

- probabilidad calibrada,

78. *Estado del Arte*

- incertidumbre observable,
- optimización / provisión,
- gobernanza y reproducibilidad.

78.0.4. Implicación

Esta ubicación permite una estrategia de publicación por piezas sin perder coherencia global: cada paper vive en una intersección distinta, pero todos beben del mismo núcleo experimental y del mismo vocabulario metodológico.

79. Contribuciones de la Tesis

La tesis completa debe leerse como un sistema de contribuciones encadenadas, no como una suma de notebooks o dashboards. El companion `streamlit_app/pages/thesis_contribution.py` ya anticipa esa lectura.

79.0.1. Contribuciones metodológicas

1. integrar calibración probabilística y conformal prediction en un mismo stack de riesgo;
2. reinterpretar intervalos conformales como objetos útiles para decisión robusta;
3. enriquecer IFRS9 con una lectura prudencial de incertidumbre y SICR;
4. llevar cobertura por subgrupo a un caso de crédito real con monitoreo temporal.

79.0.2. Contribuciones operativas

Tabla 79.1.: Contribuciones operativas de la tesis

Aporte	Evidencia
Pipeline end-to-end reproducible	libro + Streamlit + artefactos congelados
Gobernanza explícita	fairness, MRM, champion registry
Companion interactivo	30 páginas temáticas
Trazabilidad de notebooks	inventario y manifests

79.0.3. Contribuciones de defendibilidad

La tesis también aporta algo menos visible, pero crucial: una forma de documentar proyectos de riesgo donde claims, artefactos y narrativa permanecen alineados. Esa disciplina reduce la brecha entre:

- investigación aplicada,
- revisión de jurados,
- y preparación de papers.

79.0.4. Claim central

El claim más fuerte y sostenible del proyecto es:

en riesgo crediticio, la combinación de calibración, incertidumbre conformal y decisión robusta produce un sistema más defendible que un pipeline centrado solo en predicción puntual.

Ese claim se sostiene porque cada componente tiene evidencia propia y, además, porque la integración completa ya fue ejecutada y documentada.

80. Direcciones Futuras

La agenda futura del proyecto no consiste en abrir veinte frentes nuevos, sino en profundizar las líneas que ya tienen evidencia y potencial de publicación.

80.0.1. Prioridad inmediata

Tabla 80.1.: Agenda temporal sugerida

Horizonte	Objetivo
0-3 meses	cerrar versión publicable de los tres papers
3-6 meses	endurecer benchmarks, backtesting y pruebas de estabilidad
6-12 meses	explorar extensiones causales, temporales y de fairness conformal

80.0.2. Direcciones metodológicas

1. formalización completa del vínculo **alpha** - **robustez** en el Paper Estrella;
2. extensión de Mondrian hacia garantías más cercanas a validez condicional;
3. integración de forecasting temporal y riesgos competitivos dentro de una policy IFRS9 más fuerte;
4. comparadores adicionales con decision-focused learning y CRO contextual.

80.0.3. Direcciones de producto y plataforma

- automatizar aún más los reportes MRM y de companion editorial;
- consolidar exportables selectivos a .docx para asesoría y revisión;
- convertir algunos anexos en catálogos generados automáticamente desde manifests.

80.0.4. Regla de priorización

La agenda debe seguir una disciplina simple:

1. primero fortalecer claims ya casi defendibles;
2. después ampliar comparadores y teoría;
3. solo al final abrir líneas totalmente nuevas.

80. Direcciones Futuras

Con esa secuencia, el proyecto mantiene foco y evita diluir una contribución que ya es científicamente interesante.

Parte VI.

Apéndices

81. Atlas de Notebooks

Este anexo convierte el histórico de notebooks en un mapa navegable de evidencia. La fuente principal es `data/processed/notebooks_inventory.parquet`, complementada por `reports/notebook_images/manifest.json` y `reports/notebook_exec/manifest.json`.

81.0.1. Resumen del inventario

Tabla 81.1.: Resumen del inventario de notebooks

Categoría	Conteo
core_thesis	9
paper_research	4
side_projects	1

81.0.2. Notebooks núcleo de tesis

Tabla 81.2.: Núcleo experimental del proyecto

Nº	Notebook	Rol principal
01	01_eda_lending_club.ipynb	EDA y contrato de datos
02	02_feature_engineering.ipynb	construcción de features
03	03_pd_modeling.ipynb	modelado PD
04	04_conformal_prediction.ipynb	cobertura e incertidumbre
05	05_time_series_forecasting.ipynb	series temporales
06	06_survival_analysis.ipynb	supervivencia y lifetime risk
07	07_causal_inference.ipynb	inferencia causal
08	08_portfolio_optimization.ipynb	asignación de portafolio
09	09_end_to_end_pipeline.ipynb	integración completa

81.0.3. Notebooks de paper

Tabla 81.3.: Notebooks orientados a publicación

Nº	Notebook	Uso actual
10	<code>10_paper1_cp_robust_opt.ipynb</code>	material Paper Estrella
11	<code>11_paper2_ifrs9_e2e.ipynb</code>	material Paper 2
12	<code>12_paper3_mondrian.ipynb</code>	material Paper 3
13	<code>13_model_explainability.ipynb</code>	evidencia de interpretabilidad

81.0.4. Cómo usar este atlas

1. usar `reports/notebook_exec/manifest.json` para confirmar ejecuciones y outputs;
2. usar `reports/notebook_images/manifest.json` para localizar figuras reutilizables;
3. tratar cada notebook como evidencia complementaria, no como única fuente narrativa.

81.0.5. Regla editorial

El libro Quarto y el companion Streamlit ya no dependen del notebook vivo para explicar la historia. Este atlas existe para auditar procedencia, no para obligar al lector a reconstruir el proyecto desde celdas sueltas.

82. Benchmarks GPU / RAPIDS

Este anexo resume la capa de aceleración GPU del proyecto. La fuente principal es `data/processed/gpu_consolidado` complementada por la narrativa operativa de `streamlit_app/pages/gpu_benchmark.py`.

82.0.1. Hallazgos rápidos

En ETL, el artefacto consolidado muestra que incluso sin entrar a GPU ya había ganancias grandes frente a pandas:

Tabla 82.1.: Comparación ETL base

Backend	Speedup vs pandas
polars_cpu	18.83x
duckdb	23.43x

Esto es importante porque deja una lección metodológica: no todo cuello de botella requiere GPU; a veces la primera mejora real es usar el motor de CPU correcto.

82.0.2. Dónde sí aporta RAPIDS

La narrativa del replay GPU del proyecto ubica el valor principal en:

1. optimización y frontera de trade-off con cuOpt;
2. escenarios masivos de IFRS9 Monte Carlo con CuPy;
3. algunas etapas de LGD/EAD y analítica exploratoria.

82.0.3. Lectura correcta del anexo

La historia final no es “migrar todo a GPU”. Es seleccionar cuidadosamente las etapas donde:

- el tamaño del problema es grande;
- la repetición de solves o escenarios es alta;
- la latencia del método CPU ya se vuelve limitante para investigación o stress testing.

82.0.4. Checklist de uso

Tabla 82.2.: Mapa funcional de RAPIDS en el proyecto

Sección	Tarea	Comentario
cuDF ETL	reemplazo de ETL pesado	compite con Polars/DuckDB
cuML Models	experimentación y clustering	útil, pero no necesariamente champion
cuGraph Analytics	grafos/comunidades	valor exploratorio
cuOpt Portfolio	optimización de decisión	caso GPU más convincente
CuPy IFRS9 MC	Monte Carlo masivo	fuerte para escenarios

82.0.5. Conclusión

Este anexo deja una postura honesta: la GPU ya cambió partes importantes del proyecto, pero de forma selectiva y defendible. Esa lectura es mucho más útil que una narrativa inflada de “aceleración universal”.

83. Catálogo de Artefactos

Este catálogo resume los artefactos más importantes del proyecto y cómo se conectan entre sí. No pretende ser exhaustivo a nivel de cada archivo generado, sino cubrir los objetos que soportan la narrativa del libro y las decisiones más importantes.

83.0.1. Artefactos canónicos

Tabla 83.1.: Catálogo mínimo de artefactos críticos

Ruta	Productor principal	Consumidor principal	Rol
data/processed/model_comparison.RDjson	validación	libro, Streamlit, papers	métricas finales y calibración
models/conformal_policy_validation.json	validación	libro, MRM, papers	cobertura y checks
data/processed/ifrs9_scenario_summary.parquet	libro, Paper 2		ECL por escenario
data/processed/alpha_expansion_both.parquet	libro, Paper Estrella		frontera cobertura-ancho-retorno
models/champion_registration / gobernanza	libro, companion		run activo y policy campeona

83.0.2. Familias de artefactos

- 1. data/processed/: tablas y snapshots analíticos listos para consumo narrativo.
- 2. models/: policies, estados de validación y registros de promoción.
- 3. reports/: material editorial, imágenes de notebooks y figuras de papers.
- 4. configs/: políticas y parámetros declarativos.
- 5. book/: capa editorial larga y citable.

83.0.3. Regla de trazabilidad

Cada claim importante del libro debería poder seguir esta cadena:

claim → artefacto → script/config → run tag

Cuando esa cadena se rompe, el proyecto pierde defendibilidad. Por eso el catálogo no es un anexo ornamental: es una herramienta de auditoría narrativa.

83.0.4. Uso recomendado

- cuando una métrica aparezca en dos superficies, verificar que ambas apunten al mismo artefacto canónico;
- evitar usar figuras o tablas derivadas sin registrar su fuente en `reports/`;
- promover siempre políticas y resultados acompañados de registro en `champion_registry.json`.

84. Referencia de Configuración

El proyecto ya no depende de “parámetros escondidos en notebooks”. La capa `configs/` concentra las decisiones declarativas que gobiernan modelado, conformal, fairness, optimización y perfiles de ejecución.

84.0.1. Configuraciones clave

Tabla 84.1.: Núcleo de configuración declarativa

Archivo	Función
<code>configs/pd_model.yaml</code>	configuración base del modelo PD
<code>configs/pd_model.paper_grade_final.yaml</code>	perfil del run canónico de papers
<code>configs/conformal_policy.yaml</code>	metas y thresholds de cobertura
<code>configs/fairness_policy.yaml</code>	límites de fairness y política de evaluación
<code>configs/mrm_policy.yaml</code>	reglas de gobernanza y validación
<code>configs/optimization.yaml</code>	parámetros de portafolio robusto
<code>configs/time_series.yaml</code>	forecasting y escenarios temporales

84.0.2. Perfiles de ejecución

La carpeta `configs/run_profiles/` empaqueta modos de trabajo completos, por ejemplo:

- `canonical_operational.yaml`
- `paper_grade_final.yaml`
- `insights_factory_canonical.yaml`
- `overnight_full.yaml`

Esta separación es valiosa porque desacopla:

1. la lógica del pipeline,
2. la política de validación,
3. el contexto de ejecución.

84.0.3. Convención recomendada

Una configuración útil en este proyecto debería responder tres preguntas sin ambigüedad:

- qué método se está usando;
- con qué thresholds o constraints;
- bajo qué perfil narrativo u operacional corre.

84.0.4. Relación con el libro

Muchos capítulos del libro citan resultados congelados. Este anexo recuerda que esos resultados no nacen de magia editorial: nacen de YAML y JSON concretos, versionados y trazables. Esa disciplina es parte central de la reproducibilidad del proyecto.

85. Companion Interactivo Streamlit

Este companion es la capa interactiva del proyecto y convive con el libro Quarto sin duplicar responsabilidades. Según `data/processed/runtime_status.json`, el sistema expone 30 páginas Streamlit.

85.1. Qué resuelve Streamlit

Mientras Quarto organiza una narrativa larga, citable y editorial, Streamlit cumple otras funciones:

1. exploración rápida de KPIs y artefactos;
2. lectura por audiencias distintas;
3. validación visual de resultados antes de cristalizarlos en capítulos o papers.

85.1.1. Mapa de páginas

Tabla 85.1.: Mapa funcional del companion

Grupo	Páginas representativas
Fundamentos y arquitectura	<code>executive_summary.py</code> , <code>data_architecture.py</code> , <code>tech_stack.py</code>
Modelado e incertidumbre	<code>model_laboratory.py</code> , <code>uncertainty_quantification.py</code> , <code>model_interpretability.py</code>
IFRS9 y gobernanza	<code>ifrs9_provisions.py</code> , <code>model_governance.py</code>
Papers y agenda	<code>paper_estrella_predict_optimize.py</code> , <code>paper_2_ifrs9_e2e.py</code> , <code>paper_3_mondrian.py</code> , <code>research_landscape.py</code>
Tesis y defensa	<code>tesis_especializacion.py</code> , <code>thesis_contribution.py</code> , <code>thesis_defense.py</code>
Complementos	<code>gpu_benchmark.py</code> , <code>notebook_evidence.py</code> , <code>papers_backlog.py</code>

85.1.2. **Cómo leerlo junto al libro**

- usar Streamlit para exploración, contraste y narrativa viva;
- usar Quarto para consolidación, escritura larga y citabilidad;
- usar ambos sobre los mismos artefactos canónicos para evitar divergencia.

85.1.3. **Recomendación editorial**

Cuando una página Streamlit ya contiene una historia madura, el libro debe absorber su estructura, no copiarla mecánicamente. El companion es un laboratorio de presentación; el libro es la versión cristalizada y argumentada.

85.1.4. **Resultado esperado**

Con esta división de trabajo, el proyecto gana dos superficies complementarias:

1. una experiencia interactiva para trabajo diario y revisión;
2. un libro coherente para defensa, tesis y publicación.

Referencias

- Angelopoulos, A. N., & Bates, S. (2023). Conformal Prediction: A Gentle Introduction. *Foundations and Trends in Machine Learning*. <https://arxiv.org/abs/2107.07511>
- Athey, S., & Wager, S. (2019). Estimating Treatment Effects with Causal Forests: An Application. *Annals of Statistics*. <https://doi.org/10.1214/18-AOS1709>
- Ayari, N., Guetari, R., & Kraiem, N. (2026). ML powered financial credit scoring: systematic review. *AI Review (Springer)*.
- Bertsimas, D., & Sim, M. (2004a). The Price of Robustness. *Operations Research*, 52(1), 35-53. <https://doi.org/10.1287/opre.1030.0065>
- Bertsimas, D., & Sim, M. (2004b). The Price of Robustness. *Operations Research*. <https://doi.org/10.1287/opre.1030.0065>
- Boström, H. et al. (2021). Mondrian Conformal Predictive Distributions. *COPA (PMLR v152)*. <https://proceedings.mlr.press/v152/bostrom21a/bostrom21a.pdf>
- Causal Inference for Banking, Finance, and Insurance: A Survey. (2023). <https://arxiv.org/abs/2307.16427>
- Chernozhukov, V. et al. (2018). Double/Debiased Machine Learning for Treatment and Structural Parameters. *The Econometrics Journal*. <https://doi.org/10.1111/ectj.12097>
- Christoffersen, P. F. (1998). Evaluating Interval Forecasts. *International Economic Review*, 39(4), 841-862. <https://doi.org/10.2307/2527341>
- Cox, D. R. (1972). Regression Models and Life-Tables. *Journal of the Royal Statistical Society: Series B (Methodological)*, 34(2), 187-202. <https://doi.org/10.1111/j.2517-6161.1972.tb00899.x>
- Elmachtoub, A. N., & Grigas, P. (2022). Smart «Predict, then Optimize». *Management Science*, 68(1). <https://doi.org/10.1287/mnsc.2020.3922>
- Huangfu, Q., & Hall, J. A. J. (2018). Parallelizing the dual revised simplex method. *Mathematical Programming Computation*, 10(1), 119-142. <https://doi.org/10.1007/s12532-017-0130-5>
- International Accounting Standards Board. (2014). *IFRS 9 Financial Instruments: Project Summary*. <https://www.ifrs.org/-/media/project/fi-impairment/ifrs-standard/published-documents/project-summary-july-2014.pdf>
- Ishwaran, H., Kogalur, U. B., Blackstone, E. H., & Lauer, M. S. (2008). Random Survival Forests. *The Annals of Applied Statistics*, 2(3), 841-860. <https://doi.org/10.1214/08-AOAS169>
- Johnstone, C., & Cox, B. (2021). Conformal Uncertainty Sets for Robust Optimization. *COPA (PMLR v152)*. <https://arxiv.org/abs/2105.14957>
- Kupiec, P. H. (1995). Techniques for Verifying the Accuracy of Risk Measurement Models. *The Journal of Derivatives*, 3(2), 73-84. <https://doi.org/10.3905/jod.1995.407942>
- Lessmann, S. et al. (2015). Benchmarking state-of-the-art classification algorithms for credit scoring. *European Journal of Operational Research*. <https://doi.org/10.1016/j.ejor.2015.05.030>
- Murphy, A. H. (1973). A New Vector Partition of the Probability Score. *Journal of Applied Meteorology*, 12(4), 595-600.
- Papadopoulos, H., Proedrou, K., Vovk, V., & Gammerman, A. (2002). Inductive Confidence Machines for Regression. En *Machine Learning: ECML 2002* (Vol. 2430, pp. 345-356). Springer. https://doi.org/10.1007/3-540-36755-1_29

- Platt, J. C. (1999). Probabilistic Outputs for Support Vector Machines. En *Advances in Large Margin Classifiers*. MIT Press.
- Romano, Y., Patterson, E., & Candès, E. J. (2019). Conformalized Quantile Regression. *Advances in Neural Information Processing Systems (NeurIPS)*. <https://arxiv.org/abs/1905.03222>
- Sharma, A., & Kiciman, E. (2020). DoWhy: An End-to-End Library for Causal Inference. *arXiv preprint arXiv:2011.04216*. <https://arxiv.org/abs/2011.04216>
- Taquet, V. et al. (2025). MAPIE: an open-source library for distribution-free uncertainty quantification. *arXiv preprint*.
- Vovk, V., Gammerman, A., & Shafer, G. (2005). *Algorithmic Learning in a Random World*. Springer. <https://doi.org/10.1007/978-3-031-06649-8>
- Vovk, V., & Petej, I. (2014). Venn-Abers Predictors. *UAI*. <https://arxiv.org/abs/1211.0025>
- Winkler, R. L. (1972). A Decision-Theoretic Approach to Interval Estimation. *Journal of the American Statistical Association*, 67(337), 187-191. <https://doi.org/10.1080/01621459.1972.10481224>
- Xia, Y., Liu, C., Li, Y., & Liu, N. (2017). A boosted decision tree approach using Bayesian hyperparameter optimization for credit scoring. *Expert Systems with Applications*, 78, 225-241.