



Conformal Prediction para la Calibración y Cuantificación de Incertidumbre en Modelos de Riesgo Crediticio

Carlos Alfredo Vergara Rojas



**UNIVERSIDAD TECNOLÓGICA DE PEREIRA
PROGRAMA DE ESPECIALIZACIÓN EN ANALÍTICA Y
CIENCIA DE DATOS, COLOMBIA
Febrero de 2026**



Conformal Prediction para la Calibración y Cuantificación de Incertidumbre en Modelos de Riesgo Crediticio

Carlos Alfredo Vergara Rojas

**Documento de investigación para optar al título de Especialista
en Analítica y Ciencia de Datos Aplicada**

Docente:

Alejandra María Restrepo Franco

**UNIVERSIDAD TECNOLÓGICA DE PEREIRA
PROGRAMA DE ESPECIALIZACIÓN EN ANALÍTICA Y
CIENCIA DE DATOS, COLOMBIA
Febrero de 2026**

CONTENIDO

pág.

1. 1. Introducción.....	4
2. 2. Planteamiento del Problema.....	5
3. 3. Justificación de la Investigación.....	7
4. 4. Objetivos.....	8
5. 5. Marco Teórico y Estado del Arte.....	9
6. 6. Metodología.....	12
7. 7. Resultados Esperados.....	15
8. 8. Cronograma.....	16
9. 9. Consideraciones Éticas.....	16
10. Referencias.....	17

1. INTRODUCCIÓN

En la actualidad, los sistemas financieros enfrentan un entorno complejo y altamente regulado, en el cual la correcta estimación del riesgo crediticio constituye un pilar fundamental para la estabilidad económica y la confianza de los inversionistas. La probabilidad de incumplimiento (PD, por sus siglas en inglés), la pérdida dado incumplimiento (LGD) y la exposición en caso de incumplimiento (EAD) son métricas centrales utilizadas para calcular provisiones, asignar capital y cumplir con estándares regulatorios como la Norma Internacional de Información Financiera 9 (IFRS 9) y el marco regulatorio de Basilea III [1, 2]. Estas métricas no solo determinan la salud financiera de las entidades bancarias, sino que también inciden directamente en la confianza del mercado y en la capacidad de las instituciones para absorber pérdidas inesperadas.

Sin embargo, los modelos tradicionales de riesgo crediticio, tales como la regresión logística y los modelos lineales generalizados, así como muchos de los modelos modernos basados en machine learning, presentan limitaciones significativas en cuanto a la cuantificación de la incertidumbre. Estos modelos típicamente ofrecen predicciones puntuales sin acompañarlas de una medida fiable de la confianza asociada a dichas predicciones [3, 4]. Más aún, en la mayoría de los casos, las probabilidades estimadas carecen de una adecuada calibración, lo que significa que una predicción del 70% de probabilidad de incumplimiento no necesariamente se corresponde con una tasa real de incumplimiento del 70% en la población correspondiente [5]. Estas deficiencias se traducen en tres consecuencias críticas para las instituciones financieras: pérdidas inesperadas por subestimación del riesgo, provisiones excesivas por sobreestimación conservadora, y desconfianza por parte de auditores y reguladores que exigen cada vez mayor explicabilidad y robustez en los modelos.

La predicción conformal (Conformal Prediction, CP) surge como una alternativa metodológica rigurosa para abordar estas limitaciones. Propuesta originalmente por Vovk, Gammerman y Shafer [6], la predicción conformal es un marco estadístico que permite acompañar cada predicción con intervalos o conjuntos de confianza que poseen garantías

formales de cobertura, sin requerir supuestos paramétricos sobre la distribución de los datos subyacentes. A diferencia de los métodos bayesianos, que dependen de la especificación de distribuciones a priori, o de los métodos de bootstrap, que pueden ser computacionalmente costosos y carecen de garantías formales en muestras finitas, CP ofrece una cobertura marginal garantizada bajo el único supuesto de intercambiabilidad de los datos [7, 8]. Esta propiedad convierte a CP en una técnica especialmente prometedora para el sector financiero, donde la robustez estadística y la transparencia metodológica son requisitos regulatorios fundamentales.

La presente propuesta describe un proyecto de investigación orientado a implementar y evaluar el uso de técnicas de Conformal Prediction en modelos de riesgo crediticio, con el propósito de mejorar su calibración, cuantificar de manera explícita la incertidumbre asociada a las predicciones, y fortalecer la confiabilidad regulatoria de dichos modelos. El estudio se apoyará en el dataset público de LendingClub (2007–2020), que constituye uno de los conjuntos de datos más completos y utilizados en la literatura de riesgo crediticio, permitiendo la replicabilidad de los resultados y la comparación con trabajos previos [9].

2. PLANTEAMIENTO DEL PROBLEMA

En el sector financiero, los modelos de riesgo crediticio son herramientas fundamentales para estimar las tres métricas principales del riesgo: la probabilidad de incumplimiento (PD), la pérdida dado incumplimiento (LGD) y la exposición en caso de incumplimiento (EAD) [1]. Estas métricas alimentan directamente el cálculo de las pérdidas esperadas (Expected Loss, $EL = PD \times LGD \times EAD$), que a su vez determinan las provisiones contables bajo IFRS 9 y los requerimientos de capital regulatorio bajo Basilea III [2, 10]. Sin embargo, estos modelos presentan una limitación recurrente y crítica: suelen entregar predicciones puntuales sin una adecuada calibración y sin cuantificar explícitamente la incertidumbre asociada a dichas predicciones.

Esta deficiencia tiene un impacto significativo y multidimensional. En primer lugar, la ausencia de cuantificación de incertidumbre puede conducir a una subestimación sistemática del riesgo, generando pérdidas inesperadas que erosionan el capital de las entidades financieras. Estudios recientes han demostrado que los modelos de machine learning, a pesar de su superior capacidad predictiva en términos de métricas como AUC-ROC, frecuentemente producen probabilidades mal calibradas que pueden distorsionar las decisiones de originación y pricing de crédito [5, 11]. En segundo lugar, ante la incertidumbre no cuantificada, las entidades tienden a adoptar posturas conservadoras que resultan en un exceso de capital inmovilizado, provisiones excesivas que reducen la eficiencia operativa y la liquidez disponible para la concesión de nuevos créditos. En tercer lugar, los reguladores y auditores exigen cada vez más que los modelos cumplan con criterios de robustez, explicabilidad y fairness, requisitos que los modelos de caja negra difícilmente satisfacen sin mecanismos adicionales de cuantificación de incertidumbre [12, 13].

En este contexto, la predicción conformal (Conformal Prediction, CP) emerge como un enfoque metodológico prometedor. CP permite generar intervalos o conjuntos predictivos con garantías estadísticas de cobertura en muestras finitas, independientemente de la distribución subyacente de los datos y del modelo base utilizado [6, 7]. De esta forma, cada predicción puntual se acompaña de una medida rigurosa de la incertidumbre asociada, lo que permite a los tomadores de decisiones evaluar no solo el riesgo esperado sino también la confianza que se puede depositar en dicha estimación.

Para el caso específico de LGD y EAD, que son variables continuas acotadas, los métodos de Conformalized Quantile Regression (CQR) ofrecen intervalos predictivos eficientes que se adaptan localmente a la heteroscedasticidad de los datos, produciendo intervalos más estrechos donde el modelo es más confiable y más amplios donde la incertidumbre es mayor [8]. Para PD, que es una variable de clasificación binaria, variantes como los predictores de Venn–Abers permiten obtener probabilidades multiprobabilísticas bien calibradas que mejoran significativamente la calibración respecto a métodos tradicionales como Platt Scaling o Isotonic Regression [14, 15].

El impacto potencial de resolver este problema es amplio y relevante. Una mejora en la calibración y cuantificación de la incertidumbre implica mayor confianza regulatoria en los modelos internos, optimización en la asignación de capital regulatorio, reducción de pérdidas inesperadas por mejor gestión del riesgo, y en última instancia, fortalecimiento de la estabilidad del sistema financiero. Estas técnicas permiten además a las instituciones financieras adoptar decisiones más informadas y cumplir con estándares regulatorios internacionales como Basilea II/III e IFRS 9 [1, 2].

Pregunta de investigación: ¿Cómo mejorar la calibración y la cuantificación de la incertidumbre en los modelos de riesgo crediticio (PD, LGD, EAD) mediante la aplicación de técnicas de predicción conformal, y cuál es su desempeño comparado frente a métodos tradicionales de calibración?

3. JUSTIFICACIÓN DE LA INVESTIGACIÓN

La presente investigación se justifica desde múltiples dimensiones que abarcan el ámbito académico, regulatorio y práctico, respondiendo a necesidades reales tanto del sector financiero como de la comunidad científica en ciencia de datos aplicada.

Desde la perspectiva académica, esta investigación contribuye a una línea de trabajo emergente y de alto impacto que integra la cuantificación de incertidumbre con los modelos de machine learning aplicados al riesgo financiero. Aunque la predicción conformal ha sido ampliamente estudiada en dominios como la medicina y la visión por computador [7, 16], su aplicación específica al riesgo crediticio permanece relativamente inexplorada, particularmente en lo que respecta a la modelación conjunta de PD, LGD y EAD con garantías formales de cobertura. Los trabajos de Angelopoulos y Bates [7] han popularizado el marco teórico general, pero la literatura sobre su implementación práctica en portafolios crediticios reales es aún escasa, lo que posiciona a esta investigación como una contribución original y relevante al campo.

En el ámbito regulatorio, la investigación ofrece un marco metodológico que se alinea directamente con los requerimientos de IFRS 9 y Basilea III. Bajo IFRS 9, las entidades financieras deben estimar pérdidas crediticias esperadas (ECL) incorporando información prospectiva y escenarios macroeconómicos, lo que requiere modelos que no solo predigan sino que cuantifiquen la incertidumbre de manera transparente [2, 10]. Basilea III, por su parte, exige que los modelos internos de riesgo sean sometidos a validación rigurosa, incluyendo pruebas de backtesting que verifiquen la cobertura real de las estimaciones [1]. La predicción conformal, con sus garantías formales de cobertura, ofrece un camino natural para satisfacer estos requisitos regulatorios, fortaleciendo la trazabilidad y auditabilidad de los modelos utilizados.

Desde la perspectiva práctica, la adopción de estas técnicas permitiría a las instituciones financieras lograr una asignación más eficiente del capital regulatorio, al contar con intervalos de confianza que permiten distinguir entre predicciones de alto y bajo nivel de certeza. Esto se traduce en una reducción de provisiones excesivas para aquellos segmentos

del portafolio donde el modelo exhibe alta confianza, y en un refuerzo de las reservas para segmentos de mayor incertidumbre. Adicionalmente, la implementación de estos métodos incrementaría la confianza de los comités de riesgo y de los reguladores en las decisiones crediticias automatizadas, un aspecto cada vez más relevante en la era de la banca digital y la originación algorítmica de crédito [13, 17].

Finalmente, esta investigación representa una innovación significativa para el contexto local colombiano, donde la adopción de técnicas avanzadas de cuantificación de incertidumbre en modelos de riesgo crediticio es aún incipiente. La implementación exitosa de estos métodos posicionaría a la organización como referente en la adopción de modelos explicables, confiables y alineados con las mejores prácticas internacionales.

4. OBJETIVOS

4.1 Objetivo General

Implementar y evaluar técnicas de predicción conformal para mejorar la calibración y cuantificación de la incertidumbre en modelos de riesgo crediticio (PD, LGD, EAD), utilizando el dataset público de LendingClub como caso de estudio, y comparar su desempeño frente a métodos tradicionales de calibración.

4.2 Objetivos Específicos

1. Realizar una revisión sistemática del estado del arte sobre calibración de modelos, cuantificación de incertidumbre y predicción conformal aplicada al riesgo crediticio, identificando las principales variantes metodológicas (Split Conformal, CQR, Venn–Abers) y sus ventajas comparativas.
2. Construir y preparar un dataset a partir de los registros públicos de LendingClub (2007–2020), definiendo las variables objetivo (PD, LGD, EAD) y realizando el preprocesamiento necesario para la experimentación.

3. Diseñar e implementar experimentos aplicando técnicas de Conformal Prediction (Split Conformal Prediction, Conformalized Quantile Regression y Venn–Abers Predictors) sobre modelos base de PD, LGD y EAD.
4. Comparar el desempeño de Conformal Prediction con métodos tradicionales de calibración (Platt Scaling, Isotonic Regression, Bootstrap) mediante métricas de calibración, cobertura, eficiencia de intervalos y discriminación.
5. Evaluar el impacto potencial de la predicción conformal en la estimación de provisiones bajo IFRS 9, la asignación de capital regulatorio bajo Basilea III, y las métricas de validación de modelos internos.
6. Proponer lineamientos prácticos y recomendaciones para la adopción de Conformal Prediction en entornos bancarios reales, considerando aspectos de implementación, escalabilidad y gobernanza de modelos.

5. MARCO TEÓRICO Y ESTADO DEL ARTE

5.1 Modelos de Riesgo Crediticio


Los modelos de riesgo crediticio buscan estimar la probabilidad y severidad de las pérdidas asociadas al incumplimiento de obligaciones financieras. Los tres componentes fundamentales son la probabilidad de incumplimiento (PD), que mide la probabilidad de que un deudor no cumpla con sus obligaciones en un horizonte temporal determinado; la pérdida dado incumplimiento (LGD), que estima la fracción de la exposición que se pierde en caso de incumplimiento después de considerar las recuperaciones; y la exposición en caso de incumplimiento (EAD), que cuantifica el monto expuesto al momento del incumplimiento [1, 10]. Históricamente, la PD ha sido modelada mediante regresión logística, mientras que LGD y EAD han utilizado modelos de regresión beta, Tobit o regresión lineal con transformaciones. En años recientes, modelos de machine learning como Gradient Boosting, Random Forest y redes neuronales han demostrado mejoras significativas en la capacidad discriminativa, aunque frecuentemente a costa de la interpretabilidad y la calibración [3, 11].

5.2 El Problema de la Calibración

La calibración se refiere a la correspondencia entre las probabilidades predichas por un modelo y las frecuencias observadas de los eventos. Un modelo bien calibrado es aquel en el que, por ejemplo, de todos los créditos a los que se les asignó una PD del 10%, aproximadamente el 10% efectivamente incumple [5]. La calibración es particularmente importante en el contexto financiero porque las probabilidades predichas se utilizan directamente para calcular provisiones y capital regulatorio. Los métodos tradicionales de post-hoc calibración incluyen Platt Scaling, que ajusta una transformación sigmoideal a las salidas del modelo, e Isotonic Regression, que ajusta una función monótona no decreciente [18]. Sin embargo, estos métodos carecen de garantías formales de cobertura y pueden ser sensibles al sobreajuste en el conjunto de calibración, especialmente cuando el tamaño de muestra es limitado o la distribución de los datos cambia en el tiempo [14].

5.3 Predicción Conformal: Fundamentos Teóricos

La predicción conformal fue introducida formalmente por Vovk, Gammerman y Shafer en su trabajo seminal "Algorithmic Learning in a Random World" [6]. El marco teórico se fundamenta en el concepto de nonconformity scores (puntuaciones de no conformidad), que miden cuán "inusual" es una nueva observación respecto a un conjunto de datos de referencia. La idea central es que, bajo el supuesto de intercambiabilidad (exchangeability) de los datos, es posible construir intervalos o conjuntos de predicción que contengan el valor verdadero con una probabilidad predefinida $(1 - \alpha)$, sin requerir supuestos paramétricos sobre la distribución de los datos [7].



La variante más utilizada en la práctica es Split Conformal Prediction (SCP), que divide los datos en un conjunto de entrenamiento para ajustar el modelo base y un conjunto de calibración para calcular los cuantiles de los nonconformity scores [7, 8]. Esta variante es computacionalmente eficiente y fácil de implementar, aunque puede perder poder estadístico al no utilizar todos los datos para el entrenamiento. Extensiones como Cross-Conformal Prediction y Jackknife+ abordan esta limitación utilizando esquemas de validación cruzada [19].

Para problemas de regresión con datos heteroscedásticos, Romano, Patterson y Candès [8] propusieron la Conformalized Quantile Regression (CQR), que combina la regresión cuantílica con el marco conformal para producir intervalos predictivos que se adaptan localmente a la variabilidad de los datos. CQR es particularmente relevante para la modelación de LGD y EAD, donde la varianza de las predicciones puede diferir significativamente entre segmentos del portafolio. Para problemas de clasificación, los Venn–Abers Predictors ofrecen una forma de obtener probabilidades bien calibradas con garantías teóricas, produciendo intervalos de probabilidad $[p_lower, p_upper]$ en lugar de una única probabilidad puntual [14, 15].

5.4 Aplicaciones de CP en el Sector Financiero

La aplicación de predicción conformal en finanzas es un área de investigación activa. Bellotti [4] fue uno de los primeros en aplicar CP específicamente a la calificación crediticia (credit scoring), demostrando que los conjuntos de predicción conformal pueden proporcionar información valiosa sobre la confiabilidad de las decisiones de otorgamiento de crédito. Más recientemente, Javanmardi y Vovk [15] extendieron los predictores Venn–Abers para mejorar la calibración de modelos de PD en portafolios bancarios. En el ámbito de series temporales financieras, Xu y Xie [20] propusieron métodos conformales adaptivos que

pueden manejar la no estacionariedad inherente a los datos financieros, abordando una de las principales críticas al supuesto de intercambiabilidad en contextos financieros.

A pesar de estos avances, la literatura existente presenta vacíos significativos. La mayoría de los estudios se enfocan exclusivamente en PD, dejando sin explorar la aplicación conjunta de CP a LGD y EAD. Además, pocos trabajos evalúan el impacto práctico de CP en métricas regulatorias específicas como las provisiones bajo IFRS 9 o el capital económico bajo Basilea III. Esta investigación busca contribuir a cerrar estos vacíos mediante una evaluación integral de CP en los tres componentes del riesgo crediticio.

6. METODOLOGÍA

La investigación seguirá un enfoque cuantitativo y experimental, estructurado en seis fases secuenciales que abarcan desde la revisión del estado del arte hasta la validación regulatoria de los resultados. A continuación se detalla cada fase con la profundidad necesaria para garantizar la replicabilidad del estudio.


6.1 Fase 1: Revisión Bibliográfica Sistemática

Se realizará una revisión sistemática de la literatura siguiendo las directrices PRISMA (Preferred Reporting Items for Systematic Reviews and Meta-Analyses). La búsqueda se realizará en bases de datos académicas incluyendo Scopus, Web of Science, IEEE Xplore, arXiv y Google Scholar, utilizando términos de búsqueda como "conformal prediction credit risk", "uncertainty quantification credit scoring", "calibration probability of default", "conformalized quantile regression LGD" y combinaciones relacionadas. Se incluirán artículos publicados entre 2005 y 2025, con especial énfasis en contribuciones recientes (2019–2025) que reflejen el estado actual del campo. Adicionalmente, se revisarán guías regulatorias del Comité de Basilea, documentos técnicos de la IFRS Foundation, y reportes de consultoras especializadas en riesgo financiero.

6.2 Fase 2: Construcción y Preparación del Dataset

El estudio utilizará el dataset público de LendingClub (2007–2020 Q1), disponible en la plataforma Kaggle, que contiene aproximadamente 2.9 millones de registros de préstamos con más de 140 variables asociadas a cada crédito [9]. Este dataset es ampliamente utilizado en la literatura de riesgo crediticio por su riqueza y representatividad del mercado de préstamos peer-to-peer en Estados Unidos.

El preprocesamiento de datos seguirá un pipeline estructurado que incluye las siguientes etapas. En primer lugar, se definirán las variables objetivo: para PD, se construirá una variable binaria de incumplimiento basada en los estados del préstamo ("Charged Off" y "Default" como positivos); para LGD, se calculará la tasa de pérdida como 1 menos la tasa de recuperación ($\text{total_rec_prncp} / \text{funded_amnt}$); y para EAD, se estimará la exposición residual al momento del incumplimiento considerando los pagos realizados hasta la fecha de incumplimiento.



En segundo lugar, se realizará un análisis exploratorio de datos (EDA) para comprender la distribución de las variables, identificar valores atípicos, evaluar la proporción de datos faltantes y examinar las correlaciones entre variables. En tercer lugar, se aplicarán técnicas de imputación para datos faltantes (imputación por mediana para variables numéricas y por moda para categóricas), codificación de variables categóricas (target encoding para variables de alta cardinalidad y one-hot encoding para variables de baja cardinalidad), y selección de

features mediante importancia basada en Gradient Boosting y análisis de correlación. Finalmente, el dataset se dividirá en tres conjuntos: entrenamiento (60%), calibración (20%) y test (20%), manteniendo la proporción temporal de los datos para respetar la estructura cronológica inherente al riesgo crediticio.

6.3 Fase 3: Modelado Base

Se implementarán múltiples modelos base para cada componente del riesgo. Para PD, se ajustarán tres modelos: regresión logística como baseline interpretable, LightGBM como representante de los métodos de gradient boosting de alto rendimiento, y XGBoost para comparación. Para LGD, se utilizarán regresión beta (modelo paramétrico tradicional), LightGBM con función de pérdida Tweedie, y Quantile Regression Forests. Para EAD, se emplearán regresión lineal como baseline, LightGBM y una regresión cuantílica. Todos los modelos serán implementados en Python utilizando las bibliotecas scikit-learn, LightGBM y XGBoost. La optimización de hiperparámetros se realizará mediante Optuna con validación cruzada estratificada de 5 folds, utilizando AUC-ROC como métrica principal para PD y RMSE para LGD y EAD.




6.4 Fase 4: Aplicación de Conformal Prediction

Esta fase constituye el núcleo experimental de la investigación. Se aplicarán tres variantes de predicción conformal adaptadas a cada componente del riesgo crediticio.

Para la modelación de PD, se implementarán Venn–Abers Predictors (VAP), que transforman las predicciones del modelo base en intervalos de probabilidad $[p_{\text{lower}}, p_{\text{upper}}]$ con garantías de calibración. Los VAP se implementarán utilizando el procedimiento de calibración isotónica multi-probabilística descrito por Vovk y Petej [14], aplicado sobre las probabilidades estimadas por el modelo LightGBM. Adicionalmente, se implementará Split Conformal Classification para obtener conjuntos de predicción (prediction sets) que incluyen las clases plausibles a un nivel de confianza $1 - \alpha$.

Para LGD y EAD, se implementará Conformalized Quantile Regression (CQR) siguiendo la metodología de Romano, Patterson y Candès [8]. CQR combina un modelo de regresión cuantílica (que estima los cuantiles condicionales $\alpha/2$ y $1 - \alpha/2$) con el ajuste conformal que garantiza la cobertura marginal. La implementación utilizará Quantile Regression con LightGBM como modelo base, y el ajuste conformal se realizará sobre el conjunto de calibración. Se evaluarán niveles de confianza de 80%, 90% y 95% para analizar el trade-off entre cobertura y eficiencia de los intervalos.



Como métodos de comparación (benchmarks), se implementarán: Platt Scaling e Isotonic Regression como calibradores post-hoc para PD; intervalos de predicción basados en

Bootstrap (1000 repeticiones) para LGD y EAD; e intervalos naïve basados en la desviación estándar de los residuos del modelo base. Todas las implementaciones utilizarán la librería MAPIE de Python para los métodos conformales, y scikit-learn para los métodos tradicionales de calibración.

6.5 Fase 5: Evaluación Comparativa

La evaluación comparativa se realizará utilizando un conjunto integral de métricas diseñadas para capturar diferentes aspectos del desempeño de los modelos. Para la calibración de PD, se utilizarán el Expected Calibration Error (ECE), el Brier Score y el reliability diagram (diagrama de confiabilidad). Para la cobertura de los intervalos predictivos de LGD y EAD, se calculará la cobertura empírica (proporción de observaciones que caen dentro del intervalo), que debe aproximarse al nivel nominal ($1 - \alpha$). Para la eficiencia, se medirá el ancho promedio de los intervalos y el intervalo medio normalizado (MPIW, Mean Prediction Interval Width). Adicionalmente, se evaluará la cobertura condicional por segmentos del portafolio (por grado de riesgo, monto del préstamo, plazo) para verificar que las garantías de cobertura se mantienen en subgrupos relevantes.

Se realizarán pruebas estadísticas formales para comparar los métodos, incluyendo el test de Kupiec para evaluar la cobertura incondicional, el test de Christoffersen para evaluar la cobertura condicional e independencia, y tests de Wilcoxon para comparar el ancho de los intervalos entre métodos.

6.6 Fase 6: Validación Regulatoria e Impacto

En la fase final, se evaluará el impacto práctico de la predicción conformal en el contexto regulatorio. Se simulará el cálculo de provisiones bajo IFRS 9 utilizando las estimaciones de PD, LGD y EAD con y sin el ajuste conformal, comparando el monto total de provisiones y su distribución por etapas (Stage 1, Stage 2, Stage 3). Se estimará el impacto en el capital

regulatorio bajo Basilea III, calculando los requerimientos de capital con los diferentes enfoques. Finalmente, se realizará un análisis de backtesting para evaluar si los modelos conformales mejoran la estabilidad y precisión de las estimaciones en un marco temporal out-of-time, simulando el desempeño del modelo en períodos subsecuentes no utilizados en el entrenamiento.

6.7 Herramientas y Tecnologías

Todo el desarrollo experimental se realizará en Python 3.10+, utilizando las siguientes bibliotecas principales: scikit-learn para modelado base y calibración tradicional; LightGBM y XGBoost para modelos de gradient boosting; MAPIE (Model Agnostic Prediction Interval Estimator) para la implementación de métodos conformales; statsmodels para regresión cuantílica y pruebas estadísticas; pandas y numpy para manipulación de datos; y matplotlib y seaborn para visualización de resultados. Los experimentos se ejecutarán en un entorno reproducible documentado mediante notebooks de Jupyter, y el código fuente se estructurará siguiendo principios de ingeniería de software para facilitar la replicabilidad.

7. RESULTADOS ESPERADOS

Aunque el proyecto se encuentra en etapa de propuesta, se anticipan los siguientes resultados basándose en la evidencia teórica y empírica disponible en la literatura.

En primer lugar, se espera obtener intervalos predictivos confiables para LGD y EAD que alcancen una cobertura empírica consistente con el nivel nominal especificado (90% y 95%), con una eficiencia (ancho de intervalos) superior a la de los métodos de bootstrap y los intervalos naïve. La literatura sugiere que CQR produce intervalos hasta un 30% más estrechos que los métodos de bootstrap manteniendo la cobertura nominal [8, 19].

En segundo lugar, se anticipa una mejora significativa en la calibración de las probabilidades de incumplimiento al utilizar Venn–Abers Predictors, con una reducción estimada del

Expected Calibration Error (ECE) respecto a los modelos base sin calibrar y respecto a los métodos de Platt Scaling e Isotonic Regression, particularmente en los segmentos de alta y baja probabilidad de incumplimiento donde la calibración suele ser más deficiente [14, 15].

En tercer lugar, se espera demostrar que la incorporación de intervalos de confianza en las estimaciones de pérdida esperada puede conducir a una optimización del capital regulatorio, distinguiendo entre segmentos del portafolio con alta y baja incertidumbre, lo que permitiría una asignación más eficiente de las provisiones bajo IFRS 9.

Finalmente, se espera producir un marco metodológico documentado y replicable que incluya lineamientos prácticos para la implementación de predicción conformal en entornos bancarios reales, considerando aspectos de escalabilidad, gobernanza de modelos y cumplimiento regulatorio.

8. CRONOGRAMA

El proyecto se desarrollará en un período estimado de 16 semanas, distribuidas de la siguiente manera. Las semanas 1 a 3 se dedicarán a la revisión bibliográfica sistemática y la consolidación del marco teórico. Las semanas 4 a 6 se enfocarán en la construcción, limpieza y preparación del dataset de LendingClub, incluyendo el análisis exploratorio de datos. Las semanas 7 a 9 abarcarán la implementación de los modelos base y la optimización de hiperparámetros. Las semanas 10 a 12 corresponden al núcleo experimental, con la aplicación de las técnicas de Conformal Prediction y los métodos benchmark de comparación. Las semanas 13 y 14 se destinarán a la evaluación comparativa y el análisis de impacto regulatorio. Finalmente, las semanas 15 y 16 se reservan para la redacción del documento final, la revisión de resultados y la preparación de la defensa.

9. CONSIDERACIONES ÉTICAS

La presente investigación se adhiere a los más altos estándares de ética en la investigación científica, abordando de manera proactiva los aspectos éticos relevantes para el manejo de

datos financieros y el desarrollo de modelos de riesgo crediticio.

En cuanto a la privacidad y protección de datos, el estudio utiliza exclusivamente datos de acceso público provenientes de la plataforma LendingClub, los cuales han sido previamente anonimizados y no contienen información de identificación personal (PII). No obstante, se adoptarán medidas adicionales para garantizar que ningún análisis individual pueda conducir a la re-identificación de deudores específicos, siguiendo las directrices de la Ley de Protección de Datos Personales de Colombia (Ley 1581 de 2012) y las mejores prácticas internacionales en materia de privacidad de datos.

Respecto al uso responsable de modelos, la investigación se compromete a evaluar y reportar posibles sesgos algorítmicos en las predicciones crediticias. Se analizará si los intervalos de confianza producidos por los métodos conformales exhiben cobertura equitativa entre diferentes subgrupos demográficos (cuando esta información esté disponible), alineándose con los principios de fairness y no discriminación en la toma de decisiones automatizada [12, 13].

En términos de transparencia y reproducibilidad, todo el código fuente, los notebooks de experimentación y los resultados intermedios serán documentados de manera que permitan la reproducción completa de los resultados por terceros. Los modelos serán descritos con suficiente detalle para ser auditables, y se reportarán tanto los resultados positivos como las limitaciones encontradas durante la investigación. La integridad académica se garantiza mediante el uso riguroso de referencias bibliográficas, la atribución adecuada de las contribuciones de otros investigadores, y el cumplimiento de las normas de citación APA vigentes.

REFERENCIAS

- [1] Basel Committee on Banking Supervision, "International Convergence of Capital Measurement and Capital Standards: A Revised Framework," Bank for International Settlements (BIS), 2006. [Online]. Available: <https://www.bis.org/publ/bcbs128.htm>
- [2] International Accounting Standards Board (IASB), "IFRS 9 Financial Instruments," IFRS Foundation, London, 2014.
- [3] S. Lessmann, B. Baesens, H.-V. Seow, and L. C. Thomas, "Benchmarking state-of-the-art classification algorithms for credit scoring: An update of research," *European Journal of Operational Research*, vol. 247, no. 1, pp. 124–136, 2015. doi: 10.1016/j.ejor.2015.05.030
- [4] T. Bellotti, "Reliable region predictions for automated credit scoring," in *Proceedings of the Workshop on Conformal and Probabilistic Prediction and Applications (COPA)*, PMLR, 2017.
- [5] A. Niculescu-Mizil and R. Caruana, "Predicting good probabilities with supervised learning," in *Proceedings of the 22nd International Conference on Machine Learning (ICML)*, pp. 625–632, 2005. doi: 10.1145/1102351.1102430
- [6] V. Vovk, A. Gammerman, and G. Shafer, *Algorithmic Learning in a Random World*, 2nd ed. Cham: Springer, 2022. doi: 10.1007/978-3-031-06649-8
- [7] A. N. Angelopoulos and S. Bates, "A Gentle Introduction to Conformal Prediction and Distribution-Free Uncertainty Quantification," *Foundations and Trends in Machine Learning*, vol. 16, no. 4, pp. 494–591, 2023. doi: 10.1561/22000000101
- [8] Y. Romano, E. Patterson, and E. Candès, "Conformalized Quantile Regression," in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 32, 2019.
- [9] Lending Club, "Lending Club Loan Data 2007–2020 Q1," *Kaggle Dataset*, 2020. [Online]. Available: <https://www.kaggle.com/datasets/ethon0426/lending-club-20072020q1>
- [10] Deloitte, "IFRS 9 and Expected Credit Loss: Modelling and Validation Challenges," *Deloitte Technical Report*, 2020.
- [11] B. Baesens, D. Roesch, and H. Scheule, *Credit Risk Analytics: Measurement Techniques, Applications, and Examples in SAS*. Hoboken, NJ: John Wiley & Sons, 2016.
- [12] S. R. Rao and A. Verma, "Fairness in Credit Scoring: Assessment, Implementation and Profit

- Implications," *European Journal of Operational Research*, vol. 297, no. 3, pp. 1083–1096, 2022. doi: 10.1016/j.ejor.2021.06.023
- [13] European Banking Authority (EBA), "Guidelines on Loan Origination and Monitoring," EBA/GL/2020/06, 2020.
- [14] V. Vovk and I. Petej, "Venn-Abers Predictors," in *Proceedings of the 30th Conference on Uncertainty in Artificial Intelligence (UAI)*, pp. 829–838, 2014.
- [15] F. Javanmardi and V. Vovk, "Multip probability predictions for credit scoring with Venn–Abers predictors," in *Conformal and Probabilistic Prediction and Applications (COPA)*, PMLR, 2023.
- [16] H. Lu, H. Karimireddy, N. Ponomareva, and A. Mirrokni, "Conformal Prediction in the Medical Domain: A Comprehensive Survey," *IEEE Reviews in Biomedical Engineering*, vol. 17, pp. 127–142, 2024.
- [17] M. Almunia, A. Antón, S. Macias, and D. Moreno, "Machine Learning in Credit Risk: Literature Review and Practical Implications," *Bank of Spain Occasional Paper No. 2302*, 2023.
- [18] J. Platt, "Probabilistic Outputs for Support Vector Machines and Comparisons to Regularized Likelihood Methods," in *Advances in Large Margin Classifiers*, MIT Press, pp. 61–74, 1999.
- [19] R. F. Barber, E. J. Candès, A. Ramdas, and R. J. Tibshirani, "Predictive Inference with the Jackknife+," *The Annals of Statistics*, vol. 49, no. 1, pp. 486–507, 2021. doi: 10.1214/20-AOS1965
- [20] C. Xu and Y. Xie, "Conformal Prediction for Time Series with Modern Hopfield Networks," in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 36, 2023.
- [21] V. Balasubramanian, S.-S. Ho, and V. Vovk (Eds.), *Conformal Prediction for Reliable Machine Learning: Theory, Adaptations and Applications*. Waltham, MA: Morgan Kaufmann, 2014.
- [22] MAPIE Contributors, "MAPIE: Model Agnostic Prediction Interval Estimator," *Documentation*, 2023. [Online]. Available: <https://mapie.readthedocs.io/>
- [23] G. Tasche, "Validation of internal model hypotheses," *Deutsche Bundesbank Discussion Paper No. 17/2006*, 2006.
- [24] A. K. Gneiting and A. E. Raftery, "Strictly Proper Scoring Rules, Prediction, and Estimation," *Journal of the American Statistical Association*, vol. 102, no. 477, pp. 359–378, 2007. doi:



10.1198/016214506000001437

- [25] M. Fontana, G. Zeni, and S. Vantini, "Conformal Prediction: A Unified Review of Theory and New Challenges," *Bernoulli*, vol. 29, no. 1, pp. 1–23, 2023. doi: 10.3150/21-BEJ1447